หัวข้อโครงงานวิศวกรรมคอมพิวเตอร์

หลักสูตรวิศวกรรมศาสตร์ สาขาวิชาวิศวกรรมคอมพิวเตอร์

ปีการศึกษา 2568

ชื่อโครงงาน: An Exploration of Artificial Intelligence for Detection of Inhibition Zones in Antibiotic Susceptibility Testing

สมาชิกกลุ่ม

1. **พีรพัฒน์ ศิริพัฒนคุณ 65070505214 pheeraphat.siri@mail.kmutt.ac.th**
2. **ภัทรดนย์ ธนประสิทธิ์พัฒนา 65070505223 phattaradon.than@mail.kmutt.ac.th**

ที่ปรึกษา

1. ผศ.ดร.นนทพรรษน์ ลีราช
2. ผศ.ดร.ปณิธิ อัจฉราฤทธิ์
3. ดร.คริษฐา แจ้งสามสี

By signing this, I hereby acknowledge that I have read the proposal and approved this project

Advisor No.1 name: _____

Advisor No.2 name: _____

Advisor No.3 name: คริษฐา แจ้งสามสี

By Date: _____

บทที่ 1
บทนำ

1.1 คำสำคัญ

Antimicrobial Resistance, Antimicrobial susceptibility testing, Image Processing, Deep learning, Artificial Intelligence, Machine learning, Reinforcement Learning, Disk Diffusion, Web Application

1.2 ความสำคัญของปัญหา

ปัญหาการดื้อยาของเชื้อแบคทีเรียเป็นปัญหาสาธารณสุขสำคัญทั่วโลก การตรวจวัดความไวต่อยา (Antimicrobial Susceptibility Testing; AST) ด้วยวิธีการ Kirby–Bauer disk diffusion เป็นวิธีมาตรฐานที่ใช้กันอย่างแพร่หลาย แต่การอ่านผลด้วยตนเองอาจใช้เวลา นานและมีความคลาดเคลื่อนระหว่างผู้ตรวจ นอกจากนี้ขนาดวงยับยั้ง (zone of inhibition) อาจมีวงที่กว้างในกรณีที่เชื้อมีความไวต่อยา ทำให้ zone of inhibition ซ้อนทับกันในบางส่วน ทำให้เกิดการคลาดเคลื่อนได้สูงในการวัดด้วยมือ และตาม Guideline มีการระบุ breakpoint ถึงขนาดของ zone of inhibition ใกล้กันระหว่างการแปลผลเชื้อไวต่อยา (Susceptible; S), เชื้อมีความไวต่อยาปานกลาง (Intermediate; I) และเชื้อดื้อต่อยา (Resistant; R) เช่น จาก CLSI ver. 2025 ระบุการทดสอบความไวของเชื้อ *S. epidermidis* ต่อยา oxacillin (1 μg) กำหนดว่า zone of inhibition ≥ 18 mm แปลผลได้ว่าเชื้อไวต่อยา และ ≤ 17 mm แปลผลได้ว่าเชื้อดื้อต่อยา นั่นหมายความว่าหากมีการวัด zone of inhibition ผิดไปเพียง 1 mm อาจทำให้แปลผลพลาดได้ และส่งผลต่อการตัดสินใจต่อการใช้ยารักษาของแพทย์ได้ ถึงแม้ว่าในปัจจุบันจะมีเทคโนโลยีใหม่ๆ ขึ้นมา เช่นการใช้เครื่องวัดอัตโนมัติ (Automated system) มาช่วยวิเคราะห์หรือแปลผลการทดสอบ แต่ระบบดังกล่าวยังมีค่าใช้จ่ายที่สูงต่อการวิเคราะห์ในแต่ละตัวอย่าง และโดยเฉพาะในพื้นที่ห่างไกลหรือโรงพยาบาลขนาดเล็กที่ไม่มีเครื่องวัดอัตโนมัติ ทำให้ต้องอาศัยการวัดด้วยมือ ซึ่งอาจเกิดความไม่แม่นยำจากความแตกต่างระหว่างบุคคลดังที่กล่าวมาข้างต้น

แนวคิดของโครงการนี้คือการพัฒนาโมเดลปัญญาประดิษฐ์ (Artificial Intelligence; AI) (Rajasekar et al., 2023) ที่สามารถวิเคราะห์ภาพถ่ายของจานเพาะเชื้อและวัดขนาดวงของยาที่ยับยั้งเชื้อได้ (inhibition zone) โดยอัตโนมัติอย่างแม่นยำและรวดเร็ว เพื่อนำมาประเมินและแปลผลการดื้อยาตาม

มาตรฐานสากล Clinical and Laboratory Standards Institute ปี 2025 (CLSI ver. 2025) และ European Committee on Antimicrobial Susceptibility Testing ปี 2023 (EUCAST ver. 2023) (Giske et al., 2022; Humphries et al., 2018) รวมถึงการนำการประมวลผลภาพ (Image Processing) มาประยุกต์ใช้ร่วมกับปัญญาประดิษฐ์เนื่องจากปัจจุบันการประมวลผลภาพมีการศึกษาและพัฒนาอย่างต่อเนื่องจนถึงปัจจุบันทำให้มีการใช้ทรัพยากรที่น้อยลงหรือใช้อุปกรณ์คอมพิวเตอร์ที่มีคุณภาพที่ไม่สูงมากในการประมวลผลได้ดีมากกว่าแต่ก่อน ทำให้สามารถตรวจจับรูปภาพ เพื่อหาวัตถุที่มีความเฉพาะเจาะจง เช่น การวัด zone of inhibition จากรูปภาพที่มีลักษณะเป็นวงกลม เป็นต้น ซึ่งโมเดลที่พัฒนานี้จะช่วยลดเวลาและภาระงานของบุคลากรห้องปฏิบัติการ พร้อมทั้งเพิ่มความแม่นยำของการแปลผลและยังสนับสนุนการใช้งานในพื้นที่ที่ไม่มีอุปกรณ์วัดขั้นสูง

แม้ว่าจะมีงานวิจัยเผยแพร่ออกมาบ้างแล้วในการใช้ปัญญาประดิษฐ์ร่วมกับการประมวลผลภาพมาช่วยวิเคราะห์การทดสอบความไวต่อยาต้านจุลชีพของแบคทีเรียเพื่อหา zone of inhibition แต่ในโครงการนี้ จะมีการศึกษาเพิ่มเติมในการเปรียบเทียบโมเดลปัญญาประดิษฐ์ที่มีวิธีการคิดที่แตกต่างกัน ซึ่งโมเดลปัญญาประดิษฐ์จะสามารถมีประสิทธิภาพเพิ่มมากขึ้นในงานวิจัยก่อนหน้านี้ในการวัดขนาดวงยับยั้ง และศึกษาปัจจัยที่แตกต่างกันในห้องทดลองจะส่งผลต่อการวัดวงยับยั้ง เช่น พื้นหลังของจานเพาะเชื้อ, จำนวนในการตรวจสอบวงกลม และวงทับซ้อนหรือไม่เป็นวงกลมเต็มรูป เป็นต้น จะส่งผลต่อการวัดประสิทธิภาพของการวัดขนาดวงยับยั้งหรือไม่ จึงเกิดความสนใจในการทดสอบหรือวิจัยในการค้นหาวิธีที่ช่วยในการวัดขนาดวงยับยั้งการดื้อยาปฏิชีวนะให้คลาดเคลื่อนน้อยที่สุด

1.3 ประเภทของโครงงาน

Web Application, Artificial Intelligence และ Antimicrobial susceptibility testing โดยวิธี Kirby–Bauer disk diffusion

1.4 วิธีการนำเสนอ

1. ศึกษาค้นคว้ากระบวนการหรือเครื่องมือทางคอมพิวเตอร์ในการแก้ไขปัญหาของโครงงาน
2. สำรวจข้อมูลหรือประเด็นปัญหาของผู้ใช้งานในการพัฒนาระบบหรือเว็บแอปพลิเคชัน
3. รวบรวมรูปภาพการทดลองหาภาวะดื้อยาต้านจุลชีพจากการทดลองด้วยตัวเองหรือจากบนอินเตอร์เน็ต
4. พัฒนาโมเดลในการวัดและแปลผลการดื้อยาต้านจุลชีพจาก 4 โมเดลที่แตกต่างกัน ได้แก่ FAST R-CNN, YOLOv7 และ Hough Transform

5. ออกแบบ User Interface และประเมินความพึงพอใจของผู้ใช้งาน

6. พัฒนาเว็บแอปพลิเคชันในการใช้งาน

7. ทดสอบและปรับปรุงการใช้งานเพิ่มเติม

1.5 จุดประสงค์ของโครงการ

1. เพื่อศึกษาวิธีการแปลผล Antimicrobial susceptibility testing โดยวิธี Kirby–Bauer disk diffusion ตามมาตรฐาน CLSI และ EUCAST

2. เพื่อพัฒนาโมเดลปัญญาประดิษฐ์ที่สามารถวัดเส้นผ่านศูนย์กลางของ zone of inhibition จากภาพถ่ายแผ่นทดสอบให้ได้ตรงตามมาตรฐาน CLSI และ EUCAST

3. เพื่อเปรียบเทียบความแม่นยำและความรวดเร็วระหว่างการวัด zone of inhibition โดยการวัดวงด้วยไม้บรรทัดกับโมเดลปัญญาประดิษฐ์ทั้งหมด 2 โมเดลที่แตกต่างกัน ได้แก่ FASTER R-CNN, YOLOv11n และ Hough Transform

4. เพื่อนำระบบไปใช้งานจริงในรูปแบบของเว็บไซต์

1.6 ขอบเขตของโครงงาน

1. ใช้ข้อมูลภาพถ่ายจานเพาะเชื้อจากการทดสอบในห้องปฏิบัติการ ซึ่งมีการกำหนดมาตรฐานการถ่ายภาพโดยการถ่ายเป็นแนวนอนที่ขนานกับจานเพาะเชื้อ เพื่อตรวจสอบปัจจัย ที่อาจส่งผลต่อความแม่นยำการวัด zone of inhibition ได้แก่ พื้นหลังของจานเพาะเชื้อ จำนวนในการตรวจสอบวงกลม และ วงทับซ้อนหรือไม่เป็นวงกลมเต็มรูป พร้อมข้อมูลการวัด zone of inhibition และแปลผลเชื้อไวต่อยา (Susceptible; S) เชื้อมีความไวต่อยาปานกลาง (Intermediate; I) และเชื้อดื้อต่อยา (Resistant; R) โดยผู้เชี่ยวชาญด้านจุลชีววิทยา

2. พัฒนาและฝึกสอนโมเดลปัญญาประดิษฐ์สำหรับการตรวจจับและวัดวงยับยั้งการเจริญเติบโตของภาพถ่ายและแปลผลโดย

3. ประเมินประสิทธิภาพความถูกต้องและความเร็วในการวัด zone of inhibition ของโมเดลปัญญาประดิษฐ์ 3 ตัว ได้แก่ FASTER R-CNN, YOLOv11n และ Hough Transform เปรียบเทียบกับการอ่านผลโดยผู้เชี่ยวชาญด้านจุลชีววิทยา

4. พัฒนาระบบเว็บแอพลิเคชันในการใช้งานจริง โดยสามารถวิเคราะห์ภาพจากการถ่ายและอัปโหลดรูปภาพแผ่นเพาะเชื้อในการวัด zone of inhibition แล้วแปลผลเป็นเชื้อไวต่อยา (Susceptible; S) เชื้อมีความไวต่อยาปานกลาง (Intermediate; I) และเชื้อดื้อต่อยา (Resistant; R)

1.7 เนื้อหาทางวิศวกรรมที่เป็นต้นฉบับ

Web Application สำหรับนักจุลชีววิทยา นักเทคนิคการแพทย์ หรือบุคลากรทางการแพทย์ เพื่อให้สามารถแปลผลการทดสอบ Disk Diffusion ตามมาตรฐาน CLSI และ EUCAST ได้อย่างแม่นยำและรวดเร็ว โดยประยุกต์ใช้ Machine Learning ในการวัดขนาดวงยับยั้ง (zone of inhibition) จากภาพของจานเพาะเชื้อที่ทดสอบความไวของยาต้านจุลชีพด้วยวิธี Disk Diffusion ระบบรับหน้าที่ในการประมวลผลภาพเพื่อระบุขอบเขตของเขต zone of inhibition และคำนวณค่าเส้นผ่านศูนย์กลางของ zone of inhibition โดยอัตโนมัติจากนั้นจะแสดงผลการแปลผลการยับยั้งเชื้อตามมาตรฐาน CLSI และ EUCAST ผ่านเว็บแอปพลิเคชัน ทำให้ผู้ใช้งาน สามารถตรวจสอบผลลัพธ์ได้ทันที ลดความคลาดเคลื่อนจากการอ่านผลด้วยตาเปล่าและเพิ่มประสิทธิภาพในการ วิเคราะห์ข้อมูลสำหรับงานวิเคราะห์ด้านจุลชีววิทยาในห้องปฏิบัติการของโรงพยาบาลหรือโรงเรียนแพทย์

1.8 แผนการดำเนินงาน

1.8.1 ภาคเรียนที่ 1

ภาคเรียนที่ 1																							
ที่	รายการ	สิงหายน				กันยายน				ตุลาคม				พฤษจิกายน				ธันวาคม				ผู้รับผิดชอบ
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	
1	ศึกษาหัวข้อ Senior Project																					ทุกคน
2	จัดทำ Idea project																					ทุกคน
3	จัดทำ Proposal project																					ทุกคน
4	ศึกษา literature review																					ทุกคน
5	ศึกษาข้อมูลเกี่ยวกับ Disk diffusion																					ทุกคน
6	ศึกษาข้อมูลการทำ Image processing																					ทุกคน
7	ศึกษาข้อมูลการทำ Machine learning																					ทุกคน
8	ศึกษาข้อมูลการทำ Reinforcement learning																					ทุกคน
9	ศึกษาข้อมูลการทำ Deep learning																					ทุกคน
10	รวบรวมตัวอย่างภาพการทดลองภาวะดื้อยา																					ทุกคน
11	ออกแบบ Use case diagram และ Architecture																					ภัทรดนย์
12	ประเมินการออกแบบ Use case diagram กับผู้ใช้งาน																					ทุกคน
13	สร้าง model ในการวัดการดื้อยา																					ทุกคน
14	ออกแบบ User Interface																					ภัทรดนย์
15	ประเมิน User Interface กับผู้ใช้งาน																					ทุกคน
16	เตรียมการนำเสนอภาคเรียนที่ 1																					ทุกคน
17	นำเสนอโครงงานภาคเรียนที่ 1																					ทุกคน

ภาพที่ 1.1 Gantt Chart ของภาคเรียนที่ 1

1.8.2 ภาคเรียนที่ 2

ภาคเรียนที่ 2																							
ที่	รายการ	มกราคม				กุมภาพันธ์				มีนาคม				เมษายน				พฤษภาคม				ผู้รับผิดชอบ
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	
18	วัดผล model ที่ดีที่สุด																					พีรพัฒน์
19	สร้างเว็บแอปพลิเคชัน																					
	สร้าง Backend																					พีรพัฒน์
	สร้าง Frontend																					ภัทรดนย์
20	ทำรูปเล่มจบ project																					ทุกคน
21	ประเมิน Prototype																					
	ประเมินครั้งที่ 1																					ทุกคน
	ปรับแก้ไข Prototype ครั้งที่ 1																					ทุกคน
	ประเมินครั้งที่ 2																					ทุกคน
	ปรับแก้ไข Prototype ครั้งที่ 2																					ทุกคน
	ประเมินครั้งที่ 3																					ทุกคน
22	ทดสอบเว็บแอปพลิเคชัน																					ทุกคน
23	Deploy เว็บแอปพลิเคชัน																					
	อัปขึ้นเว็บไซต์																					พีรพัฒน์
	ประเมินประสิทธิภาพการใช้งานเว็บไซต์																					ภัทรดนย์
24	เตรียมการนำเสนอภาคเรียนที่ 2																					ทุกคน
25	นำเสนอโครงงานภาคเรียนที่ 2																					ทุกคน

ภาพที่ 1.2 Gantt Chart ของภาคเรียนที่ 2

บทที่ 2

ที่มา ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 บทนำ

การทดสอบความไวต่อยาปฏิชีวนะ (Antibiotic Susceptibility Testing; AST) เป็นกระบวนการพื้นฐานที่มีความสำคัญอย่างยิ่งในทางจุลชีววิทยา เนื่องจากมีบทบาทโดยตรงต่อการคัดเลือกยาปฏิชีวนะที่เหมาะสมและมีประสิทธิภาพในการรักษาโรคติดเชื้อ โดยจะใช้การทดสอบแบบ Kirby–Bauer disk diffusion และวัดเส้นผ่านศูนย์กลางของบริเวณยับยั้งการเจริญของเชื้อแบคทีเรีย (zone of inhibition) รอบแผ่นยาที่วางบนจานเพาะเชื้อ อย่างไรก็ตามการวัดผลด้วยวิธีดั้งเดิมซึ่งอาศัยการสังเกตด้วยสายตาร่วมกับเครื่องมือพื้นฐานยังคงมีข้อจำกัด ทั้งในด้านความแม่นยำ ความสม่ำเสมอ ตลอดจนความแตกต่างระหว่างผู้สังเกต (inter-observer variability) ที่อาจนำไปสู่ความคลาดเคลื่อนในการตีความผล (Pascucci, M. et al., 2020; Pascucci, M. et al., 2021)

ความก้าวหน้าของปัญญาประดิษฐ์ (Artificial Intelligence; AI) และเทคโนโลยีการประมวลผลภาพ ได้ถูกพัฒนาและนำมาใช้ในการแปลผล AST ให้มีความถูกต้อง รวดเร็ว และมีมาตรฐานมากขึ้น การประยุกต์ใช้ปัญญาประดิษฐ์จะสามารถช่วยลดความผิดพลาดจากข้อจำกัดและยังเพิ่มความน่าเชื่อถือของข้อมูล ในการดำเนินโครงงาน An Exploration of Artificial Intelligence for Detection of Inhibition Zones in Antibiotic Susceptibility Testing คณะผู้จัดทำจึงได้สืบค้นทฤษฎี งานวิจัยที่เกี่ยวข้อง และเทคโนโลยีที่เกี่ยวข้อง เพื่อสนับสนุนแนวคิดการพัฒนาเครื่องมือที่สามารถตรวจวัดผลการทดสอบความไวต่อยาปฏิชีวนะได้อย่างแม่นยำและเชื่อถือได้ โดยอาศัยปัญญาประดิษฐ์และกระบวนการประมวลผลภาพ (image processing) เข้ามาช่วยเสริมประสิทธิภาพของวิธีมาตรฐานที่ใช้ในปัจจุบัน การศึกษานี้จึงไม่เพียงแต่มีเป้าหมายเพื่อยกระดับความถูกต้องและความรวดเร็วของการวิเคราะห์ แต่ยังมีบทบาทสำคัญต่อการแก้ไขปัญหาสาธารณสุขในมิติของการจัดการเชื้อดื้อยา และเพิ่มโอกาสให้กับสถานพยาบาลที่มีข้อจำกัดด้านเครื่องมือวิเคราะห์ขั้นสูง สามารถเข้าถึงระบบที่ทันสมัยและมีความน่าเชื่อถือได้มากขึ้น (Ercan, M. et al., 2020)

2.2 ที่มาและความสำคัญ

สืบเนื่องจากปัญหาการดื้อยาปฏิชีวนะที่ทวีความรุนแรงขึ้นทั่วโลก การตรวจวัดความไวต่อยาด้วยวิธี Kirby–Bauer disk diffusion จึงยังคงมีความสำคัญในฐานะเครื่องมือมาตรฐานที่ช่วยกำหนดแนวทางการรักษา

ของแพทย์ อย่างไรก็ตามการอ่านผลด้วยสายตายังมีข้อจำกัด ทั้งในแง่ของเวลา ความแม่นยำ และความแตกต่างระหว่างผู้ตรวจ โดยเฉพาะเมื่อ zone of inhibition มีขนาดใกล้เคียงกับค่าขอบเขต (breakpoint) ที่ระบุไว้ในแนวทางของ CLSI และ EUCAST ซึ่งอาจทำให้เกิดความคลาดเคลื่อนแม้เพียง 1 มิลลิเมตร และส่งผลต่อการแปลผลว่าเชื้อไวหรือดื้อยา แม้ในปัจจุบันจะมีเครื่องอ่านผลอัตโนมัติ (Automated systems) ที่มีความแม่นยำสูงเข้ามาใช้งานในห้องปฏิบัติการขนาดใหญ่ แต่เทคโนโลยีดังกล่าวมีต้นทุนการติดตั้งและค่าใช้จ่ายในการบำรุงรักษาที่สูงมาก ทำให้โรงพยาบาลขนาดเล็กหรือสถานพยาบาลในพื้นที่ห่างไกลไม่สามารถเข้าถึงได้และยังคงต้องพึ่งพาวิธี Kirby-Bauer แบบดั้งเดิมเป็นหลัก นอกจากนี้ ความก้าวหน้าอย่างรวดเร็วของเทคโนโลยีการประมวลผลภาพ (Computer Vision) และการเรียนรู้เชิงลึก (Deep Learning) มีความสามารถในการจัดการกับความซับซ้อนของภาพถ่ายทางชีวภาพ เช่น การแยกแยะขอบเขตที่เลือนรางหรือการจัดการกับสภาพแสงที่ไม่สม่ำเสมอ ซึ่งเป็นข้อจำกัดที่อัลกอริทึมประมวลผลภาพแบบดั้งเดิมมักทำได้ไม่ดีพอ การประยุกต์ใช้เทคโนโลยีเหล่านี้จึงไม่เพียงแต่เป็นการเพิ่มประสิทธิภาพการทำงาน แต่ยังเป็นการลดความเหลื่อมล้ำในการเข้าถึงเทคโนโลยีทางการแพทย์ที่มีมาตรฐานอีกด้วย ดังนั้นโครงการนี้จึงมีความสำคัญในการนำปัญญาประดิษฐ์และการประมวลผลภาพมาช่วยวัดเส้นผ่านศูนย์กลางและแปลผล zone of inhibition เพื่อลดความคลาดเคลื่อน เพิ่มความรวดเร็วในการทำงาน และสนับสนุนการใช้งานในสถานพยาบาลที่ไม่มีเครื่องมืออัตโนมัติ (Yu et al., 2025)

2.3 ทฤษฎีที่เกี่ยวข้อง

2.3.1 การประมวลผลภาพ (Image Processing)

การประมวลผลภาพ (Image Processing) และการเรียนรู้ของเครื่อง (Machine Learning) รวมถึงการเรียนรู้เชิงลึก (Deep Learning) ได้รับการประยุกต์ใช้อย่างกว้างขวางในงานวิจัยทางการแพทย์ โดยเฉพาะการตรวจหาความผิดปกติและการจำแนกประเภทของภาพ (Egger et al., 2022) เพื่อสนับสนุนกระบวนการวินิจฉัยและการติดตามผลการรักษาของแพทย์ในปัจจุบัน แนวคิดดังกล่าวได้รับการนำมาใช้ในงานวิจัยด้านการดื้อยาต้านจุลชีพ (Antimicrobial Resistance; AMR) โดยผ่านการทดสอบแบบ disk diffusion (Callebaut et al., 2024). ซึ่งใช้เทคนิคการประมวลผลภาพในการวัดและระบุ ขนาดของโซนยับยั้ง (inhibition zone) และใช้ Machine Learning หรือ Deep Learning ในการจำแนกผล ความไวต่อยาปฏิชีวนะ ตามมาตรฐาน Clinical and Laboratory Standards Institute (CLSI) และ European Committee on Antimicrobial Susceptibility Testing (EUCAST) เพื่อให้ได้ผลลัพธ์ที่มีความถูกต้องและความสม่ำเสมอสูง

นอกจากนี้การบูรณาการเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence; AI) ร่วมกับการเรียนรู้แบบเสริมกำลัง (Reinforcement Learning) ยังแสดงให้เห็นถึงศักยภาพในการพัฒนาระบบที่สามารถเรียนรู้และปรับปรุงกระบวนการตีความผลการทดสอบได้อย่างต่อเนื่องจากข้อมูลใหม่ (Murphy, 2025) โดยระบบดังกล่าวสามารถนำไปประยุกต์ใช้ร่วมกับ web application เพื่อเพิ่มความสะดวกในการเข้าถึงการแปลผลตามมาตรฐาน CLSI และ EUCAST ลดความคลาดเคลื่อนที่อาจเกิดจากการวัดด้วยมือและเพิ่มประสิทธิภาพด้านความรวดเร็วและความถูกต้องในการวิ-เคราะห์ผล

2.3.1.1 การเพิ่มคุณภาพภาพ (Image Enhancement) มีบทบาทสำคัญในการปรับปรุง คุณภาพของภาพในสาขาการประมวลผลภาพ โดยทำได้ผ่านการเน้นข้อมูลที่มีประโยชน์และการลดทอนข้อมูลที่ซ้ำซ้อนภายในภาพ

1. เทคนิคเชิงพื้นที่ (Spatial Domain Techniques)

เป็นการประมวลผลภาพที่ทำงานโดยตรงกับค่าความเข้ม (intensity) ของพิกเซล วิธีที่นิยมใช้ ได้แก่ การปรับความสว่าง (Brightness Adjustment) ซึ่งเป็นการปรับค่า intensity ของทั้งภาพให้สูงขึ้นหรือต่ำลง เหมาะสำหรับกรณีที่ภาพมีความมืดหรือสว่างเกินไป การปรับความเปรียบต่าง (Contrast Adjustment) ซึ่งเป็นการขยายช่วงค่าความเข้ม (dynamic range) ของพิกเซลเพื่อทำให้รายละเอียดของภาพชัดเจนและสามารถแยกความแตกต่างได้ชัดขึ้น และวิธีการที่อาศัยฮิสโตแกรม (Histogram-based Methods) ซึ่งใช้การกระจายของฮิสโตแกรมในการปรับ Contrast Adjustment ของภาพ วิธีการปรับฮิสโตแกรมที่ใช้กันมาก ได้แก่ Histogram Equalization (HE) ที่กระจายค่าระดับสีเทา (gray level) ให้ครอบคลุมทั้งช่วง ซึ่งช่วยเพิ่ม Contrast Adjustment โดยรวมของภาพ แต่มีข้อจำกัดคืออาจทำให้รายละเอียดบางส่วนหายไปหรือเกิดการปรับเกินจริง (over-enhancement) ต่อมาได้มีการพัฒนา Adaptive Histogram Equalization (AHE) ที่คำนวณฮิสโตแกรมเฉพาะในพื้นที่ย่อย (local regions) เหมาะสำหรับภาพที่มีการกระจายแสงไม่สม่ำเสมอ ทำให้สามารถเพิ่มรายละเอียดเฉพาะพื้นที่ได้ดีกว่า HE โดยจะเห็นผลได้ชัดเจนจากรูปที่ 2.1 ที่จะเห็นว่าวิธี AHE จากภาพ (c) ที่มีความชัดเจนมากกว่า HE จากภาพ (b) ซึ่งทั้ง 2 วิธีการ ทำให้ภาพต้นฉบับจากภาพ (a) มีความชัดเจนมากขึ้น

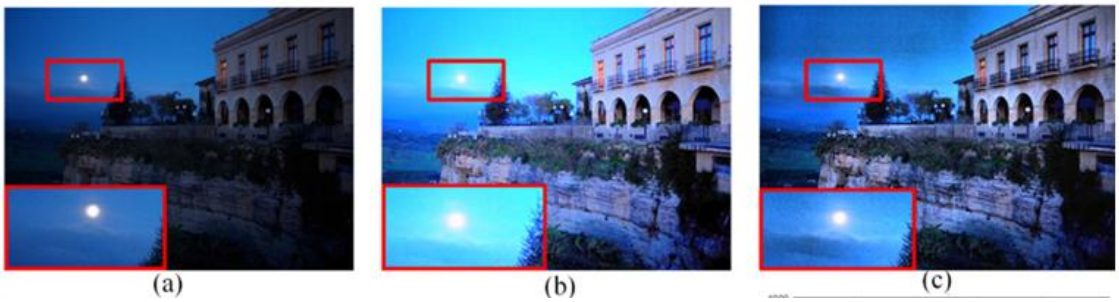

รูปที่ 2.1 Image Enhancement ด้วยวิธีการ ฮิสโทแกรม (a) คือภาพต้นฉบับ (b) และ (c) คือผลลัพธ์การปรับปรุงของการปรับสมดุลฮิสโทแกรม (HE) และการปรับสมดุลฮิสโทแกรมแบบปรับตัว (AHE) ตามลำดับ

ที่มา : (Qi et al., 2021).

เข้าถึงเมื่อวันที่ 18 กันยายน 2658 (ใช้ข้อมูลเพื่อประกอบการศึกษาวิจัยเท่านั้น)

สรุปได้ว่าเทคนิคเชิงพื้นที่ช่วยปรับการกระจายของค่าความเข้มให้สมดุลมากขึ้น ทำให้รายละเอียดในภาพเด่นชัดและง่ายต่อการสังเกต ข้อดีคือเป็นวิธีที่ค่อนข้างตรงไปตรงมาไม่ซับซ้อน และสามารถประมวลผลได้อย่างรวดเร็ว อย่างไรก็ตาม หากปรับมากเกินไปอาจทำให้เกิดการสูญเสียรายละเอียดบางส่วนหรือทำให้ภาพผิดเพี้ยนไปจากข้อมูลจริง

2. เทคนิคเชิงความถี่ (Frequency Domain Techniques)

ใช้วิธีการแปลงภาพจากโดเมนเชิงพื้นที่ไปเป็นโดเมนความถี่ เช่น Fourier Transform แล้วใช้ตัวกรอง (filters) เพื่อเน้นหรือปรับเปลี่ยนคุณลักษณะบางอย่างของภาพตัวอย่างเช่น High-pass filtering ใช้เน้นรายละเอียดหรือขอบของภาพซึ่งเหมาะกับภาพที่ต้องการเน้นขอบเขตที่ชัดเจนขณะที่ Low-pass filtering ใช้ลดสัญญาณรบกวนและทำให้ภาพเรียบขึ้น ซึ่งจะเหมาะสำหรับการจัดการกับภาพ ที่มี noise สูงหรือภาพที่ต้องการเน้นแต่ทั้ง 2 ตัวกรองมีข้อจำกัดคือการประมวลผลซับซ้อนมากกว่า เทคนิคเชิงพื้นที่ (Spatial Domain Techniques) และหากเลือกตัวกรองไม่เหมาะสมอาจทำให้ภาพ เบลอได้ (Qi et al., 2021)

2.3.1.2. การแยกส่วนภาพ (Image Segmentation)

คือ กระบวนการใน image processing และ computer vision ที่ใช้แบ่งภาพออกเป็นส่วนย่อย ๆ (segments) โดยอาศัยลักษณะ ร่วมกันของพิกเซล เช่น ความเข้มของแสง (intensity), สี (color), พื้นผิว (texture) หรือรูปร่าง (shape) เพื่อให้สามารถแยกวัตถุ (objects) หรือพื้นที่ที่สนใจ (regions of interest; ROI) ออกจากฉากหลังได้อย่างชัดเจน (Jasim et al., 2019) โดยเทคนิคที่ใช้หลักๆ มีดังนี้

1.Thresholding ใช้ค่าความเข้ม (intensity) ของพิกเซลเพื่อแบ่งภาพ เช่น
การแยกส่วนที่สว่างและมืดเหมาะกับภาพที่มี contrast ชัดเจน

2.Edge-based Segmentation อาศัยการตรวจหาขอบ (edges) ของภาพ เช่น Sobel, Canny edge detector เหมาะกับการหาขอบเขตของวัตถุ

3.Region-based Segmentation แบ่งพื้นที่ที่มีคุณสมบัติใกล้เคียงกัน เช่น Region growing, Watershed algorithm เหมาะกับการแยกพื้นที่ที่ต่อเนื่องกัน จากตัวอย่างรูป 2.2
จะเห็นว่าภาพแรกจะเป็นภาพใบไม้จากชีวิตจริง
แล้วถัดมาที่ภาพกลางจะเป็นการแบ่งขอบเขตของวัตถุจากความเข้มของสี
และภาพสุดท้ายทางขวาจะเป็นการปรับปรุงขอบเขตความเข้มของสีให้ชัดเจนมากขึ้น

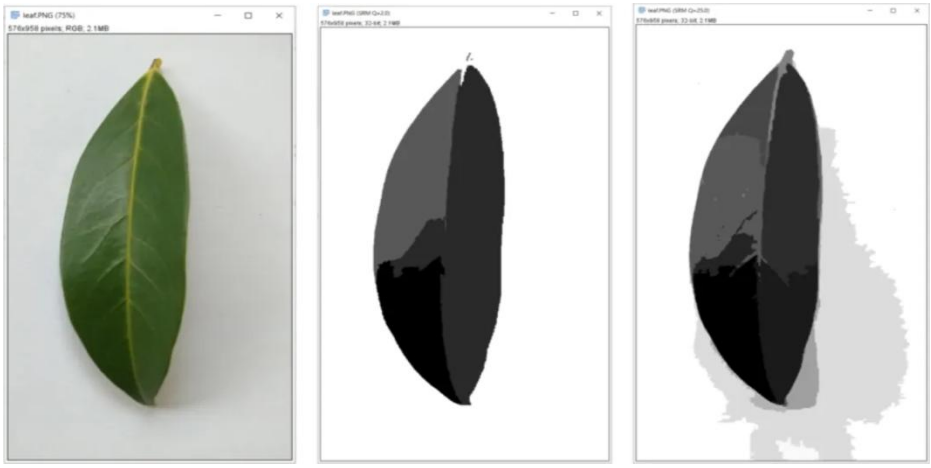

รูปที่ 2.2 ภาพตัวอย่างการระบุใบไม้จากภาพถ่ายด้วยวิธีการ Region-based Segmentation
ที่มา : https://medium.com/@fraidoonomarzai99/image-segmentation-in-depth-8ec11fb56371
เข้าถึงเมื่อวันที่ 18 กันยายน 2658 (ใช้ข้อมูลเพื่อประกอบการศึกษาวิจัยเท่านั้น)

4.Clustering-based Segmentation ใช้ Machine Learning เช่น K-means, Fuzzy C-means ในการจัดกลุ่มพิกเซลได้ผลดีในภาพที่มีหลายกลุ่มสี/พื้นผิว (Dhanachandra, N. et al., 2015)

5.Deep Learning-based Segmentation ใช้ Convolutional Neural Networks (CNNs) หรือโครงข่ายแบบพิเศษ เช่น U-Net, Mask R-CNN เหมาะกับการประมวลผลภาพทางการแพทย์และงานที่ต้องการความแม่นยำสูง (Jasim et a., 2021)

2.3.1.3. การปรับภาพเป็นสีขาวดำ (Image Binarization)

คือ กระบวนการแปลงภาพดิจิทัลจากระดับสีเทาหรือสีเต็มรูปแบบให้กลายเป็นภาพขาว-ดำแบบไบนารี ซึ่งแต่ละพิกเซลจะถูกกำหนดค่าเพียงสองค่า เท่านั้น ได้แก่ ค่าสีดำ (0) และสีขาว (1) โดยกระบวนการนี้มักใช้วิธีการ Thresholding ซึ่งกำหนดค่าจำกัด (threshold) เพื่อแยกวัตถุออกจากพื้นหลัง การทำ Image Binarization มีความสำคัญในหลายงานประมวล ผลภาพ เช่น การจดจำตัวอักษร (OCR) การวิเคราะห์เอกสารทางวิชาการ และการตรวจจับวัตถุ เพราะช่วยลดความซับซ้อนของข้อมูลและเน้นส่วนสำคัญของภาพให้ชัดเจน ทำให้การประมวลผลต่อไปทั้งด้านการวิเคราะห์ หรือการจำแนกประเภทภาพมีความแม่นยำและรวดเร็วมากขึ้น (Yang et al., 2021)

2.3.2. กระบวนการของ Machine Learning

Machine Learning คือ กระบวนการที่ทำให้คอมพิวเตอร์สามารถเรียนรู้และพัฒนาการทำงานด้วยข้อมูลและสภาพแวดล้อมโดยไม่ต้องอาศัยการควบคุมจากมนุษย์ (Alam. et al., 2023) ซึ่งกระบวนการพัฒนาโมเดลเพื่อ วิเคราะห์ภาพจานเพาะเชื้อในวิธี disk diffusion ประกอบด้วยหลายขั้นตอน เริ่มจากการเก็บรวบรวมข้อมูล ภาพจานเพาะเชื้อที่มีความหลากหลายทั้งเชื้อและยา เพื่อให้โมเดลสามารถเรียนรู้รูปแบบต่าง ๆ ของขนาดวงยับ ยั้งเชื้อ (zone of inhibition) ต่อด้วยการเตรียมข้อมูล (Data Preparation) ซึ่งรวมถึงการปรับแสง สี การลบ สัญญาณรบกวน และการแบ่งข้อมูลเป็นชุดฝึกสอน ชุดตรวจสอบ และชุดทดสอบ เพื่อรองรับการฝึกและประเมิน ผลของโมเดลอย่างมีประสิทธิภาพ การเลือกหรือพัฒนาโมเดล (Model Selection) เป็นขั้นตอนสำคัญในการ กำหนดโครงสร้าง เช่น Convolutional Neural Network (CNN) หรืออัลกอริทึมประมวลผลภาพอื่น ๆ ที่สามารถวิเคราะห์ขอบเขตของ zone of inhibition ได้อย่างแม่นยำ จากนั้นเป็นขั้นตอนการฝึกโมเดล (Model Training) โดยใช้ชุดฝึกสอนเพื่อปรับพารามิเตอร์ให้สามารถระบุและวัดขนาด zone of inhibition ได้อย่างถูกต้อง การประเมินโมเดล (Model Testing and Evaluation) ใช้ชุดทดสอบและตัวชี้วัดต่าง ๆ เช่น Mean Absolute Error (MAE) ซึ่งวัดค่าเฉลี่ยของความคลาดเคลื่อนระหว่างค่าที่โมเดลทำนายกับค่าจริง, Accuracy ที่วัดสัดส่วน

ของผลลัพธ์ที่โมเดลทำนายถูกต้องเมื่อเทียบกับค่าจริง, และความแม่นยำของการทำนายตำแหน่งวัตถุในภาพ (Intersection over Union; IoU) ที่ประเมินความแม่นยำของการตรวจจับขอบเขตของ zone of inhibition โดยวัดการทับซ้อนระหว่างพื้นที่ที่โมเดลทำนายและพื้นที่จริง เพื่อวัดความแม่นยำและความเชื่อถือได้ของโมเดล ขั้นตอนการปรับแต่งโมเดล (Model Tuning) เป็นการปรับค่า Hyperparameters เช่น Learning Rate, Batch Size และจำนวนชั้นของเครือข่าย เพื่อเพิ่มความแม่นยำ ลดการ overfitting และทำให้โมเดลมีความเสถียร สุดท้ายคือการนำโมเดลที่ผ่านการฝึกและปรับแต่งแล้วไปทำนายผล (Prediction) และวัดขนาด zone of inhibition จากภาพใหม่ ซึ่งสามารถให้ข้อมูลเชิงตัวเลข เช่น เส้นผ่านศูนย์กลางหรือพื้นที่ของ zone of inhibition เพื่อใช้ในการวิเคราะห์และสนับสนุนการตัดสินใจด้านการวิจัยและการแพทย์ (Pascucci, M. et al., 2020)

2.3.3. การแปลงภาพเป็นข้อความ (Optical Character Recognition; OCR)

คือ เทคโนโลยีที่ใช้ในการแปลงข้อความจากรูปภาพหรือเอกสารสแกนให้กลายเป็นข้อมูลตัวอักษรดิจิทัล ที่สามารถแก้ไข ค้นหา หรือประมวลผลด้วยคอมพิวเตอร์ได้ โดยกระบวนการทำงานด้วยการปรับคุณภาพภาพ แล้วดึงตัวอักษรออกมาจำแนกอักษรออกมาก่อนที่จะตรวจศัพท์จากฐานข้อมูลเพื่อดึงคำที่มีความหมายนั้นออกมา เพื่อนำไปใช้ต่อได้ ซึ่งเทคโนโลยีนี้ถูกนำไปใช้ในหลายด้าน เช่น การสแกนเอกสาร การแปลงหนังสือเก่าเป็นดิจิทัล การประมวลผลบิลหรือใบเสร็จ และการอ่านตัวอักษรจากภาพถ่าย OCR ทำงานโดยวิเคราะห์ลักษณะของตัวอักษร เช่น รูปร่าง ขนาด และตำแหน่ง จากนั้นจับคู่กับตัวอักษรที่รู้จักในระบบ ฐานข้อมูล ทำให้สามารถถอดข้อความจากภาพเป็นไฟล์ข้อความได้อย่างแม่นยำ (Wang et al., 2023) ได้สรุปประวัติ การพัฒนา OCR และชี้แนวทางการพัฒนาต่อไปของเทคโนโลยีนี้ในอนาคต ซึ่งช่วยให้ OCR มีความแม่นยำและสามารถรองรับเอกสารที่หลากหลายรูปแบบได้มากขึ้น

2.3.4. Convolution Neural Network (CNN)

Convolution Neural Network (CNN) เป็นโครงสร้างของ Neural Network ที่ถูกออกแบบมาโดยเฉพาะเพื่อจัดการกับข้อมูลประเภทภาพ ทำให้สามารถสกัดคุณลักษณะเชิงพื้นที่และเชิงโครงสร้างได้ดีกว่า Neural Network ทั่วไป ด้วยเหตุนี้ CNN จึงได้รับความนิยมอย่างสูงในงานด้านการประมวลผลภาพและการเรียนรู้เชิงลึก เช่น การจำแนกประเภทภาพ การวิเคราะห์วัตถุ และการทำนายคุณสมบัติต่าง ๆ (Purwono et al., 2023) สำหรับงานวิจัยนี้ CNN ถูกนำมาใช้ในการวิเคราะห์และวัดขนาดวงยับยั้งเชื้อ (zone of inhibition) จากภาพการทดสอบความไวต่อการดื้อยา (Antimicrobial Susceptibility Testing; AST) โดยอาศัยการทำงานหลักสองขั้น

ตอน คือ การสกัดคุณลักษณะ (Feature Extraction) และ การจำแนก (Classification) ในขั้นแรก Convolution Layers จะใช้ kernel หรือ filter ในการสแกนภาพเพื่อค้นหาลักษณะสำคัญ เช่น ขอบเขตวงของ zone of inhibition รูปร่าง และระดับความเข้มสี ก่อนจะสร้างเป็น Feature Maps ที่แทนคุณลักษณะของภาพ จากนั้น Pooling Layers จะทำการลดขนาด Feature Maps เพื่อคัดเลือกเฉพาะคุณลักษณะที่สำคัญและลดภาระการคำนวณ ทำให้โมเดลเรียนรู้ได้อย่างมีประสิทธิภาพมากขึ้น เมื่อได้คุณลักษณะเหล่านี้แล้ว ขั้นตอนต่อมาจะส่งต่อไปยัง Fully Connected Layers ซึ่งทำหน้าที่รวมคุณลักษณะทั้งหมดและใช้ในการทำนายหรือจำแนกผล ซึ่งจะเห็นกระบวนการทำงานจากภาพที่ 2.3 โดยในงานวิจัยนี้ถูกใช้เพื่อคาดคะเนและจัดกลุ่มขนาดของ zone of inhibition ตามเกณฑ์ที่กำหนด ทั้งนี้การใช้ CNN จึงช่วยให้การวิเคราะห์ภาพ disk diffusion ที่มีความแม่นยำและสามารถทำงานได้แบบอัตโนมัติ ลดความคลาดเคลื่อนจากการประเมินด้วยสายตาของผู้ เชี่ยวชาญ

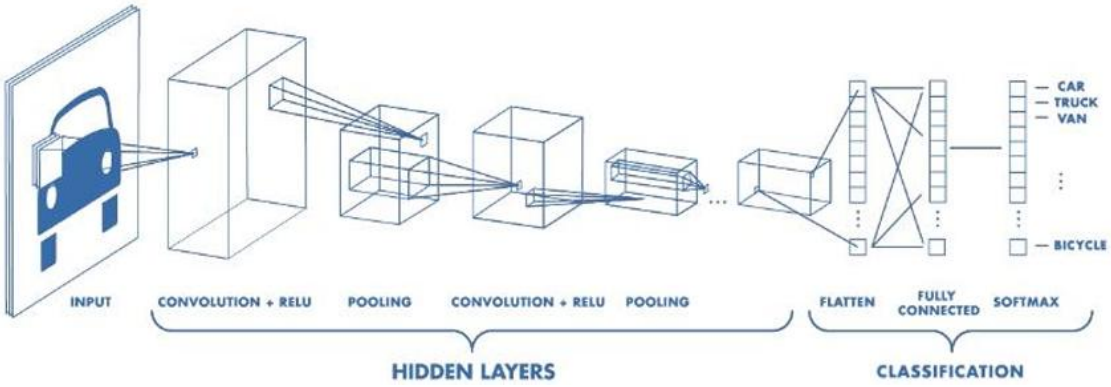

ภาพที่ 2.3 Architecture ของ CNN

ที่มา : (Purwono et al., 2023)

2.3.5 เชื้อแบคทีเรีย (Bacteria)

เป็นเชื้อแบคทีเรียที่ใช้สำหรับการทดสอบความไวต่อการดื้อยาปฏิชีวนะ โดยใช้เชื้อแบคทีเรียที่เป็นสายพันธุ์มาตรฐาน (Standardized Strains) และเป็นแบคทีเรียที่ได้รับความอนุเคราะห์จาก รศ.ดร.สุทธิรัตน์ สิทธิศักดิ์ ภาควิชาจุลชีววิทยา และปรสิตวิทยา คณะ วิทยาศาสตร์การแพทย์ มหาวิทยาลัยเรศวร เพื่อเป็นตัวควบคุมในการทดสอบให้มีความเชื่อถือในการทดสอบ โดยมีแหล่งที่มาจาก

2.3.5.1 American Type Culture Collection (ATCC)

เป็นศูนย์ที่รวบรวมข้อมูลทางชีวภาพจากประเทศสหรัฐอเมริกามาตั้งแต่ปีคริสต์ศักราช 1925 จนถึงปัจจุบัน โดยเป็นที่เก็บรวบรวมข้อมูลทางชีวภาพหลายชนิดไว้ด้วยกัน ซึ่งถือเป็นฐานข้อมูลที่สำคัญสำหรับการกำหนดมาตรฐานเชื้อแบคทีเรียในการทดสอบความไวต่อการดื้อยาปฏิชีวนะ เช่น *Staphylococcus aureus*, *Pseudomonas aeruginosa* และ *Escherichia coli* เป็นต้น (American Society for Microbiology., 2009; K. I. et al., 1996)

2.3.5.2 Department of Medical Sciences Thailand (DMST)

กรมวิทยาศาสตร์การแพทย์เป็นศูนย์ที่เก็บรวบรวมข้อมูลทางชีวภาพของประเทศไทย โดยเฉพาะข้อมูลแบคทีเรียที่ได้รับมาตรฐานในการทดสอบความไวต่อการดื้อยาปฏิชีวนะ เช่น *Bacillus cereus*, *Bacillus subtilis*, *Klebsiella pneumoniae* และ *Sallonella typinimurium* เป็นต้น (Department of Medical Sciences., 2025)

2.3.6 ยาปฏิชีวนะ (Antibiotic)

เป็นยาที่ใช้สำหรับทดสอบการดื้อยาของเชื้อที่สนใจ ในการทดสอบจะมีการดื้อยาปฏิชีวนะหรือไม่ดื้อยา จึงทำให้มีการนำยามาทดสอบแต่ละชนิดด้วยวิธีการ Kirby–Bauer disk diffusion เพื่อทดสอบ โดยยาที่ใช้ในการทดสอบก็จะมีความแตกต่างกันไปตามแต่เชื้อว่าจะทดสอบแล้วสามารถวัดตามหลักเกณฑ์ที่มีกำหนดตาม CLSI หรือ EUCAST ได้ ยาปฏิชีวนะที่มีการใช้ทดสอบมีจำนวนมาก เช่น Ampicillin, Oxacillin, Gentamicin, Azithromycin และ Ciprofloxacin เป็นต้น (Lewis, J. et al., 2025)

2.3.7. วิธีการ Disk Diffusion

เป็นวิธีการทดสอบความไวของจุลชีพต่อยาปฏิชีวนะ (Antimicrobial Susceptibility Testing; AST) โดยอาศัยหลักการที่ว่าเมื่อวางแผ่นกระดาษที่บรรจุยาปฏิชีวนะบนจานเพาะเชื้อ แบคทีเรียหรือจุลชีพ และแบคทีเรียหรือจุลชีพจะเจริญเติบโตบนจาน แต่พื้นที่รอบ ๆ แผ่นยาจะถูกยับยั้งเกิดเป็นขนาดวงยับยั้ง (zone of inhibition) ขนาดของ zone of inhibition แสดงถึงความไวของเชื้อต่อยานั้นมีขั้นตอนดังนี้ (Callebaut et al., 2024).

2.3.7.1 การเตรียมจานเพาะเชื้อ (Preparation of Agar Plates)

ในการทดสอบความไวของเชื้อต่อยาปฏิชีวนะ จะดำเนินการตาม Guideline CLSI โดยวิธี Aseptic technique ดังนี้

1. ใช้ Mueller-Hinton agar (MHA) ซึ่งเป็นอาหารเลี้ยงเชื้อแบคทีเรียมาตรฐานสำหรับการทดสอบความไวต่อยาปฏิชีวนะ

2. เทอาหาร MHA ที่ผ่านการนึ่งฆ่าเชื้อโดยวิธี Autoclave ในจาน Petri dish ให้มีความหนาประมาณ 4 mm หรือ 20 mL ใน Petri dish ขนาด 10 cm เพื่อให้ผลการแพร่ของยาและขนาด zone of inhibition สม่ำเสมอ

3. ปล่อยให้วุ้นแข็งตัวและตรวจสอบความสะอาดของจานเพาะเชื้อ

2.3.7.2 การเตรียมเชื้อ (Inoculum Preparation)

1. นำเชื้อแบคทีเรียที่เพาะไว้ โดยเขี่ยโคโลนีเดี่ยวมาปรับความหนาแน่นให้เท่ากับ McFarland 0.5 หรือนำแบคทีเรียที่เลี้ยงไว้ใน Mueller-Hinton broth (MHB) มาปรับความหนาแน่นให้เท่ากับ McFarland 0.5 (จะมีความหนาแน่นเชื้อประมาณ 1.5×10^8 CFU/mL)

2. ใช้ MHB เป็นสารละลายสำหรับปรับความหนาแน่นของเชื้อ

3. ป้ายเชื้อบนจานเพาะเชื้อด้วย sterile swab ให้ครอบคลุมผิวจานอย่างสม่ำเสมอเพื่อให้การเจริญเติบโตของเชื้อเท่าเทียมกันทั้งจาน

2.3.7.3 การวางแผ่นยาปฏิชีวนะ (Placement of Antibiotic Disks)

1. วาง antibiotic discs ที่มีขนาดมาตรฐาน (เช่น 6 mm) บนผิวจานที่ป้ายเชื้อแล้ว

2. เว้นระยะระหว่างแผ่นยาอย่างน้อย 24 mm เพื่อป้องกัน zone of inhibition ของแผ่นยาแต่ละแผ่นทับกัน

3. ใช้ forcep หรือเครื่องวาง disk แบบอัตโนมัติสำหรับความแม่นยำ

2.3.7.4 การบ่มเชื้อ (Incubation)

1. นำ Petri dish ที่มีการวางยาแล้วไปบ่มใน incubator ที่อุณหภูมิ 35–37°C เป็นเวลา 18–24 ชั่วโมง

2. ตรวจสอบให้แน่ใจว่า Petri dish ตั้งอยู่ในตำแหน่งแนวนอนและไม่มีการสั่นสะเทือน

3. ในช่วงนี้ ยาจะกระจายเข้าสู่วุ้นและยับยั้งจุลชีพที่กำลังแบ่งตัว ทำให้เกิด zone of inhibtion รอบแผ่นยา

2.3.7.5 การวัดและประเมินผล (Measurement and Interpretation)

1. วัดเส้นผ่านศูนย์กลางของ zone of inhibition ด้วย ไม้บรรทัดแบบ millimeter หรือ caliper

2. เปรียบเทียบผลกับมาตรฐาน Clinical and Laboratory Standards Institute (CLSI) และ European Committee on Antimicrobial Susceptibility Testing (EUCAST)

3. ตัดสินความไวของเชื้อเป็น เชื้อไวต่อยา (Susceptible; S), เชื้อมีความไวต่อยาปานกลาง (Intermediate; I) และเชื้อดื้อต่อยา (Resistant; R) ตามตารางมาตรฐานของแต่ละยาปฏิชีวนะ เช่นตัวอย่างจากภาพที่ 2.4

	Resistant	Intermediate	Susceptible
Cefazolin (30 µg)	≤14	15-17	≥18
Clindamycin (2 µg)	≤14	15-20	≥21
Erythromycin (15 µg)	≤13	14-22	≥23
Gentamicin (10 µg)	≤12	13-14	≥15
Oxacillin (1 µg)	≤10	11-12	≥13
Penicillin G (10 µg)	≤28	--	≥29
Tobramycin (10 µg)	≤12	13-14	≥15
Vancomycin (30 µg)	--	--	≥15

ภาพที่ 2.4 ตัวอย่างมาตรฐานการทดสอบความไวต่อการดื้อยาจากวิธีการ Disk Diffusion

ที่มา : https://asm.org/protocols/kirby-bauer-disk-diffusion-susceptibility-test-pro

เข้าถึงเมื่อวันที่ 18 กันยายน 2658 (ใช้ข้อมูลเพื่อประกอบการศึกษาวิจัยเท่านั้น)

2.3.8. การแปลผลตามมาตรฐาน Clinical and Laboratory Standards Institute (CLSI) และ European Committee on Antimicrobial Susceptibility Testing (EUCAST)

2.3.8.1 Clinical and Laboratory Standards Institute (CLSI)

CLSI เป็นมาตรฐานจากประเทศสหรัฐอเมริกาที่ให้คำแนะนำเกี่ยวกับวิธีปฏิบัติในห้องปฏิบัติการสำหรับการทดสอบความไวของจุลชีพต่อยาปฏิชีวนะ เช่น Disk Diffusion และ Minimum Inhibitory Concentration (MIC) CLSI กำหนด cut-off values สำหรับการจำแนกผลว่าเชื้อเป็น เชื้อไวต่อยา (Susceptible; S), เชื้อมีความไวต่อยาปานกลาง (Intermediate; I) และเชื้อดื้อต่อยา (Resistant; R) (Kahlmeter et al., 2019; Giske, C. G. et al., 2022) ซึ่งช่วยให้ห้องปฏิบัติการสามารถรายงานผลได้อย่างสม่ำเสมอและ เชื่อถือได้ มาตรฐาน CLSI ใช้กันแพร่หลายในสหรัฐอเมริกาและหลายห้องปฏิบัติการ รวมถึงในประเทศไทยที่ยึดหลักปฏิบัติแบบเดียวกัน

2.3.8.2 European Committee on Antimicrobial Susceptibility Testing (EUCAST)

EUCAST เป็นมาตรฐานจากยุโรปที่มุ่งเน้นสร้างแนวทางสำหรับการทดสอบความไวของเชื้อจุลชีพต่อยาปฏิชีวนะให้เป็นมาตรฐานสากลในยุโรป เช่นเดียวกับ CLSI และ EUCAST เป็นมาตรฐานสำหรับกำหนดวิธีการ cut-off values สำหรับการตีความผล Disk Diffusion และ MIC ขอบเขต เชื้อไวต่อยา (Susceptible; S), เชื้อมีความไวต่อยาปานกลาง (Intermediate; I) และเชื้อดื้อต่อยา (Resistant; R) ของ EUCAST อาจแตกต่างจาก CLSI เล็กน้อย เนื่องจากอิงข้อมูลทางคลินิกและการแพร่ระบาดของเชื้อในยุโรป ความแตกต่างเหล่านี้อาจส่งผลต่อการตีความผล และการรายงานความไวของเชื้อจุลชีพ (Kahlmeter et al., 2019; Humphries, R. M. et al., 2018)

2.4. ภาษาคอมพิวเตอร์และเทคโนโลยี

2.4.1 Python คือ ภาษาโปรแกรมที่มีความนิยมสูงในวงการพัฒนาโปรแกรม โดยถูกออกแบบให้ใช้งานง่ายและอ่านเข้าใจได้ง่าย มีลักษณะการเขียนที่สะอาดและกระชับ จึงเหมาะสำหรับผู้เริ่มต้นโปรแกรมมิ่งและนักพัฒนามืออาชีพ โดย Python รองรับการเขียนโปรแกรมหลายรูปแบบ เช่น การเขียนโปรแกรมเชิงวัตถุ (Object-Oriented Programming) การเขียนโปรแกรมฟังก์ชัน (Functional Programming) การเขียนโปรแกรมสคริปต์ (Scripting) Python ถูกใช้ในหลายแวดวง เช่น การพัฒนาเว็บไซต์ (Django, Flask),

การวิเคราะห์ข้อมูล (Pandas, NumPy), ปัญญาประดิษฐ์ (AI, Machine Learning), วิทยาศาสตร์ข้อมูล (Data Science), การพัฒนาเกม และงานด้านระบบต่างๆ (Siva, P. et al., 2023)

2.4.2 html คือ ภาษา HTML (HyperText Markup Language) เป็นภาษามาร์กอัปมาตรฐานที่ถูกพัฒนาขึ้นเพื่อใช้ในการสร้างและแสดงผลเอกสารบนเครือข่ายเวิลด์ไวด์เว็บ โดย HTML กำหนดโครงสร้างของเนื้อหาในรูปแบบขององค์ประกอบ (elements) ที่ระบุความสัมพันธ์ระหว่างข้อความ ภาพ เสียง วิดีโอ และสื่อดิจิทัลอื่น ๆ เพื่อให้สามารถเชื่อมโยงข้อมูลผ่านไฮเปอร์ลิงก์ได้อย่างมีประสิทธิภาพ (W3C, 2017) HTML ถูกใช้ทั้งในฐานะสื่อกลางของข้อมูล (medium of information) และ เครื่องมือการทดลอง (experimental tool) ตัวอย่างเช่น งานวิจัยด้านการศึกษาออนไลน์ การจำลองอินเทอร์เฟซผู้ใช้ ไปจนถึงการประยุกต์ใช้ในระบบสารสนเทศสุขภาพและการแพทย์ เนื่องจาก HTML มีความเป็นสากล รองรับอุปกรณ์ที่หลากหลาย (Sharma, A. et al., 2018)

2.5. งานวิจัยที่เกี่ยวข้อง

2.5.1 Circle detection on images using Learning Automata

จากการศึกษาของ Ayala-Ramirez, V. และคณะ (2014) ศึกษาการตรวจจับวงกลมจากรูปภาพ โดยได้พัฒนาโมเดลที่มีประสิทธิภาพมากขึ้นจากโมเดลก่อนหน้า ได้แก่ Learning Automata (LA) ซึ่งเป็นวิธีการ reinforcement learning รูปแบบหนึ่งโดยอาศัยการเรียนรู้แบบให้รางวัล (reward) โดยได้มีการทดสอบรูปภาพที่มีความแตกต่างกัน 6 รูปแบบ ได้แก่ ระบุตำแหน่งวงกลม, จำแนกรูปร่าง, ตรวจจับวงกลมหลายวง, ประมาณรูปร่างวงกลม, ตรวจวงกลมที่มีวัตถุบังบางส่วน และ วงกลมที่มีความซับซ้อน ซึ่งเทียบกับโมเดลแบบเก่า Hough Transform (HT) ซึ่งเป็นโมเดลที่มีการพัฒนามาอย่างต่อเนื่องจึงออกมาเป็นโมเดล Iterative Randomized HT (IRHT) ที่พัฒนาล่าสุด โดยมีต้นทุนในการใช้โมเดลที่น้อยกว่าโมเดลแบบเดิมแต่มีการเรียนรู้ที่ซับซ้อนจากการสุ่มตำแหน่งตามจำนวนที่กำหนดในการใช้เพื่อหาจุดที่ดีที่สุดในการระบุตำแหน่งที่เป็นวงกลม นอกจากนั้นมีอีกวิธีการในการหาวงกลม คือ Genetic Algorithm (GA) ใช้การเพิ่มประสิทธิภาพรูปภาพและตรวจจับวัตถุที่มีความสำคัญในรูปภาพ หลังจากวัดผลการทดลองพบว่า Learning Automata มีประสิทธิภาพมากขึ้นเมื่อเทียบกับโมเดลแบบเก่า เห็นได้จากภาพที่ 2.5 ที่จะให้ความเร็วในการประมวลผลที่น้อยที่สุด ส่วนผลความสำเร็จในการตอบถูก (Success rate) ถึง 100% และเกิดค่าความคลาดเคลื่อนเฉลี่ยน้อยที่สุดจากโมเดลทั้งหมด (Ayala-Ramirez, V. et al., 2014)

Image	Averaged execution time ± Standard deviation (s)			Success rate (SR) (%)			Averaged *Es* ± Standard deviation		
	GA	IRHT	LA	GA	IRHT	LA	GA	IRHT	LA
Synthetic images									
(a)	2.23±(0.41)	1.71±(0.51)	**0.21±(0.22)**	94	**100**	**100**	0.41±(0.044)	0.33±(0.052)	**0.22±(0.033)**
(b)	3.15±(0.39)	2.80±(0.65)	**0.36±(0.24)**	81	95	**98**	0.51±(0.038)	0.37±(0.032)	**0.26±(0.041)**
(c)	3.02±(0.63)	4.11±(0.71)	**0.64±(0.19)**	93	78	**100**	0.71±(0.036)	0.77±(0.044)	**0.42±(0.011)**
Natural Images									
(a)	2.02±(0.32)	3.11±(0.41)	**0.31±(0.12)**	**100**	**100**	**100**	0.45±(0.051)	0.41±(0.029)	**0.25±(0.037)**
(b)	2.11±(0.31)	3.04±(0.29)	**0.57±(0.13)**	**100**	92	**100**	0.87±(0.071)	0.71±(0.051)	**0.54±(0.071)**
(c)	2.50±(0.39)	2.80±(0.17)	**0.51±(0.11)**	91	80	**97**	0.67±(0.081)	0.61±(0.048)	**0.31±(0.015)**

ภาพที่ 2.5 ภาพการวัดผลการทดลองเปรียบแต่ละโมเดล โดย GA, IRHT และ LA

ที่มา : (Ayala-Ramirez, V. et al., 2014)

เข้าถึงเมื่อวันที่ 20 พฤศจิกายน 2658 (ใช้ข้อมูลเพื่อประกอบการศึกษาวิจัยเท่านั้น)

2.5.2 Circle detection in images: A deep learning approach

จากการศึกษาของ Ercan, M. และคณะ (2020) ได้มีการศึกษาการใช้ deep learning ในการตรวจจับวงกลมใต้น้ำ โดยมีการใช้วิธีการจับวงกลมแบบใหม่ คือ Faster R-CNN ที่ใช้วิธีการหาตำแหน่งวัตุก่อนแล้วค่อยมาเลือกวัตถุที่จะจับอีกทีเพื่อให้มีความแม่นยำ แล้วนำไปเปรียบเทียบกับวิธีการแบบเก่า ได้แก่ Hough Transform และ Single Shot Multi-Box Detector (SSD) ซึ่งมี Hough Transform เป็นวิธีการแบบดั้งเดิมที่ไม่มีความซับซ้อนเมื่อเทียบกับวิธีการ deep learning นอกจากนั้นรวมถึง การใช้ Feature Extractors ที่มีความแตกต่างกันในการเปรียบเทียบเพื่อหาวิธีการที่ดีที่สุด โดยพบว่าวิธีการแบบ Faster R-CNN ได้ค่าแม่นยำที่มากที่สุดในการตรวจจับวงกลมจากรูปภาพ โดยวัดผลจากความแม่นยำของการทำนายตำแหน่งวัตถุ

ในภาพ (Intersection over Union; IoU) จากภาพที่ 2.7 ในการดูความแม่นยำ ซึ่งมีการทดสอบจากข้อมูลจาก 2 แหล่งในการทดสอบ สรุปได้ว่าจากการทดลองวิธีการแบบ deep learning ที่มีการทำมีประสิทธิภาพได้มากกว่าวิธีการแบบดั้งเดิมจากผลการทดสอบ เห็นได้จากผล IoU ของ Faster R-CNN ที่ได้ผลแม่นยำมากที่สุดจากรูปที่ 2.6 เมื่อเทียบกับโมเดลที่มีความแตกต่างกัน (Ercan, M. et al., 2020)

	IOU (dataset1 models)	IOU (dataset2 models)	Processing time(s)
faster_rcnn_resnet50	0.692	0.866	0.225
faster_rcnn_resnet_101	0.720	0.832	0.250
faster_rcnn_inception_resnet_v2	0.687	0.833	0.744
faster_rcnn_inceptionv2	0.231	0.744	0.115
ssd_inception_v2	0.546	0.753	0.041
ssd_mobilenet_v2	0.535	0.713	0.030
Hough Transform	0.491		3.868

ภาพที่ 2.6 ภาพการวัดผลการทดลองเปรียบแต่ละโมเดล Faster R-CNN, SSD และ Hough Transform

ที่มา : (Ercan et al., 2020)

จากรูปที่ 2.6 จากงานวิจัยจะเห็นได้ว่าขาดการทดสอบโมเดลด้วยวิธีการ reinforcement learning ในการทดสอบตรวจจับวงกลมเนื่องจาก Faster R-CNN และ SSD เป็นโมเดล deep learning ส่วน Hough Transform เป็นโมเดลการประมวลผลภาพ (Image processing) ซึ่งโมเดลเป็นโมเดลแบบเก่า ที่มีมานานแล้ว และขาดการทดสอบภาพถ่ายที่ได้จากกล้องที่มีคุณภาพที่ต่ำ เนื่องจากข้อมูลรูปภาพการทดสอบเป็นการนำภาพที่ถ่ายด้วยกล้องที่มีคุณภาพสูงในการเก็บข้อมูล

2.5.3 AI-based mobile application to fight antibiotic resistance

จากการศึกษาของ Pascucci, M. และคณะ (2021) ได้ศึกษาและพัฒนาวิธีการตรวจสอบการดื้อยาด้วยวิธีการ Kirby-Bauer disk diffusion ซึ่งได้นำปัญญาประดิษฐ์ (Artificial Intelligence; AI) เข้ามาช่วยในการพัฒนาในการวัด ทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing; AST) เพื่อลดความเสี่ยงที่จะเกิดข้อผิดพลาดและเวลาในการทดสอบที่นาน โดยอ้างอิงการวัดผลของการดื้อยาจากหลักเกณฑ์ CLSI และ EUCAST ซึ่งมีขั้นตอนทั้งหมด 3 ครั้งตอน ได้แก่ Image Processing (IP)

เป็นการวิเคราะห์ภาพจากกล้องถ่ายภาพ Expert System (ES) เป็นการตีความผล จากข้อมูลที่ได้จาก IP และ Graphical User Interface (GUI) เป็นการแสดงผลหรือฟังก์ชันการใช้ของผู้ใช้งาน รวมถึงทางคณะวิจัยได้มีการตรวจสอบข้อผิดพลาดจากการทดลองโดยแบ่งข้อผิดพลาด 3 ระดับ ได้แก่ ผิดพลาดมากจากการแปลผลผิดเป็นดื้อยา (Resistant; R) แต่ผลจริงเป็นไวต่อยา (Susceptible; S) แทน ผิดพลาดปานกลางจากการทายผิดเป็นไวต่อยา (Susceptible; S) แต่ผลจริงเป็นดื้อยา (Resistant; R) แทน และผิดพลาดน้อยจากการทายผิดเป็นไวปานกลาง (Intermediate; I) แต่ผลจริงเป็นดื้อยา (Resistant; R) หรือ ไวต่อยา (Susceptible; S) โดยเมื่อวัดผลตามวิธีการดังกล่าวพบว่ามีผลถูกมากกว่า 90% จากชุดข้อมูล ทั้งหมดและมีความเร็วที่มากขึ้นเมื่อเทียบกับการทดสอบ AST ด้วยวิธีไม่ใช้ AI (Pascucci, M. et al., 2020; Pascucci, M. et al., 2021)

แม้งานวิจัยดังกล่าวจะมีโมเดลที่ทายผลได้ดีแต่ยังมีข้อจำกัดจากการที่มีข้อมูลในการสอนปัญญาประดิษฐ์ที่มีจำนวนน้อยที่น้อยเกินไป ซึ่งอาจเสี่ยงต่อการเกิด overfitting หรือการที่โมเดลเรียนรู้มากเกินทายผลข้อมูลการฝึก (trainning data) ได้ดีแต่ถ้าทายผลข้อมูลการทดสอบ (test data) จะทายผลได้แย่ ซึ่งไม่เหมาะสมสำหรับการใช้งานในแอปพลิเคชันบนอุปกรณ์พกพา และการทดสอบตัวแอปพลิเคชันพบว่าจำเป็นต้องมีการวิเคราะห์จากมนุษย์ด้วย เพื่อเช็คความถูกต้องของผลจากการวัดความไวของยาปฏิชีวนะ รวมถึงถ้าการทดสอบความไวของยาปฏิชีวนะที่ไม่มีในฐานข้อมูลจะทำให้ไม่สามารถวัดผลได้ จึงจำเป็นต้องมีการเพิ่มหรือพัฒนาเพิ่มเติมในการจัดการปัญหานี้

2.5.4 A Novel Automated AI Tool for Reporting Antibiograms.

จากการศึกษาของ Rajasekar, Thiyagarajan และ Mohamed Ali (2022) ได้มีการพัฒนาเครื่องมือชื่อว่า Ab.ai ซึ่งเป็นระบบปัญญาประดิษฐ์ที่ออกแบบมาเพื่อช่วยทำรายงานผลแอนติไบโอแกรม (antibiogram) หรือเชื้อแบคทีเรียตอบสนองต่อยาปฏิชีวนะ (antibiotics) อย่างไรบ้าง โดยปกติแล้วกระบวนการ antibiogram ต้องใช้เวลาและแรงงานมาก และยังเสี่ยงต่อการเกิดความผิดพลาดจากการวัดเส้นผ่านศูนย์กลางด้วยเจ้าหน้าที่ แต่ Ab.ai สามารถนำข้อมูลจากการทดสอบความไวต่อยาปฏิชีวนะ (Antimicrobial Susceptibility Testing; AST) มาประมวลผลและสรุปออกมาเป็นรายงานอัตโนมัติทำให้ได้ผลที่รวดเร็วและแม่นยำ การศึกษานี้ชี้ให้เห็นว่าการใช้ปัญญาประดิษฐ์สามารถลดภาระของบุคลากรทางการแพทย์ได้ (Rajasekar et al., 2022)

อย่างไรก็ตาม แม้ว่างานวิจัยนี้จะชี้ให้เห็นถึงศักยภาพของ Ab.ai ในการช่วยยกระดับความรวดเร็วและความแม่นยำของการรายงานผล antibiogram แต่ก็ยังมีข้อจำกัดบางประการที่ควรกล่าวถึงเพื่อสะท้อนภาพรวมของการประยุกต์ใช้จริงในห้องปฏิบัติการทางการแพทย์ 1.งานวิจัยใช้ข้อมูลภายถ่าย antibiogram จากเพียง 50 จาน ครอบคลุมเฉพาะเชื้อแบคทีเรียในกลุ่ม *Gram-positive cocci* (GPC) และ *Gram-negative bacilli* (GNB) บางสายพันธุ์ รวมถึงยาที่ใช้ทดสอบเพียงบางกลุ่มเท่านั้น ซึ่งอาจทำให้ผลการประเมินยังไม่ครอบคลุมความหลากหลายของรูปแบบการดื้อยา จำเป็นต้องมีการทดสอบเพิ่มเติมกับฐานข้อมูลที่ใหญ่และหลากหลายยิ่งขึ้นเพื่อเพิ่มความแม่นยำและความทั่วไปของโมเดล

นอกจากนี้ ภาพที่ใช้ในการพัฒนาระบบถูกถ่ายด้วยกล้องโทรศัพท์มือถือเพียงรุ่นเดียว (Redmi Note 8) ซึ่งยังไม่สามารถยืนยันได้ว่าผลลัพธ์ที่ได้จะมีความสอดคล้องหากเปลี่ยนไปใช้อุปกรณ์ถ่ายภาพรุ่นอื่นหรืออยู่ในสภาพแวดล้อมที่แตกต่างกัน อีกทั้งโมเดลปัญญาประดิษฐ์ของ Ab.ai ยังพบข้อจำกัดในการวัดเส้นผ่านศูนย์กลางของขนาดวงยับยั้ง (zone of inhibition) ในบางกรณีที่ขอบเขตของ zone of inhibition ไม่ชัดเจนหรือมีการเจริญของเชื้อรบกวนบริเวณขอบเขต ทำให้เกิดความคลาดเคลื่อนในการประเมินผล ดังนั้นการพัฒนาในอนาคตควรมุ่งเน้นที่การเพิ่มความยืดหยุ่นของโมเดลต่อความหลากหลายของเงื่อนไขภาพและการจัดการกับรูปแบบ zone of inhibition ที่ไม่สมบูรณ์เพื่อให้ระบบสามารถประยุกต์ใช้งานได้จริงอย่างมีประสิทธิภาพในห้องปฏิบัติการที่หลากหลายมากขึ้น

2.5.5 AI-driven identification and analysis of inhibition zones in disk diffusion tests with the hue contrast method.

Yu และคณะ (2025) ได้พัฒนาระบบอัตโนมัติสำหรับการตรวจวัดขนาดวงยับยั้ง (zone of inhibition) ในการทดสอบ Kirby–Bauer disk diffusion โดยใช้เทคนิคการประมวลผลภาพ (image processing) ได้แก่ hue contrast method และ Hough circle และการใช้โมเดลปัญญาประดิษฐ์ YOLOv7 ที่เป็นการตรวจจับวัตถุแบบ real-time ที่แม่นยำสำหรับวัตถุขนาดเล็ก ก่อนจะส่งเขาระบบ LINE chatbot เพื่อรายงานผล จากภาพ 2.7

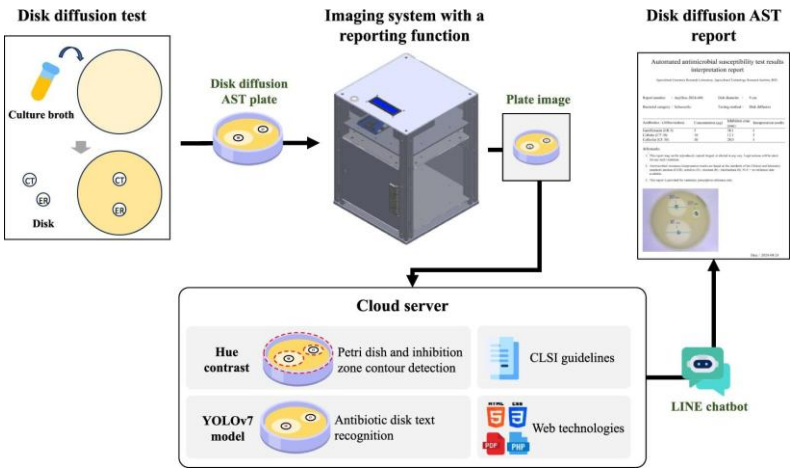

ภาพที่ 2.7 ภาพแสดงกระบวนการตรวจวัดขนาดวงยับยั้งส่งให้ LINE chatbot

ที่มา : (Yu et al., 2025)

ซึ่งงานวิจัยนี้มีเป้าหมายเพื่อลดความแปรปรวนที่เกิดจากการวัดผลด้วยมือ ผลการทดลองแสดงให้เห็นว่าโมเดลปัญญาประดิษฐ์สามารถจำแนก zone of inhibition ได้ด้วยความแม่นยำสูง (100% สำหรับ ceftiofur และ colistin และ 98% สำหรับ enrofloxacin) นอกจากนี้ยังเปรียบเทียบประสิทธิภาพระหว่าง hue contrast method เป็นการแปลงสีภาพแบบ RGB เป็นรูปแบบสี HSV ที่จะเป็นการแบ่งเป็นโทนสี (Hue; H), ความเข้มของสี (Saturation; S) และความสว่างของสี (Value; V) และ Hough circle method ที่เป็นวิธีแปลงภาพเป็นสีเทา (grayscale) ในการตรวจจับ zone of inhibition พบว่าวิธี hue contrast ให้ความแม่นยำมากกว่า (88% เทียบกับ 54–82%) อีกทั้งผลการวัดจากระบบอัตโนมัติมีความสอดคล้องกับการวัดด้วยมือ โดยมีค่าความแตกต่างเฉลี่ยของเส้นผ่านศูนย์กลางเพียงเล็กน้อย ทั้งใน *Salmonella enterica* และ *Escherichia coli* งานวิจัยดังกล่าวสะท้อนให้เห็นว่าการใช้เทคโนโลยี computer vision ร่วมกับระบบรายงานผลอัตโนมัติ เช่น LINE chatbot สามารถช่วยยกระดับความถูกต้องและความสม่ำเสมอในการแปลผลการทดสอบความไวต่อยาปฏิชีวนะ (Antimicrobial Susceptibility Testing : AST) (Yu et al., 2025)

อย่างไรก็ตาม งานวิจัยนี้ยังมีข้อจำกัดบางประการ ได้แก่ (1) การใช้งาน YOLOv7 ต้องการฮาร์ดแวร์ที่มีสมรรถนะสูง เช่น GPU ทำให้ยากต่อการประยุกต์ใช้ในห้องปฏิบัติการที่มีทรัพยากรจำกัด (2) แม้วิธี hue contrast จะมีความแม่นยำกว่าวิธี Hough circle แต่ยังมีข้อจำกัดในการตรวจจับโซนที่มีสภาพแสงหรือพื้นหลังไม่ สม่ำเสมอ ซึ่งอาจทำให้ค่าการวัดคลาดเคลื่อน (3) ระบบรายงานผลที่ผูกกับ LINE chatbot แม้จะสะดวก

แต่จำกัดการเข้าถึงเฉพาะผู้ใช้แพลตฟอร์มนี้ และ (4) ระบบไม่รองรับการประมวลผลภาพทีละจำนวนมาก (batch processing) และไม่สามารถส่งออกผลลัพธ์เป็นไฟล์เชิงมาตรฐาน เช่น XLSX ได้ ทำให้การนำข้อมูลไปใช้วิเคราะห์ต่อหรือเชื่อมโยงกับระบบสารสนเทศทางห้องปฏิบัติการ (LIS) ทำได้ยาก ซึ่งเป็นอุปสรรคต่อการนำไปประยุกต์ใช้จริงในระดับองค์กรหรือการวิจัยขนาดใหญ่

2.5.6 The role of artificial intelligence and machine learning in predicting and combating antimicrobial resistance

จากการศึกษาของ Bilal, H. และคณะ (2025) ศึกษาการพัฒนาเทคโนโลยีการทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing; AST) เพื่อวัดผลได้อย่างรวดเร็วและแม่นยำ ซึ่งมีความจำเป็นต่อการรักษาเชิงแม่นยำ (precision treatment) โดยพบว่าเทคโนโลยีปัญญาประดิษฐ์มีผลอย่างมากในการพัฒนาการทดสอบ AST จึงได้ศึกษาวิธีการต่างๆในการพัฒนาปัญญาประดิษฐ์ ได้แก่ machine learning และ deep learning โดยได้มีการใช้ข้อมูลรูปภาพการทดสอบเชื้อที่มีความไวต่อการดื้อยาจากการศึกษาทั่วโลก ได้แก่ European Antimicrobial Resistance Surveillance Network (EARS-Net) จากกลุ่มประเทศในยุโรป, National Antimicrobial Resistance Monitoring System (NARMS) จากสหรัฐอเมริกา และ Global Antimicrobial Resistance Surveillance System (GLASS) จากองค์กรอนามัยโลก ซึ่งเป็นแหล่งข้อมูลที่มีการศึกษาและรวบรวมข้อมูลภาวะการดื้อยาต้านจุลชีพ (Antimicrobial Resistance; AMR) ในปัจจุบันรวมถึงมีการแชร์ข้อมูลให้กัน โดยในงานวิจัยนี้มีการศึกษาโมเดลปัญญาประดิษฐ์ที่สามารถมาประยุกต์ใช้กับการตัดสินใจทางคลินิค (Clinical Decision Support Systems; CDSS) โดยเห็นจากภาพที่ 2.8 ในส่วน Convolutional Neural Networks (CNNs) ที่เหมาะกับกับการวิเคราะห์ข้อมูลทางการแพทย์ จากประโยชน์ดังกล่าวสามารถนำมาประยุกต์ใช้ในการจับภาพกับการวัด AST ได้ (Bilal, H. et al., 2025)

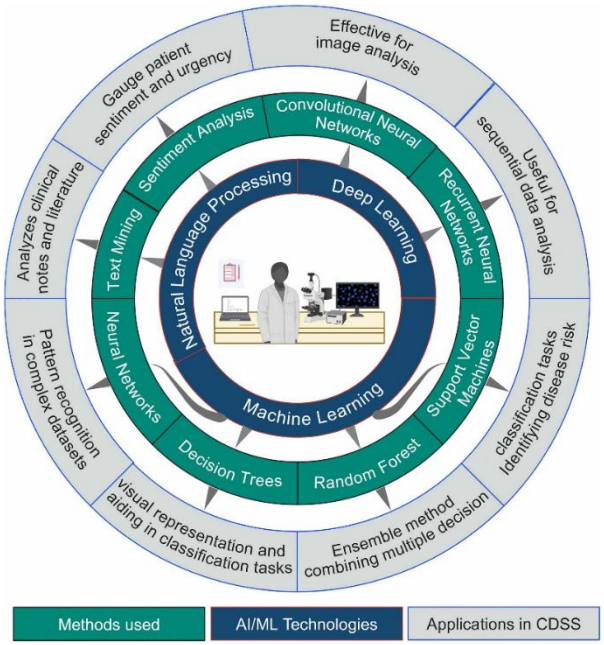

ภาพที่ 2.8 การนำปัญญาประดิษฐ์ประยุกต์ใช้กับ CDSS

ที่มา : (Bilal, H. et al., 2025)

แต่คณะวิจัยก็มีข้อจำกัดในกระบวนการวิจัยจากหลายปัจจัย โดยจะเห็นได้จากคุณภาพของข้อมูลที่นำมาฝึกสอนจากการที่ข้อมูลมีความไม่สมดุลกันเนื่องข้อมูลที่นำมามีการเก็บข้อมูลที่ต่างที่กันหรือจำนวนที่เก็บที่มีจำนวนไม่เท่ากัน รวมถึงอาจจะเกิดข้อกังขาจากข้อมูลที่นำมาจากคนละที่กัน ซึ่งจากกระบวนการดังกล่าวก็อาจจะส่งให้ผลที่ได้มีความไม่มีความน่าเชื่อถือ การที่ข้อมูลที่นำมาใช้มีแค่ภายในประเทศอาจจะทำให้มีผลที่ผิดพลาดกันได้ถ้านำไปใช้กับประเทศอื่นและการขาดด้านอุปกรณ์ที่จำเป็นในการเก็บข้อมูลหรือต้องการใช้ทรัพยากรเป็นจำนวนมากในการสอนปัญญาประดิษฐ์เพื่อเรียนรู้เป็นจำนวนมาก ถ้าเกิดมีทรัพยากรที่มีประสิทธิภาพสูงจะสามารถทำให้มีผลการทดสอบได้ดีมากขึ้น

2.5.7 Advancements in AI-driven drug sensitivity testing research

จากการวิจัยของ Liao, H. และคณะ (2025) ได้ศึกษาการดื้อยาต้านจุลชีพ (Antimicrobial Resistance; AMR) ด้วยการใช้ปัญญาประดิษฐ์ซึ่งปัจจัยที่ทำให้เกิดการวิจัยนี้เกิดจากพบว่าแพทย์มักใช้ยาปฏิชีวนะเชิงประสบการณ์ (Empirical Antibiotic Therapy) โดยยังไม่ได้ทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing; AST) นอกจากนั้นยังสั่งยาปฏิชีวนะโดยไม่จำเป็นหรือการสั่งยาโดยไม่จำเป็นจาก

แหล่งข้อมูลการทดสอบ AMR จาก European Antimicrobial Resistance Surveillance Network (EARS-Net) ที่รวบรวมจากกลุ่มประเทศในยุโรป และการขาดอุปกรณ์ในการพัฒนาการศึกษาดื้อยาต้านจุลชีพที่ไม่เพียงพอจะรับมือกับเชื้อดื้อยาใหม่ๆในอนาคต ซึ่งการดื้อยาสามารถพบได้จาก 2 ปัจจัย คือ การดื้อยาโดยกำเนิด (Intrinsic Resistance) และการดื้อยาที่เกิดภายหลัง (Acquired Resistance) และในการทดสอบ AST หลายวิธี ซึ่งคณะวิจัยพบว่ามี 5 วิธี ได้แก่ Kirby-Bauer Disk Diffusion, Broth Dilution, E-test, Automated AST และ Molecular methods (Liao, H. et al., 2025)

2.5.8 YOLOV11: Comparative performance of YOLOv8, YOLOV9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species

จากงานวิจัยของ Sharma และคณะ ได้ศึกษาในการประเมินประสิทธิภาพเชิงเปรียบเทียบของโมเดลการตรวจจับวัตถุยุคใหม่ในตระกูล YOLO (You Only Look Once) หลายเวอร์ชัน ได้แก่ YOLOv8, YOLOv9, YOLOv10, YOLOv11 และโมเดล Faster R-CNN ซึ่งเป็นฐานสำคัญในการพัฒนากลยุทธ์การจัดการวัชพืชแบบจำเพาะเจาะจงชนิดและพื้นที่ (SSSWM) โดยการใช้เทคโนโลยี machine learning ขั้นสูง เนื่องจากวัชพืชที่ดื้อยาฆ่าแมลงทวีความรุนแรงขึ้น งานวิจัยนี้จึงได้รวบรวมและสร้างชุดข้อมูลภาพถ่ายวัชพืช 5 ชนิด ได้แก่ Cocklebur, Dandelion, Common Waterhemp, Palmer Amaranth, และ Common Lambsquarters เพื่อใช้ในการฝึกสอนและทดสอบโมเดล จากผลการทดสอบเชิงประสิทธิภาพ พบว่า YOLOv9 ให้ผลลัพธ์ด้านความแม่นยำสูงสุด โดยมีค่า mAP@0.5 (Mean Average Precision) อยู่ที่ 0.935 ในขณะที่โมเดลตระกูล YOLO แสดงให้เห็นถึงความได้เปรียบอย่างชัดเจนในด้านความเร็วในการประมวลผล (Inference Time) โดยเฉพาะ YOLOv11 ที่มีความเร็วสูงที่สุดที่ 13.5 มิลลิวินาที (ms) ต่อภาพ ซึ่งเร็วกว่า Faster R-CNN (63.8 ms) อย่างมาก ผลสรุปนี้ชี้ให้เห็นว่า โมเดลตระกูล YOLO โดยเฉพาะ YOLOv8 และ YOLOv11 ซึ่งมีความสมดุลระหว่างความแม่นยำและความเร็วสูง ซึ่งสามารถดูผลลัพธ์ทั้งหมดในการเปรียบเทียบกับโมเดลอื่นๆได้จากภาพที่ 2.9 (Sharma et al., 2024)

Model	**mAP@0.5** (Train)	mAP@0.5 (Test)	mAP@0.5–0.95 (Test)	Inference Time (Test - ms)	Precision (Test)	Recall (Test)
YOLOv11	0.914	0.921	0.621	13.5	0.894	0.854
YOLOv10	0.899	0.872	0.591	19.3	0.889	0.804
YOLOv9	0.926	0.935	0.650	54.2	0.894	0.893
YOLOv8	0.921	0.925	0.650	23	0.860	0.858
Faster RCNN	0.889	0.865	0.615	63.8	0.901	0/825

ภาพที่ 2.9 ภาพการเปรียบเทียบประสิทธิภาพ

โมเดล YOLOv11, YOLOv10, YOLOv9, YOLOv8 และ Faster RCNN

ที่มา : (Sharma et al., 2024)

2.6 สรุปจากการทบทวนงานวิจัยที่เกี่ยวข้อง

จากการสืบค้นงานวิจัยที่ผ่านมา พบว่ามีความพยายามนำเทคโนโลยีปัญญาประดิษฐ์และการประมวลผลภาพเข้ามาช่วยในกระบวนการทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing : AST) ไม่ว่าจะเป็นการตรวจวัดขนาดวงยับยั้งด้วย hue contrast method, การใช้โมเดล deep learning เช่น YOLOv11 หรือ Faster R-CNN, การพัฒนาเครื่องมืออัตโนมัติอย่าง Ab.ai และการสร้างแอปพลิเคชันบนอุปกรณ์พกพา อย่างไรก็ตาม งานวิจัยเหล่านี้ยังมีข้อจำกัดหลายประการ เช่น

1. ความต้องการใช้ฮาร์ดแวร์ที่มีสมรรถนะสูงทำให้ไม่สามารถนำไปใช้ได้ในห้องปฏิบัติการทั่วไปที่มีทรัพยากรจำกัด
2. ปัญหาด้านคุณภาพข้อมูล ทั้งในเชิงปริมาณหรือจำนวนข้อมูลไม่เพียงพอและเชิงคุณภาพที่มีความแตกต่างของสภาพแสง, กล้องถ่ายภาพ หรือความไม่สมดุลของชุดข้อมูล
3. ความจำกัดในการรองรับความหลากหลายของเชื้อและยาต้านจุลชีพ ทำให้โมเดลที่พัฒนาแล้วไม่สามารถครอบคลุมการใช้งานจริงได้อย่างกว้างขวาง
4. โมเดลที่ใช้มีโอกาสเสี่ยงต่อการเกิด overfitting จากการที่โมเดลถูกฝึกด้วยข้อมูลที่มีจำนวนน้อยหรือไม่หลากหลาย ทำให้ทำนายได้ดีเฉพาะกับชุดข้อมูลที่ใกล้เคียงกับที่ใช้ฝึก

จากช่องว่างเหล่านี้สะท้อนให้เห็นว่า แม้งานวิจัยที่ผ่านมาจะช่วยยกระดับความแม่นยำและความรวดเร็วของการทดสอบ AST แต่ยังมีประเด็นที่ต้องพัฒนาต่อ ทั้งด้าน การจัดการข้อมูล, ความยืดหยุ่นของโมเดล,

การลดข้อจำกัดด้านทรัพยากร และการบูรณาการเข้ากับระบบสารสนเทศทางห้องปฏิบัติการ เพื่อให้สามารถนำไปใช้ได้จริงในระดับองค์กรและสนับสนุนการวิจัยขนาดใหญ่ ดังนั้นงานวิจัยของเราจึงมุ่งพัฒนาระบบที่ตอบโจทย์ข้อจำกัดเหล่านี้ โดยเน้นการสร้างโมเดลที่ มีความแม่นยำสูง ใช้งานได้กับทรัพยากรจำกัด รองรับการประมวลผลข้อมูลจำนวนมาก และสามารถเชื่อมโยงกับระบบข้อมูลมาตรฐาน ซึ่งจะช่วยลดความแปรปรวนจากการวัดด้วยมือ ยกระดับความถูกต้องของการวิเคราะห์ และเพิ่มประสิทธิภาพในการจัดการปัญหาการดื้อยาต้านจุลชีพในทางปฏิบัติจริง ซึ่งเห็นได้กังตาราง 2.1 ต่อไปนี้

ตารางที่ 2.1 ตารางเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

ผู้วิจัย/ปี	**วัตถุประสงค์**	**วิธีการ/เทคนิค**	**ข้อมูลที่ใช้ทดสอบ**	**ผลลัพธ์/ข้อค้นพบ**	**ข้อจำกัด**
Ayala-Ramirez et al., 2014	เปรียบเทียบโมเดล 3 ตัว ได้แก่ GA, IRHT และ LA ในการโมเดลที่จับวงกลมในรูปภาพได้ดีที่สุด	ใช้โมเดล Reinforcement learning ที่ศึกษา ได้แก่ LA ในการเทียบกับโมเดล GA และ IRHT	รูปภาพงกลม ที่มีคามแตกต่างกัน 6 ลักณะ	โมเดล LA ให้ความเร็วที่สูงที่สุดที่, Success rate 100% และมี Error rate ที่ 0.22	ต้องใช้การสุ่มซ้ำหลายครั้งในการหาวงกลลม และมี LA มีอัลโกลิทิมที่ซับซ้อน
Ercan et al., 2020	เปียบเทียบ image processing กับโมเดลในการจับภาพวงกลมใต้น้ำ	Faster R-CNN เทียบกับ SSD, Hough Transform	ภาพจาก ImageNet และ ภาพใต้น้ำ	Faster R-CNN ให้ผลลัพธ์ดีที่สุด ความแม่นยำในการตรวจจับวัตถุ ในสภาพที่ซับซ้อนสูงกว่า SSD และ Hough Transform อย่างชัดเจน	เปรียบเทียบแค่ Deep Learning (Faster R CNN, SSD) กับ Image Processing (Hough Transform) ไม่มีการทดอบโมเดล reinforcement learning เช่น LA ที่เคย ใช้ตรจจับงกลมมา ก่อน
Pascucci et al., 2021	พัฒนาแอปพลิเคชันบนสมาร์ตโฟน สำหรับ Antibiotic Susceptibility Testing; AST แบบ disk diffusion	Classification models, Diameter measurement algorithm และ Expert System	ภาพ Kirby-Bauer disk diffusion	ความถูกต้องของขนาด clear zone >90% ลดเวลาในการแปลผล	ข้อมูล train น้อย เสี่ยง overfitting และยังต้องการตรวจสอบจากมนุษย์ภายหลัง
Rajasekar et al., 2022	ใช้ทำรายงานแอนติไบโอแกรม (antibiogram) อัตโนมัติ	ใช้โมเดลปัญญาประดิษฐ์ที่คิดค้นขึ้นชื่อ Ab.ai	ใช้ข้อมูลภาพถ่าย antibiogram 50 จาน	ลดภาระการทำงานของบุคลากร, สามารถสรุปผลได้รวดเร็ว และมีความแม่นยำเกือบเ	ข้อมูลจำกัด, ใช้กล้องรุ่นเดียวทดสอบ, พบข้อผิดพลาดในการวัด zone of inhibtion

				ทียบเท่าผู้เชี่ยวชาญจุลชีววิทยา	
Sharma et al., 2024	เปรียบเทียบโมเดล 5 โมเดลเพื่อแยกวัชพืชแบบจำเพาะเจาะจงชนิดและพื้นที่ (SSSWM)	Yolov11, Yolov10, Yolov9, Yolov8 และ Faster R-CNN เปรียบเทียบกัย	ภาพถ่ายวัชพืช	YOLOv11 มีความเร็วสูงที่สุดที่ 13.5 มิลลิวินาที (ms) ต่อภาพ ซึ่งเร็วกว่า Faster R-CNN (63.8 ms) อย่างมาก	ไม่มีการเปรียบเทียบกับโมเดลพื้นฐาน
Yu et al., 2025	พัฒนา LINE Chatbot อัตโนมัติสำหรับตรวจวัดขนาดวงยับยั้ง (zone of inhibition) ในการทดสอบ Kirby–Bauer disk diffusion	Hue contrast method, Hough circle method และ YOLOv7	ภาพแผ่น disk diffusion ที่มีเชื้อ Salmonella enterica และ Escherichia coli ที่ทดสอบกับยาปฏิชีวนะ ceftiofur, colistin, enrofloxacin	โมเดล AI สามารถจำแนก zone of inhibition ได้แม่นยำสูง 100% สำหรับ ceftiofur และ colistin 98% สำหรับ enrofloxacin	YOLOv7 ต้องการฮาร์ดแวร์ประสิทธิภาพสูง , ไม่รองรับ batch processing และไม่สามารถส่งออกผลลัพธ์เป็นไฟล์เชิงมาตรฐาน (เช่น XLSX)
Bilal et al., 2025	ศึกษา AI/ML ในการพัฒนาให้เข้ากับการใช้งานเกี่ยวกับ AMR	Machine learning และ Deep learning	ข้อมูล AMR จาก EARS-Net, NARMS และ GLASS	พบว่า AI ช่วยเพิ่มความแม่นยำในการหา AST และสามารถช่วยตัดสินใจทางคลินิกได้	ข้อมูลที่ทดสอบมาจากหลายแหล่งอาจทำให้ข้อมูลไม่สมดุลได้และต้องใช้ทรัพยากรที่มากในการทดสอบ
Liao et al., 2025	ศึกษาการดื้อยาต้านจุลชีพ (Antimicrobial Resistance; AMR) ด้วยการใช้ AI	Random Forest, Gradient Boosting, Support Vector Machine (SVM)	AMR surveillance data จาก EARS-Net	AI ช่วยทำให้การตรวจ AST ได้เร็วและแม่นยำมากยิ่งขึ้น	โมเดลต้องการ ข้อมูลจำนวนมากและคุณภาพสูง เพื่อให้ผลแม่นยำ และไม่สามารถใช้งานได้บนสมาร์ทโฟน

บทที่ 3

วิธีการดำเนินงาน

3.1 รายละเอียดโครงงาน

3.1.1 ความต้องการของระบบ (System Requirements)

เพื่อให้ระบบสามารถทำงานได้อย่างมีประสิทธิภาพและตอบสนองต่อความต้องการของผู้ใช้งาน คณะผู้จัดทำได้กำหนดความต้องการของระบบแบ่งออกเป็น 3 ด้าน ดังนี้

1. ความต้องการด้านฮาร์ดแวร์ (Hardware Requirements)

1.1 ฝั่งผู้ใช้งาน (Client Side)

- เครื่องคอมพิวเตอร์ (PC/Laptop) หรืออุปกรณ์เคลื่อนที่ (Smartphone/Tablet)
- กล้องถ่ายรูป (ในกรณีใช้งานผ่านมือถือหรือเว็บแคม) ความละเอียดไม่น้อยกว่า 5 ล้านพิกเซล เพื่อความคมชัดของภาพจานเพาะเชื้อ

1.2 ฝั่งเซิร์ฟเวอร์ (Server Side)

- หน่วยประมวลผลกลาง (CPU) ที่รองรับการทำงานแบบ Multi-thread
- หน่วยความจำ (RAM) ไม่น้อยกว่า 8 GB เพื่อรองรับการประมวลผลภาพ
- พื้นที่จัดเก็บข้อมูล (Storage) 1 TB

2. ความต้องการด้านซอฟต์แวร์ (Software Requirements)

- ระบบปฏิบัติการ: รองรับ Windows, macOS, iOS และ Android
- เว็บเบราว์เซอร์: Google Chrome, Microsoft Edge, Safari หรือ Firefox เวอร์ชันปัจจุบัน
- ภาษาที่ใช้พัฒนา: TypeScript (React Framework) สำหรับส่วนติดต่อผู้ใช้งาน และ Python สำหรับโมเดลปัญญาประดิษฐ์
- ระบบจัดการฐานข้อมูล: PostgreSQL

3. ความต้องการด้านฟังก์ชันการทำงาน (Functional Requirements)

- ระบบต้องสามารถสมัครสมาชิกและเข้าสู่ระบบเพื่อยืนยันตัวตนได้

- ระบบต้องสามารถนำเข้าภาพถ่ายจานเพาะเชื้อได้ทั้งแบบอัปโหลดไฟล์และถ่ายภาพผ่านกล้อง
- ระบบต้องสามารถตรวจจับตำแหน่งและวัดขนาดของวงยับยั้ง (Inhibition Zone) ได้อัตโนมัติ
- ระบบต้องสามารถแปลผลความไวต่อยา (S/I/R) ตามมาตรฐาน CLSI และ EUCAST ได้
- ระบบต้องสามารถบันทึกประวัติการวิเคราะห์และส่งออกรายงานในรูปแบบไฟล์ Excel ได้

3.1.2 แผนภาพยูสเคส (Use Case Diagram)

3.1.2.1 ผู้ใช้งานทั่วไป (User)

คือ บุคลากรทางการแพทย์หรือเจ้าหน้าที่ห้องปฏิบัติการ ซึ่งเป็นกลุ่มผู้ใช้งานหลักของระบบมีกรณีการใช้งาน (Use Case) จากภาพที่ 3.1 ที่สำคัญได้แก่

1. การจัดการบัญชีผู้ใช้: สมัครสมาชิก, เข้าสู่ระบบ, แก้ไขข้อมูลส่วนตัว และกู้คืนรหัสผ่าน
2. การวิเคราะห์ผล: อัปโหลดภาพถ่ายจานเพาะเชื้อ, ถ่ายภาพผ่านกล้อง, ระบุข้อมูลเชื้อและยา และสั่งประมวลผลภาพ
3. การจัดการผลลัพธ์และประวัติ: ดูผลการวิเคราะห์, ดูประวัติการใช้งานย้อนหลัง, และดาวน์โหลดรายงานผลในรูปแบบไฟล์

3.1.2.2 ผู้ดูแลระบบ (Admin)

คือ ผู้ที่มีหน้าที่ดูแลรักษาความเรียบร้อยของระบบและจัดการข้อมูลพื้นฐาน มีกรณีการใช้งาน (Use Case) เพิ่มเติมจากภาพที่ 3.1 ได้แก่

1. การจัดการสมาชิก: ดูรายชื่อผู้ใช้งานทั้งหมดในระบบ, ตรวจสอบสถานะการใช้งาน, และจัดการสิทธิ์การเข้าถึง
2. การจัดการข้อมูลมาตรฐาน: เพิ่ม ลบ หรือแก้ไขฐานข้อมูลรายชื่อยาปฏิชีวนะ, รายชื่อเชื้อแบคทีเรีย และเกณฑ์การแปลผล ตามมาตรฐาน CLSI และ EUCAST เพื่อให้ระบบมีความทันสมัยอยู่เสมอ

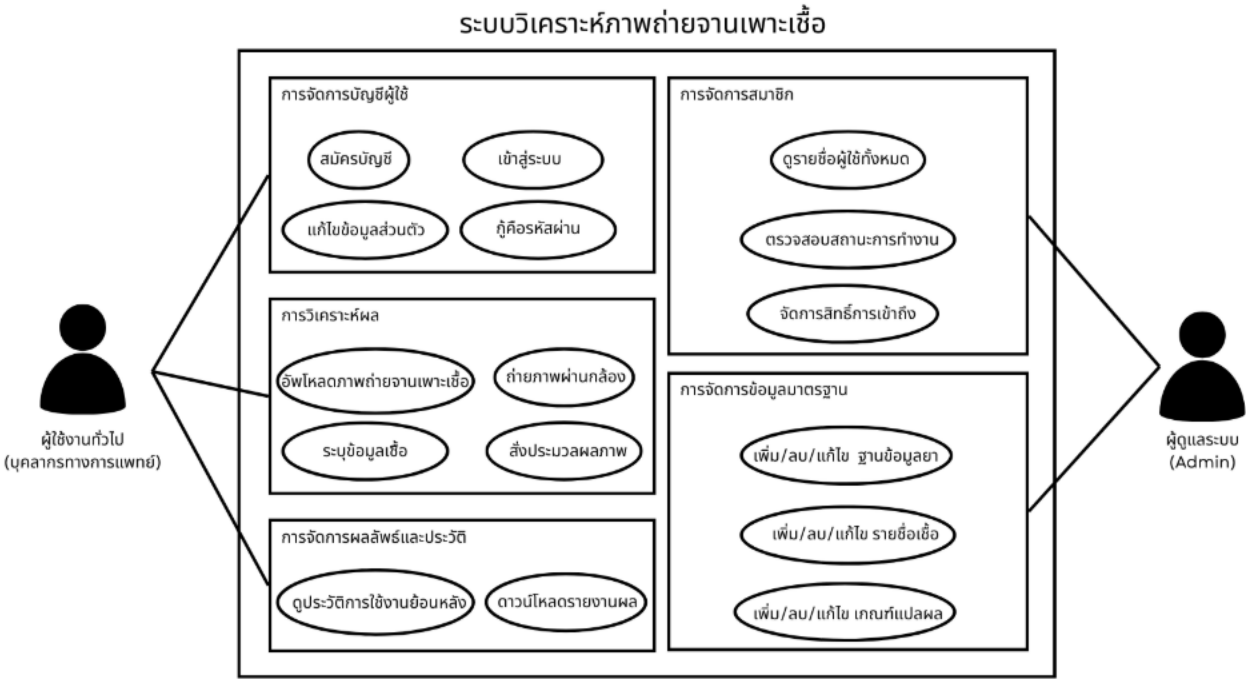

ภาพที่ 3.1 ภาพ Use Case Diagram

3.1.3 คำอธิบายยูสเคส (Use Case Narrative)

ตัวอย่างคำอธิบายขั้นตอนการทำงานของ Use Case หลัก "การวิเคราะห์ผลทดสอบ (Analyze AST)" มีดังนี้

- ชื่อ Use Case: การวิเคราะห์ผลทดสอบความไวต่อยา (Analyze AST)
- ผู้กระทำ (Actor): ผู้ใช้งานทั่วไป (User)
- เงื่อนไขเริ่มต้น (Pre-condition): ผู้ใช้งานต้องเข้าสู่ระบบ (Login) เรียบร้อยแล้ว
- Basic Flow :

1. ผู้ใช้งานเลือกเมนู "วิเคราะห์ภาพ" จากหน้า Dashboard
2. ผู้ใช้งานทำการอัปโหลดไฟล์ภาพ หรือกดปุ่มถ่ายภาพผ่านกล้อง
3. ระบบแสดงรายการภาพที่นำเข้า และให้ผู้ใช้งานเลือกชนิดของเชื้อแบคทีเรีย (Bacteria Strain)
4. ผู้ใช้งานกดปุ่ม "เริ่มการวิเคราะห์" (Analyze)

5. ระบบทำการส่งภาพไปประมวลผลด้วยโมเดล AI
และคำนวณค่าเทียบกับฐานข้อมูลมาตรฐาน
6. ระบบแสดงผลลัพธ์เป็นภาพที่ระบุตำแหน่งวงยับยั้งและตารางสรุปผล

- เงื่อนไขสิ้นสุด (Post-condition): ข้อมูลผลการวิเคราะห์ถูกบันทึกลงในฐานข้อมูลประวัติ

3.1.4 แผนภาพกิจกรรม (Workflow)

ลำดับการทำงานของระบบ (System Workflow) จากภาพที่ 3.2 เริ่มต้นจาก

1. Login/Register: ผู้ใช้งานเข้าสู่ระบบ
2. Dashboard: เข้าสู่หน้าหลัก เลือกโหมดการทำงาน (ภาพเดียว/หลายภาพ)
3. Input: นำเข้าภาพจานเพาะเชื้อ (File Upload / Camera Capture)
4. Settings: ระบุข้อมูลประกอบ (ชื่อเชื้อ)
5. Processing: ระบบประมวลผลภาพ (Detection & Measurement)
6. Interpretation: ระบบแปลผลตามเกณฑ์มาตรฐาน (CLSI/EUCAST)
7. Output: แสดงผลลัพธ์และกราฟิกบนภาพ
8. Action: ผู้ใช้เลือกบันทึกผล หรือดาวน์โหลดรายงาน

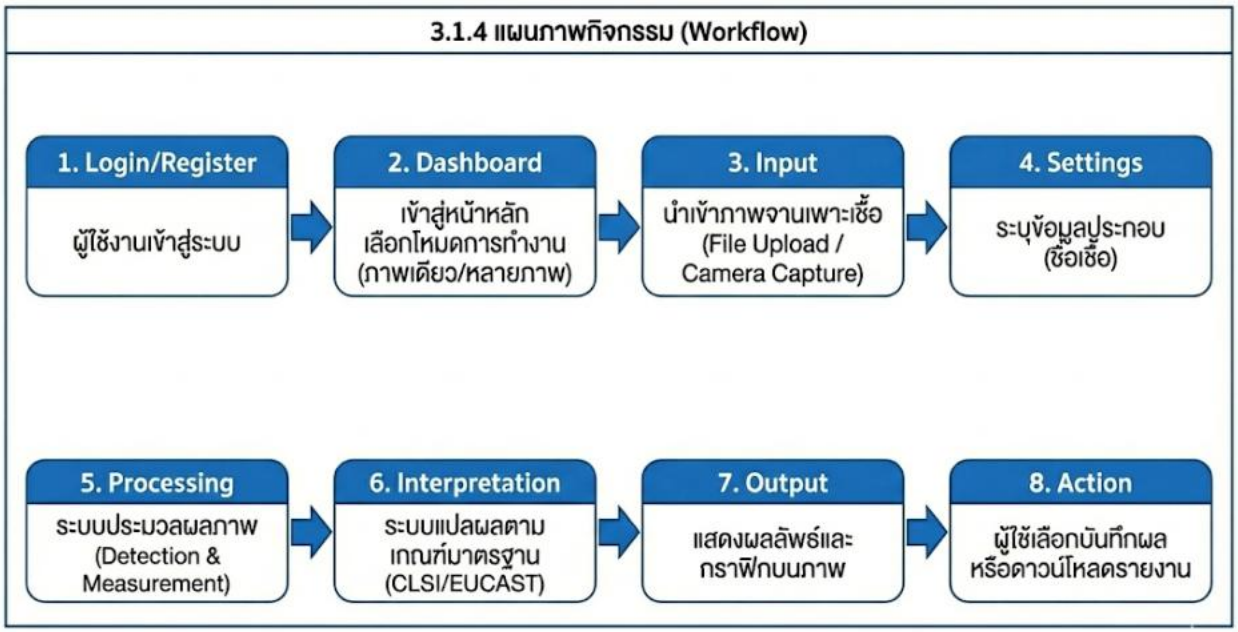

ภาพที่ 3.2 ภาพ Workflow

3.1.5 สถาปัตยกรรมระบบ (System Architecture)

ระบบถูกออกแบบด้วยสถาปัตยกรรมแบบ Web Application Architecture โดยแบ่งส่วนประกอบหลักออกเป็น 3 ส่วน โดยสามารถเห็นได้ดังภาพที่ 3.3 และมีรายละเอียดดังนี้

1. **ส่วนติดต่อผู้ใช้งาน (Frontend / Client Side):**
   - ทำหน้าที่เป็นส่วนติดต่อกับผู้ใช้งาน (User Interface) รับคำสั่งและแสดงผลลัพธ์
   - พัฒนาด้วย React (ร่วมกับ Vite และ TypeScript) เพื่อประสิทธิภาพและความรวดเร็ว
   - ตกแต่งและจัดรูปแบบหน้าจอด้วย Tailwind CSS และ Shadcn UI เพื่อความสวยงามและรองรับการใช้งานบนอุปกรณ์ต่าง ๆ (Responsive Design)
2. **ส่วนประมวลผลและบริการข้อมูล (Backend & AI Engine):**
   - พัฒนาด้วยภาษา Python โดยใช้เฟรมเวิร์ก FastAPI ทำหน้าที่เป็นเว็บเซิร์ฟเวอร์ (Web Server) และ API Gateway ในการเชื่อมต่อและรับส่งข้อมูลระหว่างส่วนหน้า (Frontend) กับส่วนประมวลผล AI ให้ทำงานร่วมกันได้อย่างราบรื่นและรวดเร็ว
   - ใช้ไลบรารี OpenCV สำหรับการประมวลผลภาพเบื้องต้น (Image Preprocessing) เช่น การปรับสีและลดสัญญาณรบกวน
   - ใช้โมเดลปัญญาประดิษฐ์สำหรับการตรวจจับวัตถุ (Object Detection) เพื่อระบุตำแหน่งและขอบเขตของวงยับยั้ง (Inhibition Zone)
3. **ส่วนจัดเก็บข้อมูล (Database):**
   - ใช้ PostgreSQL เป็นระบบฐานข้อมูลเชิงสัมพันธ์ (Relational Database)
   - ทำหน้าที่จัดเก็บข้อมูลบัญชีผู้ใช้งาน (Users), ประวัติการวิเคราะห์ (Analysis History) และข้อมูลอ้างอิงมาตรฐานยาและเชื้อ (Standard Reference Data) เพื่อใช้ในการแปลผลและเรียกดูย้อนหลัง

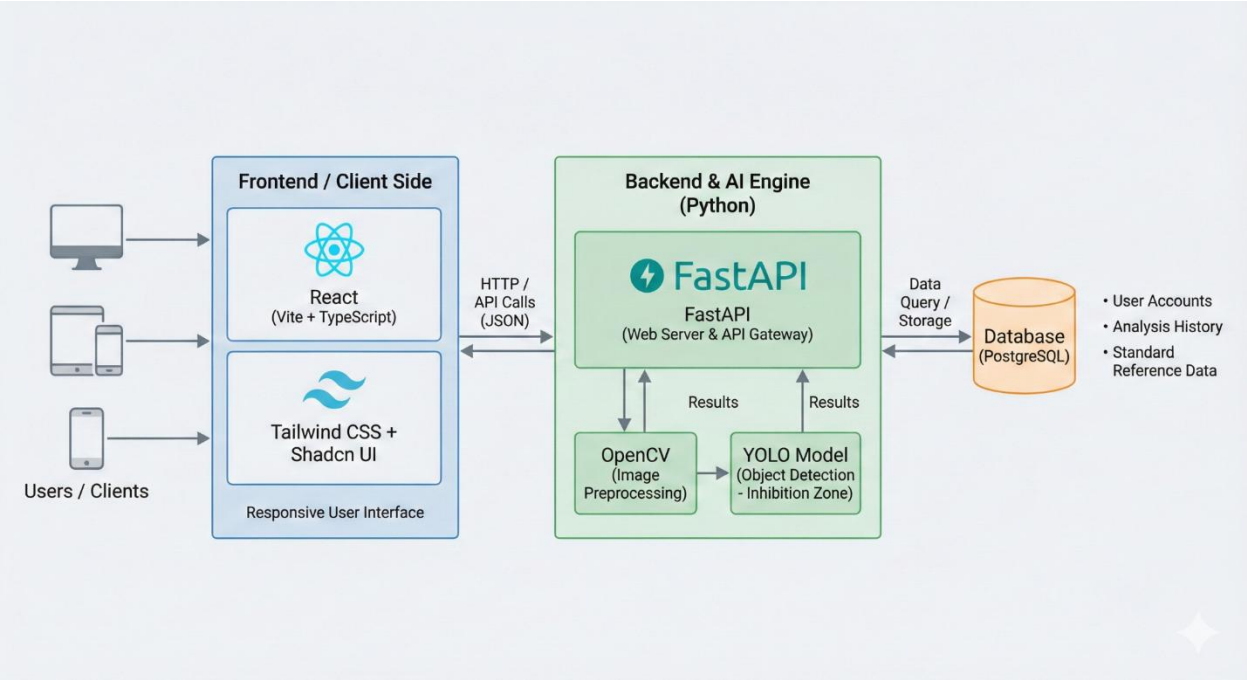

ภาพที่ 3.3 ภาพ System Arcritecture

3.2 แผนภาพแนวคิด (Conceptual Diagram)

กระบวนการประมวลผลหลักของระบบ (Core Processing Pipeline) ในภาพที่ 3.4 และมีรายละเอียดขั้นตอนดังนี้

1. Image Acquisition: รับภาพถ่ายจานเพาะเชื้อ
2. Preprocessing: ปรับภาพเป็น Grayscale และลดสัญญาณรบกวน (Noise Reduction)
3. Disk Detection: ใช้โมเดลตรวจจับแผ่นยามาตรฐาน (6 mm) เพื่อคำนวณอัตราส่วนพิกเซลต่อมิลลิเมตร (Calibration)
4. Zone Detection: ใช้โมเดลตรวจจับขอบเขตวงยับยั้ง (Inhibition Zone)
5. Measurement: วัดขนาดเส้นผ่านศูนย์กลางของวงยับยั้งและแปลงเป็นหน่วยมิลลิเมต
6. Interpretation: นำค่าที่วัดได้ไปเทียบกับฐานข้อมูล Breakpoints (CLSI/EUCAST)
7. Reporting: สรุปผลเป็น S/I/R และสร้างรายงาน

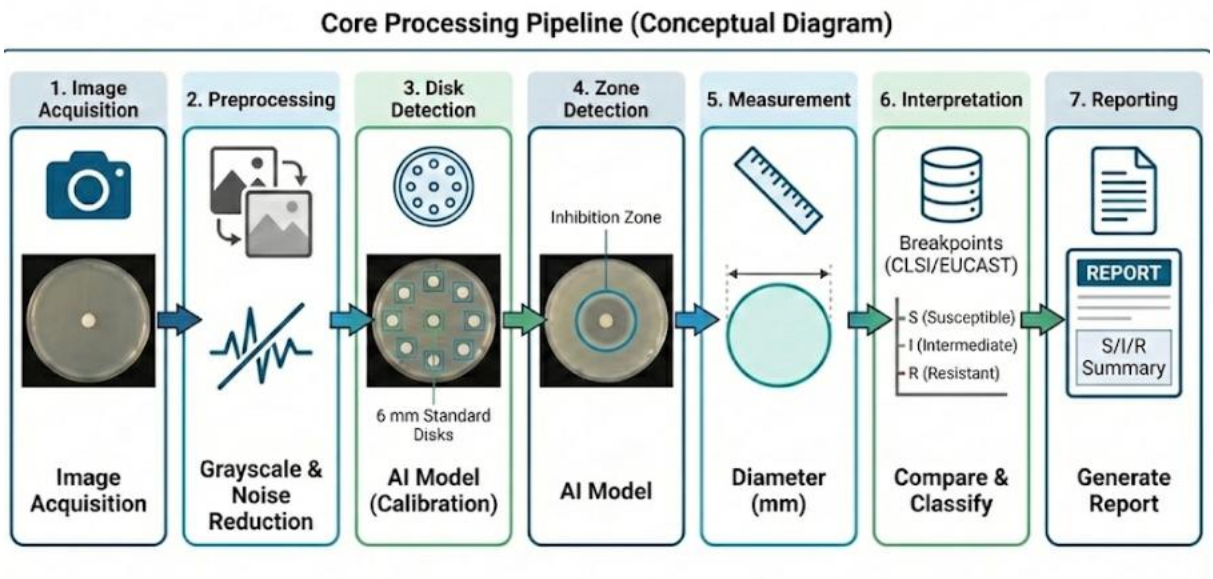

ภาพที่ 3.4 ภาพ Conceptual Diagram

3.3 การออกแบบฐานข้อมูล (Database Design)

3.3.1 แผนภาพความสัมพันธ์ของข้อมูล (ER Diagram)

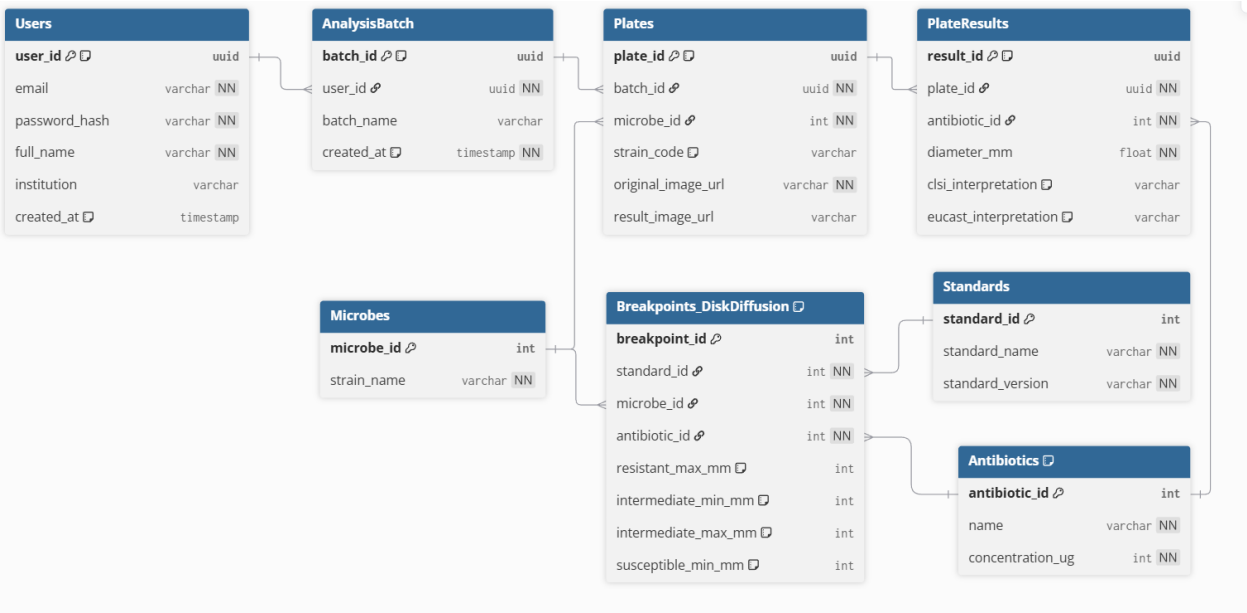

ภาพที่ 3.5 ภาพ ER Diagram

3.3.2 โครงสร้างฐานข้อมูล

จากภาพที่ 3.5 ที่เป็นภาพการออกแบบฐานข้อมูลที่ใช้รองรับการเก็บข้อมูล 2 ส่วนหลัก ได้แก่

1. ส่วนข้อมูลการวิเคราะห์ (Analysis Data)

- ตาราง Users: เก็บข้อมูลบัญชีผู้ใช้ รหัสผ่าน และข้อมูลหน่วยงาน
- ตาราง AnalysisBatch: เก็บข้อมูลรอบการวิเคราะห์เพื่อใช้จัดการกลุ่มของภาพและนโยบายการลบข้อมูลตามเวลา
- ตาราง Plates: เก็บข้อมูลภาพถ่ายแต่ละใบ เชื่อมโยงกับผู้ใช้และชนิดเชื้อ
- ตาราง PlateResults: เก็บผลการวัด (mm) และผลการแปล (S/I/R) ของยาแต่ละตัวในจาน

2. ส่วนข้อมูลมาตรฐาน (Reference Data)

- ตาราง Standards: เก็บเวอร์ชันของมาตรฐาน (CLSI, EUCAST)
- ตาราง Antibiotics & Microbes: เก็บรายชื่อยาและเชื้อมาตรฐาน
- ตาราง Breakpoints: เก็บเกณฑ์การแปลผล (จุดตัด) สำหรับจับคู่เชื้อกับยาตามมาตรฐานที่มีการกำหนดไว้

3.4. รายละเอียดแต่ละหน้าเว็บ

ระบบ Web Application ประกอบด้วยหน้าจอหลักที่ได้รับการออกแบบตามหลักการ User Experience (UX) ที่ดี ดังนี้

1. หน้าแรก (Home Page)

- เป็นหน้า Landing Page สำหรับต้อนรับผู้ใช้งานและประชาสัมพันธ์ระบบ
- ส่วนนำ (Hero Section): แสดงชื่อระบบ "ZoneAnalyzer" โลโก้ และคำอธิบายสั้นๆ พร้อมปุ่ม Call-to-Action (เข้าสู่ระบบ/สมัครสมาชิก) ที่โดดเด่น
- ส่วนคุณสมบัติ (Features): แสดงจุดเด่นของระบบ ได้แก่ การวิเคราะห์รวดเร็วด้วย AI, ความแม่นยำสูงตามมาตรฐานสากล, และฟังก์ชันครบวงจร (ตรวจจับ-วัด-แปลผล)
- ส่วนวิธีการใช้งาน (How It Works): อธิบายขั้นตอนการทำงาน 4 ขั้นตอนง่ายๆ (อัปโหลด

-> เลือกมาตรฐาน -> วิเคราะห์ -> ดูผลลัพธ์) เพื่อให้ผู้ใช้เข้าใจภาพรวมก่อนใช้งานจริง

- ส่วนเกี่ยวกับทีมพัฒนา (About): แสดงข้อมูลเกี่ยวกับโครงงานและคณะผู้จัดทำ

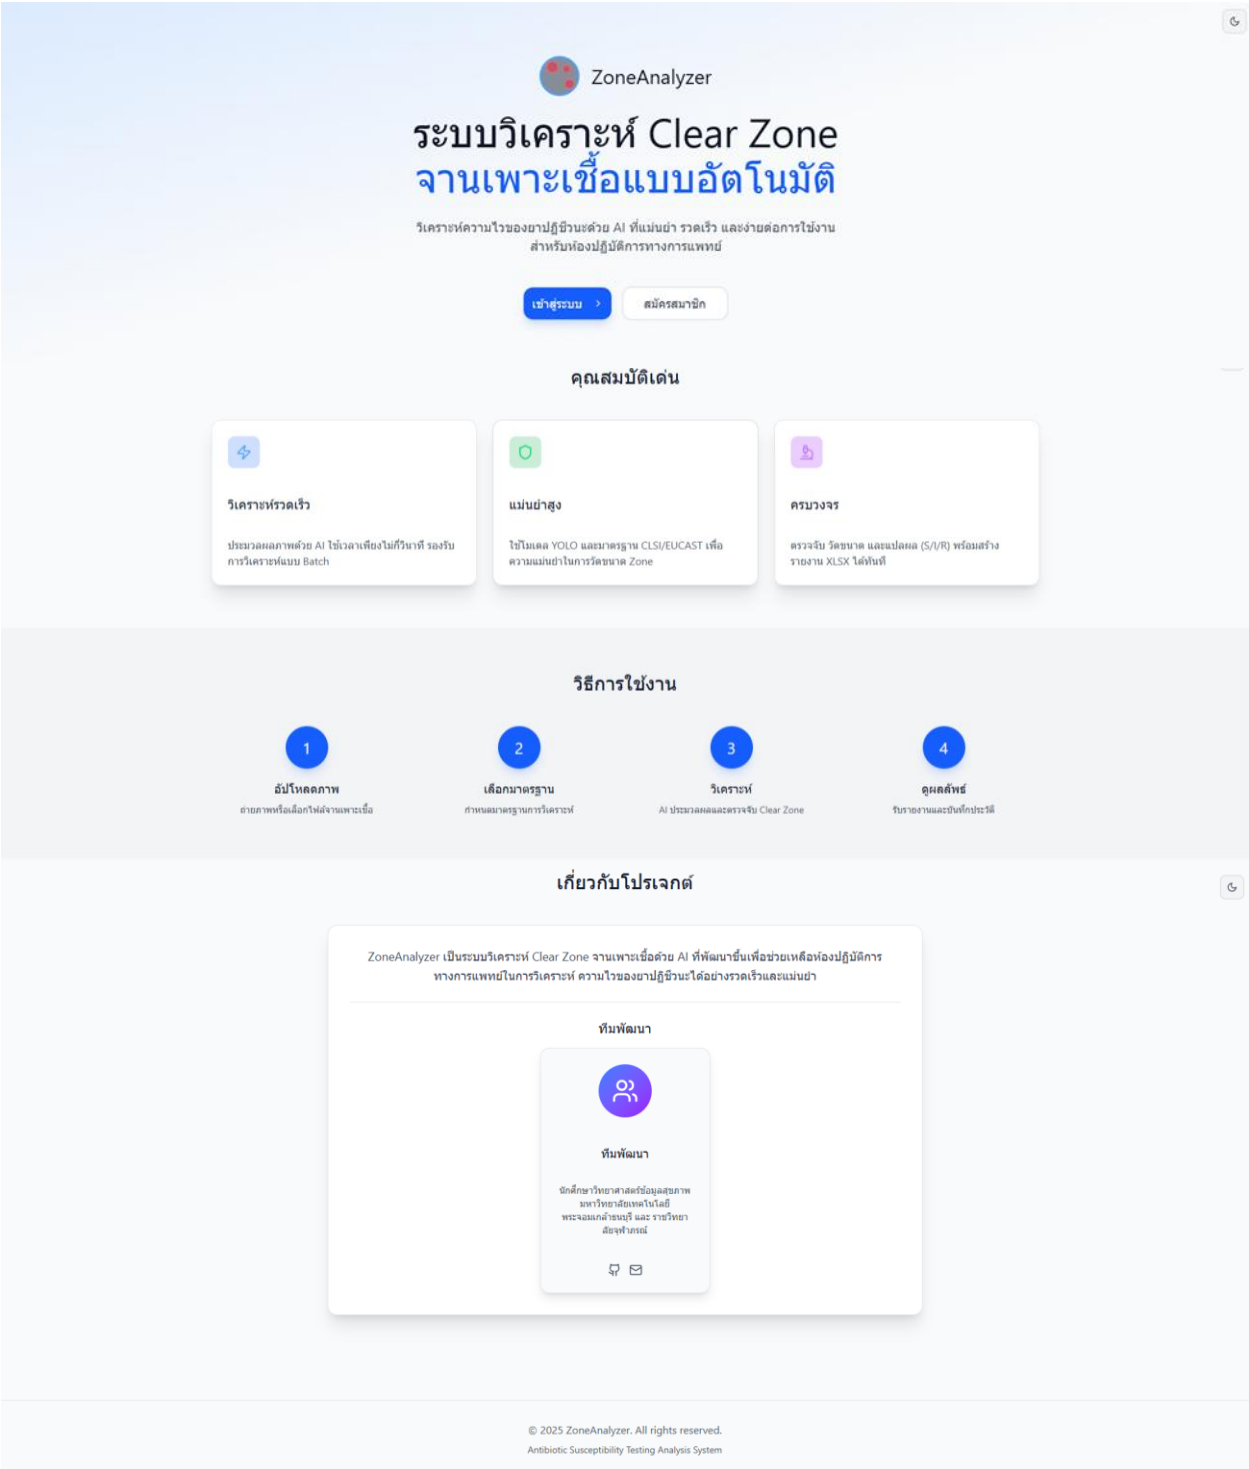

ภาพที่ 3.6 ภาพหน้า Home page

2. หน้าเข้าสู่ระบบ (Login Page)

- ออกแบบให้มีความเรียบง่าย (Minimalist) โดยวางแบบฟอร์มไว้กึ่งกลางหน้าจอ (Card Layout) เพื่อให้ผู้ใช้โฟกัสที่การกรอกข้อมูล
- มีช่องกรอก Email และ Password พร้อมฟังก์ชันแสดง/ซ่อนรหัสผ่าน (Eye Icon) เพื่อลดความผิดพลาดในการพิมพ์
- รองรับฟังก์ชัน "จดจำฉันไว้ในระบบ" (Remember Me) และลิงก์ "ลืมรหัสผ่าน" เพื่อความสะดวกในการใช้งานต่อเนื่อง

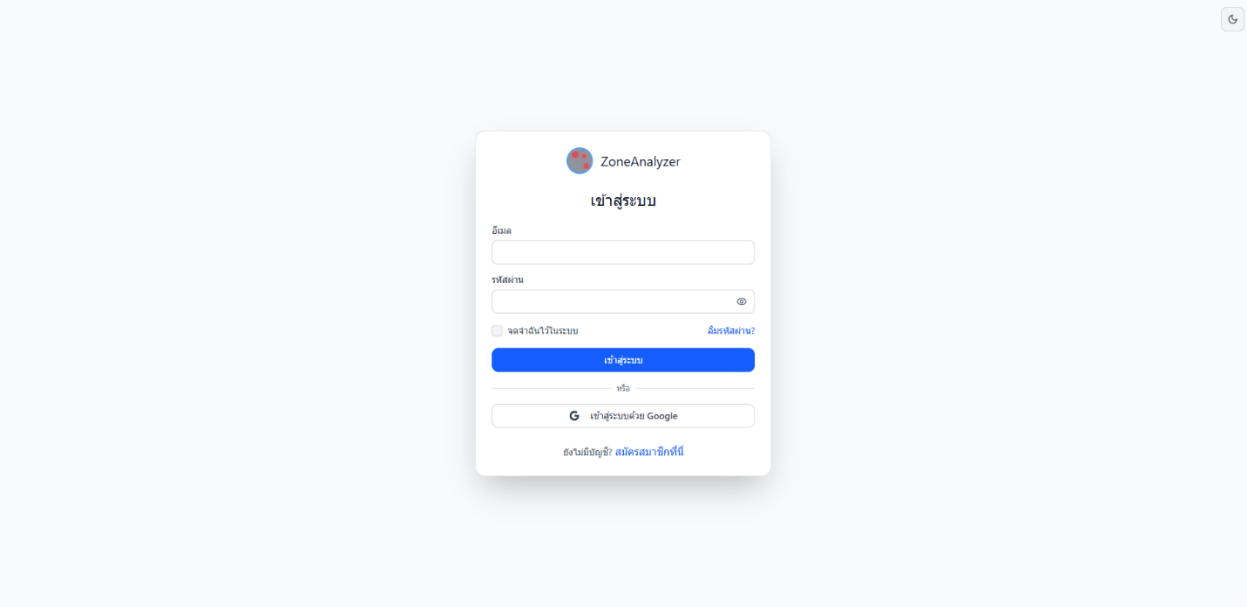

ภาพที่ 3.7 ภาพหน้า Login Page

3. หน้าแผงควบคุมการวิเคราะห์ (Analysis Dashboard)

- เป็นหน้าจอการทำงานหลัก (Workspace) หลังจากเข้าสู่ระบบ รองรับการทำงานแบบ Batch Processing
- พื้นที่นำเข้าภาพ (Dropzone): พื้นที่ขนาดใหญ่ที่รองรับการลากไฟล์มาวาง (Drag & Drop) หรือกดปุ่มเพื่อเลือกไฟล์จากเครื่อง
- ปุ่มเปิดกล้อง (Camera Integration): สำหรับการถ่ายภาพสดจากกล้องเว็บแคมหรือกล้องมือถือ
- รายการไฟล์ (File List): แสดงรายชื่อภาพที่รอการวิเคราะห์ พร้อมปุ่มลบและ Dropdown

สำหรับเลือกชนิดเชื้อ (Bacteria Strain) ให้แต่ละภาพ

- สถานะการทำงาน (Progress Indicator): แสดงแถบความคืบหน้าเมื่อระบบกำลังประมวลผลภาพ

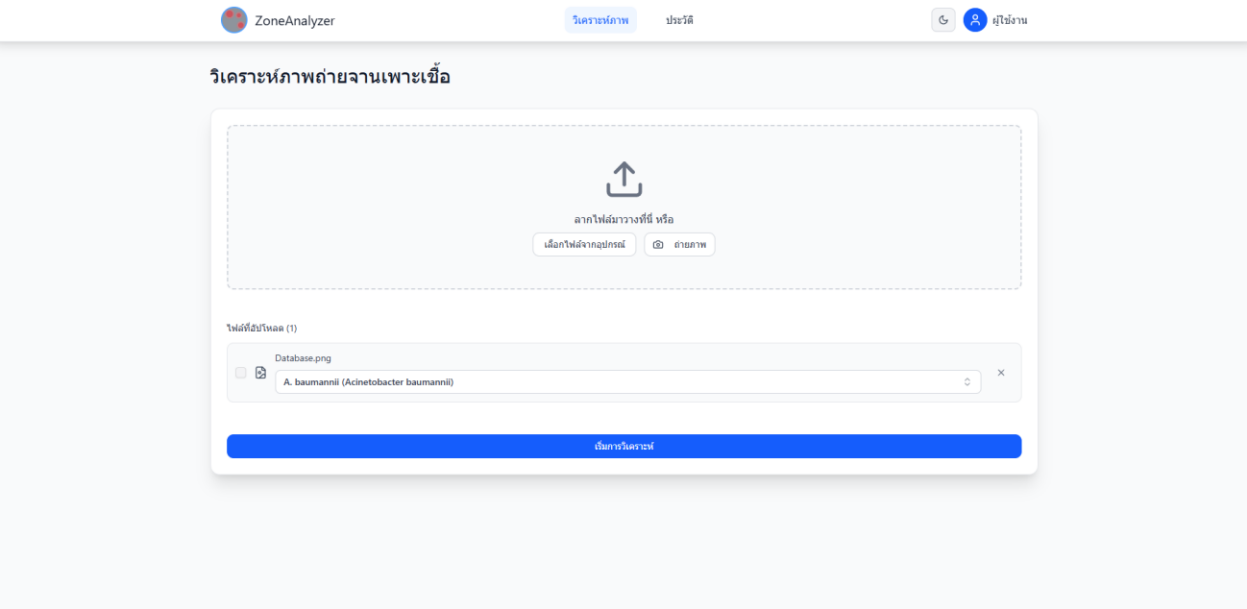

ภาพที่ 3.8 ภาพหน้า Analysis Dashboard

4. หน้าถ่ายภาพ (Camera Capture)

- หน้าจอสำหรับถ่ายภาพผ่านกล้อง (Camera Interface) ที่ออกแบบมาเพื่อการใช้งานบนอุปกรณ์เคลื่อนที่
- มีเส้นไกด์ (Overlay Mask) ทั้งรูปแบบวงกลมและสี่เหลี่ยม เพื่อช่วยให้ผู้ใช้งานจัดวางจานเพาะเชื้อให้อยู่ในตำแหน่งและระยะห่างที่เหมาะสมที่สุดสำหรับการวิเคราะห์
- ปุ่มชัตเตอร์ (Capture) ขนาดใหญ่ที่กดได้ง่าย และปุ่มสลับกล้องหน้า/หลัง

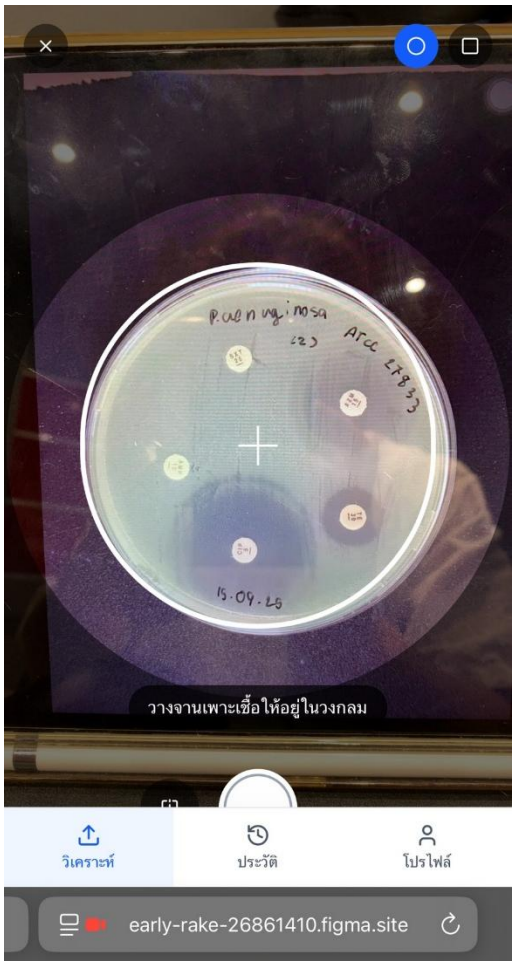

ภาพที่ 3.9 ภาพหน้าระบบขณะถ่ายภาพ (Camera Capture) จานเพาะเชื้อ

5. หน้าแสดงผลลัพธ์ (Results View)

แสดงผลการวิเคราะห์อย่างละเอียด โดยแบ่งหน้าจอเป็น 2 ส่วนหลัก ดังนี้

1. ส่วนแสดงภาพ (Image Viewer): แสดงภาพจานเพาะเชื้อต้นฉบับที่มีการวาด กราฟิกทับ (Overlay) ระบุตำแหน่งแผ่นยา (สีน้ำเงิน) และขอบเขตวงยับยั้ง (สีเขียว)

2. ตารางสรุปผล (Antibiogram Table): แสดงรายชื่อยา, รหัสยา, ขนาดยา, ค่าที่วัดได้ (mm), เกณฑ์มาตรฐาน (Breakpoints), และผลการแปล (S/I/R) ที่มีการใช้สีสื่อความหมาย (Color-coded) อย่างชัดเจน

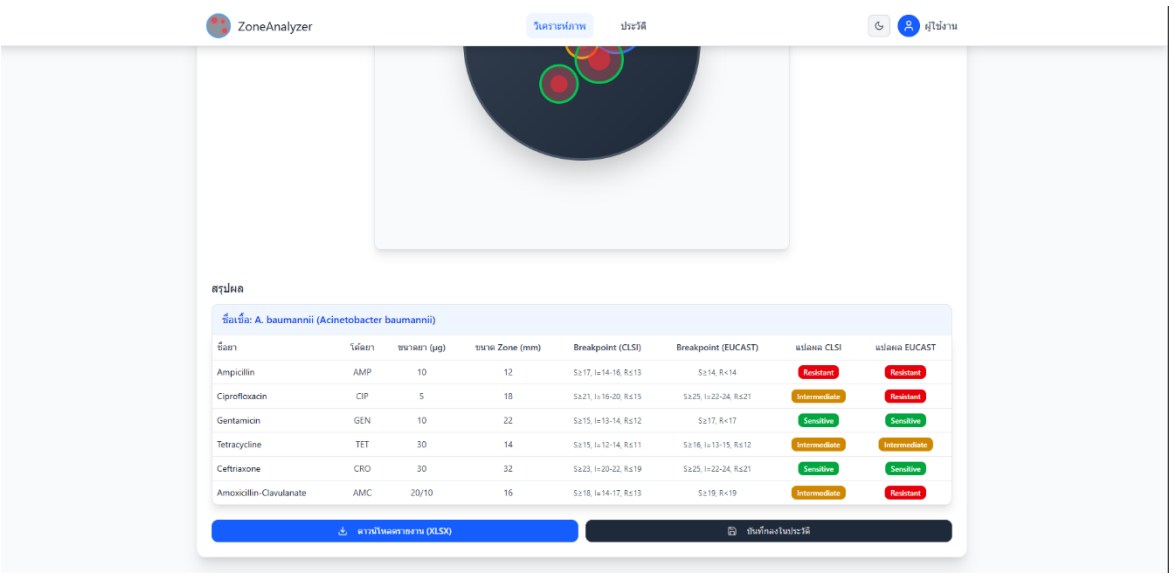

ภาพที่ 3.10 ภาพหน้าการแสดงผลลัพธ์ (Results View) หลังการถ่ายภาพจานเพาะเชื้อ

6. หน้าประวัติการวิเคราะห์ (History Page)

- แสดงรายการการวิเคราะห์ย้อนหลังในรูปแบบการ์ด (Card List) เพื่อให้อ่านง่าย
- มีระบบค้นหา (Search) ที่สามารถกรองข้อมูลได้ตามชื่อรอบการวิเคราะห์ (Batch Name) หรือวันที่
- แต่ละรายการจะแสดงสรุปจำนวนภาพในชุดนั้นๆ และมีปุ่มสำหรับดูรายละเอียดหรือลบรายการ

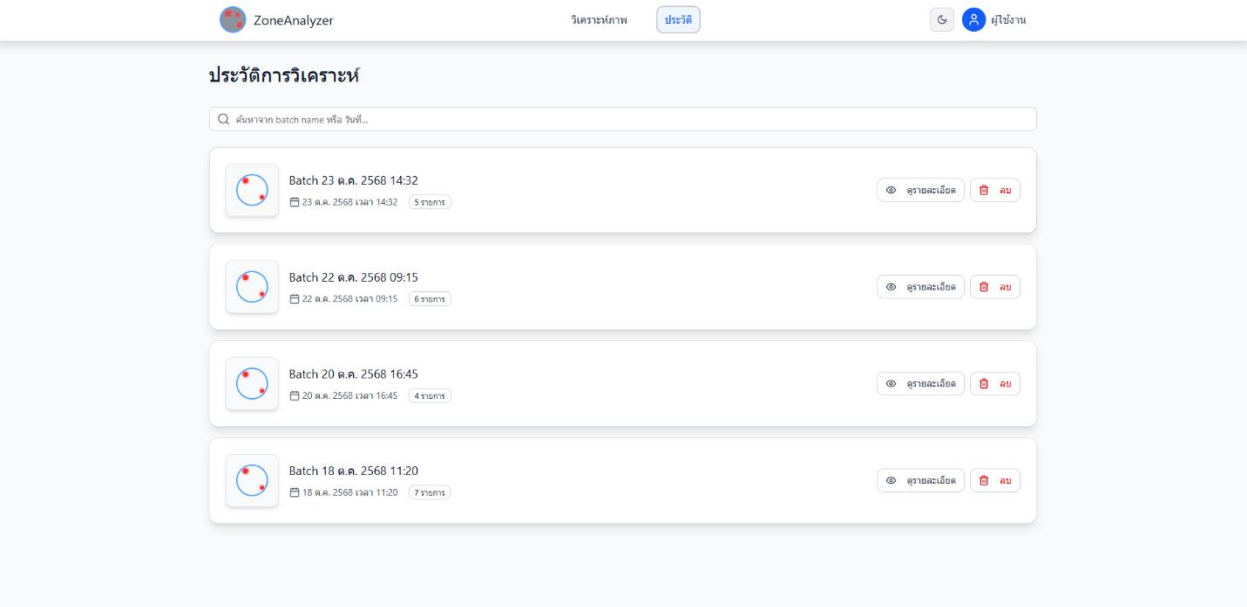

ภาพที่ 3.11 ภาพหน้าแสดงประวัติ (History Page) การวิเคราะห์

7. หน้ารายละเอียดประวัติ (History Detail Page)

- แสดงข้อมูลเจาะลึกของรอบการวิเคราะห์นั้นๆ
- ในกรณีที่มีหลายภาพในหนึ่งรอบ จะมี Grid ให้ผู้ใช้เลือกดูผลลัพธ์ทีละภาพได้
- มีปุ่ม "ดาวน์โหลดรายงาน" (Export Excel) ที่จะรวบรวมผลการวิเคราะห์ของทุกภาพในรอบนั้นๆ ออกมาเป็นไฟล์ .xlsx ที่จัดรูปแบบสมบูรณ์สำหรับการนำไปใช้งานต่อ

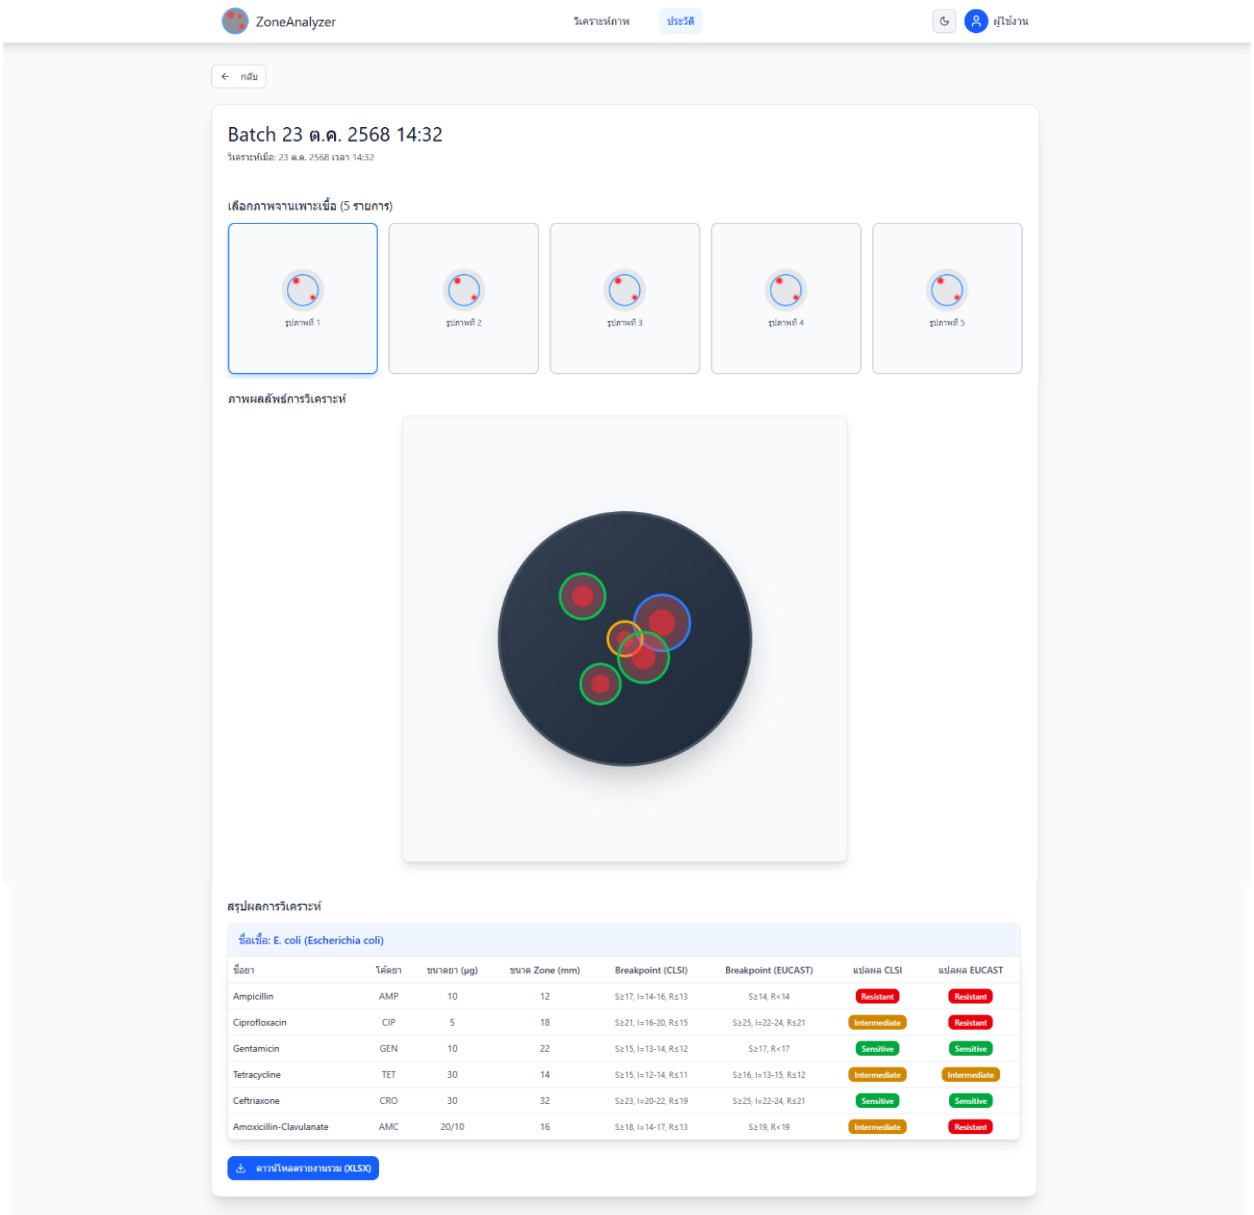

ภาพที่ 3.12 ภาพหน้าแสดงรายละเอียดประวัติ (History Detail Page)

3.5 การรวบรวมข้อมูล (Data Source)

การศึกษานี้จะนำข้อมูลที่มีการศึกษาและรวบรวมข้อมูลภาวะการดื้อยาต้านจุลชีพ (Antimicrobial Resistance: AMR) โดยจะประกอบไปด้วย ข้อมูลการวัดเส้นผ่านศูนย์กลางของบริเวณยับยั้ง (inhibition zone), ข้อมูลการจำแนกประเภทการดื้อยา ได้แก่ ไวต่อยา (Susceptible : S), ไวปานกลาง (Intermediate : I) และดื้อยา (Resistant : R) และรูปภาพของการทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing: AST) ซึ่งแหล่งข้อมูลจากข้อมูลทางอินเตอร์เน็ตและจากการทดลองด้วยตัวเอง โดยการทดลองด้วยตัวเองจะใช้อุปกรณ์ในห้องแลปคณะแพทยศาสตร์ศรีสวางควัฒน ศาสตร์ราชวิทยาลัยจุฬาภรณ์ ซึ่งจะมีวิธีการดังต่อไปนี้

1. เตรียมจานเพาะเชื้อ (Agar Plate Preparation)

ใช้ Mueller-Hinton agar (MHA) เทลงในจานให้หนาประมาณ 4 mm แล้วปล่อยให้แข็งตัวและตรวจความสะอาด

2. เตรียมเชื้อ (Inoculum Preparation)

ปรับความหนาแน่นเชื้อให้เท่ากับ McFarland 0.5 (≈ 1.5×10^{8} CFU/mL) แล้วใช้ swab ป้ายเชื้อให้ทั่วผิวจานอย่างสม่ำเสมอ โดยเห็นอุปกรณ์ได้จากภาพที่ 3.13

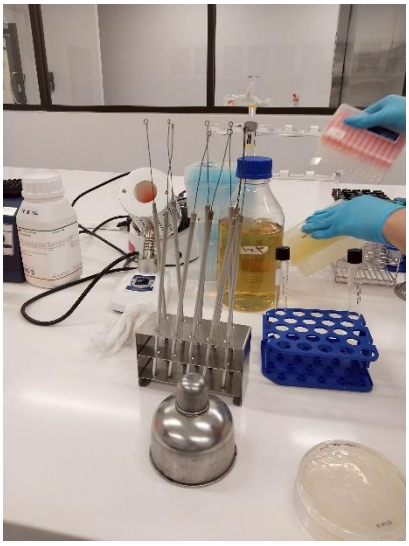

ภาพที่ 3.13 ภาพอุปกรณ์การเตรียมเชื้อ (ซ้าย) และดำเนินการปรับค่า McFarland (ขวา)

3. วางแผ่นยาปฏิชีวนะ (Placement of Antibiotic Disks)

วาง antibiotic disks ขนาดมาตรฐานบนผิวจาน โดยเว้นระยะห่างของ antibiotic disk ด้วยสายตา เพื่อไม่ให้ zone ทับกัน โดยเห็นได้จากภาพที่ 3.14

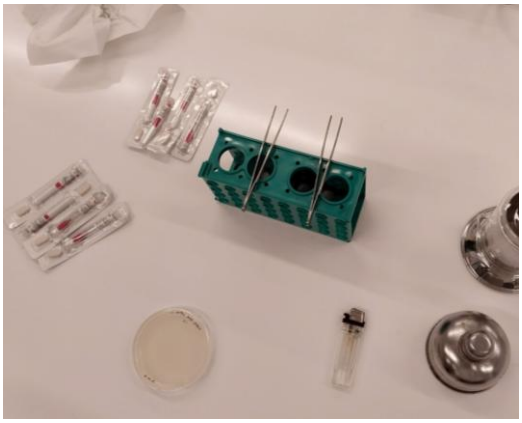

ภาพที่ 3.14 ภาพอุปกรณ์วางแผ่นยาปฏิชีวนะ (ซ้าย) และการดำเนินการวางแผ่นยาปฏิชีวนะ (ขวา)

4. บ่มเชื้อ (Incubation)

บ่มที่ 35–37°C นาน 18–24 ชม. ให้จานอยู่แนวนอน แล้วปล่อยให้ยากระจายและเกิด zone of inhibition รอบแผ่นยา

5. วัด Zone of inhibitor

โดยให้ผู้เชี่ยวชาญวัดเส้นผ่านศูนย์กลางของ zone of inhibitor เป็นหน่วยมิลลิเมตร แล้วจะบันทึกลง excel ไว้

6. ถ่ายภาพจานเพาะเชื้อ

โดยใช้กล้องจากมือถือรุ่น Iphon 16 ในการถ่ายภาพ โดยจะถ่ายในพื้นที่ควบคุมแสงสะท้อนและพื้นที่ไม่ควบคุมแสงสะท้อน ส่วนการถ่ายภาพจานเพาะเชื้อ จะถ่ายถ่ายแบบขนานไปกับจานเพาะเชื้อ

ภาพที่ 3.15 ภาพอุปกรณ์ในการลดแสงสะท้อนในการถ่ายภาพจานเพาะเชื้อ

3.6 การสร้างโมเดล

3.6.1 โมเดลที่นำมาทดลอง

การทดลองโดยนำ Deep learning model มาทดสอบ 2 model ได้แก่ Yolov11n และ Faster R-CNN กับโมเดลพื้นฐาน 1 โมเดล ได้แก่ Hough Transform โดยแต่ละโมเดลมีรายละเอียด ดังนี้

1. Hough Transform เป็นวิธีการตรวจจับวัตถุที่มีรูปทรงเฉพาะ เช่น วงกลมหรือเส้นตรง ในภาพ โดยอาศัยการวิเคราะห์กลุ่มของจุดขอบพิกเซล (edge pixels) ในภาพแต่ละจุดจะโหวต (vote) เพื่อกำหนดว่าจุดนั้นน่าจะเป็นส่วนหนึ่งของรูปร่างใด หากรูปร่างใดได้รับคะแนนโหวตมากที่สุด จะถือว่ารูปร่างนั้นมีอยู่จริงในภาพ (Shehata et al., 2015) วิธีนี้เหมาะกับการตรวจจับวัตถุที่มีรูปทรงคงที่และชัดเจน

2. Faster R-CNN เป็นโมเดลตรวจจับวัตถุที่พัฒนาต่อยอดมาจาก R-CNN และ Fast R-CNN โดยออกแบบมาเพื่อแก้ไขข้อจำกัดหลักในกระบวนการสร้างพื้นที่คาดว่าจะมีวัตถุ (region proposals) ซึ่งในวิธีเดิม เช่น Selective Search หรือ EdgeBoxes ต้องใช้เวลานานและไม่สอดคล้องกับการเรียนรู้เชิงลึก (deep learning) โดย Faster R-CNN แนะนำแนวคิดใหม่คือ Region Proposal Network (RPN) ซึ่งเป็นเครือข่าย convolutional ที่สร้างกรอบพื้นที่คาดว่าวัตถุน่าจะอยู่ได้อย่างรวดเร็วและมีประสิทธิภาพ โดยใช้ feature map เดียวกับเครือข่ายตรวจจับหลัก พร้อมทั้งทำนายความน่าจะเป็นของวัตถุในแต่ละตำแหน่ง ทำให้ระบบตรวจจับทำงานได้รวดเร็วและแม่นยำสูง นอกจากนี้ RPN ยังใช้ระบบ anchor boxes ที่รองรับวัตถุหลายขนาดและอัตราส่วน ทำให้โมเดลนี้สามารถจัดการกับวัตถุที่มีความหลากหลายได้ดี และเป็นพื้นฐานของงานวิจัยและระบบประยุกต์ที่ต้องการตรวจจับที่รวดเร็วและเชื่อถือได้ (Ren et al., 2016)

3. You Only Look Once version 11 Nano (Yolov11n) เป็นโมเดลตรวจจับวัตถุรุ่นล่าสุดในตระกูล YOLO ที่ถูกพัฒนาเพื่อเพิ่มทั้งความแม่นยำและความเร็วในการประมวลผลภาพแบบเรียลไทม์ มีการปรับปรุงสถาปัตยกรรมหลายส่วน เช่น การใช้บล็อก C3k2 ที่มีประสิทธิภาพสูงขึ้น บล็อก SPPF ที่ช่วยรวบรวมข้อมูลหลายสเกลอย่างรวดเร็ว และบล็อก C2PSA ที่เพิ่มความสามารถในการโฟกัสบริเวณสำคัญของภาพ โมเดลนี้รองรับงานคอมพิวเตอร์วิทัศน์หลากหลายประเภท ทั้งการตรวจจับวัตถุ การแยก instance segmentation การจำแนกภาพ การประเมินท่าทาง รวมถึงการตรวจจับวัตถุแบบหมุน โดยมีหลายขนาดโมเดลให้เลือกใช้ (Khanam et al., 2024) โดยนั้นก็คือโมเดล Yolov11n ที่มีขนาดเล็กที่สุดจากโมเดลทั้งหมด 5 ตัว

3.6.2 การเพิ่มข้อมูล (Data Augmentation)

การนำรูปภาพเดิมที่มีอยู่ทั้งหมดที่รวบรวมนำไปผ่านเว็บไซต์ Roboflow เพื่อเพิ่มรูปภาพให้มีจำนวนที่มากขึ้นทำให้ข้อมูลที่จำนวนที่เพียงพอต่อการนำไป train กับโมเดลที่จะใช้ทดสอบ โดยวิธีการดังนี้

1. การพลิกภาพตามแนวนอน (Horizontal) และการพลิกแนวตั้ง (Vertical)
2. การหมุนภาพ 90 องศาไปจนครบรอบนาฬิกา

3.6.3 การกำหนดพารามิเตอร์สำหรับรูปภาพ

จากภาพ AST ทั้งหมดจำนวนจะแบ่งข้อมูล ดังนี้

- ข้อมูลการเทรน (Train set) เป็น 80%
- ข้อมูลการตรวจสอบความถูกต้อง (Validation set) เป็น 10%
- ข้อมูลการทดสอบ (Test set) เป็น 10%

การกำหนดขนาดรูปภาพที่ 640x640 และ batch size = 8

3.6.4 การกำหนดพารามิเตอร์สำหรับโมเดล

1. Yolov11n

- Train จำนวน 200 epochs
- augment = False

2. Faster R-CNN

- Optimizer ตั้งค่าดังนี้ lr = 0.005, momentum = 0.9 และ weight_decay = 0.0005

- Learning Rate Scheduler ตั้งค่าดังนี้ step size = 3 และ gamma = 0.1
- Train จำนวน 10 epochs

3. Hough Transform

- GuassianBlur ตั้งค่าดังนี้ ksize = (17,17) และ sigma = 0
- HoughCircles ตั้งค่าดังนี้ dp = 1.5, minDist = 150, param1 = 100, param2 = 50, minRadius = 80 และ maxRadius = 300
- Grow Radius ตั้งค่าดังนี้ max_radius = 2000, angle steps = 360 และ intensity jump = 8

3.6.5 เมทริกซ์สำหรับวัดผลโมเดล

- mAP@50
- mAP@50-95

3.7 การวัดเส้นผ่านศูนย์กลางของ zone of inhibitor

ในการวัดเส้นผ่านศูนย์กลางของ zone of inhibitor ได้ลองเปรียบเทียบการวัดด้วย 2 การคำนวณในการหาการเปลี่ยนพิกเซล (pixel) เป็นหน่วยมิลลิเมตร (mm) โดยการวัดจากพื้นที่ (Area) จริงของยา (antibiotic) และเส้นผ่านศูนย์กลาง (diameter) ของยา เนื่องจากขนาดยามีขนาดที่เป็นมาตรฐานโดยยามีขนาดเส้นผ่านศูนย์กลางที่ 6 มิลลิเมตร

1. สูตรการคำนวณเปลี่ยนจาก pixel เป็น mm จากพื้นที่จริงของยา

$$\text{mm per pixel} = \sqrt{\frac{\text{real area (mm}^2)}{\text{detected area (pixels}^2)}} \qquad (1)$$

2. สูตรการคำนวณเปลี่ยนจาก pixel เป็น mm จากเส้นผ่านศูนย์กลางจริงของยา

$$\text{mm per pixel} = \frac{\text{real diameter (mm)}}{\text{detected diameter (pixels)}} \qquad (2)$$

จากการได้ค่าที่เปลี่ยน pixel เป็น mm แล้วจะนำค่านั้นไปคูณกับค่า pixel ของเส้นผ่านศูนย์กลางของ zone of inhibitor เพื่อหาขนาดเส้นผ่านกลางที่เป็นหน่วยมิลลิเมตร ดังนี้

$$\text{diameter(mm)} = \text{diameter(pixels)} \times \text{mm per pixel} \qquad (3)$$

แล้วจะมีการวัดผลของการคำนวณเส้นผ่านศูนย์กลางจากสูตรเพื่อตรวจสอบความแม่นยำกับเส้นผ่านศูนย์กลางจริงที่วัดด้วยไม้บรรทัด ได้แก่ ค่า Bias และ Mean Average Error (MAE)

3.8 โมเดลที่ตรวจจับตรวจอักษรบนยา (Detect Antibiotic Discs)

3.8.1 EasyOCR

เป็นโมเดลแบบ open-source ที่ได้รับความนิยมอย่างมาก เนื่องจากรองรับภาษาได้กว่า 80 ภาษา ประมวลผลได้รวดเร็ว และติดตั้งง่าย ใช้งานได้โดยไม่ต้องเตรียมข้อมูลหรือฝึกโมเดลใหม่ เหมาะสำหรับงานที่ต้องการ “อ่านข้อความจากภาพที่หลากหลายแบบ” เช่น ข้อความโค้ง ข้อความที่มี noise หรือข้อความที่อยู่บนพื้นผิวไม่เรียบ (JaidedAI., 2024) เหมือนกรณีของแผ่นยาในจานเพาะเชื้อ ซึ่งจะดึงข้อความจากบริเวณที่โมเดล Object Detection ตรวจจับว่าเป็นแผ่นยา ซึ่งส่วนใหญ่มักเป็นข้อความสั้นๆ เช่น CIP 5, AMC 30, CTX 30 เป็นต้น และเหตุผลหลักที่ใช้โมเดลนี้

- รองรับภาษาอังกฤษและตัวเลขที่ใช้บน antibiotic discs อยู่แล้ว
- ใช้งานง่าย ไม่ต้องตั้งค่าอะไรมาก
- มีความแม่นยำค่อนข้างดีแม้ในภาพที่แสงไม่สม่ำเสมอ
- เหมาะกับ pipeline ที่ต้องการความเร็ว

3.8.2 TyphoonOCR

เป็นโมเดล OCR ที่ถูกพัฒนาโดยทีม Typhoon ซึ่งออกแบบมาให้เหมาะกับโครงสร้างตัวอักษรของภาษาไทยโดยเฉพาะ แต่ยังรองรับภาษาอังกฤษและตัวเลขด้วย จุดเด่นสำคัญคือการจัดการกับฟอนต์ไทยที่ สระ–วรรณยุกต์ ซ้อนกันหลายชั้น รวมถึงข้อความที่มีลักษณะซับซ้อน เช่น ตัวอักษรขนาดเล็กหรือมี noise เยอะ ซึ่งเป็นสิ่งที่มักพบในงานด้านการแพทย์ในประเทศไทย (OpenTyphoon.ai., เข้าถึงเมื่อ 14 พฤศจิกายน 2025) โดยในการดึงข้อความออกมาจะใช้ภาพจากโมเดล Object Detection ที่ตรวจจับว่าเป็นแผ่นยาแล้วเลือกบริเวณนั้นในการดึงคำออกมา ซึ่งเหตุผลที่ใช้โมเดล มีดังนี้

- มีความแม่นยำกับภาษาไทยสูงกว่าระบบ OCR ทั่วไป
- อ่านตัวเลขและภาษาอังกฤษได้ดี เหมาะกับ antibiotic discs ที่ผลิตในไทย
- รับมือกับภาพที่คุณภาพไม่สม่ำเสมอ เช่น แสงสะท้อนหรือภาพเอียง
- นำมาเปรียบเทียบกับโมเดล EasyOCR

3.9 การวัดผล (Evaluation)

ในการประเมินประสิทธิภาพของระบบตรวจจับแผ่นยาและการประมาณเส้นผ่านศูนย์กลางของบริเวณยับยั้ง (zone of inhibition) จะแบ่งการวัดผลออกเป็น 2 ส่วนหลัก ได้แก่ การประเมินประสิทธิภาพของโมเดล, ตรวจจับวัตถุ และ การประเมินความถูกต้องของค่าที่คำนวณจากการวัด zone

3.9.1 การประเมินประสิทธิภาพโมเดลตรวจจับวัตถุ (Object Detection Evaluation)

สำหรับโมเดล Yolov11n, Faster R-CNN และ Hough Transform จะใช้ตัวชี้วัดมาตรฐานในการวัดคุณภาพของการตรวจจับวัตถุ ดังนี้

- mAP@50 (Mean Average Precision at IoU = 0.50) ใช้วัดความแม่นยำของโมเดลเมื่อพิจารณาว่ากรอบที่ตรวจจับถูกต้องหากมีค่า IoU ตั้งแต่ 0.50 ขึ้นไป ตัวชี้วัดนี้ช่วยสะท้อนว่าโมเดลสามารถตรวจจับแผ่นยาและวง zone ได้ตรงตำแหน่งมากน้อยเพียงใด
- mAP@50–95 เป็นค่า mAP ที่คำนวณจากหลายระดับ IoU ตั้งแต่ 0.50 ถึง 0.95 (เพิ่มทีละ 0.05) เป็นการประเมินที่เข้มงวดกว่า เนื่องจากต้องการความแม่นยำทั้งตำแหน่งและขนาดของกรอบที่ตรวจจับได้ เหมาะสำหรับเปรียบเทียบประสิทธิภาพระหว่างโมเดลอย่างละเอียด

ค่าทั้งสองนี้ช่วยยืนยันว่าโมเดลสามารถตรวจจับในภาพได้ถูกต้องเมื่อเจอสถานการณ์ที่แตกต่างกัน เช่น แสงไม่สม่ำเสมอ มุมเอียง หรือขนาดวงที่หลากหลาย

3.9.2 การประเมินความแม่นยำของการวัดเส้นผ่านศูนย์กลาง Zone of Inhibition

หลังจากคำนวณการเปลี่ยนค่าจากพิกเซล (pixel) เป็นมิลลิเมตร (millimeter) แล้ว ระบบจะนำค่าที่ได้ไปคูณกับขนาดของเส้นผ่านศูนย์กลาง zone ที่ตรวจจับมา เพื่อหาค่าที่เป็นหน่วยมิลลิเมตรตามสมการในหัวข้อ 3.7 เพื่อประเมินความแม่นยำของค่าที่คำนวณจากระบบ จะเปรียบเทียบกับค่าจริงที่ผู้เชี่ยวชาญวัดด้วยไม้บรรทัด โดยใช้ตัวชี้วัด ดังนี้

- Bias คือ การวัดค่าความคลาดเคลื่อนเชิงทิศทาง (systematic error) แสดงให้เห็นว่าระบบมี

แนวโน้มวัดค่า “มากกว่า” หรือ “น้อยกว่า” ค่าจริง หรือเป็นตัวชี้วัดที่ช่วยประเมินว่าการคำนวณต้องปรับสมการ หรือแก้ไข preprocessing หรือไม่

- Mean Absolute Error (MAE) เป็นค่าความคลาดเคลื่อนเฉลี่ยของการวัดทั้งหมด โดยไม่สนใจว่าเพี้ยนมากหรือน้อยกว่าค่าจริง ค่านี้ยิ่งน้อยเท่าใด แสดงว่าระบบวัดเส้นผ่านศูนย์กลางได้ใกล้เคียงกับค่าจริงมากเท่านั้น

บทที่ 4

ผลการดำเนินการ

4.1 ผลการรวบรวมข้อมูล (Data collection results)

4.1.1 The Digital Repository of Information and Data for Evolution (DRIADE /DRYAD)

เป็นข้อมูลรูปภาพและข้อมูลได้มาจากกิจกรรมการวินิจฉัยประจำวันที่สถาบันจุลชีววิทยาทางการแพทย์ มหาวิทยาลัยซูริก ที่เป็นภาพข้อมูลแบคทีเรียแกรมลบ (Gram-negative bacteria) 225 ตัวอย่าง ซึ่งมีฟีโนไทป์ เฉพาะ 826 หมวดหมู่ โดยได้ข้อมูลจากการใช้เครื่อง SIRscan 2000 ได้ข้อมูล ดังนี้ ข้อมูลการวัดเส้นผ่าน ศูนย์กลางของบริเวณยับยั้ง (inhibition zone), ข้อมูลการจำแนกประเภทการดื้อยา ได้แก่ ไวต่อยา (Susceptible : S), ไวปานกลาง (Intermediate : I) และ ดื้อยา (Resistant : R) และรูปภาพของการทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing: AST) ในภาพที่ 4.1 (Giske, C et al., 2024)

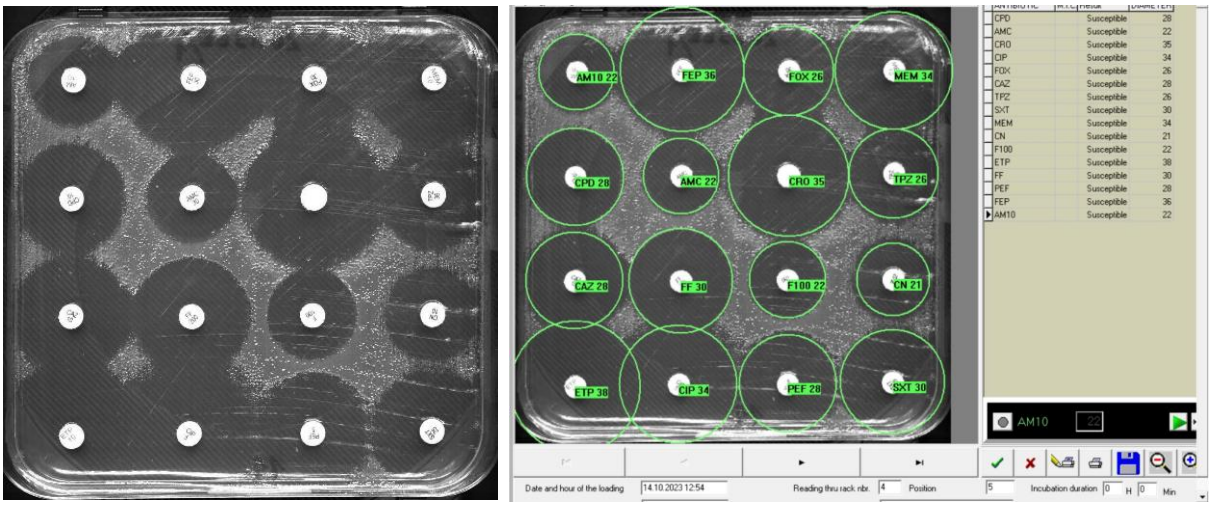

ภาพที่ 4.1 ตัวอย่างภาพจานเพาะเชื้อ (ซ้าย) และหลังแปรผลจานเพาะเชื้อผ่านเครื่อง SIRscan 2000 (ขวา)

ที่มา : (Giske, C et al., 2024)

4.1.2 Combined Defence Services Examination (CDS)

รวบรวมข้อมูลรูปภาพ AST จำนวน 50 ภาพ ที่เป็นเชื้อแบคทีเรียแกรมบวก (Gram-positive bacteria) และแบคทีเรียแกรมลบ (Gram-negative bacteria) โดยจะใช้ยา (Antibiotic) หลายชนิดด้วยกัน โดยการแคปรูปภาพจากเว็บไซต์

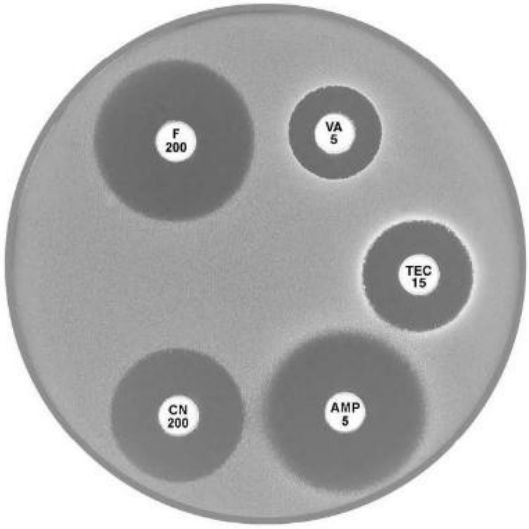

ภาพที่ 4.2 ตัวอย่างภาพจานเพาะเชื้อจากเว็บไซต์

ที่มา : https://cdstest.net/manual/tables/plates/

เข้าถึงเมื่อวันที่ 20 พฤศจิกายน 2658 (ใช้ข้อมูลเพื่อประกอบการศึกษาวิจัยเท่านั้น)

4.1.3. การศึกษาที่ราชวิทยาลัยจุฬาภรณ์ (CRA)

ทำการทดลองวัดการดื้อยาของเชื้อ (Antimicrobial susceptibility testing; AST) ภายในห้องแลปคณะแพทยศาสตร์ศรีสวางควัฒน ราชวิทยาลัยจุฬาภรณ์ โดยได้ข้อมูลรูปภาพ AST จำนวน 32 ภาพ จะเห็นตัวอย่างของภาพถ่ายที่ภาพที่ 4.3 โดยประกอบด้วยการทดลอง 4 เชื้อแบคทีเรีย ได้แก่ S. aureus ATCC25923, S. aureus ATCC12600, E.coli ATCC 25922 และ P. aeruginosa ATCC 27853 โดยทำซ้ำ 2 รอบต่อหนึ่งเชื้อ ซึ่งจะใช้ Antibiotic จำนวน 9 ชนิด ได้แก่ Penicillin, Oxacillin, Chloramphenicol, Gentamicin, Tetracycline, Ciprofloxacin, Trimethoprim-sulfamethoxa-zole, Azithromycin และ Ampicillin รวมถึงมีการวัดเส้นผ่านศูนย์กลางของวงยับยั้งและการแปรผลประเภทของการดื้อยาโดยผู้เชี่ยวชาญด้าน ระบาดวิทยาในภาพที่ 4.4 ส่วนกระบวนการถ่ายภาพจะถ่าย 2

แบบต่อหนึ่งเชื้อโดยถ่ายในพื้นที่ควบคุม แสงสะท้อนและไม่ควบคุมแสงสะท้อนและใช้โทรศัพท์ Iphone รุ่นที่ 16 ถ่ายภาพในการเก็บข้อมูล

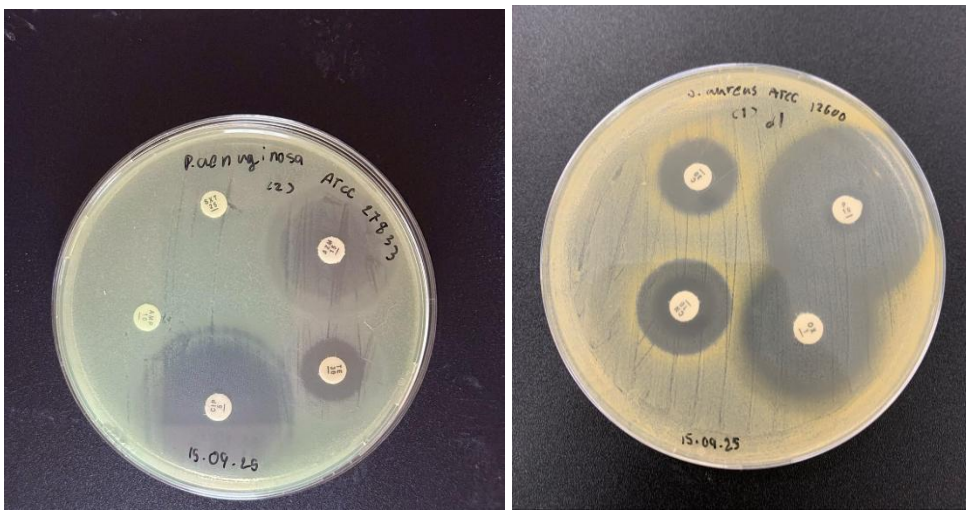

ภาพที่ 4.3 ตัวอย่างภาพถ่ายจานเพาะเชื้อจากห้องแลปพื้นที่ควบคุมแสงสะท้อน (ซ้าย) และไม่ควบคุมแสงสะท้อน (ขวา)

เชื้อ	ลำดับการทำซ้ำ	จาน	ยา	ตัวย่อยา	พีเบส					บีเอ็ม					ลูกหมี				
					Clear Zone (mm)	time (s)	SIR	time (s)	All time (s)	Clear Zone (mm)	time (s)	SIR	time (s)	All time (s)	Clear Zone (mm)	time (s)	SIR	time (s)	All time (s)
S. aureus ATCC25923	1	1	Penicillin (10 units)	P	34	20.48	S	38.08	58.56	34	38.54	S	115.41	153.95	37	30.38	S	203.41	233.79
			Oxacillin (30 µg)	OX	22		R			27		S			29		S		
			Chloramphenicol * (30 µg)	C	26		S			25		S			27		S		
			Gentamicin (10 µg)	CN	23		S			24		S			23		S		
		2	Tetracycline (30 µg)	TE	32	26.84	S	24.58	51.42	31	32.23	S	113.68	145.91	33	40	S	75	115
			Ciprofloxacin (5 µg)	CIP	28		S			29		S			29		S		
			Trimethoprim-sulfamethoxazole (1.25/23.75 µg)	SXT	29		S			29		S			29		S		
			Azithromycin (15 µg)	AZM	24		S			23		S			25		S		
			Ampicillin (10 µg)	AMP	25		S			21		S			25		S		
	2	1	Penicillin (10 units)	P	25	19.99	S	22.69	42.68	31	30.37	S	47.45	77.82	40	29.4	S	102.34	131.74
			Oxacillin (30 µg)	OX	26		S			27		S			30		S		
			Chloramphenicol * (30 µg)	C	25		S			25		S			30		S		
			Gentamicin (10 µg)	CN	23		S			23		S			23		S		
		2	Tetracycline (30 µg)	TE	33	18.41	S	32.82	51.23	32	26.4	S	77.36	103.76	35	38.17	S	57.82	95.99
			Ciprofloxacin (5 µg)	CIP	28		S			29		S			24		S		
			Trimethoprim-sulfamethoxazole (1.25/23.75 µg)	SXT	28		S			27		S			29		S		
			Azithromycin (15 µg)	AZM	24		S			23		S			23		S		
			Ampicillin (10 µg)	AMP	20		S			21		S			21		S		
S. aureus ATCC12600	1	1	Penicillin (10 units)	P	38	17.5	S	24.91	42.41	37	34.97	S	32.15	67.12	39	25.54	S	62.25	87.79
			Oxacillin (30 µg)	OX	30		S			31		S			30		S		
			Chloramphenicol * (30 µg)	C	20		S			20		S			20		S		
			Gentamicin (10 µg)	CN	17		S			18		S			13		I		
		2	Tetracycline (30 µg)	TE	32	25.39	S	31.7	57.09	31	39.72	S	60.87	100.59	33	38.16	S	51.9	90.06
			Ciprofloxacin (5 µg)	CIP	29		S			24		S			30		S		
			Trimethoprim-sulfamethoxazole (1.25/23.75 µg)	SXT	29		S			29		S			30		S		
			Azithromycin (15 µg)	AZM	9		R			7		R			8		R		
			Ampicillin (10 µg)	AMP	29		S			29		S			29		S		
	2	1	Penicillin (10 units)	P	38	19	S	23.78	42.78	39	37.03	S	43.49	80.52	36	28.89	S	30.68	59.57
			Oxacillin (30 µg)	OX	29		S			30		S			32		S		
			Chloramphenicol * (30 µg)	C	16		I			17		I			17		I		
			Gentamicin (10 µg)	CN	20		S			20		S			19		S		
		2	Tetracycline (30 µg)	TE	32		S			33		S			33		S		
			Ciprofloxacin (5 µg)	CIP	30		S			30		S			30		S		

ภาพที่ 4.4 ตัวอย่างการวัดเส้นผ่านศูนย์กลางของวงยับยั้งและการแปรผลประเภทของการดื้อยา

สรุปจากการรวบรวมข้อมูลจากทั้ง 3 แหล่ง พบว่าจะมีข้อมูลรวมกันทั้งหมด 287 ภาพ ที่นำมาใช้ในการนำไปสอนโมเดลปัญญาประดิษฐ์ (Artificial Intelligence; AI) โดยเห็นได้จากตาราง 4.1

ตารางที่ 4.1 ตารางสรุปจำนวนข้อมูลแต่ละแหล่ง

แหล่งข้อมูล	จำนวนรูปภาพ	มีการวัดเส้นผ่านศูนย์กลาง	มีการแปรผล (S/I/R)
DRYAD	225	✓	✓
CDS	50	✗	✗
CRA	32	✓	✓
รวม	287	-	-

4.2 การกำหนดกรอบข้อมูล (Data Annotation)

การนำภาพทั้งหมดนำไปเข้าเว็บไซต์ Roboflow ที่เป็นเว็บในการกำหนดกรอบของ Zone of inhibitor และวงยา (Antibiotic) โดยเห็นจากตัวอย่างภาพที่ 4.5 จากข้อมูลการกำหนดกรอบที่ได้จะนำไปใช้สอนโมเดล deep learning 2 ตัว ไดแก่ Yolov11n และ Faster R-CNN เพื่อให้เกิดการเรียนรู้ในการตรวจจับวัตถุ (detect object) รวมถึงใน Roboflow จะนำข้อมูลที่ได้ออกเป็นนามสกุล 2 แบบที่ต่างกัน โดยเป็นสกุล xml ที่ใช้กับโมเดล Faster R-CNN และสกุล yaml ที่ใช้กับโมเดล Yolov11n

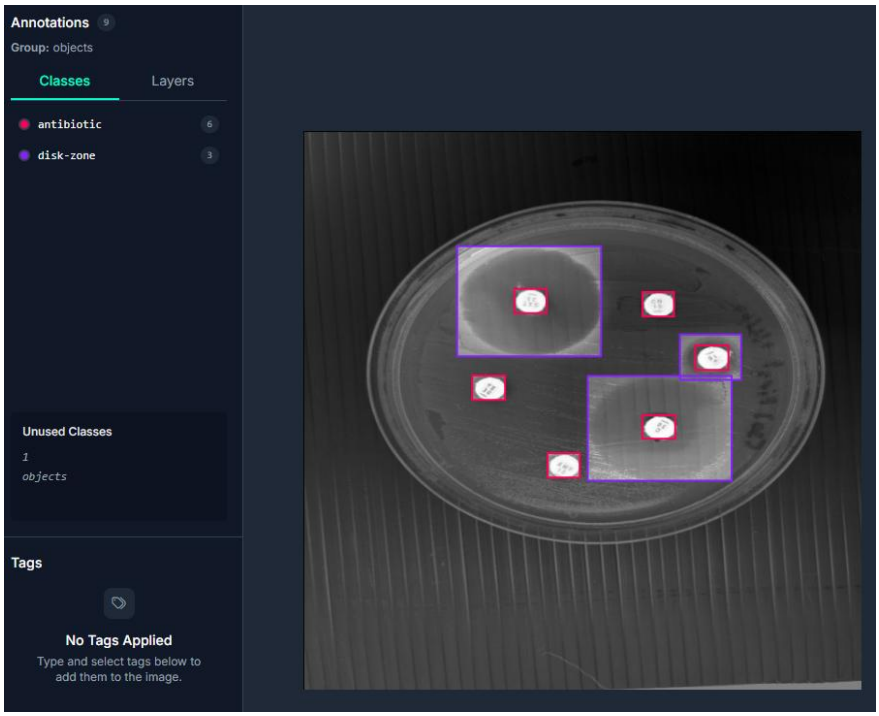

ภาพที่ 4.5 ตัวอย่างการวาดกรอบในจานเพาะเชื้อ พร้อมการแบ่งเป็นกรอบ Antibiotic และ Zone of inhibitor

4.3 ผลจากการเพิ่มข้อมูล (Data Augmentation)

จากการเพิ่มข้อมูลผ่าน Roboflow ทำให้ข้อมูลรูปภาพมีจำนวนที่เพิ่มขึ้นเป็นจำนวน 543 ภาพ โดยแบ่งเป็นข้อมูลเทรน (Train set) จำนวน 433 ภาพ ข้อมูลการตรวจสอบความถูกต้อง (Validation set) จำนวน 55 ภาพ และข้อมูลการทดสอบ 55 ภาพ ตามอัตตราส่วนที่กำหนดไว้ 8:1:1 โดยสามารถเห็นสรุปผลได้ดังภาพที่ 4.6

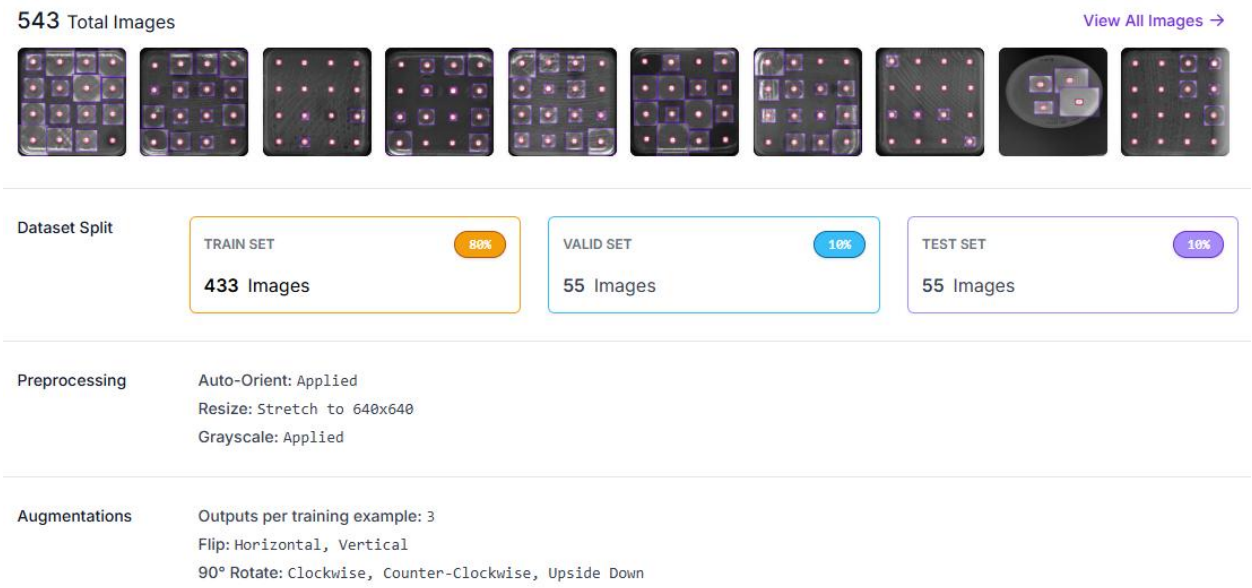

ภาพที่ 4.6 ข้อมูลหลังจากผ่านการ Augmentation

4.4 ผลจากการทดลองโมเดล

เป็นการทดลองจับภาพด้วยโมเดลพื้นฐานและโมเดล deep learning ที่มีความสามารถในการตรวจจับวัตุที่ความแตกต่างกัน โดยใช้ข้อมูลทดสอบจาก 2 แหล่งที่ใช้ทดสอบ ได้แก่ ราชวิทยาลัยจุฬาภรณ์ และ DRYAD ส่วนข้อมูล CDS test ที่ลักษณะที่เหมือนข้อมูลรูปภาพราชวิทยาลัยจุฬาภรณ์จากการที่ใช้จานเป็นวงกลมเหมือนกัน ส่วนจานของ DRYAD มีรูปทรงที่เป็นสี่เหลี่ยม รวมถึงมีจำนวนในการวางยาต่อการทดสอบการดื้อยาของเชื้อที่มีจำนวนมากกว่าของข้อมูลรูปภาพราชวิทยาลัยจุฬาภรณ์

4.4.1 Hough Transform

จากการทดลองพบว่าโมเดลพื้นฐาน Hough Transform สามารถตรวจจับได้แค่วง antibiotic แต่ไม่สามารถตรวจจับวง zone of inhibitor ได้ ในข้อมูลรูปภาพราชวิทยาลัยจุฬาภรณ์ และส่วนรูปภาพจาก

แหล่งข้อมูล DRYAD ไม่สามารถจับวง antibiotic แต่สามารถจับวง zone of inhibitor ได้บางส่วน โดยจะเห็นได้จากรูปที่ 4.7

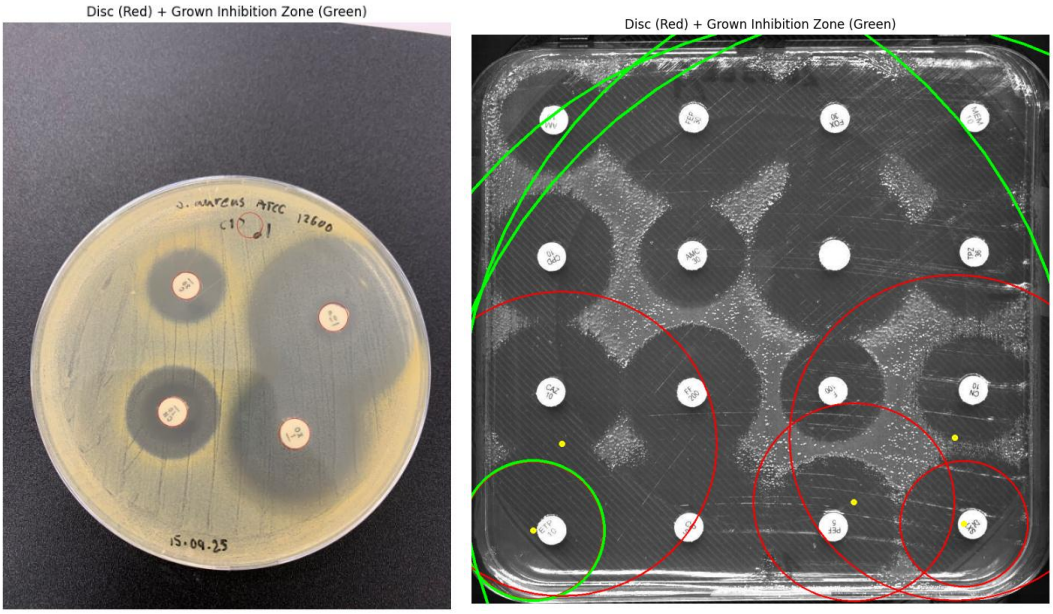

ภาพที่ 4.7 ตัวอย่างผลการจับ Zone of inhibitor ด้วยวิธีการ Hough Transform
จากข้อมูล 2 แหล่ง ได้แก่ ราชวิทยาลัยจุฬาภรณ์ (ซ้าย) และ DRYAD (ขวา)

4.4.2 Faster R-CNN

จากการทดลองพบว่าโมเดล Faster R-CNN สามารถตรวจจับวง antibiotic ได้ทั้งหมด รวมถึงสามารถตรวจจับวง zone of inhibitor ได้เกือบทั้งหมด แต่ยังมีข้อผิดพลาดในการตรวจจับวงที่มีความซับซ้อน โดยจะเห็นได้จากการที่วงมีการทับซ้อนกันหรือเป็นวงที่ไม่เต็มวงกันจากข้อมูลรูปภาพราชวิทยาลัยจุฬาภรณ์ ส่วนรูปภาพจากแหล่งข้อมูล DRYAD สามารถจับวง antibiotic และจับวง zone of inhibitor ได้ทั้งหมด โดยจะเห็นได้จากรูปที่ 4.8

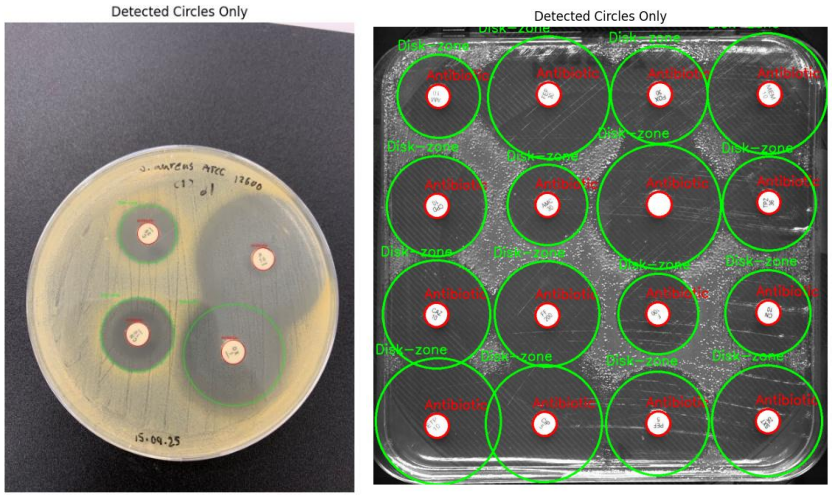

ภาพที่ 4.8 ตัวอย่างผลการจับ Zone of inhibitor ด้วยวิธีการ Faster R-CNN
จากข้อมูล 2 แหล่ง ได้แก่ ราชวิทยาลัยจุฬาภรณ์ (ซ้าย) และ DRYAD (ขวา)

4.4.3 Yolov11n

จากการทดลองพบว่าโมเดล Yolov11n สามารถตรวจจับวง antibiotic ได้ทั้งหมด แต่ไม่สามารถตรวจจับวง zone of inhibitor ได้ทั้งหมดจากวงมีความซับซ้อนจากการที่วงทับกับอีกวงทำให้ไม่สามารถตรวจจับวงได้ จากข้อมูลรูปภาพราชวิทยาลัยจุฬาภรณ์ ส่วนรูปภาพจากแหล่งข้อมูล DRYAD สามารถจับวง antibiotic ได้ทั้งหมด แต่ไม่สามรถจับวง zone of inhibitor ได้ทั้งหมด เนื่องจากวงที่มีความซับซ้อนจากการที่วงมีเส้นขอบไม่เต็มวง รวมถึงมีวงที่มีการทับกัน โดยจะเห็นได้จากรูปที่ 4.8

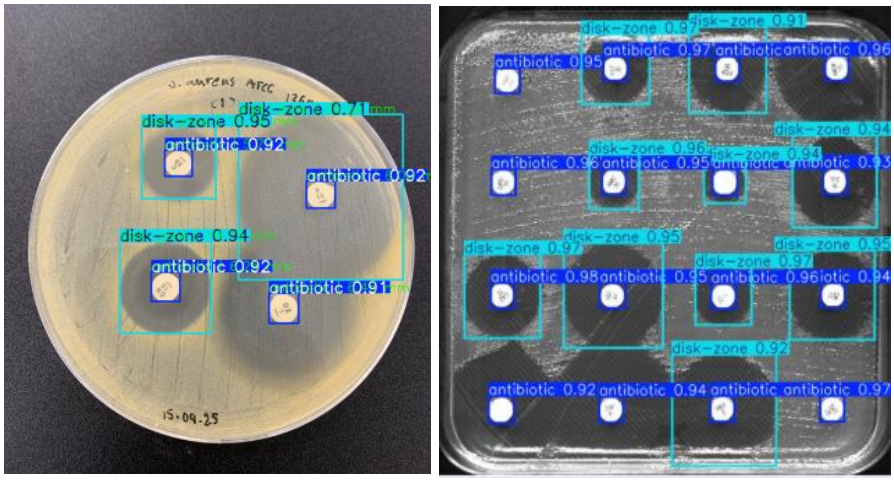

ภาพที่ 4.9 ตัวอย่างผลการจับ Zone of inhibitor ด้วยวิธีการ Yolov11n
จากข้อมูล 2 แหล่ง ได้แก่ ราชวิทยาลัยจุฬาภรณ์ (ซ้าย) และ DRYAD (ขวา)

4.5 ประเมินประสิทธิภาพโมเดล

4.5.1 Faster R-CNN

จากภาพที่ 4.10 การแสดงผลการเรียนรู้ของโมเดล (Training Loss และ Validation Loss) สามารถอธิบายเส้นกราฟเป็น 2 ช่วงได้ดังนี้

1. ช่วงต้นของการเทรน (Epoch 0–1)

ค่า Training Loss เริ่มต้นค่อนข้างสูง เนื่องจากโมเดลยังไม่คุ้นชินกับลักษณะข้อมูล แต่ลดลงอย่างรวดเร็วในช่วงไม่กี่รอบแรก แสดงว่าโมเดลสามารถเรียนรู้ลักษณะของวัตถุในข้อมูลได้ดี ในขณะเดียว กัน Validation Loss ก็ลดลงตามอย่างมีนัยสำคัญ ซึ่งเป็นสัญญาณที่ดีว่าการเรียนรู้ของโมเดลไม่ได้จำเฉพาะชุดเทรน แต่สามารถประยุกต์ใช้กับข้อมูลที่ไม่เคยเห็นได้จริง

2. ช่วงกลางถึงปลายการเทรน (Epoch 2–9)

ทั้ง Training Loss และ Validation Loss มีแนวโน้มลดลงต่อเนื่องจนไปถึงระดับคงที่ (plateau) ประมาณค่า ≈ 0.19–0.20 การที่กราฟของทั้งสองชุดข้อมูลเคลื่อนตัวไปในทิศทางเดียวกัน และมีค่าที่ใกล้เคียงกัน แสดงให้เห็นว่าโมเดล ไม่มีอาการ overfitting อย่างชัดเจน

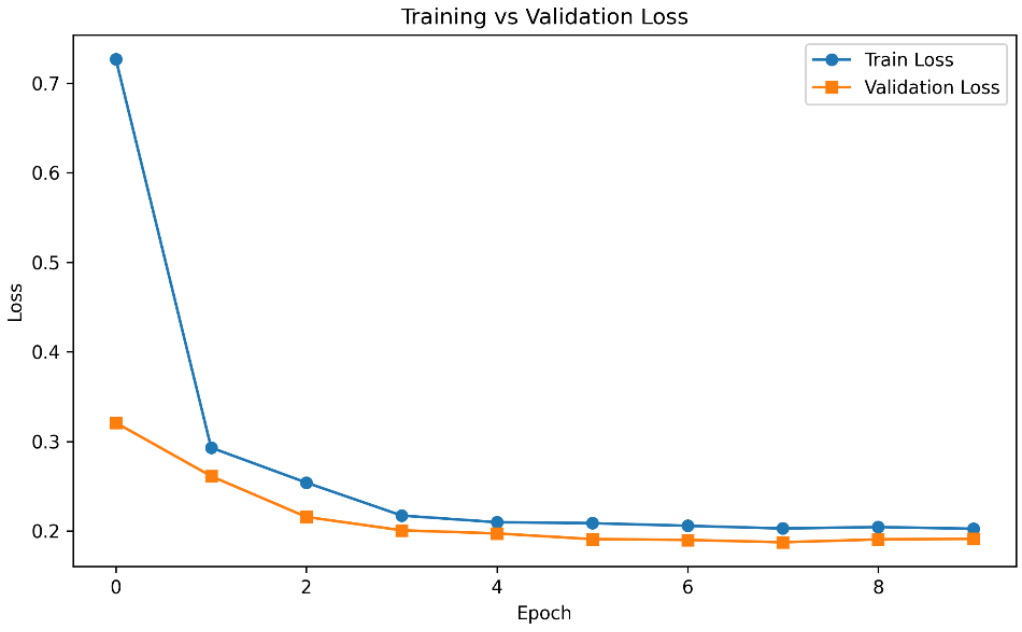

ภาพที่ 4.10 กราฟแสดงการเรียนรู้ของโมเดล (Training Loss และ Validation Loss)

จากภาพที่ 4.11 กราฟแสดงค่า Validation mAP@50 ตลอดช่วงการเทรน สามารถสังเกตได้ว่าโมเดลมีประสิทธิภาพในการตรวจจับวัตถุอยู่ในระดับที่สูงมากตั้งแต่เริ่มต้น โดยค่า mAP@50 อยู่ที่ประมาณ 0.998–0.9984 ซึ่งถือว่าสูงมากสำหรับงานตรวจจับวัตถุ ส่วนในช่วงแรก (Epoch 0-1) ค่าความแม่นยำลดลงเล็กน้อย ซึ่งเป็นลักษณะที่พบได้ทั่วไป เนื่องจากโมเดลเริ่มปรับน้ำหนักจากจุดเริ่มต้น อย่างไรก็ตาม หลังจาก Epoch 2 เป็นต้นไป ค่า mAP@50 มีความคงที่ โดยไม่เพิ่มขึ้นหรือลดลงอย่างมีนัยสำคัญบ่งบอกว่า - - - โมเดลสามารถตรวจจับวัตถุได้อย่างมีประสิทธิภาพตั้งแต่ช่วงต้น การเพิ่ม Epoch มากขึ้นไม่ได้ทำให้ประสิทธิภาพดีขึ้นอย่างมีนัยสำคัญ โมเดลได้เรียนรู้คุณลักษณะที่สำคัญของข้อมูลอย่างเพียงพอแล้ว และไม่มีสัญญาณของ overfitting

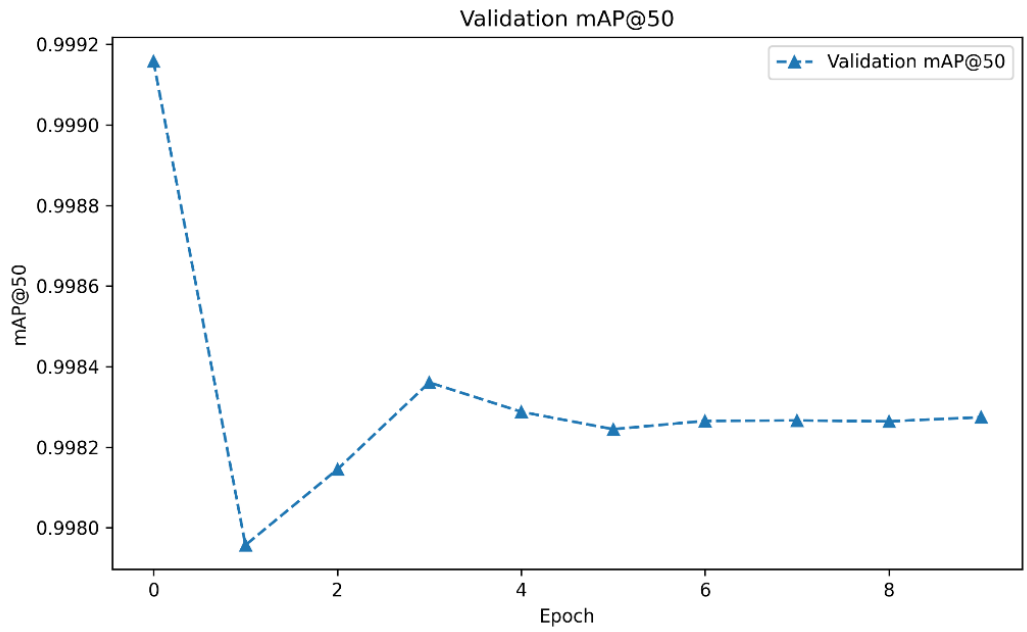

ภาพที่ 4.11 กราฟแสดงค่า Validation mAP@50 แต่ละ Epoch

สรุปจากผลทั้งสองกราฟสามารถสรุปได้ว่าโมเดล Faster R-CNN มีการเรียนรู้ที่มีประสิทธิภาพ โดยค่า Training Loss และ Validation Loss ลดลงอย่างต่อเนื่องและมีความใกล้เคียงกันตลอดการเทรน ซึ่งเป็นสัญญาณว่าการเรียนรู้ของโมเดลมีความเสถียรและไม่เกิดอาการ overfitting ในขณะเดียวกัน ค่า mAP@50 ที่อยู่ในระดับสูงและมีความคงตัวตลอดการเทรน สะท้อนว่าโมเดลสามารถตรวจจับวัตถุได้อย่างแม่นยำตั้งแต่ช่วงต้น และการเพิ่ม epoch เพิ่มเติมไม่น่าจะทำให้ผลดีขึ้นอย่างมีนัยสำคัญ

4.5.2 Yolov11n

จากภาพที่ 4.12 ซึ่งแสดงผลการเรียนรู้ของโมเดล YOLOv11n ตั้งแต่ค่า Trainning loss และ Validation loss ไปจนถึงค่า Precision, Recall และ mAP สามารถสรุปพฤติกรรมของโมเดลได้ดังนี้

1. ค่า Training Loss

กราฟแสดงค่า train/box_loss, train/cls_loss และ train/dfl_loss มีแนวโน้มลดลงอย่างต่อเนื่องตลอดช่วงการเทรน แสดงว่าโมเดลสามารถเรียนรู้ตำแหน่ง (Localization), การจำแนกประเภท (Classification) และการปรับรูปร่างกรอบ (Distribution Focal Loss) ได้ดีขึ้นเรื่อยๆ รวมถึงโมเดลค่อยๆปรับน้ำหนักเพื่อให้สามารถตรวจจับวัตถุได้แม่นยำมากขึ้น

2. ค่า Validation Loss

ในส่วนของ val/box_loss, val/cls_loss และ val/dfl_loss มีแนวโน้มลดลงในลักษณะเดียวกันกับชุดเทรน แม้จะมีความผันผวนอยู่บ้าง (เนื่องจากข้อมูลวาลิเดชันมีความหลากหลายมากกว่า) แต่โดยรวมแล้วค่าลดลงและมีความเสถียรในช่วงท้าย แสดงว่าการเรียนรู้ของโมเดลสามารถทั่วไป (generalize) ได้ดีและไม่มีอาการ overfitting ที่ชัดเจน

3. ค่าประเมินประสิทธิภาพ (Precision, Recall, mAP)

ค่าประเมินประสิทธิภาพของโมเดลในส่วน metrics/precision(B), metrics/recall(B), metrics/mAP50(B) และ metrics/mAP50-95(B) ล้วนมีแนวโน้มพุ่งสูงอย่างรวดเร็วตั้งแต่ช่วงต้น และคงที่ในระดับสูงหลังจากเริ่มต้นการเทรนไม่นาน แสดงให้เห็นว่า

- โมเดลสามารถตรวจจับวัตถุได้อย่างแม่นยำตั้งแต่ช่วงแรกของการเรียนรู้
- ค่า Precision และ Recall ใกล้เคียง 1.0 ชี้ว่าโมเดลทั้ง “ตรวจเจอถูกต้อง” และ “ไม่พลาดวัตถุ”
- ค่า mAP@50 และ mAP@50–95 สูงมาก แสดงถึงคุณภาพโดยรวมที่ดีเยี่ยมในการตรวจจับวัตถุในทุกระดับ IoU

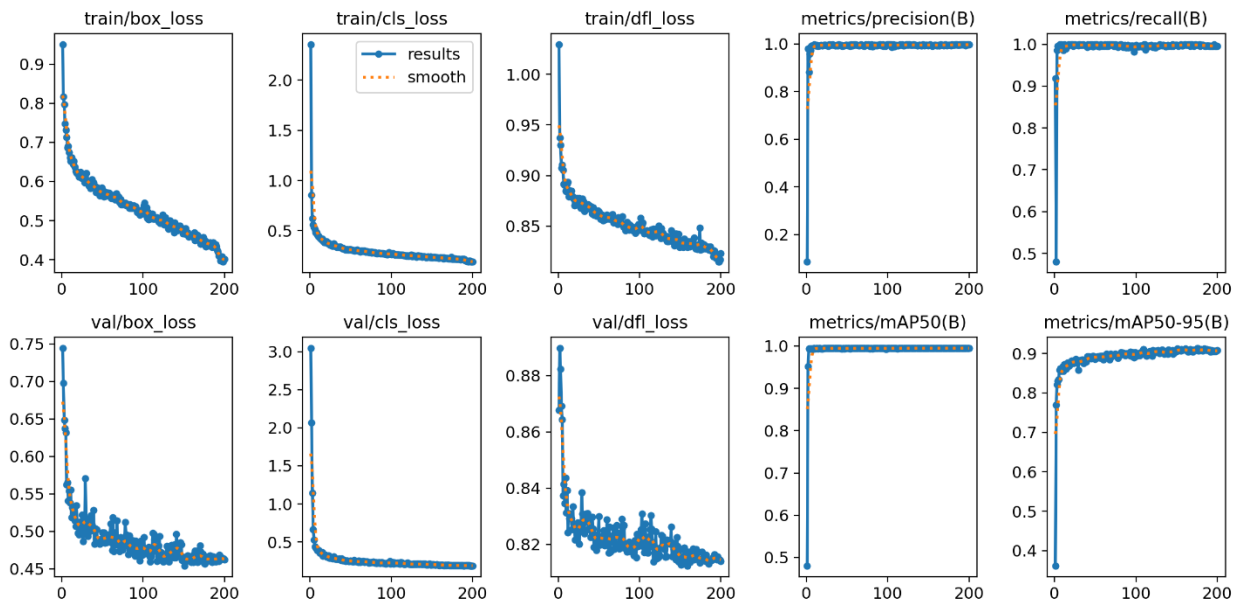

ภาพที่ 4.12 กราฟแสดงค่า Trainning loss, Validation loss,

Precision, Recall และ mAP ของโมเดล Yolov11n

สรุปโมเดล YOLOv11n แสดงให้เห็นถึงการเรียนรู้ที่มีประสิทธิภาพอย่างชัดเจน โดยค่า Loss ทั้งของชุด Trainning และ Validation ลดลงอย่างต่อเนื่อง สะท้อนว่าโมเดลสามารถเข้าใจและเรียนรู้ลักษณะของวัตถุได้ดีขึ้นเรื่อย ๆ ตลอดการเทรน อีกทั้งเส้นของกราฟ Loss และค่าตัวชี้วัดประสิทธิภาพต่างๆ เช่น Precision, Recall และ mAP มีความสอดคล้องกัน ทำให้มั่นใจได้ว่าโมเดลไม่ได้เกิดอาการ overfitting นอกจากนี้ ค่า Precision และ Recall ที่สูงเกือบเต็ม รวมถึงค่า mAP ที่คงที่ในระดับสูง แสดงว่าโมเดลสามารถตรวจจับวัตถุได้อย่างแม่นยำและเสถียรตั้งแต่ช่วงต้นของการเทรน ทำให้ YOLOv11n สามารถบรรลุประสิทธิภาพที่ดีมากได้อย่างรวดเร็วและมีความสามารถทั่วไป (generalization) ที่ดี เหมาะสำหรับงานตรวจจับวัตถุในสภาพข้อมูลจริงเป็นอย่างยิ่ง

4.6 ผลจากการวัดเส้นผ่านศูนย์กลางของ zone of inhibitor

การทดลองนี้ทำขึ้นเพื่อประเมินความสามารถของโมเดล Faster R-CNN และ YoloV11 ในการวัดเส้นผ่านศูนย์กลางของบริเวณยับยั้งเชื้อจุลชีพ (Disk-zone) จากภาพถ่าย โดยใช้วิธีการแปลงค่าจากพิกเซล (pixel) เป็นมิลลิเมตร (mm) จำนวน 2 วิธี ได้แก่ (1) วิธีคำนวณจากเส้นผ่านศูนย์กลางของ antibiotic และ (2) วิธี

คำนวณจากพื้นที่ของ antibiotic ผลลัพธ์ที่ได้ถูกนำมาเปรียบเทียบกับค่าจริงที่วัดด้วยเครื่องมือทางห้องปฏิบัติการ โดยเห็นผลได้จากตารางที่ 4.2

ตารางที่ 4.2 ผลการเปรียบเทียบการการวัดเส้นผ่านศูนย์กลางกับผู้เชี่ยวชาญใน 1 ตัวอย่าง โดยค่า Bias และ Mean Average Error (MAE)

Antibiotic	วัดด้วยมือ (Disk-zone) (mm)	วัดจาก Faster R-CNN (Disk-zone) (mm)		วัดจาก Yolov11 (Disk-zone) (mm)		ผลต่าง			
						Faster R-CNN		Yolov11n	
	ผู้เชี่ยวชาญ ระบาดวิทยา	เส้นผ่าน ศูนย์กลาง	พื้นที่	เส้นผ่าน ศูนย์กลาง	พื้นที่	เส้นผ่าน ศูนย์กลาง	พื้นที่	เส้นผ่าน ศูนย์กลาง	พื้นที่
P	38	30.52	30.06	35.54	30.51	+7.48	+7.94	+2.46	+7.46
OX	30	25.69	25.30	-	-	+4.31	+4.69	-	-
C	20	14.68	14.46	15.75	13.98	+5.32	+5.54	+4.25	+6.01
CN	17	18.50	18.21	19.79	17.55	-1.5	-1.21	-2.79	-0.55
ความคลาดเคลื่อนเฉลี่ย (Bias)						+3.9025	+4.24	-	-
ขนาดคลาดเคลื่อนเฉลี่ย (MAE)						4.6525	4.845	-	-

สรุปพบว่าผลการทดลองในตารางที่ 4.2 แสดงให้เห็นว่า ทั้งสองโมเดลมีแนวโน้มให้ค่าที่สูงกว่าค่าจริงในหลายตัวอย่าง โดยในการคำนวณค่าความคลาดเคลื่อนเฉลี่ย (Bias) พบว่าโมเดล Faster R-CNN มีค่า Bias เท่ากับ +3.9025 mm ในขณะที่ YoloV11 มีค่า Bias เท่ากับ +4.24 mm ซึ่งแสดงว่าทั้งสองโมเดลมีแนวโน้มประเมินค่ามากกว่าค่าจริงเล็กน้อย นอกจากนี้ ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (MAE) ของ Faster R-CNN และ YoloV11 มีค่าใกล้เคียงกันอยู่ที่ 4.8525 mm และ 4.845 mm ตามลำดับ ซึ่งสะท้อนให้เห็นว่าทั้งสองโมเดลมีประสิทธิภาพในการประเมินค่านั้นอยู่ในระดับใกล้เคียงกัน ดังนั้นการทดลองในส่วนนี้แสดงให้เห็นว่าการใช้สูตรคำนวณจากเส้นผ่านศูนย์กลางเป็นวิธีที่เหมาะสมกว่าในการแปลงค่าพิกเซลเป็นมิลลิเมตรเนื่องจากให้ค่าความคลาดเคลื่อนที่เสถียร

และสม่ำเสมอมากกว่า รองรับการทำงานร่วมกับทั้งโมเดล Faster R-CNN และ YoloV11 ได้ดี และมีความเหมาะสมสำหรับการนำไปใช้งานในระบบจริง

4.7 ผลจากการตัวจับตัวอักษรบนยา

ในการทดลองนี้ ผู้วิจัยทำการตรวจจับตัวอักษรที่พิมพ์อยู่บนยาปฏิชีวนะ (antibiotic) ซึ่งเป็นข้อมูลสำคัญที่ใช้ระบุประเภทของยาและปริมาณความเข้มข้น (Concentration) โดยเปรียบเทียบผลลัพธ์ระหว่าง EasyOCR และ TyphoonOCR ซึ่งเป็นวิธี OCR คนละเทคนิค เพื่อประเมินความถูกต้องและความสามารถในการอ่านตัวอักษรที่เอียงหรือหมุนหลายมุม

4.7.1 EasyOCR

จากผลการทดลองของ EasyOCR พบว่ามีข้อผิดพลาดในการระบุคำของประเภทของยาและปริมาณความเข้มข้น โดยสามารถดูได้จากภาพที่ 4.13 ที่ภาพ (A) คำที่ต้องตรวจได้ควรเป็น “C 30” แต่ตัวของ EasyOCR ได้เป็น “6” รวมถึงการระบุยาตัวอื่นๆด้วยที่มีการระบุคำที่ผิดพลาดจากคำจริงที่ควรจะเป็น

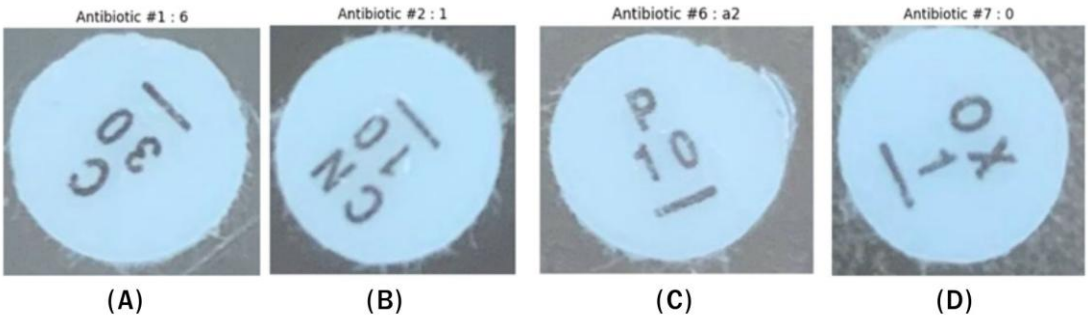

ภาพที่ 4.13 ผลการตรวจจับคำด้วย EasyOCR

4.7.2 TyphoonOCR

จากผลการทดลองของ TyphoonOCR พบว่ามีข้อผิดพลาดในการระบุคำของประเภทของยาและปริมาณความเข้มข้น โดยสามารถดูได้จากภาพที่ 4.14 ที่ภาพ (A) คำที่ต้องตรวจได้ควรเป็น “C 30” แต่ตัวของ EasyOCR ได้เป็น “C 130” ที่มีความใกล้เคียงกับคำจริงที่ระบุบนยา นอกจากนั้นก็มีคำที่ไม่สามารถระบุได้เลยจะแสดงเป็นแค่ “disk zone” จากตัวอย่างที่ (C)

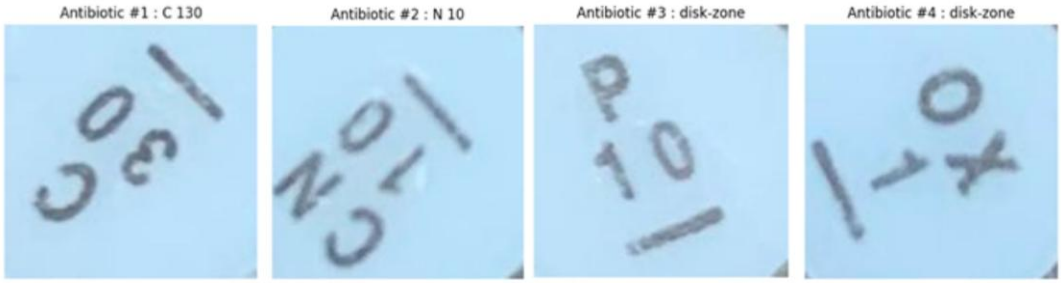

(A) (B) (C) (D)

ภาพที่ 4.14 ผลการตรวจจับคำด้วย TyphoonOCR

สรุปจากวิธีการทั้ง 2 วิธีทำให้สามารถระบุได้ว่าการใช้วิธี TyphoonOCR มีแนวโน้มที่จะสามารถนำไปพัฒนาต่อในการระบุประเภทของยาและความเข้มข้นของยาได้มากกว่าวิธี EasyOCR ที่ไม่สามารถระบุประเภทของยาได้ใกล้เคียงกับคำที่แสดงในภาพได้

ประเมินผลการทำงาน

การประเมินผลการดำเนินงานในภาคการศึกษาที่ 1 (Evaluation of Current Progress)

จากการดำเนินงานตลอดภาคการศึกษาที่ 1 คณะผู้จัดทำขอสรุปผลการประเมินความคืบหน้าโดยเทียบกับแผนการดำเนินงาน (Gantt Chart) ที่วางไว้ ดังนี้

1. ภาพรวมความสำเร็จ (Overall Achievement): การดำเนินงานในภาพรวม "เป็นไปตามแผนที่วางไว้ (On Plan)" โดยคณะผู้จัดทำสามารถดำเนินการในส่วนที่สำคัญที่สุดของภาคการศึกษานี้ได้สำเร็จ คือ

1. การศึกษาและวิเคราะห์เทคโนโลยี: ได้ทำการศึกษาเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence) และการประมวลผลภาพ (Image Processing) ที่เหมาะสมสำหรับการตรวจวัดขนาดวงยับยั้ง (Zone of Inhibition) อย่างละเอียด ทั้ง Machine Learning, Deep Learning และ Reinforcement Learning ตามที่ระบุไว้ในขอบเขตโครงงาน

2. การออกแบบระบบและรวบรวมข้อมูล: ดำเนินการรวบรวมตัวอย่างภาพถ่ายการทดลองภาวะดื้อยา และออกแบบสถาปัตยกรรมระบบ (System Architecture) รวมถึง Use Case Diagram เบื้องต้นได้แล้วเสร็จ ซึ่งเป็นพื้นฐานสำคัญสำหรับการพัฒนาในขั้นต่อไป

3. การเริ่มต้นพัฒนาโมเดล: ได้เริ่มศึกษาและเปรียบเทียบประสิทธิภาพของโมเดลที่จะนำมาใช้ ได้แก่ FAST R-CNN, YOLO และ Hough Transform เพื่อค้นหาวิธีการที่แม่นยำที่สุดในการวัดขนาดวงยับยั้งและแปลผลตามมาตรฐาน CLSI และ EUCAST

2. การปรับเปลี่ยนขอบเขตและแผนงาน (Scope & Plan Adjustments): ในระหว่างการดำเนินงาน มีการปรับเปลี่ยนและขยายรายละเอียดบางส่วนเพื่อให้สอดคล้องกับความต้องการใช้งานจริงมากขึ้น

1. การเน้นความหลากหลายของปัจจัย: จากเดิมที่เน้นเพียงการวัดขนาดวง ได้มีการเพิ่มขอบเขตการศึกษาปัจจัยที่อาจส่งผลกระทบต่อความแม่นยำ (Factors Affecting Accuracy) เช่น สภาพพื้นหลังของจานเพาะเชื้อ (Background), การซ้อนทับกันของวงยับยั้ง (Overlapping Zones), และความสมบูรณ์ของรูปทรงวงกลม ซึ่งส่งผลให้ต้องใช้เวลาในการเตรียมข้อมูล (Data Preprocessing) เพิ่มขึ้นเล็กน้อย แต่ยังอยู่ในกรอบเวลาที่บริหารจัดการได้

2. การปรับปรุงสถาปัตยกรรม: ปรับเปลี่ยนแนวคิดจากการประมวลผลแบบ Standalone มาเป็นการประมวลผลผ่านเว็บแอปพลิเคชัน (Web Application) อย่างเต็มรูปแบบ เพื่อให้สามารถเข้าถึงและใช้งานได้ง่ายจากอุปกรณ์ต่างๆ ตามวัตถุประสงค์ที่ต้องการสนับสนุนโรงพยาบาลในพื้นที่ห่างไกล

3. อภิปรายผลการดำเนินงาน (Discussion of Results)

จากการทดลองและพัฒนาโมเดลปัญญาประดิษฐ์ พบว่าโมเดล YOLOv11m ให้ประสิทธิภาพในการตรวจจับวงยับยั้ง (Inhibition Zone) ที่สูงที่สุดเมื่อเทียบกับโมเดลอื่นๆ โดยมีค่าความแม่นยำเฉลี่ย (mAP@0.5) สูงถึง 95.91% ซึ่งผลลัพธ์นี้สะท้อนให้เห็นว่า สถาปัตยกรรมของ YOLOv11 ที่มีความซับซ้อนระดับกลาง (Medium) มีความเหมาะสมต่อการเรียนรู้คุณลักษณะ (Feature Extraction) ของขอบเขตวงใสและแผ่นยาที่มีความละเอียดอ่อนได้ดีกว่าโมเดลขนาดเล็ก (Nano/Small) ที่อาจลดทอนรายละเอียดภาพมากเกินไป

นอกจากนี้ การตัดสินใจปรับเปลี่ยนสถาปัตยกรรมระบบไปเป็นแบบ Client-Server ถือเป็นจุดเปลี่ยนสำคัญที่ช่วยปลดล็อกข้อจำกัดด้านฮาร์ดแวร์ เพราะการประมวลผลโมเดลที่มีความแม่นยำสูงบนสมาร์ตโฟนโดย

ตรงมักประสบปัญหาความล่าช้าและการใช้พลังงานสูง การย้ายภาระงานประมวลผลไปยัง Backend Server ที่มีประสิทธิภาพสูงกว่า จึงช่วยให้ระบบสามารถรองรับการใช้งานจริงได้อย่างลื่นไหล และยังเอื้อต่อการขยายผล (Scalability) ในอนาคต หากต้องการอัปเดตโมเดลให้ฉลาดขึ้นโดยไม่ต้องบังคับให้ผู้ใช้อัปเดตแอปพลิเคชัน

4. ข้อจำกัดของการศึกษา (Limitations of the Study)

แม้การดำเนินงานจะบรรลุเป้าหมายหลัก แต่ยังคงมีข้อจำกัดบางประการที่พบในระยะนี้ ได้แก่

1. การพึ่งพาอินเทอร์เน็ต: เนื่องจากการปรับมาใช้สถาปัตยกรรมแบบ Client-Server ทำให้ระบบจำเป็นต้องมีการเชื่อมต่ออินเทอร์เน็ตที่เสถียรเพื่อส่งภาพไปประมวลผล ซึ่งอาจเป็นอุปสรรคต่อการใช้งานในพื้นที่ห่างไกลที่สัญญาณไม่ครอบคลุม
2. ความหลากหลายของสภาพแสง: แม้โมเดลจะทำงานได้ดีในชุดข้อมูลทดสอบ แต่ในสภาวะการถ่ายภาพจริงผ่านกล้องจุลทรรศน์ที่มีแสงสะท้อนหรือแสงไม่สม่ำเสมอ อาจส่งผลต่อความแม่นยำในการตรวจจับขอบเขตของวงยับยั้งได้ ซึ่งเป็นประเด็นที่ต้องทำการทดสอบและปรับปรุงเพิ่มเติม (Fine-tuning) ในภาคการศึกษาถัดไป

สรุปผลจากการดำเนินโครงงานในภาคการศึกษาที่ 1 ประสบความสำเร็จตามวัตถุประสงค์ที่ตั้งไว้ โดยคณะผู้จัดทำสามารถคัดเลือกและพัฒนาโมเดลปัญญาประดิษฐ์ (YOLOv11n) ที่มีความแม่นยำสูงถึง 95.91% ซึ่งเพียงพอต่อ การนำไปใช้งานจริงในการอ่านผล AST และได้วางรากฐานสถาปัตยกรรมระบบแบบ Client-Server ที่แข็งแรง พร้อมสำหรับการพัฒนาต่อยอด

ในภาคการศึกษาที่ 2 การดำเนินงานจะมุ่งเน้นไปที่การนำโมเดลนี้ไปประกอบร่างเข้ากับแอปพลิเคชันมือถือ (Mobile Application Development) และระบบ Backend ให้สมบูรณ์ เพื่อให้ได้ระบบที่สามารถสนับสนุนการทำงานของนักเทคนิคการแพทย์ได้อย่างเป็นรูปธรรม และช่วยลดปัญหาความผิดพลาดจากการอ่านผลด้วยตาเปล่าได้อย่างมีประสิทธิภาพ

แผนการดำเนินงานในภาคการศึกษาที่ 2 (Plans for the Next Semester)

เพื่อให้โครงงานสำเร็จลุล่วงตามวัตถุประสงคและสามารถส่งมอบชิ้นงานที่ใช้งานได้จริง คณะผู้จัดทำได้วางแผนการดำเนินงานสำหรับภาคการศึกษาถัดไป โดยแบ่งออกเป็น 3 ระยะ ดังนี้

1. ระยะการพัฒนาโมเดลและระบบ (Model Training & System Development Phase) [มกราคม - มีนาคม]:
    1. AI Model Optimization: พัฒนาและฝึกสอน (Train) โมเดลปัญญาประดิษฐ์ทั้ง 3 แบบ (FAST R-CNN, YOLO, Hough Transform) ให้สมบูรณ์ และทำการทดสอบเปรียบเทียบประสิทธิภาพ (Benchmarking) เพื่อคัดเลือกโมเดลที่ดีที่สุด (Best Model Selection) ในการวัดขนาดวงยับยั้ง
    2. Web Application Development: พัฒนาระบบเว็บแอปพลิเคชันทั้งส่วนหน้า (Frontend) สำหรับผู้ใช้งาน และส่วนหลัง (Backend) สำหรับประมวลผลภาพ โดยเชื่อมต่อกับโมเดล AI ที่คัดเลือกไว้
    3. Standard Integration: นำฐานข้อมูลมาตรฐาน CLSI และ EUCAST เข้าสู่ระบบ เพื่อให้สามารถแปลผล S/I/R (Susceptible, Intermediate, Resistant) ได้อัตโนมัติทันทีหลังการวัด

2. ระยะการทดสอบและปรับปรุง (Testing & Optimization Phase) [เมษายน]:

    1. System Testing: ทดสอบการทำงานของระบบเว็บแอปพลิเคชันในสถานการณ์จำลอง (UAT) โดยทดสอบกับภาพถ่ายจานเพาะเชื้อที่มีความหลากหลาย ทั้งแบบวงชัดเจนและแบบที่มีปัจจัยรบกวน
    2. Accuracy Evaluation: ประเมินความแม่นยำของการวัดเทียบกับการอ่านผลโดยผู้เชี่ยวชาญ (Ground Truth) และปรับจูนค่าพารามิเตอร์ (Fine-tuning) เพื่อลดความคลาดเคลื่อนให้น้อยที่สุด
    3. User Feedback: นำระบบต้นแบบ (Prototype) ไปให้กลุ่มเป้าหมายหรืออาจารย์ที่ปรึกษาทดลองใช้งาน เพื่อรับฟังความคิดเห็นและปรับปรุง UX/UI

3. ระยะการเตรียมส่งมอบและนำเสนอ (Documentation & Presentation Phase) [พฤษภาคม]:

    1. Final Report: จัดทำรายงานโครงงานฉบับสมบูรณ์
    2. Deployment: นำเว็บแอปพลิเคชันขึ้นสู่ระบบออนไลน์ (Deploy) เพื่อให้พร้อมใช้งานจริง
    3. Presentation: จัดเตรียมสื่อนำเสนอและโปสเตอร์สำหรับการสอบป้องกันโครงงานจบ

4. เป้าหมายความสำเร็จ (Key Deliverables): เมื่อสิ้นสุดภาคการศึกษาที่ 2 โครงงานนี้จะส่งมอบ:

    1. โมเดลปัญญาประดิษฐ์ ที่สามารถตรวจจับและวัดขนาดวงยับยั้ง (Inhibition Zone) ได้อย่างแม่นยำ
    2. เว็บแอปพลิเคชัน ที่พร้อมใช้งานสำหรับการวิเคราะห์และแปลผลการดื้อยาตามมาตรฐาน CLSI/EUCAST
    3. รายงานผลการเปรียบเทียบประสิทธิภาพ ของโมเดลต่างๆ และคู่มือการใช้งานระบบฉบับสมบูรณ์

บรรณานุกรม

Ercan, M. & Qiankun, Allen & Sakai, Simon & Miyazaki, Takashi. (2020). Circle detection in images: A deep learning approach. 10.1109/IEEECONF38699.2020.9389048.

Cuevas, E., Wario, F., Zaldivar, D., & Perez, M. (2014). *Circle detection on images using Learning Automata*. arXiv. https://arxiv.org/abs/1405.5406

Bilal, H., Khan, M. N., Khan, S., Shafiq, M., Fang, W., Khan, R. U., Rahman, M. U., Li, X., Lv, Q.-L., & Xu, B. (2025). The role of artificial intelligence and machine learning in predicting and combating antimicrobial resistance. *Computational and Structural Biotechnology Journal, 27*, 423–439. https://doi.org/10.1016/j.csbj.2025.01.006

Pascucci, M., Royer, G., Adamek, J., Asmar, M. A., Aristizabal, D., Blanche, L., Bezzarga, A., Boniface-Chang, G., Brunner, A., Curel, C., Dulac-Arnold, G., Fakhri, R. M., Malou, N., Nordon, C., Runge, V., Samson, F., Sebastian, E., Soukieh, D., Vert, J. P., Ambroise, C., & Madoui, M. A. (2021). AI-based mobile application to fight antibiotic resistance. *Nature communications*, *12*(1), 1173. https://doi.org/10.1038/s41467-021-21187-3

Liao, H., Xie, L., Zhang, N., Lu, J., & Zhang, J. (2025). Advancements in AI-driven drug sensitivity testing research. *Frontiers in cellular and infection microbiology*, *15*, 1560569. https://doi.org/10.3389/fcimb.2025.1560569

Pascucci, M., Royer, G., Adamek, J., Aristizabal, D., Blanche, L., Bezzarga, A., Boniface-Chang, G., Brunner, A., Curel, C., Dulac-Arnold, G., Malou, N., Nordon, C., Runge, V., Samson, F., Sebastian, E., Soukieh, D., Vert, J.-P., Ambroise, C., & Madoui,

M.-A. (2020). *The first AI-based mobile application for antibiotic resistance testing* [Preprint]. bioRxiv. https://doi.org/10.1101/2020.07.23.216929

Fitwi, B. A., Bikila, T., & Fekadu, G. (2020). *Detection and antimicrobial profile of Bacillus cereus in milk from lactating farm animals*. East African Journal of Veterinary and Animal Sciences, 4(2). https://doi.org/10.20372/eajvas.v4i2.388

Jiang, N., Hong, B., Luo, K., Li, Y., Fu, H., & Wang, J. (2023). Isolation of *Bacillus subtilis* and *Bacillus pumilus* with Anti-*Vibrio parahaemolyticus* Activity and Identification of the Anti-*Vibrio parahaemolyticus* Substance. *Microorganisms*, *11*(7), 1667. https://doi.org/10.3390/microorganisms11071667

Rajasekar, S. J. S., Thiyagarajan, S., & Mohamed Ali, S. (2022). Ab.ai - A Novel Automated AI Tool for Reporting Antibiograms. *Studies in health technology and informatics*, *299*, 202–207. https://doi.org/10.3233/SHTI220984

Giske, C. G., Turnidge, J., Cantón, R., Kahlmeter, G., & EUCAST Steering Committee. (2022). Update from the European Committee on Antimicrobial Susceptibility Testing (EUCAST). *Journal of Clinical Microbiology, 60*(3), e00276-21. https://doi.org/10.1128/JCM.00276-21

Humphries, R. M., Ambler, J., Mitchell, S. L., Castanheira, M., Dingle, T., Hindler, J. A., Koeth, L., Sei, K., & CLSI Methods Development and Standardization Working Group of the Subcommittee on Antimicrobial Susceptibility Testing (2018). CLSI Methods Development and Standardization Working Group Best Practices for

Evaluation of Antimicrobial Susceptibility Tests. *Journal of clinical microbiology*, *56*(4), e01934-17. https://doi.org/10.1128/JCM.01934-17

Giske, C. G., Bressan, M., Fiechter, F., Hinic, V., Mancini, S., Nolte, O., & Egli, A. (2024, October 13). *Image dataset of disk diffusion assay scanned with the SIRscan system* [Data set]. University of Zurich. Dryad. https://doi.org/10.5061/dryad.5dv41nsfj

Yu, G.-Y., Lee, G.-W., Hung, Y.-T., Li, S.-C., Ma, Y.-P., Chen, Z.-W., & Hsuan, S.-L. (2025). AI-driven identification and analysis of inhibition zones in disk diffusion tests with the hue contrast method. *Microchemical Journal, 208,* 112459. https://doi.org/10.1016/j.microc.2024.112459

Rajasekar, S. J. S., Thiyagarajan, S., & Mohamed Ali, S. (2022). Ab.ai - A Novel Automated AI Tool for Reporting Antibiograms. *Studies in health technology and informatics, 299,* 202–207. https://doi.org/10.3233/SHTI220984

Mozilla Contributors. (2025, July 9). *HTML: HyperText Markup Language*. MDN Web Docs. https://developer.mozilla.org/en-US/docs/Web/HTML

Qi, Y., Yang, Z., Sun, W., Lou, M., Lian, J., Zhao, W., Deng, X., & Ma, Y. (2021). *A comprehensive overview of image enhancement techniques. Archives of Computational Methods in Engineering.* https://doi.org/10.1007/s11831-021-09587-6

Jasim, W., & Mohammed, R. (2021). A survey on segmentation techniques for image processing. *Iraqi Journal for Electrical and Electronic Engineering, 17*(2), 73–93. https://doi.org/10.37917/ijeee.17.2.10

Yang, Z., Zhang, R., Zhou, Y., He, J., Shi, J., & Zuo, S. (2024). *Summary of document image binarization.* Preprints, 2024011534. https://doi.org/10.20944/preprints202401.1534.v1

Alam, A. (2023). *What is machine learning?* Zenodo. https://doi.org/10.5281/zenodo.8231581

Wang, J. (2023). *A study of the OCR development history and directions of development. Highlights in Science, Engineering and Technology, 72,* 409–415. https://doi.org/10.54097/bm665j77

Purwono, I., Ma'arif, A., Rahmaniar, W., Imam, H., Fathurrahman, H. I. K., Frisky, A., & Haq, Q. M. U. (2023). *Understanding of convolutional neural network (CNN): A review. International Journal of Robotics and Control Systems, 2,* 739–748. https://doi.org/10.31763/ijrcs.v2i4.888

Callebaut, K., Stoefs, A., Emmerechts, K., et al. (2024). *Evaluation of automated disk diffusion antimicrobial susceptibility testing using Radian® in-line carousel. Current Microbiology, 81,* 196. https://doi.org/10.1007/s00284-024-03710-z

Kahlmeter, G., Giske, C. G., Kirn, T. J., & Sharp, S. E. (2019). *Point-counterpoint: Differences between the European Committee on Antimicrobial Susceptibility Testing and Clinical and Laboratory Standards Institute recommendations for reporting antimicrobial susceptibility results. Journal of Clinical Microbiology, 57.* https://doi.org/10.1128/jcm.01129-19

Egger, J., Gsaxner, C., Pepe, A., Pomykala, K. L., Jonske, F., Kurz, M., Li, J., & Kleesiek, J. (2022). Medical deep learning—A systematic meta-review. *Computer Methods and Programs in Biomedicine, 221,* 106874. https://doi.org/10.1016/j.cmpb.2022.106874

Murphy, K. (2025). Reinforcement learning: An overview (Version 4). *arXiv*. https://doi.org/10.48550/arXiv.2412.05265

American Society for Microbiology. (2009, December 8). *Kirby-Bauer Disk Diffusion Susceptibility Test Protocol*. American Society for Microbiology. https://asm.org/protocols/kirby-bauer-disk-diffusion-susceptibility-test-pro

Institute of Medicine (US) Committee on Resource Sharing in Biomedical Research, Berns, K. I., Bond, E. C., & Manning, F. J. (Eds.). (1996). *Resource Sharing in Biomedical Research*. National Academies Press (US). https://www.ncbi.nlm.nih.gov/books/NBK209072/

Lewis, J. S., II, Mathers, A. J., Bobenchik, A. M., Bryson, A. L., Campeau, S., Cullen, S. K., Dingle, T., Esparza, G., Humphries, R. M., Kirn, T. J., Jr., Lutgring, J., Narayanan, N., Palavecino, E., Pierce, V. M., Schuetz, A. N., Sharp, S., Simner, P. J., Tamma, P. D., & Weinstein, M. P. (2025). *M100 | Performance Standards for Antimicrobial Susceptibility Testing, 35th Edition*. Clinical and Laboratory Standards Institute. https://clsi.org/shop/standards/m100/

Department of Medical Sciences. (n.d.). *National Institute of Health*. Retrieved September 20, 2025, from https://nih.dmsc.moph.go.th/data/data/laboratory_central/DMST_Catalogue67.pdf

Shehata, A., Mohammad, S., Abdallah, M. S., & Ragab, M. E. (2015). *A Survey on Hough Transform, Theory, Techniques and Applications*. arXiv. https://doi.org/10.48550/arXiv.1502.02160

Ren, S., He, K., Girshick, R., & Sun, J. (2016). *Faster R-CNN: Towards real-time object detection with Region Proposal Networks* (Version 3). arXiv. https://doi.org/10.48550/arXiv.1506.01497

Khanam, R., & Hussain, M. (2024). *YOLOv11: An overview of the key architectural enhancements*. arXiv. https://doi.org/10.48550/arXiv.2410.17725

Sharma, A., Kumar, V., & Longchamps, L. (2024). Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species. *Smart Agricultural Technology*, *9*, 100648. https://doi.org/10.1016/j.atech.2024.100648

Dhanachandra, N., Manglem, K., & Chanu, Y. J. (2015). *Image segmentation using K-means clustering algorithm and subtractive clustering algorithm*. Procedia Computer Science, 54, 764–771. https://doi.org/10.1016/j.procs.2015.06.090

Siva, P. N., Yamaganti, R., & Sikharam, U. M. (2023). *A review on Python for data science, machine learning and IoT*. https://doi.org/10.13140/RG.2.2.18708.48000

Sharma, A. (2018). *Introduction to HTML (Hyper Text Markup Language) – A review paper*. *International Journal of Science and Research (IJSR), 7*(5), 1337–1339.

Purwono, I., Ma'arif, A., Rahmaniar, W., Imam, H., Fathurrahman, H. I. K., Frisky, A., & Haq, Q. M. U. (2023). Understanding of convolutional neural network (CNN): A review. *International Journal of Robotics and Control Systems*, *2*, 739–748. https://doi.org/10.31763/ijrcs.v2i4.888

Ercan, M., Qiankun, A., Sakai, S., & Miyazaki, T. (2020). Circle detection in images: A deep learning approach. https://doi.org/10.1109/IEEECONF38699.2020.9389048

Giske, C. G., Bressan, M., Fiechter, F., et al. (2024). *Image dataset of disk diffusion assay scanned with the SIRscan system* [Dataset]. Dryad. https://doi.org/10.5061/dryad.5dv41nsfj

JaidedAI. (2024). *EasyOCR* (v1.7.2) [Source code]. GitHub. https://github.com/JaidedAI/EasyOCR

OpenTyphoon.ai. (2025, November 14). *Typhoon OCR* [Software].

https://opentyphoon.ai/model/typhoon-ocr