KING MONGKUT'S UNIVERSITY OF TECHNOLOGY THONBURI

Faculty of Engineering

Department of Computer Engineering

FINAL PROJECT REPORT

An Exploration of Artificial Intelligence for Detection of Inhibition Zones in Antibiotic Susceptibility Testing

Submitted by

Peeraphat Siripathanakun Student ID: 65070505214

Phattaradon Thanaprasitpattana Student ID: 65070505223

Advisors

Assoc. Prof. Dr. Nontapon Leeraj

Assoc. Prof. Dr. Panit Ajchararit

Dr. Kritsana Jaengsamsi

Academic Year 2025

ABSTRACT

Antibiotic resistance is a critical global health challenge that demands accurate and rapid diagnostic methods. The Kirby-Bauer disk diffusion method is the internationally accepted standard for Antimicrobial Susceptibility Testing (AST), yet manual measurement of zone of inhibition (ZOI) diameters remains time-consuming and prone to human error. This project develops an artificial intelligence (AI)-based web application to automate the detection and measurement of inhibition zones from photographs of antibiotic susceptibility testing plates.

The system integrates deep learning object detection models—Faster R-CNN with a ResNet-50 backbone and YOLOv11n—together with classical image processing via Hough Circle Transform, to localize and measure ZOI diameters. An Optical Character Recognition (OCR) pipeline using EasyOCR with preprocessing (global thresholding, adaptive binarization, and image rotation) identifies antibiotic disk labels on the plate. Detected zone diameters are interpreted against CLSI 2025 and EUCAST 2023 breakpoints to classify bacteria as Susceptible (S), Intermediate (I), or Resistant (R).

A dataset of 287 real laboratory images was augmented to 543 training images and supplemented with 2,000 synthetic images to improve model generalization. Experimental results demonstrate that both deep learning models outperform Hough Transform in ZOI detection accuracy. YOLOv11n achieved superior accuracy with a mean absolute error (MAE) of approximately **2.5–2.7 mm** and a mAP@0.5 of 95.91%, significantly outperforming the Faster R-CNN baseline (MAE 4.65 mm). The complete system, including the React frontend, FastAPI backend, and SQLite database, is fully integrated and has been **successfully deployed for production use at the Chulabhorn Royal Academy (CRA)** hospital server. User evaluation by five domain experts yielded an overall usefulness score of 3.60 out of 5.00, confirming the system's readiness for real-world microbiological laboratory workflows.

Keywords: Antimicrobial Susceptibility Testing, Zone of Inhibition, Deep Learning, Object Detection, Faster R-CNN, YOLOv11, Hough Transform, EasyOCR, Image Processing, CLSI, EUCAST, Web Application

บทคัดย่อ

ปัญหาการดื้อยาต้านจุลชีพ (Antibiotic Resistance) เป็นความท้าทายระดับโลกที่ต้องการวิธีการวินิจฉัยที่รวดเร็วและแม่นยำ การทดสอบความไวของเชื้อแบคทีเรียต่อยาปฏิชีวนะด้วยวิธี Kirby-Bauer disk diffusion เป็นมาตรฐานสากลที่ได้รับการยอมรับในระดับนานาชาติ อย่างไรก็ตาม การวัดขนาดเส้นผ่านศูนย์กลางของวงยับยั้ง (Zone of Inhibition: ZOI) ด้วยตนเองนั้นยังคงใช้เวลานานและเสี่ยงต่อความผิดพลาดจากตัวบุคคล (Human Error) โครงงานนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันที่ใช้ปัญญาประดิษฐ์ (AI) เพื่อตรวจจับและวัดขนาดวงยับยั้งจากภาพถ่ายจานเพาะเชื้อโดยอัตโนมัติ

ระบบที่พัฒนาขึ้นได้รวมโมเดลตรวจจับวัตถุแบบ Deep Learning ได้แก่ YOLOv11n (โมเดลหลัก) และ Faster R-CNN ร่วมกับการประมวลผลภาพดิจิทัล (Image Processing) เพื่อระบุตำแหน่งและวัดขนาด ZOI นอกจากนี้ยังใช้ระบบ Optical Character Recognition (OCR) โดย EasyOCR ร่วมกับเทคนิค Preprocessing (Global Thresholding, Adaptive Binarization และ Image Rotation) เพื่อระบุชื่อยาปฏิชีวนะจากรหัสบนแผ่นยา ผลการวัดจะถูกนำไปแปลผลตามมาตรฐาน CLSI 2025 และ EUCAST 2023 เพื่อจำแนกเชื้อแบคทีเรียเป็นกลุ่ม ไวต่อยา (Susceptible: S), ก้ำกึ่ง (Intermediate: I) หรือ ดื้อยา (Resistant: R) โดยอัตโนมัติ

ในการทดลองได้ใช้ชุดข้อมูลภาพจริงจากห้องปฏิบัติการ 287 ภาพ และเพิ่มจำนวนเป็น 543 ภาพผ่านเทคนิค Augmentation ร่วมกับภาพจำลอง (Synthetic Images) อีก 2,000 ภาพ เพื่อเพิ่มความสามารถในการเรียนรู้ของโมเดล ผลการทดสอบพบว่า YOLOv11n มีประสิทธิภาพสูงสุด โดยมีค่าความคลาดเคลื่อนเฉลี่ย (Mean Absolute Error: MAE) อยู่ที่ประมาณ **2.5–2.7 มม.** และมีค่า mAP@0.5 สูงถึง 95.91% ซึ่งดีกว่าโมเดล Faster R-CNN และวิธี Hough Transform อย่างมีนัยสำคัญ ปัจจุบันระบบได้รับการพัฒนาเป็นเว็บแอปพลิเคชันแบบ Full-stack และติดตั้งใช้งานจริง (Production Deployment) บนเครื่องเซิร์ฟเวอร์ของ **วิทยาลัยวิทยาศาสตร์การแพทย์เจ้าฟ้าจุฬาภรณ์ (CRA)** โดยผลการประเมินจากผู้เชี่ยวชาญ 5 ท่าน พบว่าระบบมีความเหมาะสมในการใช้งานจริงในระดับ 3.60 จาก 5.00 คะแนน ซึ่งยืนยันถึงความพร้อมในการสนับสนุนการทำงานในห้องปฏิบัติการจุลชีววิทยาคลินิก

คำสำคัญ: การทดสอบความไวต่อยาต้านจุลชีพ, วงยับยั้ง, ดีพเลิร์นนิง, การตรวจจับวัตถุ, YOLOv11, การประมวลผลภาพ, มาตรฐาน CLSI, มาตรฐาน EUCAST, เว็บแอปพลิเคชัน

CONTENTS

Abstract i

บทคัดย่อ ii

1 บทนำ (Introduction) 1

1.1 ภูมิหลังและที่มาของปัญหา (Background and Problem Statement) 1

1.2 แรงจูงใจ (Motivation) 3

1.3 วัตถุประสงค์ (Objectives) 4

1.4 ขอบเขตของโครงงาน (Project Scope) 5

1.5 ผลที่คาดว่าจะได้รับ (Expected Outcomes) 6

1.6 โครงสร้างของรายงาน (Report Structure) 7

2 งานวิจัยที่เกี่ยวข้องและทฤษฎีพื้นฐาน (Related Work and Background Theory) 8

2.1 การทดสอบความไวต่อยาปฏิชีวนะ (Antibiotic Susceptibility Testing) 8

2.1.1 มาตรฐานทางคลินิก: CLSI และ EUCAST (Clinical Standards: CLSI and EUCAST) 8

2.1.2 ความสำคัญทางคลินิกของความแม่นยำในการวัด (Clinical Significance of Measurement Precision) 9

2.2 Deep Learning สำหรับการตรวจจับวัตถุ (Deep Learning for Object Detection) 10

2.2.1 Faster R-CNN 10

2.2.2 YOLOv11 12

2.2.3 Hough Circle Transform 13

2.3 การจดจำอักขระด้วยแสงสำหรับฉลากแผ่นดิสก์ยาปฏิชีวนะ (Optical Character Recognition for Antibiotic Disk Labeling) 14

2.3.1 EasyOCR และสถาปัตยกรรม CRAFT (EasyOCR and the CRAFT Architecture) 15

2.4 เทคนิคการเตรียมการประมวลผลภาพ (Image Preprocessing Techniques) . . 15

2.5 งานวิจัยที่เกี่ยวข้องในการวิเคราะห์ AST อัตโนมัติ (Related Work in Automated AST Analysis) 17
2.5.1 แนวทาง Deep Learning สำหรับการวิเคราะห์ภาพ AST (Deep Learning Approaches for AST Image Analysis) 17
2.5.2 มาตรฐานการประเมินสำหรับวิธี AST อัตโนมัติ (Evaluation Standards for Automated AST Methods) 18

3 ระเบียบวิธีวิจัย (Methodology) 19
3.1 ภาพรวมสถาปัตยกรรมระบบ (System Architecture Overview) 19
3.2 การรวบรวมและการเตรียมชุดข้อมูล (Dataset Collection and Preparation) . 21
3.2.1 การรวบรวมรูปภาพจริง (Real Image Collection) 21
3.2.2 การเพิ่มข้อมูล (Data Augmentation) 21
3.2.3 การสร้างข้อมูลสังเคราะห์ (Synthetic Data Generation) 22
3.2.4 การแบ่งชุดข้อมูลขั้นสุดท้าย (Final Dataset Split) 22
3.3 การระบุป้ายกำกับ (Annotation) 23
3.4 การฝึกฝนโมเดล (Model Training) 23
3.4.1 Faster R-CNN 23
3.4.2 YOLOv11n 24
3.4.3 Hough Circle Transform 25
3.5 การวัดเส้นผ่านศูนย์กลาง ZOI และการสอบเทียบ (ZOI Diameter Measurement and Calibration) 25
3.6 OCR Pipeline สำหรับการระบุชื่อยาปฏิชีวนะ (OCR Pipeline for Antibiotic Label Recognition) 26
3.6.1 กลยุทธ์การครอบตัดแผ่นยาและการประมวลผลเบื้องต้น (Disk Crop and Preprocessing Strategy) 27
3.7 การติดตั้งระบบและโครงสร้างพื้นฐาน (System Deployment and Infrastructure) 28
3.7.1 สภาพแวดล้อมเซิร์ฟเวอร์และบริการ Backend (Server Environment and Backend Services) 28
3.7.2 Reverse Proxy และความปลอดภัย (Reverse Proxy and Security) 28
3.7.3 การให้บริการ Frontend (Frontend Serving) 28

3.7.4 การประมวลผลหลังการทำงานและการจับคู่ชื่อยาปฏิชีวนะ (Post-Processing and Antibiotic Name Matching) 29
3.8 การจำแนกความไวต่อยา (Susceptibility Classification) 29

4 Results and Discussion 31
4.1 Object Detection Performance 31
4.1.1 Per-Antibiotic Error Analysis 32
4.1.2 YOLOv11n vs. Faster R-CNN: Architectural Explanation . . . 34
4.1.3 Hough Transform Baseline 35
4.1.4 Detection Accuracy (mAP) 36
4.2 Effect of Dataset Size on Training 36
4.2.1 Underfitting at Very Small Dataset Sizes (54 and 274 Images) 37
4.2.2 Overfitting Onset at Intermediate Size (702 Images) 37
4.2.3 Optimal Generalization at Full Dataset (1,884 Images) . . . 37
4.3 OCR Performance 38
4.3.1 Preprocessing Pipeline 39
4.3.2 Comparison Results 40
4.4 Calibration and Pixel-to-mm Conversion 41
4.4.1 The Calibration Problem 41
4.4.2 Calibration Formula 41
4.4.3 Initial vs. Refined Calibration 42
4.5 Processing Time 42
4.5.1 End-to-end Pipeline Timing 42
4.5.2 Clinical Workflow Context 43
4.6 User Evaluation 43
4.6.1 Participant Profile 43
4.6.2 Scenario-based Test Results 44
4.6.3 Usability Ratings (Likert Scale 1–5) 45
4.6.4 Discussion of Accuracy Trust Score (3.20/5.00) 45
4.6.5 Overall Evaluation Summary 46
4.7 Web Application 46

5 บทสรุปและงานในอนาคต (Conclusion and Future Work) 48

5.1 บทสรุป (Conclusion) 48
5.1.1 สรุปโปรเจกต์ (Summary of the Project) 48
5.1.2 สรุปเชิงปริมาณ (Quantitative Summary) 48
5.1.3 สถานะความสำเร็จของโปรเจกต์ (Project Completion Status) . . 49
5.2 ข้อจำกัด (Limitations) 49
5.2.1 ความคลาดเคลื่อนเชิงระบบที่เหลืออยู่ของการสอบเทียบ (Residual Calibration Bias) 50
5.2.2 ความหลากหลายของชุดข้อมูล (Dataset Diversity) 50
5.3 งานในอนาคต (Future Work) 50
5.3.1 การศึกษาความถูกต้องทางคลินิกขนาดใหญ่ (Large-Scale Clinical Validation Study) 50
5.3.2 การใช้ Instance Segmentation สำหรับการปรับแต่งส่วนโค้ง (Instance Segmentation for Ellipse Fitting) 50
5.3.3 การติดตั้งใช้งานบนอุปกรณ์เคลื่อนที่ (Mobile and On-Device Deployment) 51
5.3.4 การศึกษาความถูกต้องทางคลินิก (Clinical Validation Study) . . . 51
5.3.5 โมดูลระบาดวิทยาและแนวโน้มการดื้อยา (Epidemiology and Resistance Trend Module) 51

A แบบสอบถามการประเมินระบบ 57

LIST OF FIGURES

1.1 Representative Kirby-Bauer disk diffusion plate illustrating zones of inhibition (ZOI) around antibiotic-impregnated disks. The diameter of each clearing zone is measured to determine antibiotic susceptibility. 2

2.1 Architecture of Faster R-CNN, showing the shared convolutional backbone, the Region Proposal Network (RPN) producing candidate object regions, and the detection head that classifies and refines each proposal. 11

2.2 Schematic architecture of YOLOv11, illustrating the backbone feature extraction network, the feature pyramid neck for multi-scale detection, and the decoupled detection heads for bounding box regression and class prediction. 12

2.3 Illustration of the Hough Circle Transform. Each edge point votes for a cone of candidate circles in the (x_c, y_c, r) parameter space; genuine circles produce prominent peaks in the accumulator. 14

3.1 Pipeline การวิเคราะห์รูปภาพแบบ End-to-end ของระบบ AST อัตโนมัติ ตั้งแต่การนำเข้าภาพผ่านการตรวจจับ, OCR, การสอบเทียบ และการจำแนกความไวต่อยาตาม Breakpoint 20

3.2 สถาปัตยกรรมระบบโดยรวมของเว็บแอปพลิเคชัน AST อัตโนมัติ แสดงให้เห็นส่วน React frontend, FastAPI backend, AI inference pipeline และชั้นฐานข้อมูล SQLite 20

4.1 ตัวอย่างผลลัพธ์การตรวจจับ ZOI จาก YOLOv11n แสดง Bounding boxes ที่พยากรณ์ได้ (สีเขียว) วางทับบนภาพจานวุ้น ป้ายชื่อยาปฏิชีวนะที่ระบุได้โดย OCR จะแสดงอยู่เหนือแต่ละ Bounding box และขนาดเส้นผ่านศูนย์กลาง ZOI ที่พยากรณ์ได้ในหน่วย mm จะแสดงอยู่ด้านล่าง 34

4.2 การเปรียบเทียบค่า Mean Absolute Error (MAE) ระหว่างวิธีการตรวจจับต่างๆ (ผลลัพธ์เทอม 1) Faster R-CNN diameter-based MAE: 4.6525 mm; area-based MAE: 4.845 mm ค่า MAE ของ YOLOv11n ไม่ได้ถูกรายงานในเทอม 1 จึงถูกเว้นไว้จากกราฟนี้ 35

4.3 กราฟ Training และ Validation loss ในแต่ละขนาดชุดข้อมูล (54, 274, 702, 1884 ภาพ) เส้นทึบแสดงถึง Training loss ส่วนเส้นประแสดงถึง Validation loss ช่องว่างการลู่เข้าแคบลงอย่างเห็นได้ชัดเมื่อขนาดชุดข้อมูลเพิ่มขึ้น 38

4.4 ขั้นตอน Preprocessing ของ OCR ที่ใช้กับภาพตัดแผ่นยา Kanamycin (CN) (a) ภาพตัด RGB ดิบที่มีแสงสะท้อน (Specular highlight) (b) หลังจากผ่านการปรับปรุงด้วย CLAHE — Contrast เฉพาะจุดดีขึ้น (c) หลังจากผ่านการทำ Otsu binarization — ตัวอักษรบนป้ายถูกแยกออกมาเป็นสีดำบนพื้นหลังสีขาว . 40

4.5 คะแนนความพึงพอใจของผู้ใช้งานเฉลี่ยในแต่ละเกณฑ์ความสะดวกในการใช้งาน (n=5) 45

4.6 ภาพหน้าจอ Dashboard ของ Web application แสดงผลการวัด ZOI และผลลัพธ์การจัดกลุ่ม S/I/R แต่ละแถวสอดคล้องกับแผ่นยาปฏิชีวนะหนึ่งแผ่นที่ตรวจพบ คอลัมน์ “Edit” ช่วยให้สามารถแก้ไขผลการวัดแต่ละรายการด้วยมือได้ก่อนที่จะส่งออกรายงาน 47

LIST OF TABLES

3.1 องค์ประกอบของชุดข้อมูลสำหรับการฝึกฝน การตรวจสอบ และการทดสอบโมเดล 22

4.1 ZOI Measurement Results — Per-Antibiotic Comparison (ทุกค่ามีหน่วยเป็น mm) Expert GT คือเส้นผ่านศูนย์กลางที่เป็นเอกฉันท์เพียงค่าเดียวจากผู้เชี่ยวชาญทางคลินิก คอลัมน์ “Diam.” ใช้ความกว้างของ Bounding-box โดยตรง คอลัมน์ “Area” คำนวณเส้นผ่านศูนย์กลางที่มีผลจากพื้นที่ของ Bounding-box Error = โมเดล − Expert GT (ค่าบวก = ประมาณค่าสูงเกินไป) YOLOv11n แสดงให้เห็นถึงความแม่นยำที่เหนือกว่าด้วยค่า Mean Absolute Error (MAE) ประมาณ 2.5–2.7 mm 32

4.2 ตัวชี้วัดความแม่นยำในการตรวจจับ (mAP@0.5, Precision, Recall) สำหรับทั้งสองโมเดล ผลลัพธ์มาจากการประเมินผลเทอม 1 บนชุดข้อมูลทดสอบที่แยกไว้ . . 36

4.3 Validation loss ณ จุดลู่เข้าสำหรับชุดย่อยของขนาดชุดข้อมูลแต่ละระดับ ค่าที่ต่ำกว่าบ่งบอกถึงการทำ Generalization ที่ดีกว่า คอลัมน์ “Gap” รายงานส่วนต่างเชิงสัมบูรณ์ระหว่าง Training loss และ Validation loss ขั้นสุดท้าย 38

4.4 การเปรียบเทียบประสิทธิภาพของ OCR: EasyOCR เทียบกับ TyphoonOCR ภายใต้การทำ Preprocessing ที่แตกต่างกัน “Correct Labels” รายงานจำนวนป้ายชื่อแผ่นยาที่ระบุได้ถูกต้องจากทั้งหมด 4 ป้ายในชุดทดสอบ (P, OX, C, CN) 40

4.5 รายละเอียดเวลาการประมวลผลต่อภาพสำหรับแต่ละขั้นตอนของ Pipeline เวลารายงานเป็นค่าเฉลี่ย ± ส่วนเบี่ยงเบนมาตรฐานจากการทดสอบ 30 ภาพ เวลา Inference ของโมเดลทั้งหมดใช้การเร่งการประมวลผลด้วย GPU 43

4.6 ข้อมูลเบื้องต้นของผู้เข้าร่วมการประเมินผลโดยผู้ใช้งาน 44

4.7 อัตราความสำเร็จของการทดสอบตามสถานการณ์จำลอง (n=5) ภารกิจจะถูกนับว่า “เสร็จสิ้น” หากผู้เข้าร่วมสามารถทำจนจบได้โดยไม่ต้องรับความช่วยเหลือภายในเวลาที่กำหนด 44

4.8 คะแนนความพึงพอใจของผู้ใช้งาน (1 = ไม่เห็นด้วยอย่างยิ่ง, 5 = เห็นด้วยอย่างยิ่ง, n=5) 45

CHAPTER 1: บทนำ (INTRODUCTION)

1.1 ภูมิหลังและที่มาของปัญหา (Background and Problem Statement)

การดื้อยาต้านจุลชีพ (Antimicrobial resistance หรือ AMR) ได้กลายเป็นหนึ่งในภัยคุกคามที่เร่งด่วนและซับซ้อนที่สุดต่อสาธารณสุขโลกในศตวรรษที่ยี่สิบเอ็ด เมื่อแบคทีเรีย ไวรัส เชื้อรา หรือพยาธิพัฒนากลไกที่ทำให้ทนทานต่อยาที่ออกแบบมาเพื่อกำจัดพวกมัน การรักษามาตรฐานย่อมล้มเหลว การติดเชื้อดำเนินต่อไปและแพร่กระจาย ส่งผลให้มีการเสียชีวิตเพิ่มมากขึ้น องค์การอนามัยโลก (World Health Organization หรือ WHO) จัดให้ AMR เป็นหนึ่งในประเด็นสำคัญเร่งด่วนระดับโลก โดยประมาณการว่าการติดเชื้อดื้อยาเป็นสาเหตุโดยตรงของการเสียชีวิตประมาณ 1.27 ล้านคนในปี 2019 เพียงปีเดียว และมีส่วนเกี่ยวข้องทางอ้อมกับการเสียชีวิตเพิ่มเติมเกือบ 5 ล้านคนทั่วโลก [1] หากไม่มีการดำเนินการอย่างเป็นระบบและประสานกัน มีการคาดการณ์ว่า AMR อาจคร่าชีวิตผู้คนได้ถึง 10 ล้านคนต่อปีภายในปี 2050 ซึ่งอาจแซงหน้ามะเร็งในฐานะสาเหตุหลักของการเสียชีวิตทั่วโลก นอกเหนือจากความสูญเสียด้านมนุษยธรรมแล้ว AMR ยังก่อให้เกิดต้นทุนทางเศรษฐกิจมหาศาลจากการนอนโรงพยาบาลที่ยาวนานขึ้น การใช้ยาในลำดับที่สองและสามซึ่งมีราคาแพงกว่า และการลดลงของผลิตภาพแรงงาน

หัวใจสำคัญของการรับมือกับ AMR คือการทดสอบความไวต่อยาต้านจุลชีพ (Antimicrobial Susceptibility Testing หรือ AST) ก่อนเริ่มการรักษาด้วยยาปฏิชีวนะ แพทย์จำเป็นต้องทราบว่ายาชนิดใดยังคงมีประสิทธิภาพต่อเชื้อก่อโรคแบคทีเรียที่ทำให้ผู้ป่วยติดเชื้อ การสั่งจ่ายยาปฏิชีวนะที่เชื้อนั้นดื้ออยู่แล้วไม่เพียงทำให้การรักษาล้มเหลว แต่ยังคัดเลือกให้เชื้อดื้อยาแพร่กระจายมากขึ้นในประชากร ซึ่งยิ่งซ้ำเติมวิกฤตนี้ ดังนั้น AST ที่แม่นยำและรวดเร็วจึงไม่ใช่เพียงขั้นตอนการวินิจฉัย แต่เป็นการแทรกแซงทางสาธารณสุขโดยตรง ความล่าช้าในการได้ผลความไวต่อยา ซึ่งอาจใช้เวลาตั้งแต่ 24 ถึง 72 ชั่วโมงด้วยวิธีเพาะเชื้อแบบดั้งเดิม บังคับให้แพทย์ต้องเริ่มการรักษาแบบครอบคลุมเชื้อกว้าง (empirical broad-spectrum therapy) ซึ่งเป็นแนวปฏิบัติที่เร่งการเกิดและการคัดเลือกเชื้อดื้อยา

วิธี Kirby-Bauer disk diffusion ซึ่งมีการอธิบายและตรวจสอบอย่างเป็นระบบครั้งแรกในทศวรรษ 1960 ยังคงเป็นเทคนิคที่ได้รับการยอมรับอย่างกว้างขวางที่สุดสำหรับ AST ในห้องปฏิบัติการจุลชีววิทยาทางคลินิกและห้องปฏิบัติการอ้างอิงทั่วโลก [2, 3] ความนิยมที่ยั่งยืนมาจากความเรียบง่าย ต้นทุนต่ำ และความน่าเชื่อถือเมื่อดำเนินการอย่างถูกต้อง ในวิธีนี้ จานอาหารเลี้ยงเชื้อ Mueller-Hinton agar จะถูกปลูกเชื้อด้วยสารแขวนลอยแบคทีเรียเป้าหมายมาตรฐาน (โดยทั่วไปจะปรับให้มีความขุ่นตามมาตรฐาน 0.5 McFarland) แผ่นดิสก์กระดาษที่ผลิตในเชิงพาณิชย์ ซึ่งแต่ละแผ่นจะชุ่มด้วยปริมาณยาปฏิชีวนะเฉพาะที่แม่นยำ จะถูกวางบนพื้นผิววุ้นที่ปลูกเชื้อไว้ที่ระยะห่างระหว่างแผ่นดิสก์ที่กำหนดเพื่อป้องกันการซ้อนทับของโซน หลังจากระยะเวลาการฟักตัวข้ามคืนที่ 35–37°C ยาปฏิชีวนะจะแพร่ออกไป

ในแนวรัศมีจากแผ่นดิสก์แต่ละแผ่น สร้างระดับความเข้มข้นในวุ้น ในจุดที่ความเข้มข้นของยาปฏิชีวนะในพื้นที่สูงกว่าค่าความเข้มข้นต่ำสุดที่ยับยั้งเชื้อได้ (minimum inhibitory concentration หรือ MIC) ของแบคทีเรีย การเติบโตของแบคทีเรียจะถูกระงับ ส่งผลให้เห็นเป็นวงใสที่เรียกว่าโซนการยับยั้ง (zone of inhibition หรือ ZOI) ในจุดที่ความเข้มข้นลดลงต่ำกว่า MIC แบคทีเรียจะเติบโตตามปกติ

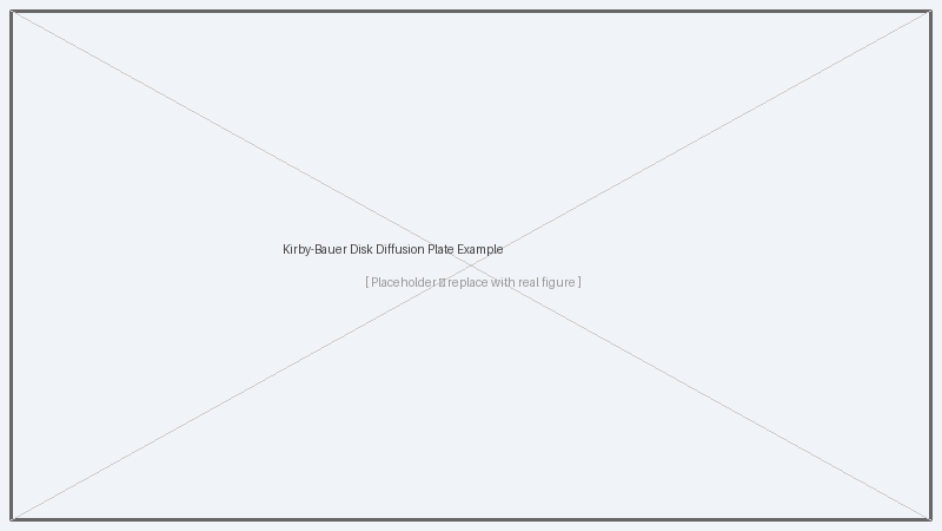

Figure 1.1: Representative Kirby-Bauer disk diffusion plate illustrating zones of inhibition (ZOI) around antibiotic-impregnated disks. The diameter of each clearing zone is measured to determine antibiotic susceptibility.

เส้นผ่านศูนย์กลางของแต่ละ ZOI จะถูกวัดและเปรียบเทียบกับจุดตัดการตีความ (interpretive breakpoints) ที่ตีพิมพ์เพื่อจำแนกสิ่งมีชีวิตที่ทดสอบว่าเป็น ไวต่อยา (Susceptible: S), ระดับปานกลาง (Intermediate: I) หรือ ดื้อยา (Resistant: R) จุดตัดเหล่านี้ได้รับการดูแลและปรับปรุงอย่างเข้มงวดโดยองค์กรระหว่างประเทศหลักสองแห่ง ได้แก่ Clinical and Laboratory Standards Institute (CLSI) ในสหรัฐอเมริกา และ European Committee on Antimicrobial Susceptibility Testing (EUCAST) ในยุโรป [4] CLSI ตีพิมพ์มาตรฐาน M02 ที่ควบคุมขั้นตอนการทดสอบ disk diffusion ในขณะที่ EUCAST ตีพิมพ์ตารางจุดตัดที่แก้ไขเป็นประจำทุกปี ซึ่งได้มาจากแบบจำลอง pharmacokinetic/pharmacodynamic (PK/PD), ค่าจุดตัดทางระบาดวิทยา (epidemiological cutoff values หรือ ECOFFs) และข้อมูลผลลัพธ์ทางคลินิก [5] ทั้งสององค์กรระบุเกณฑ์เส้นผ่านศูนย์กลางเฉพาะสำหรับสายพันธุ์และยาที่ต้องนำไปใช้อย่างถูกต้องเพื่อให้ได้ผลลัพธ์ที่มีความหมายทางคลินิก

แม้การวัดเส้นผ่านศูนย์กลางของวงใสจะดูเป็นงานง่าย แต่ในทางปฏิบัติการวัด ZOI ด้วยตนเองมีโอกาสเกิดข้อผิดพลาดสูง ช่างเทคนิคในห้องปฏิบัติการมักใช้ไม้บรรทัด เวอร์เนียร์คาลิปเปอร์ หรือเทมเพลตเฉพาะในการวัดแต่ละโซน และความแปรปรวนระหว่างผู้สังเกต (inter-observer variability) ยังคงเป็นความท้าทายสำคัญในสาขานี้ [6] ปัจจัยต่าง ๆ เช่น การทับซ้อนบางส่วนของโซนระหว่างแผ่นดิสก์ที่อยู่ใกล้กัน การเจริญแบบไม่สม่ำเสมอหรือแบบ “swarming” ภายในขอบเขตโซน พื้นผิววุ้นที่ไม่สม่ำเสมอ การป้ายเชื้อบนจานที่ไม่สม่ำเสมอ การบ่มที่ไม่เหมาะสม ตลอดจนมุมมองหรือการถ่ายภาพที่

ไม่คงที่ ล้วนทำให้เกิดความแปรปรวนในการวัด แม้ความคลาดเคลื่อนเพียง 1 มิลลิเมตรก็อาจเปลี่ยนผลการตีความทางคลินิกได้ ตัวอย่างเช่น CLSI 2025 กำหนดว่า *Staphylococcus epidermidis* ที่ทดสอบกับ oxacillin (1 μg) และมีเส้นผ่านศูนย์กลาง ZOI ตั้งแต่ 18 mm ขึ้นไปให้จัดเป็นไวต่อยา ขณะที่ 17 mm หรือน้อยกว่าจะถูกจัดเป็นดื้อยา เนื่องจากไม่มีหมวดหมู่ระดับปานกลางสำหรับคู่ยาและสิ่งมีชีวิตนี้ ทุกมิลลิเมตรจึงมีความหมาย นอกจากนี้ ห้องปฏิบัติการที่ประมวลผลตัวอย่างจำนวนมากยังต้องให้ช่างเทคนิควัดโซนหลายสิบโซนต่อกะทำงาน ซึ่งทำให้ความเหนื่อยล้ากลายเป็นอีกแหล่งหนึ่งของข้อผิดพลาด

แพลตฟอร์ม AST อัตโนมัติที่มีอยู่ในปัจจุบัน เช่น ระบบ bioMérieux VITEK 2, BD Phoenix และ Microscan WalkAway ช่วยแก้ปัญหาความท้าทายในการวัดเหล่านี้ผ่านฮาร์ดแวร์เฉพาะและซอฟต์แวร์ที่เป็นกรรมสิทธิ์ ระบบเหล่านี้ให้ผลลัพธ์ที่รวดเร็วและทำซ้ำได้ และมีการใช้กันอย่างกว้างขวางในห้องปฏิบัติการโรงพยาบาลขนาดใหญ่ อย่างไรก็ตาม ระบบเหล่านี้ต้องการการลงทุนจำนวนมาก—มักจะเป็นเงินหลายหมื่นดอลลาร์สหรัฐต่อยูนิต—รวมถึงค่าสารเคมีและค่าบำรุงรักษาอย่างต่อเนื่อง ซึ่งเป็นข้อจำกัดสำหรับคลินิกขนาดเล็ก โรงพยาบาลชุมชน และห้องปฏิบัติการในประเทศที่มีรายได้ต่ำและปานกลาง (low- and middle-income countries หรือ LMICs) สภาพแวดล้อมที่มีทรัพยากรจำกัดเหล่านี้มักเป็นที่ที่ได้รับภาระหนักที่สุดจาก AMR ทำให้เกิดความเหลื่อมล้ำอย่างชัดเจนระหว่างห้องปฏิบัติการที่ต้องการ AST ที่แม่นยำมากที่สุดกับห้องปฏิบัติการที่สามารถจ่ายค่าโซลูชันอัตโนมัติได้

ดังนั้น จึงมีเหตุผลอย่างยิ่งในการพัฒนาเครื่องมือซอฟต์แวร์ต้นทุนต่ำที่ขับเคลื่อนด้วย AI เพื่อวิเคราะห์ภาพถ่ายมาตรฐานของจาน Kirby-Bauer AST งานวิจัยล่าสุดชี้ให้เห็นว่า machine learning และ artificial intelligence สามารถมีบทบาทสำคัญในการทำนายและรับมือกับการดื้อยาต้านจุลชีพ [7] ขณะเดียวกัน ความก้าวหน้าในระบบ AST ที่ขับเคลื่อนด้วย AI ก็กำลังขยายขอบเขตการใช้งานจริงของ AST อัตโนมัติอย่างรวดเร็ว [8] เครื่องมือประเภทนี้สามารถติดตั้งบนฮาร์ดแวร์ทั่วไป เช่น แล็ปท็อปหรือแม้แต่สมาร์ทโฟน โดยไม่จำเป็นต้องพึ่งเครื่องมือเฉพาะทางเพิ่มเติมนอกเหนือจากจานวุ้นเอง จึงมีศักยภาพในการขยายการเข้าถึง AST ที่แม่นยำไปยังสภาพแวดล้อมที่ยังต้องพึ่งการอ่านผลด้วยตนเอง รวมถึงห้องปฏิบัติการที่อ้างอิงแนวทางมาตรฐานระดับชาติ เช่น มาตรฐานที่ดูแลโดยกรมวิทยาศาสตร์การแพทย์และสถาบันวิจัยวิทยาศาสตร์สาธารณสุข (NIH Thailand) [9] โครงงานนี้จึงมุ่งตอบสนองความต้องการดังกล่าวผ่านการพัฒนา ประเมิน และติดตั้งระบบ AI สำหรับการตรวจจับและวัด ZOI แบบอัตโนมัติ

1.2 แรงจูงใจ (Motivation)

ความก้าวหน้าล่าสุดใน deep learning และ computer vision ได้สร้างโมเดลที่มีประสิทธิภาพเทียบเท่าหรือเหนือกว่ามนุษย์ในงานการจดจำรูปภาพและการตรวจจับวัตถุที่หลากหลาย สิ่งที่มีความเกี่ยวข้องเป็นพิเศษกับการวิเคราะห์ภาพ AST คือความก้าวหน้าในการตรวจจับและระบุตำแหน่งของโครงสร้างวงกลมหรือวงรีในพื้นหลังภาพที่ซับซ้อนและไม่เป็นระเบียบ แตกต่างจากชุดข้อมูลภาพธรรมชาติที่วัตถุมีความหลากหลายของรูปร่างอย่างมหาศาล จาน AST นำเสนอขอบเขตภาพที่มีข้อจำกัด: โซนวงกลมบน

พื้นหลังวุ้นที่มีพื้นผิว พร้อมด้วยวัตถุอ้างอิงที่มีขนาดที่ทราบ (แผ่นดิสก์ยาปฏิชีวนะ) ที่ปรากฏในทุกภาพ โครงสร้างขอบเขตนี้ถูกนำมาใช้ประโยชน์โดยการเลือกการออกแบบของโครงงานปัจจุบัน

แรงจูงใจสำหรับโครงงานนี้เกิดขึ้นจากการสังเกตคู่ขนานสองประการ ประการแรก โมเดลการตรวจจับวัตถุที่ใช้ deep learning—โดยเฉพาะตัวตรวจจับแบบสองขั้นตอน เช่น Faster R-CNN และตัวตรวจจับแบบขั้นตอนเดียว เช่น YOLOv11—ได้แสดงความสามารถในการเรียนรู้ที่จะระบุโซนการยับยั้งจากข้อมูลการฝึกอบรมที่ติดป้ายกำกับ แม้ว่าโซนจะทับซ้อนกันบางส่วนหรือแสดงสัณฐานวิทยาที่ผิดปกติก็ตาม ประการที่สอง โซลูชันซอฟต์แวร์ที่ครอบคลุมสำหรับการอ่าน AST ไม่เพียงแต่ต้องตรวจจับโซนเท่านั้น แต่ยังต้องเชื่อมโยงแต่ละโซนเข้ากับแผ่นดิสก์ยาปฏิชีวนะที่เกี่ยวข้องอย่างถูกต้องด้วย หากไม่ทราบว่ายาปฏิชีวนะชนิดใดสร้างโซนใด การวัดเส้นผ่านศูนย์กลางก็จะไม่มีความหมายทางคลินิก ปัญหาการเชื่อมโยงนี้ต้องการการอ่านฉลากตัวอักษรและตัวเลขที่พิมพ์บนแผ่นดิสก์ยาปฏิชีวนะแต่ละแผ่น—ซึ่งเป็นงานที่อยู่ในขอบเขตของการจดจำอักขระด้วยแสง (optical character recognition หรือ OCR)

การรวมกันของกระดูกสันหลังการตรวจจับวัตถุสำหรับการระบุตำแหน่ง ZOI, เครื่องยนต์ OCR สำหรับการอ่านฉลากยาปฏิชีวนะ และฐานข้อมูลจุดตัดที่มีโครงสร้างสำหรับการจำแนกทางคลินิก ก่อให้เกิดรากฐานแนวคิดของระบบที่พัฒนาขึ้นที่นี่ องค์ประกอบแต่ละส่วนนำเสนอความท้าทายทางเทคนิคของตนเอง การตรวจจับวัตถุต้องรับมือกับสัญญาณรบกวนในภาพ แสงที่แปรปรวน และการทับซ้อนของโซน OCR ต้องอ่านข้อความขนาดเล็กที่มีความคมชัดต่ำบนพื้นผิวแผ่นดิสก์ที่มีความโค้ง ซึ่งอาจถูกถ่ายภาพในทิศทางใดก็ได้ ระบบย่อยการปรับเทียบ (calibration) ต้องแปลงการวัดมาตราส่วนพิกเซลเป็นมิลลิเมตรทางกายภาพโดยใช้ขนาดทางกายภาพที่ทราบของแผ่นดิสก์ยาปฏิชีวนะเป็นข้อมูลอ้างอิงภายใน

แรงจูงใจเพิ่มเติมคือโอกาสในการเปรียบเทียบโดยตรงและอย่างเข้มงวดระหว่างแนวทางการประมวลผลภาพแบบคลาสสิกและวิธีการ deep learning สมัยใหม่บนชุดข้อมูลและโปรโตคอลการประเมินเดียวกัน Hough Circle Transform ซึ่งเป็นเทคนิคที่จัดตั้งขึ้นเป็นอย่างดีสำหรับการตรวจจับโครงสร้างวงกลม ให้เกณฑ์มาตรฐานที่มีหลักการซึ่งโมเดล deep learning สามารถนำมาประเมินได้ การเปรียบเทียบดังกล่าวมอบหลักฐานเชิงประจักษ์เกี่ยวกับประโยชน์เชิงปฏิบัติของ deep learning สำหรับงานเฉพาะนี้ นอกเหนือจากที่มีให้จากเกณฑ์มาตรฐานเอนกประสงค์

1.3 วัตถุประสงค์ (Objectives)

โครงงานนี้มีวัตถุประสงค์หลักสี่ประการ:

1. เพื่อศึกษาและดำเนินการตีความผลการทดสอบ Kirby-Bauer disk diffusion ตามมาตรฐาน CLSI 2025 [3] และ EUCAST 2023 [4] เพื่อให้มั่นใจว่าการจำแนกความไวต่อยาของระบบมีพื้นฐานทางคลินิกที่มั่นคง

2. เพื่อพัฒนาและฝึกฝนโมเดล AI—โดยเฉพาะ Faster R-CNN และ YOLOv11n—ที่สามารถตรวจ

จับโซนการยับยั้งและวัดเส้นผ่านศูนย์กลางจากภาพถ่ายจาน AST ด้วยค่าความคลาดเคลื่อนสมบูรณ์เฉลี่ย (mean absolute error หรือ MAE) ที่หรือต่ำกว่าเกณฑ์ที่ยอมรับได้ทางคลินิกที่ 3 mm [6]

3. เพื่อเปรียบเทียบความแม่นยำ ความเร็ว และความทนทานของแนวทางการตรวจจับสามแบบอย่างเข้มงวด: Faster R-CNN (deep learning แบบสองขั้นตอน), YOLOv11n (deep learning แบบขั้นตอนเดียว) และ Hough Circle Transform (เกณฑ์มาตรฐานการประมวลผลภาพแบบคลาสสิก) เพื่อเป็นฐานเชิงปริมาณในการเลือกโมเดลที่มีประสิทธิภาพดีที่สุดสำหรับการติดตั้งใช้งาน

4. เพื่อติดตั้งใช้งานระบบเป็นเว็บแอปพลิเคชันที่ใช้งานได้จริงและหันหน้าเข้าหาผู้ใช้ ซึ่งเหมาะสมสำหรับการใช้งานจริงในสภาพแวดล้อมห้องปฏิบัติการทางคลินิก โดยผสานรวมโมเดลการตรวจจับเข้ากับไปป์ไลน์ OCR และฐานข้อมูลการจำแนกจุดตัดให้เป็นเครื่องมือที่สอดคล้องและเข้าถึงได้

1.4 ขอบเขตของโครงงาน (Project Scope)

ขอบเขตของโครงงานนี้ถูกกำหนดและมีขอบเขตดังนี้:

- **ข้อมูลนำเข้า (Input data):** ระบบยอมรับภาพถ่ายของจานวุ้น Mueller-Hinton ที่ใช้ในการทดลอง Kirby-Bauer AST มาตรฐาน คาดว่าภาพจะถูกถ่ายจากมุมมองจากบนลงล่าง พร้อมด้วยแสงที่สม่ำเสมอและระยะห่างระหว่างกล้องกับจานที่คงที่เพื่อรักษาความสม่ำเสมอของมาตราส่วน ภาพอาจมาจากกล้องในห้องปฏิบัติการ กล้องจุลทรรศน์ทางคลินิก หรือกล้องสมาร์ทโฟนมาตรฐาน

- **โมเดลการตรวจจับ (Detection models):** โครงงานนี้ฝึกฝน ประเมิน และเปรียบเทียบแนวทางการตรวจจับสามแบบ: Faster R-CNN ที่มีกระดูกสันหลังการสกัดคุณลักษณะ ResNet-50, YOLOv11n (รุ่น nano ของ Ultralytics) และ Hough Circle Transform ที่ดำเนินการผ่าน OpenCV แต่ละโมเดลจะได้รับการประเมินบนชุดข้อมูลทดสอบที่แยกไว้ชุดเดียวกันภายใต้เงื่อนไขเดียวกัน

- **เกณฑ์การประเมิน (Evaluation criteria):** ตัวชี้วัดความแม่นยำหลักคือค่าความคลาดเคลื่อนสมบูรณ์เฉลี่ย (MAE) ในหน่วยมิลลิเมตรระหว่างเส้นผ่านศูนย์กลาง ZOI ที่ระบบทำนายและเส้นผ่านศูนย์กลางอ้างอิง (ground-truth) ที่วัดโดยนักจุลชีววิทยาที่ผ่านการฝึกอบรม ตัวชี้วัดรองได้แก่ ความเร็วในการประมวลผล (เฟรมต่อวินาที) และการระลึกในการตรวจจับ (detection recall) เป้าหมาย MAE ที่ยอมรับได้ทางคลินิกคือต่ำกว่า 3 mm

- **การปรับเทียบ (Calibration):** การแปลงพิกเซลเป็นมิลลิเมตรดำเนินการโดยใช้แผ่นดิสก์ยาปฏิชีวนะเป็นตัวอ้างอิงภายในภาพ เนื่องจากเส้นผ่านศูนย์กลางทางกายภาพของแผ่นดิสก์ยาปฏิชีวนะมาตรฐานถูกกำหนดอย่างแม่นยำไว้ที่ 6 mm ตามข้อกำหนดของ CLSI ไม่จำเป็นต้องมีเป้าหมายการปรับเทียบภายนอกหรือไม้บรรทัดในมุมมองของภาพ

- **เว็บแอปพลิเคชัน (Web application):** เว็บแอปพลิเคชันขั้นสุดท้ายรองรับการอัปโหลดภาพจากไฟล์หรือการถ่ายภาพแบบเรียลไทม์ผ่านกล้องที่เชื่อมต่อกับระบบ จากนั้นระบบจะแสดงแดชบอร์ดสรุปผล ซึ่งประกอบด้วยโซนที่ตรวจพบ ฉลากยาปฏิชีวนะจาก OCR ค่าขนาดเส้นผ่านศูนย์กลางที่วัดได้ และผลจำแนก S/I/R ตามมาตรฐาน CLSI หรือ EUCAST ที่ผู้ใช้เลือก ทั้งหมดนี้จะถูกจัดเก็บเป็นประวัติสำหรับการตรวจสอบย้อนหลัง

- **นอกเหนือขอบเขต (Out of scope):** ระบบไม่ได้ทำหน้าที่ระบุชนิดหรือสายพันธุ์ของแบคทีเรีย ผู้ใช้ยังต้องระบุสิ่งมีชีวิตที่กำลังทดสอบ เช่น *Staphylococcus aureus* หรือ *Escherichia coli* เพื่อให้ระบบเลือกใช้จุดตัดที่ถูกต้อง นอกจากนี้ ระบบไม่รองรับการทดสอบแบบ broth microdilution, E-test หรือ AST รูปแบบอื่น และมีวัตถุประสงค์เพื่อช่วยตัดสินใจ ไม่ใช่แทนที่นักจุลชีววิทยาผู้เชี่ยวชาญ

1.5 ผลที่คาดว่าจะได้รับ (Expected Outcomes)

ผลลัพธ์ที่เป็นรูปธรรมที่คาดหวังของโครงงานนี้มีดังนี้:

1. **ไปป์ไลน์การตรวจจับด้วย AI (AI detection pipeline):** โครงงานคาดว่าจะได้ไปป์ไลน์อัตโนมัติแบบครบวงจรสำหรับตรวจจับและวัดเส้นผ่านศูนย์กลาง ZOI จากภาพจาน AST โดยโมเดลที่ดีที่สุดควรทำค่า MAE ได้ต่ำกว่า 3 mm บนชุดทดสอบที่แยกไว้ ซึ่งสอดคล้องกับเกณฑ์การยอมรับทางคลินิกที่รายงานโดย Humphries et al. [6]

2. **การวิเคราะห์โมเดลเชิงเปรียบเทียบ (Comparative model analysis):** โครงงานคาดว่าจะได้ผลเปรียบเทียบเชิงปริมาณของ Faster R-CNN, YOLOv11n และ Hough Circle Transform บนชุดข้อมูลเดียวกัน โดยพิจารณาความแม่นยำ ความเร็ว และความซับซ้อนในการใช้งาน ผลลัพธ์ดังกล่าวจะช่วยสนับสนุนการเลือกแนวทางที่เหมาะสมสำหรับงานวิเคราะห์ภาพทางการแพทย์ที่คล้ายกันในอนาคต

3. **เว็บแอปพลิเคชันที่ติดตั้งใช้งาน (Deployed web application):** เว็บแอปพลิเคชันที่ทำงานได้อย่างสมบูรณ์ซึ่งรวมโมเดลการตรวจจับที่มีประสิทธิภาพดีที่สุด ไปป์ไลน์การจดจำฉลากยาปฏิชีวนะที่ใช้ EasyOCR และฐานข้อมูลการจำแนกจุดตัด CLSI 2025/EUCAST 2023 มอบเวิร์กโฟลว์แบบครบวงจรตั้งแต่การอัปโหลดภาพไปจนถึงรายงานความไวต่อยา

4. **ชุดข้อมูลที่มีคำอธิบายประกอบ (Annotated dataset):** ชุดข้อมูลที่คัดสรรและติดป้ายกำกับของภาพจาน AST จริงจำนวน 287 ภาพ ซึ่งขยายเป็น 543 ภาพผ่านการเพิ่มพูนข้อมูล (augmentation) และเสริมด้วยภาพสังเคราะห์ 2,000 ภาพ เป็นทรัพยากรที่สามารถนำกลับมาใช้ใหม่ได้สำหรับการวิจัยในอนาคตเกี่ยวกับ AST ที่ได้รับความช่วยเหลือจาก AI

1.6 โครงสร้างของรายงาน (Report Structure)

ส่วนที่เหลือของรายงานจัดลำดับดังนี้ บทที่ 2 นำเสนอทฤษฎีพื้นฐานและทบทวนงานวิจัยที่เกี่ยวข้อง ครอบคลุมวิธี Kirby-Bauer AST มาตรฐานทางคลินิก สถาปัตยกรรมและหลักการของโมเดลตรวจจับวัตถุที่ใช้ (Faster R-CNN, YOLOv11n และ Hough Circle Transform) เครื่องยนต์ OCR สำหรับการอ่านฉลากยาปฏิชีวนะ เทคนิคสำคัญด้านการเตรียมและประมวลผลภาพ รวมถึงงานก่อนหน้าที่เกี่ยวข้องกับการวิเคราะห์ภาพ AST แบบอัตโนมัติ บทที่ 3 อธิบายระเบียบวิธีวิจัย ครอบคลุมเวิร์กโฟลว์การรวบรวมและเตรียมชุดข้อมูล ขั้นตอนการติดป้ายกำกับ โปรโตคอลการฝึกโมเดล แนวทางการปรับเทียบ การออกแบบไปป์ไลน์ OCR ตรรกะการจำแนกความไวต่อยา และสถาปัตยกรรมระบบโดยรวม บทที่ 4 นำเสนอผลการทดลอง ได้แก่ ตัวชี้วัดความแม่นยำในการตรวจจับ การทดสอบความเร็ว ประสิทธิภาพของ OCR ตลอดจนการวิเคราะห์แหล่งที่มาของข้อผิดพลาดและการปรับแต่งการสอบเทียบ สุดท้าย บทที่ 5 สรุปผลการศึกษา ข้อจำกัดของงาน และแนวทางสำหรับการพัฒนาต่อในอนาคต

CHAPTER 2: งานวิจัยที่เกี่ยวข้องและทฤษฎีพื้นฐาน (RELATED WORK AND BACKGROUND THEORY)

2.1 การทดสอบความไวต่อยาปฏิชีวนะ (Antibiotic Susceptibility Testing)

การทดสอบ Kirby-Bauer disk diffusion assay ได้รับการอธิบายและกำหนดมาตรฐานอย่างเป็นระบบครั้งแรกโดย Bauer, Kirby, Sherris และ Turck ในปี 1966 และตั้งแต่นั้นมาก็ได้กลายเป็นเทคนิคที่ได้รับการยอมรับอย่างกว้างขวางที่สุดสำหรับการทดสอบความไวต่อยาต้านจุลชีพในห้องปฏิบัติการจุลชีววิทยาทางคลินิกทั่วโลก [2, 3] ความยั่งยืนของวิธีนี้เกิดจากต้นทุนอุปกรณ์ที่ต่ำ ความเรียบง่ายของขั้นตอน และความสามารถในการปรับใช้กับเชื้อก่อโรคแบคทีเรียที่เติบโตในสภาวะที่มีออกซิเจนได้เกือบทุกชนิด วิธีนี้ขึ้นอยู่กับหลักการของการแพร่กระจายของยาปฏิชีวนะผ่านวุ้นกึ่งแข็ง: เมื่อแผ่นดิสก์กระดาษที่ชุ่มด้วยยาปฏิชีวนะถูกวางลงบนพื้นผิวของจานวุ้นที่ปลูกเชื้อไว้ โมเลกุลของยาจะแพร่ออกไปในแนวรัศมีจากแผ่นดิสก์ สร้างระดับความเข้มข้นที่ลดลงแบบเอกซ์โพเนนเชียลตามระยะทาง ในจุดที่ความเข้มข้นของยาปฏิชีวนะในพื้นที่สูงกว่าค่าความเข้มข้นต่ำสุดที่ยับยั้งเชื้อได้ (minimum inhibitory concentration หรือ MIC) ของสิ่งมีชีวิตที่ทดสอบ การแพร่กระจายของแบคทีเรียจะถูกยับยั้ง ทำให้เกิดวงใสทรงกลมบนสนามการเจริญเติบโตของแบคทีเรียที่หนาแน่น

เส้นผ่านศูนย์กลางของโซนการยับยั้ง (zone of inhibition หรือ ZOI) นี้มีความสัมพันธ์แบบผกผันกับ MIC: สิ่งมีชีวิตที่มีความไวสูง (MIC ต่ำ) จะแสดงโซนขนาดใหญ่ ในขณะที่สิ่งมีชีวิตที่ดื้อยาโดยกำเนิดหรือดื้อยาที่ได้รับมาจะแสดงโซนขนาดเล็กหรือไม่มีเลย ความสัมพันธ์ระหว่างเส้นผ่านศูนย์กลาง ZOI และ MIC นี้ไม่ใช่แบบเส้นตรง แต่เป็นไปตามความสัมพันธ์ทางคณิตศาสตร์ที่ขึ้นอยู่กับความลึกของวุ้น ความแรงของแผ่นดิสก์ สัมประสิทธิ์การแพร่ และระยะเวลาการฟักตัว ซึ่งทั้งหมดนี้ได้รับการควบคุมอย่างระมัดระวังโดยโปรโตคอลมาตรฐาน สำหรับการใช้งานทางคลินิก การวัดเส้นผ่านศูนย์กลาง ZOI ที่ต่อเนื่องจะถูกแปลงเป็นการตีความความไวแบบแบ่งประเภท (Susceptible, Intermediate หรือ Resistant) โดยการใช้จุดตัดการตีความ (interpretive breakpoints) ที่ตีพิมพ์ ซึ่งตัวจุดตัดเองได้มาจากข้อมูลทางคลินิกและจุลชีววิทยา วิธีนี้ได้ถูกนำไปใช้กับแบคทีเรียที่มีความเกี่ยวข้องทางคลินิกในวงกว้าง รวมถึง *Bacillus cereus* [10] และ *Bacillus subtilis* [11] ท่ามกลางเชื้อก่อโรคอื่นๆ อีกมากมายที่พบในการปฏิบัติงานในห้องปฏิบัติการตามปกติ

2.1.1 มาตรฐานทางคลินิก: CLSI และ EUCAST (Clinical Standards: CLSI and EUCAST)

จุดตัดการตีความ—เกณฑ์เส้นผ่านศูนย์กลางที่ใช้ในการจำแนกสิ่งมีชีวิตว่าเป็น ไวต่อยา (S), ระดับปานกลาง (I) หรือ ดื้อยา (R)—ได้รับการตีพิมพ์และปรับปรุงเป็นประจำโดยองค์กรกำหนดมาตรฐานระหว่าง

ประเทศหลักสองแห่ง ได้แก่ Clinical and Laboratory Standards Institute (CLSI) ในสหรัฐอเมริกา และ European Committee on Antimicrobial Susceptibility Testing (EUCAST) ในยุโรป [4] แม้ว่าทั้งสององค์กรจะมุ่งเป้าหมายทางคลินิกเดียวกัน แต่แนวทางระเบียบวิธีในการกำหนดจุดตัดนั้นแตกต่างกันในส่วนที่สำคัญ และเกณฑ์ที่ตีพิมพ์สำหรับคู่ยาและสิ่งมีชีวิตเดียวกันอาจแตกต่างกันได้หลายมิลลิเมตร

CLSI ตีพิมพ์มาตรฐาน disk diffusion ในเอกสาร M02 ซึ่งปัจจุบันอยู่ในฉบับที่สิบสี่ [3] ในขณะที่มาตรฐานประสิทธิภาพการทดสอบความไวต่อยายังถูกกำหนดไว้ใน M100 ฉบับที่ 35 [12] จุดตัดถูกกำหนดโดยกลุ่มทำงานสหวิทยาการที่รวบรวมข้อมูลการกระจาย MIC จากคอลเลกชันขนาดใหญ่ของเชื้อแยกทางคลินิก, การจำลอง PK/PD ของการได้รับยาในขนาดยาที่ใช้รักษามาตรฐาน และข้อมูลผลลัพธ์ทางคลินิกจากการทดลองแบบสุ่มที่มีกลุ่มควบคุม หมวดหมู่ระดับปานกลาง (I) ในระบบ CLSI ตามธรรมเนียมเดิมระบุถึงโซนกันชนที่ความไม่แน่นอนทางเทคนิคอาจนำไปสู่การจัดประเภทที่ผิดพลาด แต่รุ่นหลังๆ ได้ปรับตัวให้สอดคล้องกับแนวคิดของ EUCAST เกี่ยวกับหมวดหมู่ “Susceptible, Increased Exposure” (I) มากขึ้น ซึ่งระบุถึงความไวต่อยาเมื่อมีการรับยาในระดับสูงสุดผ่านการปรับปริมาณยาให้เหมาะสม

EUCAST ซึ่งตีพิมพ์ตารางจุดตัดเป็นประจำทุกปีพร้อมหมายเลขเวอร์ชัน (เวอร์ชันปัจจุบันที่อ้างอิงในโครงงานนี้คือ 13.1 [4]) กำหนดจุดตัดจากเป้าหมาย pharmacokinetic/pharmacodynamic (PK/PD), ค่าจุดตัดทางระบาดวิทยา (epidemiological cutoff values หรือ ECOFFs) และข้อมูลผลลัพธ์ทางคลินิก [5] ค่า ECOFFs แสดงถึงขอบบนของการกระจาย MIC สำหรับประชากรแบคทีเรียสายพันธุ์ป่า (wild-type) ที่ไม่มีกลไกการดื้อยาที่ได้รับมา สิ่งมีชีวิตใดๆ ที่มี MIC สูงกว่า ECOFF จะถูกกำหนดให้เป็นสายพันธุ์ที่ไม่ใช่ป่า (non-wild-type หรือ NWT) และสันนิษฐานว่ามีตัวกำหนดการดื้อยา จุดตัดของ EUCAST มักจะรุนแรงกว่าในการแยกประชากรที่ไวต่อยาออกจากประชากรที่ดื้อยา ซึ่งสะท้อนถึงกรอบงานทางเภสัชวิทยาของยุโรปที่แตกต่างจากมาตรฐานของสหรัฐอเมริกา [13] จุดตัดทั้งสองชุดได้รับการดำเนินการในฐานข้อมูลของระบบปัจจุบัน ช่วยให้ห้องปฏิบัติการสามารถเลือกมาตรฐานที่เหมาะสมตามบริบทด้านกฎระเบียบและทางคลินิกของตน

2.1.2 ความสำคัญทางคลินิกของความแม่นยำในการวัด (Clinical Significance of Measurement Precision)

ผลที่ตามมาทางคลินิกของข้อผิดพลาดในการวัดในวิธี disk diffusion นั้นส่งผลโดยตรงและอาจรุนแรง เนื่องจากจุดตัดถูกแสดงเป็นเกณฑ์จำนวนเต็มในหน่วยมิลลิเมตร ข้อผิดพลาดในการวัดเพียงมิลลิเมตรเดียวสามารถเปลี่ยนการจำแนกจากไวต่อยาเป็นดื้อยาหรือในทางกลับกัน การจำแนกที่ผิดพลาดนี้มีสองรูปแบบที่อันตราย: ความไวต่อยาเท็จ (false susceptibility: การจัดประเภทสิ่งมีชีวิตที่ดื้อยาว่าไวต่อยา) นำไปสู่ความล้มเหลวในการรักษาและอาจส่งผลถึงชีวิต การดื้อยาเท็จ (false resistance: การจัดประเภทสิ่งมีชีวิตที่ไวต่อยาว่าดื้อยา) นำไปสู่การขยับไปใช้ยาในลำดับที่สองหรือสามโดยไม่จำเป็น ซึ่งส่ง

ผลต่อแรงกดดันในการคัดเลือกเชื้อดื้อยาและต้นทุนที่สูงขึ้น Humphries et al. [6] กำหนดค่าความคลาดเคลื่อนสมบูรณ์เฉลี่ยที่น้อยกว่า 3 mm เป็นขอบเขตของความยอมรับได้ทางคลินิกสำหรับเครื่องมือวัด AST อัตโนมัติ และเกณฑ์นี้ทำหน้าที่เป็นเป้าหมายประสิทธิภาพหลักสำหรับโครงงานปัจจุบัน

2.2 Deep Learning สำหรับการตรวจจับวัตถุ (Deep Learning for Object Detection)

การตรวจจับวัตถุ (Object detection) ใน computer vision เป็นงานที่ดำเนินการระบุตำแหน่งและจำแนกวัตถุหนึ่งชิ้นหรือมากกว่าภายในภาพเดียวพร้อมกัน Machine learning ตามคำจำกัดความกว้างๆ รวมถึงกระบวนทัศน์การเรียนรู้แบบมีผู้สอน (supervised), แบบไม่มีผู้สอน (unsupervised) และการเรียนรู้แบบเสริมกำลัง (reinforcement learning) [14, 15] ซึ่ง supervised deep learning ได้รับการพิสูจน์แล้วว่ามีประสิทธิภาพสูงสุดสำหรับงานการจดจำภาพ Convolutional Neural Networks (CNNs) ก่อให้เกิดกระดูกสันหลังของตัวตรวจจับวัตถุสมัยใหม่ส่วนใหญ่ [16] และการทบทวนแอปพลิเคชัน deep learning ทางการแพทย์อย่างเป็นระบบได้ยืนยันความเหมาะสมสำหรับงานการวิเคราะห์ภาพทางคลินิกที่หลากหลาย [17] ตัวตรวจจับต้องส่งออกข้อมูลสำหรับวัตถุแต่ละชิ้นที่ตรวจพบ ทั้ง bounding box ที่ระบุขอบเขตเชิงพื้นที่ของวัตถุและป้ายกำกับคลาสที่ระบุหมวดหมู่ นี่เป็นสิ่งที่ซับซ้อนกว่าการจำแนกรูปภาพ (image classification) พื้นฐานที่กำหนดป้ายกำกับเดียวให้กับรูปภาพทั้งหมด เนื่องจากจำนวนและตำแหน่งของวัตถุไม่ทราบล่วงหน้าและต้องสรุปจากเนื้อหาในภาพ แนวทาง Deep learning ได้ครอบงำเกณฑ์มาตรฐานการตรวจจับวัตถุนับตั้งแต่การตีความครอบครัว Region-based CNN (R-CNN) และโมเดล YOLO ซึ่งมีการปรับปรุงทั้งความแม่นยำและความเร็วในการประมวลผลอย่างต่อเนื่อง

ตัวตรวจจับวัตถุแบบ deep learning สมัยใหม่โดยทั่วไปจะแบ่งออกเป็นสองตระกูลสถาปัตยกรรม: ตัวตรวจจับแบบสองขั้นตอน (two-stage detectors) ซึ่งขั้นแรกจะสร้างข้อเสนอภูมิภาค (region proposals) แล้วจึงจำแนกข้อเสนอแต่ละรายการ และตัวตรวจจับแบบขั้นตอนเดียว (one-stage หรือ single-shot detectors) ซึ่งทำนาย bounding boxes และความน่าจะเป็นของคลาสโดยตรงในการส่งต่อข้อมูลผ่านเครือข่ายเพียงครั้งเดียวเหนือภาพเต็ม แต่ละตระกูลนำเสนอข้อดีข้อเสียที่แตกต่างกันระหว่างความแม่นยำในการตรวจจับ ต้นทุนการคำนวณ และความหน่วงในการประมวลผล

2.2.1 Faster R-CNN

Faster R-CNN (Region-based Convolutional Neural Network) ถูกนำเสนอโดย Ren et al. ในปี 2015 เป็นความก้าวหน้าครั้งสำคัญที่รวมการสร้างข้อเสนอภูมิภาคเข้ากับหัวการตรวจจับให้เป็นเครือข่ายเดียวที่สามารถฝึกฝนแบบครบวงจร (end-to-end) [18] ก่อนหน้า Faster R-CNN ไปป์ไลน์ของ R-CNN และ Fast R-CNN ต้องการขั้นตอนการค้นหาแบบเลือกเฟ้น (selective search) ที่แยกจากกันและมีต้นทุนการคำนวณสูงเพื่อสร้างข้อเสนอภูมิภาค ซึ่งเป็นคอขวดของความเร็วในการประมวลผล Faster R-CNN แทนที่สิ่งนี้ด้วย Region Proposal Network (RPN) ที่ใช้กระดูกสันหลังแบบคอนโวลูชันร่วมกับหัว

การตรวจจับ ทำให้สามารถสร้างข้อเสนอได้เกือบเรียลไทม์

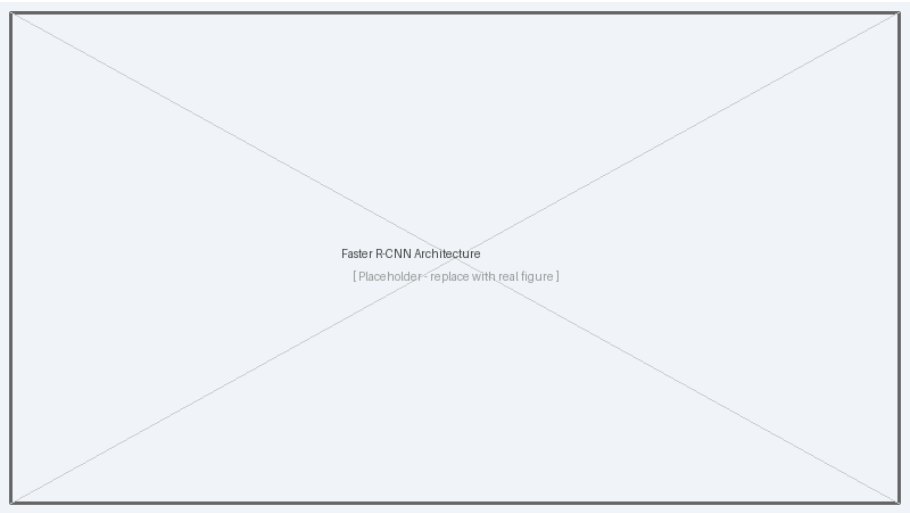

Figure 2.1: Architecture of Faster R-CNN, showing the shared convolutional backbone, the Region Proposal Network (RPN) producing candidate object regions, and the detection head that classifies and refines each proposal.

สถาปัตยกรรม Faster R-CNN ทำงานในสองขั้นตอน ในขั้นตอนแรก เครือข่ายคอนโวลูชันกระดูกสันหลัง (ในโครงงานนี้ใช้ ResNet-50 [19]) จะสกัดแผนผังคุณลักษณะเชิงพื้นที่ที่เข้มข้นจากรูปภาพอินพุตแบบเต็ม จากนั้น RPN จะเลื่อนเครือข่ายขนาดเล็กไปบนแผนผังคุณลักษณะนี้ และในแต่ละตำแหน่งเชิงพื้นที่ จะทำนายคะแนนความเป็นวัตถุ (objectness scores) และค่าชดเชยการถดถอย bounding box สำหรับชุดของ anchor boxes ที่กำหนดไว้ล่วงหน้าซึ่งมีมาตราส่วนและอัตราส่วนภาพที่หลากหลาย Anchor boxes ที่มีคะแนนสูงกว่าเกณฑ์ความเป็นวัตถุจะถูกเก็บไว้เป็นข้อเสนอภูมิภาค (โดยทั่วไปคือ 256–512 ต่อภาพหลังจากทำ non-maximum suppression) ในขั้นตอนที่สอง การดำเนินการ RoI Pooling (หรือ RoI Align) จะสกัดเวกเตอร์คุณลักษณะขนาดคงที่สำหรับแต่ละข้อเสนอจากแผนผังคุณลักษณะกระดูกสันหลังที่แชร์ร่วมกัน และหัวการจำแนกประเภทที่เชื่อมต่ออย่างสมบูรณ์จะกำหนดป้ายกำกับคลาสและปรับแต่ง bounding box สำหรับแต่ละภูมิภาค

การใช้ ResNet-50 เป็นกระดูกสันหลังการสกัดคุณลักษณะมีความเหมาะสมอย่างยิ่งสำหรับโครงงานนี้ He et al. แสดงให้เห็นว่าการเชื่อมต่อแบบเรซิดูอัล (residual connections)—การเชื่อมต่อทางลัดที่ข้ามเลเยอร์คอนโวลูชันหนึ่งเลเยอร์หรือมากกว่า—ช่วยให้สามารถฝึกเครือข่ายที่ลึกขึ้นอย่างมีนัยสำคัญโดยไม่มีปัญหาการเสื่อมถอยของความชัน (gradient degradation) ที่เคยจำกัดความลึกไว้ [19] ResNet-50 ประกอบด้วย 50 เลเยอร์ที่จัดระเบียบเป็นบล็อกเรซิดูอัล และการฝึกอบรมล่วงหน้า (pretraining) บน ImageNet ให้การเริ่มต้นของคุณลักษณะระดับต่ำ เช่น ขอบและพื้นผิว และคุณลักษณะรูปร่างระดับกลางที่ถ่ายโอนมายังขอบเขต AST ได้อย่างมีประสิทธิภาพ แม้ว่าจะมีรูปภาพ AST ที่ติดป้ายกำกับจำนวนค่อนข้างน้อยก็ตาม กระดูกสันหลัง ResNet-50 ในโครงงานนี้เริ่มต้นด้วยน้ำหนักที่ฝึกล่วงหน้าจาก ImageNet และปรับจูน (fine-tuned) แบบครบวงจรบนชุดข้อมูล AST

Faster R-CNN ได้รับการยอมรับในด้านความแม่นยำในการตรวจจับที่สูง โดยเฉพาะอย่างยิ่งในฉากที่ซับซ้อนซึ่งมีวัตถุที่ทับซ้อนกันหรืออยู่กันอย่างหนาแน่น—ซึ่งเป็นคุณลักษณะที่เกี่ยวข้องโดยตรงกับจาน AST ที่โซนจากแผ่นดิสก์ที่อยู่ติดกันอาจทับซ้อนกันบางส่วน สถาปัตยกรรมแบบสองขั้นตอนช่วยให้หัวการจำแนกประเภททำงานบนข้อเสนอที่มีคุณภาพสูงและได้รับการขัดเกลาเชิงพื้นที่ แทนที่จะเป็นตารางที่หนาแน่น ซึ่งช่วยลดอัตราการตรวจจับผิดพลาด (false positive) ข้อจำกัดหลักของ Faster R-CNN คือความเร็วในการประมวลผล: ไปป์ไลน์แบบสองขั้นตอนนำมาซึ่งความหน่วงที่ยอมรับได้สำหรับการวิเคราะห์แบบออฟไลน์ แต่อาจจำกัดปริมาณการประมวลผลแบบเรียลไทม์

2.2.2 YOLOv11

โมเดล YOLO (You Only Look Once) เป็นตัวตรวจจับแบบขั้นตอนเดียวที่กำหนดรูปแบบการตรวจจับวัตถุใหม่ให้เป็นปัญหาการถดถอย (regression) แบบรวมศูนย์ แทนที่จะสร้างข้อเสนอภูมิภาคและจำแนกแยกกัน โมเดล YOLO จะทำนายพิกัด bounding box และความน่าจะเป็นของคลาสโดยตรงจากรูปภาพเต็มในการส่งต่อข้อมูลผ่านเครือข่ายเพียงครั้งเดียว [20, 21] การออกแบบนี้ช่วยขจัดขั้นตอนข้อเสนอภูมิภาคออกไปทั้งหมด ทำให้สามารถประมวลผลได้เร็วขึ้นอย่างมาก โดยแลกมาด้วยความแม่นยำในวัตถุขนาดเล็กหรือวัตถุที่ทับซ้อนกันอย่างหนาแน่นในเวอร์ชันแรกๆ การศึกษาเชิงเปรียบเทียบได้ยืนยันถึงประสิทธิภาพที่สามารถแข่งขันได้ของ YOLOv11 เมื่อเทียบกับรุ่นก่อนๆ และ Faster R-CNN ในงานการตรวจจับที่หลากหลาย [22]

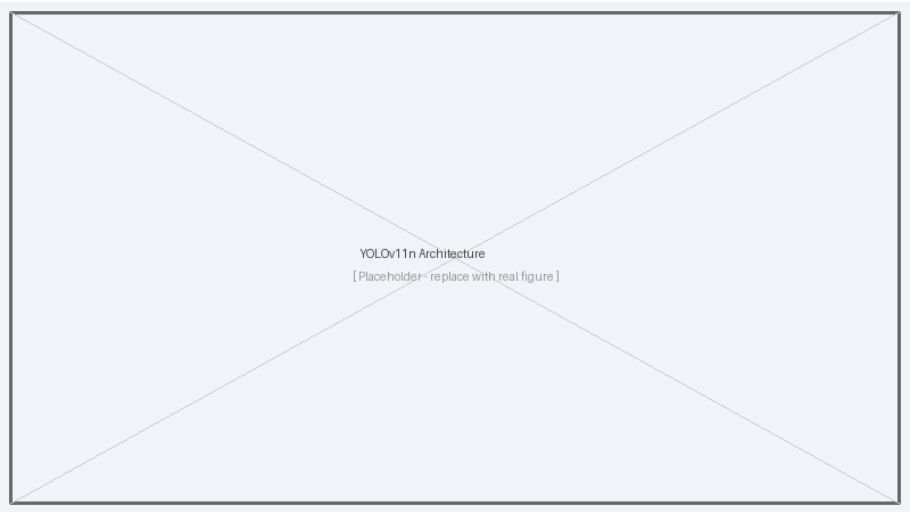

Figure 2.2: Schematic architecture of YOLOv11, illustrating the backbone feature extraction network, the feature pyramid neck for multi-scale detection, and the decoupled detection heads for bounding box regression and class prediction.

YOLOv11 ซึ่งเป็นเวอร์ชันล่าสุดในตระกูล YOLO ในขณะที่ทำโครงงานนี้และพัฒนาโดย Ultralytics ได้รวมความก้าวหน้าทางสถาปัตยกรรมหลายประการเหนือรุ่นก่อนหน้า [20] กระดูกสันหลังใช้บล็อก C3k2 ที่ปรับปรุงใหม่ (การออกแบบคอนโวลูชันที่ปรับพารามิเตอร์ใหม่) เพื่อเพิ่มประสิทธิภาพ

การสกัดคุณลักษณะ ส่วนคอ (neck) ใช้ Path Aggregation Feature Pyramid Network (PA-FPN) เพื่อหลอมรวมคุณลักษณะจากมาตราส่วนกระดูกสันหลังหลายระดับ ช่วยให้ตรวจจับวัตถุได้หลายขนาด ตั้งแต่แผ่นดิสก์ยาปฏิชีวนะขนาดเล็กไปจนถึงโซนการยับยั้งขนาดใหญ่ที่อาจครอบคลุมส่วนสำคัญของจาน หัวการตรวจจับถูกแยกออก (decoupled) โดยมีกิ่งก้านที่แยกจากกันสำหรับการทำนายการถดถอย bounding box และความน่าจะเป็นของคลาสอย่างเป็นอิสระ ซึ่งแสดงให้เห็นว่าช่วยปรับปรุงการลู่เข้า (convergence) และความแม่นยำในตัวตรวจจับแบบขั้นตอนเดียว

YOLOv11 มีให้เลือกห้าขนาด (n, s, m, l, x) ที่ให้ทางเลือกต่อเนื่องระหว่างความสามารถของโมเดลและความเร็วในการประมวลผล ในโครงงานนี้ได้เลือกใช้รุ่น nano (n) หรือ YOLOv11n เพื่อให้ความสำคัญกับความเร็วในการประมวลผลและความเหมาะสมสำหรับการติดตั้งใช้งานในอนาคตบนฮาร์ดแวร์ที่มีทรัพยากรจำกัด เช่น เวิร์กสเตชันห้องปฏิบัติการที่ไม่มี GPU เฉพาะ หรือฮาร์ดแวร์ปลายทาง (edge hardware) แม้จะเป็นรุ่นที่เล็กที่สุด แต่ YOLOv11n ก็บรรลุความแม่นยำในการตรวจจับที่แข่งขันได้ในชุดข้อมูล AST โดยได้รับประโยชน์จากการฝึกอบรมล่วงหน้าบนเกณฑ์มาตรฐาน COCO ขนาดใหญ่และการปรับจูนบนภาพ AST ที่ติดป้ายกำกับของโครงงาน โมเดลตรวจจับวัตถุสองคลาส ได้แก่ `antibiotic` (แผ่นดิสก์ที่ชุ่มด้วยยา ซึ่งใช้เป็นเป้าหมาย OCR และข้อมูลอ้างอิงการปรับเทียบ) และ `disk-zone` (โซนการยับยั้งโดยรอบ ซึ่งใช้สกัดการวัดเส้นผ่านศูนย์กลาง)

2.2.3 Hough Circle Transform

Hough Circle Transform เป็นเทคนิค computer vision แบบคลาสสิกสำหรับการตรวจจับโครงสร้างวงกลมในภาพโดยไม่ต้องใช้โมเดลที่เรียนรู้หรือข้อมูลการฝึกที่ติดป้ายกำกับ ทำงานโดยการแปลงภาพจากโดเมนเชิงพื้นที่ไปยังพื้นที่พารามิเตอร์ (parameter space) ที่กำหนดโดยสามมิติ: พิกัด x และ y ของจุดศูนย์กลางวงกลม และรัศมีวงกลม r สำหรับจุดขอบแต่ละจุดที่ตรวจพบในภาพ (โดยทั่วไปผ่าน Canny edge detection) อัลกอริทึมจะลงคะแนน (vote) ให้กับวงกลมทั้งหมดในพื้นที่พารามิเตอร์ที่อาจสร้างจุดขอบนั้นได้ วงกลมที่สะสมคะแนนได้เหนือเกณฑ์ในตัวสะสมพื้นที่พารามิเตอร์จะสอดคล้องกับวงกลมจริงในภาพ แนวทางการตรวจจับวงกลมทางเลือกที่ใช้ learning automata [23], deep learning [24] และรุ่นที่ใช้การไล่ระดับสี (gradient-based) [25] ได้ถูกนำเสนอเพื่อแก้ไขข้อจำกัดด้านความไวของทรานส์ฟอร์มแบบคลาสสิกภายใต้สภาวะภาพในโลกแห่งความเป็นจริง

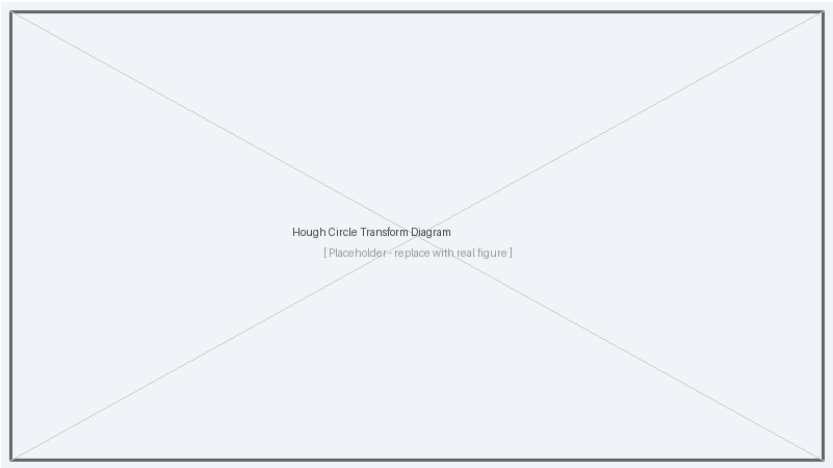

Figure 2.3: Illustration of the Hough Circle Transform. Each edge point votes for a cone of candidate circles in the (x_c, y_c, r) parameter space; genuine circles produce prominent peaks in the accumulator.

Hough Circle Transform มีประสิทธิภาพในการคำนวณและไม่สร้างผลการตรวจจับผิดพลาดสำหรับโซนที่เป็นวงกลมชัดเจนภายใต้สภาวะภาพที่ควบคุม อย่างไรก็ตาม มันมีความไวต่อแหล่งที่มาของการเสื่อมโทรมหลายอย่างที่พบบ่อยในภาพ AST จริง การสะท้อนของพื้นผิววุ้นที่ไม่สม่ำเสมอหรือแสงที่ไม่สม่ำเสมอสร้างการตอบสนองของขอบที่ผิดพลาดซึ่งสร้างสัญญาณรบกวนในตัวสะสม โซนที่ไม่ได้เป็นวงกลมที่สมบูรณ์—เนื่องจากการทับซ้อนของโซน ความไม่สม่ำเสมอของพื้นผิววุ้น หรือรูปแบบการเจริญเติบโตของแบคทีเรียที่ผิดปกติ—จะไม่สะสมคะแนนได้อย่างชัดเจน นำไปสู่การตรวจจับที่พลาดไปหรือการประมาณรัศมีที่ไม่แม่นยำ นอกจากนี้ ทรานส์ฟอร์มนี้ต้องการการปรับแต่งพารามิเตอร์หลายตัวด้วยมืออย่างระมัดระวัง (เช่น อัตราส่วนความละเอียดผกผัน `dp`, ระยะห่างขั้นต่ำระหว่างศูนย์กลาง `minDist` และเกณฑ์ขอบ Canny `param1` และ `param2`) ซึ่งมีปฏิสัมพันธ์กันในทางที่ซับซ้อนและค่าที่เหมาะสมที่สุดจะแตกต่างกันไปตามภาพที่มีมาตราส่วน แสง และชนิดของแบคทีเรียที่แตกต่างกัน ในโครงงานนี้ พารามิเตอร์ Hough Circle Transform ได้รับการปรับแต่งผ่านการค้นหาแบบตาราง (grid search) บนชุดข้อมูลเต็มรูปแบบ ซึ่งแสดงถึงสถานการณ์ที่ดีที่สุดสำหรับวิธีนี้ วิธีนี้ทำหน้าที่เป็นเกณฑ์มาตรฐานแบบคลาสสิกที่มีหลักการซึ่งโมเดลที่เรียนรู้จะถูกนำมาประเมินเปรียบเทียบ

2.3 การจดจำอักขระด้วยแสงสำหรับฉลากแผ่นดิสก์ยาปฏิชีวนะ (Optical Character Recognition for Antibiotic Disk Labeling)

แผ่นดิสก์ยาปฏิชีวนะจะมีรหัสตัวอักษรและตัวเลขสั้นๆ พิมพ์อยู่บนพื้นผิว ระบุชื่อยาปฏิชีวนะและความเข้มข้น (ตัวอย่างเช่น “OX 1” สำหรับ oxacillin 1 μg หรือ “AMX 25” สำหรับ amoxicillin 25 μg) การจดจำอักขระด้วยแสง (Optical Character Recognition หรือ OCR) ซึ่งประวัติการพัฒนาครอบคลุมความก้าวหน้าทางวิศวกรรมหลายทศวรรษ [26] มอบวิธีการคำนวณเพื่ออ่านฉลากเหล่านี้โดยอัตโนมัติ

จากภาพถ่าย การอ่านฉลากเหล่านี้อย่างถูกต้องเป็นสิ่งสำคัญสำหรับการเชื่อมโยงแต่ละ ZOI ที่ตรวจพบกับยาปฏิชีวนะที่ถูกต้อง ซึ่งจะช่วยให้สามารถดึงจุดตัดที่ถูกต้องจากฐานข้อมูล CLSI/EUCAST ได้ นี่เป็นงาน OCR ที่ท้าทายด้วยเหตุผลหลายประการ: ข้อความที่พิมพ์มีขนาดเล็ก (โดยทั่วไปสูง 2–4 มม.), ความคมชัดระหว่างหมึกและพื้นผิวแผ่นดิสก์มีความแปรปรวนตามยี่ห้อของแผ่นดิสก์, พื้นผิวแผ่นดิสก์มีความโค้งเล็กน้อย, ภาพอาจถูกถ่ายในมุมที่ไม่เหมาะสม และแผ่นดิสก์หลายแผ่นอาจถูกบดบังบางส่วน

2.3.1 EasyOCR และสถาปัตยกรรม CRAFT (EasyOCR and the CRAFT Architecture)

EasyOCR [27] เป็นเครื่องยนต์ OCR แบบเปิดเผยรหัสที่ใช้ deep learning ซึ่งรองรับภาษาและสคริปต์มากกว่า 80 ภาษา ขั้นตอนการตรวจจับข้อความขึ้นอยู่กับโมเดล CRAFT (Character Region Awareness for Text Detection) ที่นำเสนอโดย Baek et al. [28] CRAFT ตรวจจับภูมิภาคของอักขระแต่ละตัวและความสัมพันธ์ระหว่างอักขระที่อยู่ติดกัน แทนที่จะถือว่า bounding boxes ในระดับคำเป็นหน่วยการตรวจจับพื้นฐาน แนวทางการตรวจจับระดับอักขระนี้เหมาะสมอย่างยิ่งกับบริบทของฉลากยาปฏิชีวนะซึ่งต้องระบุตำแหน่งของสตริงตัวอักษรและตัวเลขสั้นๆ อย่างแม่นยำบนพื้นผิวแผ่นดิสก์ขนาดเล็กที่มีพื้นผิว

เครือข่าย CRAFT สร้างแผนผังเอาต์พุตสองแบบ: แผนผังคะแนนภูมิภาค (region score map: ระบุความน่าจะเป็นที่แต่ละพิกเซลเป็นศูนย์กลางของอักขระ) และแผนผังคะแนนความสัมพันธ์ (affinity score map: ระบุความน่าจะเป็นที่อักขระสองตัวที่อยู่ติดกันเป็นของคำเดียวกัน) แผนผังทั้งสองนี้จะถูกรวมเข้าด้วยกันเพื่อแบ่งส่วนอักขระแต่ละตัวและรวมกลุ่มกันเป็นอินสแตนซ์ข้อความระดับคำ ภูมิภาคอักขระที่ตรวจพบจะถูกส่งไปยังเครือข่ายการจดจำลำดับ—Convolutional Recurrent Neural Network (CRNN)—ซึ่งจะถ่ายทอดลำดับอักขระเป็นข้อความโดยใช้ตัวถอดรหัส connectionist temporal classification (CTC)

EasyOCR [27] ได้รับการเปรียบเทียบกับ TyphoonOCR [29] ซึ่งเป็นโมเดล OCR ที่เน้นภาษาไทยที่พัฒนาโดย OpenTyphoon.ai สำหรับงานอ่านฉลากยาปฏิชีวนะ แม้ว่า TyphoonOCR จะให้ประสิทธิภาพที่แข็งแกร่งสำหรับข้อความสคริปต์ไทย แต่ประสิทธิภาพในสตริงตัวอักษรและตัวเลขละตินภายใต้เงื่อนไขที่ท้าทายของการถ่ายภาพแผ่นดิสก์นั้นด้อยกว่า EasyOCR [27, 28] ดังนั้น EasyOCR จึงถูกเลือกเป็นเครื่องยนต์ OCR สำหรับไปป์ไลน์ขั้นสุดท้าย

2.4 เทคนิคการเตรียมการประมวลผลภาพ (Image Preprocessing Techniques)

การเตรียมการประมวลผลภาพเป็นตัวขับเคลื่อนที่สำคัญของทั้งโมเดลการตรวจจับวัตถุและไปป์ไลน์ OCR ซึ่งส่งผลโดยตรงต่ออัตราส่วนสัญญาณต่อสัญญาณรบกวนของคุณลักษณะที่สกัดโดยอัลกอริทึมปลายน้ำ [30] เทคนิคการแบ่งส่วนภาพ [31, 32] และวิธีการแปลงเป็นภาพขาวดำ (binarization) ของเอกสาร [33] ให้ข้อมูลสำหรับการเลือกการเตรียมการประมวลผลในโครงงานนี้ เพื่อจัดการกับการ

เสื่อมโทรมของภาพเฉพาะที่พบในการถ่ายภาพ AST ในห้องปฏิบัติการ

- **Global thresholding (วิธีของ Otsu):** วิธีของ Otsu จะกำหนดเกณฑ์ความเข้มที่เหมาะสมที่สุดโดยอัตโนมัติสำหรับการแปลงรูปภาพโทนสีเทาเป็นภาพขาวดำ (binary) โดยการลดความแปรปรวนภายในคลาสระหว่างพิกเซลเบื้องหน้า (ข้อความ) และเบื้องหลัง วิธีนี้ใช้กับภาพที่ครอบเฉพาะแผ่นดิสก์ก่อนทำ OCR เพื่อแยกอักขระหมึกออกจากพื้นหลังพื้นผิวแผ่นดิสก์ ซึ่งช่วยปรับปรุงคุณภาพการแบ่งส่วนอักขระ

- **Contrast Limited Adaptive Histogram Equalization (CLAHE):** แตกต่างจากการปรับฮิสโตแกรมให้เท่ากันแบบโกลบอลที่คำนวณฟังก์ชันการจับคู่เดียวสำหรับทั้งภาพ CLAHE จะใช้การปรับฮิสโตแกรมให้เท่ากันอย่างอิสระกับกระเบื้อง (tiles) ขนาดเล็กของภาพ (พร้อมขีดจำกัดความคมชัดและขนาดกระเบื้องที่กำหนดค่าได้) และประมาณค่าในช่วงระหว่างกระเบื้องอย่างราบรื่น สิ่งนี้ช่วยปรับความคมชัดในระดับพื้นที่ให้สม่ำเสมอในภูมิภาคของภาพที่มีความสว่างเฉลี่ยต่างกันมาก—ซึ่งเป็นเหตุการณ์ทั่วไปในภาพถ่ายห้องปฏิบัติการที่จุดศูนย์กลางของจานวุ้นสว่างกว่าส่วนขอบเนื่องจากรูปทรงของแสงเหนือศีรษะ CLAHE ถูกนำไปใช้กับภาพแผ่นดิสก์ที่ครอบมาเป็นขั้นตอนการเตรียมการประมวลผลก่อน OCR เพื่อปรับปรุงทัศนวิสัยของข้อความที่มีความคมชัดต่ำ

- **Gaussian Blur:** ตัวกรองความถี่ต่ำ Gaussian จะถูกนำไปใช้กับรูปภาพจานแบบเต็มก่อนการตรวจจับขอบ (สำหรับ Hough Transform) และก่อนการหาเกณฑ์ ช่วยลดสัญญาณรบกวนเซ็นเซอร์ความถี่สูงที่อาจสร้างการตอบสนองขอบที่ผิดพลาด ขนาดของเคอร์เนลการเบลอจะถูกเลือกเพื่อรักษามาตราส่วนที่เกี่ยวข้องของขอบเขตโซนในขณะที่ระงับสัญญาณรบกวน

- **การดำเนินการทางสัณฐานวิทยา (dilation และ erosion):** การขยาย (dilation) ทางสัณฐานวิทยาจะขยายภูมิภาคเบื้องหน้า (ข้อความ) ในขณะที่การกัดกร่อน (erosion) จะทำให้เล็กลง เมื่อนำมาใช้ตามลำดับ (เป็นการดำเนินการเปิดหรือปิด) สิ่งเหล่านี้สามารถเติมช่องว่างเล็กๆ ในอักขระหรือลบจุดรบกวนขนาดเล็กจากภาพขาวดำได้ ในไปป์ไลน์การเตรียมการประมวลผล OCR การเลือกและขอบเขตของการดำเนินการทางสัณฐานวิทยาจะถูกนำไปใช้อย่างเหมาะสมตามอัตราส่วนพิกเซลข้อความที่ประมาณไว้ในภาพที่ครอบมา: ภาพที่มีพิกเซลข้อความเบาบางมาก (อักขระบาง) จะถูกขยายเพื่อกู้คืนการเชื่อมต่อของเส้น ในขณะที่ภาพที่มีพิกเซลหนาแน่นเกินไป (เส้นหนาหรืออักขระกลืนกัน) จะถูกกัดกร่อน

- **การแก้ไขการหมุนของภาพ (Image rotation correction):** ทิศทางของแผ่นดิสก์ยาปฏิชีวนะบนจานไม่ได้ถูกควบคุมระหว่างการตั้งค่าในห้องปฏิบัติการ—แผ่นดิสก์อาจถูกวางในมุมใดก็ได้ ส่งผลให้ฉลากที่พิมพ์บนแผ่นดิสก์อาจปรากฏหมุนที่มุมใดก็ได้เมื่อเทียบกับเฟรมภาพ เพื่อจัดการสิ่ง

นี้ ไปป์ไลน์ OCR จะใช้ EasyOCR ที่สี่ทิศทางมาตรฐาน (0°, 90°, 180° และ 270°) และเลือกผลลัพธ์การจดจำที่มีความเชื่อมั่นสูงสุดจากทั้งสี่ทิศทาง

2.5 งานวิจัยที่เกี่ยวข้องในการวิเคราะห์ AST อัตโนมัติ (Related Work in Automated AST Analysis)

2.5.1 แนวทาง Deep Learning สำหรับการวิเคราะห์ภาพ AST (Deep Learning Approaches for AST Image Analysis)

การประยุกต์ใช้ deep learning และ computer vision ในการวิเคราะห์ภาพ AST เป็นสาขาการวิจัยที่มีความเคลื่อนไหวในช่วงทศวรรษที่ผ่านมา โดยได้รับแรงผลักดันจากการผสมผสานระหว่างความต้องการทางคลินิกและความก้าวหน้าของอัลกอริทึมที่เป็นแรงจูงใจให้เกิดโครงงานนี้ บทบาทที่กว้างขึ้นของ AI และ machine learning ในการทำนายและต่อสู้กับการดื้อยาต้านจุลชีพได้รับการทบทวนอย่างครอบคลุมโดย Bilal et al. [7] ในขณะที่ Liao et al. [8] ได้สำรวจความก้าวหน้าโดยเฉพาะในงานวิจัยการทดสอบความไวต่อยาที่ขับเคลื่อนด้วย AI Pascucci et al. [34, 35] ได้พัฒนาแอปพลิเคชันมือถือบนฐาน AI ตัวแรกสำหรับการทดสอบการดื้อยาปฏิชีวนะอัตโนมัติ แสดงให้เห็นว่ากล้องสมาร์ทโฟนรวมกับ deep learning สามารถสร้างการวัด ZOI ที่ยอมรับได้ทางคลินิกในสภาพแวดล้อมที่มีทรัพยากรจำกัด Rajasekar et al. [36] ได้นำเสนอ Ab.ai ซึ่งเป็นเครื่องมือ AI เฉพาะทางสำหรับการรายงาน antibiograms โดยอัตโนมัติ บรรลุความแม่นยำสูงบนจาน disk diffusion ในสภาวะห้องปฏิบัติการมาตรฐาน Yu et al. [37] แสดงให้เห็นถึงวิธี hue-contrast ที่ขับเคลื่อนด้วย AI สำหรับการระบุโซนการยับยั้ง ซึ่งเป็นทางเลือกนอกเหนือจากการถดถอย bounding-box Callebaut et al. [38] ประเมินระบบ Radian® in-line carousel สำหรับการทดสอบ disk diffusion อัตโนมัติ กำหนดเกณฑ์มาตรฐานประสิทธิภาพเทียบกับการอ่านด้วยตนเองโดยผู้เชี่ยวชาญซึ่งโครงงานนี้นำมาใช้เป็นเป้าหมายเปรียบเทียบ

Rajasekar et al. [39] ได้ดำเนินการทบทวนอย่างเป็นระบบเกี่ยวกับวิธีการวิเคราะห์ภาพบนฐาน AI ที่ตีพิมพ์สำหรับ AST และพบว่าโมเดล deep learning มีประสิทธิภาพเหนือกว่าแนวทางการประมวลผลภาพแบบคลาสสิกอย่างสม่ำเสมอและมีนัยสำคัญ—รวมถึง Hough Transform, active contours และ template matching—โดยเฉพาะอย่างยิ่งในสถานการณ์ที่มีความเกี่ยวข้องมากที่สุดกับการปฏิบัติทางคลินิก: จานที่มีแผ่นดิสก์จำนวนมาก, โซนที่ทับซ้อนกัน และการเจริญเติบโตของแบคทีเรียที่ไม่เป็นเนื้อเดียวกัน การทบทวนได้สำรวจวิธีการตั้งแต่อดีตที่มีการใช้เครือข่ายคอนโวลูชันดั้งเดิมกับภูมิภาคแผ่นดิสก์ที่ครอบมา ไปจนถึงไปป์ไลน์การตรวจจับแบบครบวงจรที่คล้ายกับที่พัฒนาขึ้นในโครงงานนี้

ท่ามกลางสิ่งที่ค้นพบที่สำคัญของ Rajasekar et al. คือการเพิ่มประสิทธิภาพที่มากที่สุดจาก deep learning เกิดขึ้นโดยเฉพาะในการจัดการกับโซนที่ทับซ้อนกัน—ซึ่งเป็นสถานการณ์ที่ทำลายข้อ

สมมติฐานของรูปร่างวงกลมที่แยกจากกันซึ่งเป็นพื้นฐานของแนวทาง Hough Transform—และความทนทานต่อความแปรปรวนของภาพถ่าย เช่น แสงที่ไม่สม่ำเสมอ ความผิดเพี้ยนของมุมมอง และสิ่งแปลกปลอมจากการบีบอัดภาพ [39] สิ่งเหล่านี้ช่วยยืนยันการเลือกทางสถาปัตยกรรมของโครงงานปัจจุบัน: การใช้การตรวจจับวัตถุด้วย deep learning เป็นแนวทางหลัก และจัดให้ Hough Transform เป็นเพียงเกณฑ์มาตรฐานแบบคลาสสิกมากกว่าที่จะเป็นส่วนประกอบหลักของระบบ การทบทวนยังระบุด้วยว่าขนาดที่ค่อนข้างเล็กของชุดข้อมูล AST ส่วนใหญ่ที่ตีพิมพ์ (โดยทั่วไปต่ำกว่า 500 ภาพ) เป็นปัจจัยจำกัดประสิทธิภาพของ deep learning ซึ่งเป็นแรงจูงใจให้โครงงานปัจจุบันลงทุนในการสร้างข้อมูลสังเคราะห์เพื่อให้ถึงชุดข้อมูลฝึกอบรมมากกว่า 2,000 ภาพ

2.5.2 มาตรฐานการประเมินสำหรับวิธี AST อัตโนมัติ (Evaluation Standards for Automated AST Methods)

Humphries et al. [6] ได้กล่าวถึงคำถามเชิงระเบียบวิธีเกี่ยวกับวิธีการประเมินระบบการวัด AST อัตโนมัติอย่างเหมาะสมเมื่อเทียบกับมาตรฐานทองคำ (gold standard) ของการอ่านด้วยตนเองโดยนักจุลชีววิทยาที่ผ่านการฝึกอบรม เอกสารแนวทางปฏิบัติที่ดีที่สุดของพวกเขา ซึ่งตีพิมพ์โดย CLSI Methods Development and Standardization Working Group ได้กำหนดเกณฑ์การประเมินที่สำคัญหลายประการที่โครงงานปัจจุบันนำมาใช้ สิ่งที่สำคัญที่สุดสำหรับงานนี้คือพวกเขาได้กำหนดว่าค่าความคลาดเคลื่อนสมบูรณ์เฉลี่ย (MAE) ที่น้อยกว่า 3 mm ระหว่างการวัดเส้นผ่านศูนย์กลาง ZOI แบบอัตโนมัติและแบบแมนนวล แสดงถึงเกณฑ์ของความยอมรับได้ทางคลินิก—กล่าวคือ ต่ำกว่าระดับข้อผิดพลาดนี้ ความแตกต่างในการวัดเชิงระบบไม่น่าจะนำไปสู่การจำแนก S/I/R ที่แตกต่างกันสำหรับคู่จุดตัดของยาและสิ่งมีชีวิตส่วนใหญ่ที่ใช้อยู่ในปัจจุบัน

Humphries et al. ยังเน้นย้ำถึงความสำคัญของการประเมินวิธีการอัตโนมัติในคอลเลกชันที่หลากหลายของสายพันธุ์แบคทีเรีย ชั้นของยาปฏิชีวนะ และการกำหนดค่าจาน เนื่องจากข้อผิดพลาดที่ไม่มีนัยสำคัญสำหรับคู่ยาและสิ่งมีชีวิตหนึ่งอาจตัดสินผลทางคลินิกสำหรับอีกคู่หนึ่งได้ [6] คำแนะนำนี้ให้ข้อมูลแก่การออกแบบการประเมินของโครงงานปัจจุบัน ซึ่งรายงาน MAE ในชุดข้อมูลทดสอบที่แยกไว้ทั้งหมด 235 ภาพที่นำมาจากคอลเลกชันจานจริง นอกจากนี้ Humphries et al. ยังระบุว่าความลำเอียงเชิงระบบ (ทิศทาง) มีความสำคัญพอๆ กับการระบุข้อผิดพลาดแบบสุ่ม เนื่องจากการประเมินเส้นผ่านศูนย์กลางโซนที่สูงหรือต่ำเกินไปอย่างสม่ำเสมอสามารถแก้ไขได้ด้วยขั้นตอนการแก้ไขความลำเอียงหลังการประมวลผล—ซึ่งเป็นสิ่งที่ขั้นตอนการปรับแต่งการปรับเทียบของระบบปัจจุบันดำเนินการอย่างแม่นยำ

CHAPTER 3: ระเบียบวิธีวิจัย (METHODOLOGY)

3.1 ภาพรวมสถาปัตยกรรมระบบ (System Architecture Overview)

ระบบที่นำเสนอคือ Full-stack web application ที่ใช้สถาปัตยกรรมแบบ Client-server ซึ่งออกแบบตามหลักการแยกส่วนความรับผิดชอบ (Separation of concerns) ระหว่างส่วนติดต่อผู้ใช้ (User interface), AI inference pipeline และ Data persistence layer การแยกส่วนทางสถาปัตยกรรมนี้ช่วยให้สามารถพัฒนาและทดสอบแต่ละส่วนประกอบได้อย่างอิสระ และช่วยให้ AI backend ที่ต้องใช้ทรัพยากรการคำนวณสูงสามารถปรับขนาดหรืออัปเกรดได้โดยไม่ต้องแก้ไขส่วนประสบการณ์ผู้ใช้ใน Frontend

ส่วน Frontend พัฒนาด้วย React ซึ่งเป็น Component-based JavaScript framework ที่สร้างบน HTML [40, 41] โดยทำหน้าที่เป็นอินเทอร์เฟซสำหรับอัปโหลดรูปภาพ ตัวเลือกการจับภาพจากกล้องแบบเรียลไทม์ และ Dashboard สำหรับแสดงผลลัพธ์แบบโต้ตอบ ส่วน Backend พัฒนาด้วยภาษา Python [42] โดยใช้ FastAPI [43] ซึ่งเป็น Asynchronous web framework ประสิทธิภาพสูงที่ให้บริการ RESTful API เพื่อให้ React frontend เรียกใช้งาน เมื่อได้รับรูปภาพผ่าน API แล้ว ส่วน Backend จะรัน AI inference pipeline แบบเต็มรูปแบบและส่งคืนผลลัพธ์ในรูปแบบ JSON ที่มีโครงสร้างประกอบด้วยผลการตรวจจับทั้งหมด, การวัดขนาดเส้นผ่านศูนย์กลาง, ป้ายกำกับจาก OCR และการจำแนกความไวต่อยา (Susceptibility classification) นอกจากนี้ยังมีฐานข้อมูลเชิงสัมพันธ์ที่ใช้ SQLite สำหรับจัดเก็บประวัติการวิเคราะห์, บันทึก Session ของผู้ใช้ และตาราง Breakpoint ของ CLSI 2025 และ EUCAST 2023 เพื่อให้สามารถตรวจสอบย้อนหลังและค้นหาเกณฑ์ Breakpoint ได้อย่างรวดเร็วในระหว่างกระบวนการ

Pipeline ของการวิเคราะห์รูปภาพโดยรวมประกอบด้วย 5 ขั้นตอนตามลำดับ ซึ่งแต่ละขั้นตอนจะอธิบายรายละเอียดในหัวข้อถัดไป:

1. **การรับภาพและการประมวลผลเบื้องต้น (Image acquisition and preprocessing):** รูปภาพที่นำเข้าจะได้รับการตรวจสอบความถูกต้อง, ปรับขนาดตามความละเอียดที่โมเดลต้องการ และประมวลผลเบื้องต้นตามข้อกำหนดของโมเดลการตรวจจับที่ใช้งานอยู่

2. **การตรวจจับแผ่นยาปฏิชีวนะและการระบุชื่อด้วย OCR (Antibiotic disk detection and OCR labeling):** โมเดลการตรวจจับจะระบุตำแหน่งของแผ่นยาปฏิชีวนะแต่ละแผ่น จากนั้น OCR pipeline จะอ่านรหัสตัวอักษรและตัวเลขจากภาพที่ครอบตัด (Crop) ของแต่ละแผ่นเพื่อระบุชื่อยาปฏิชีวนะ

3. **การตรวจจับ ZOI และการวัดเส้นผ่านศูนย์กลาง (ZOI detection and diameter mea-**

surement): โมเดลการตรวจจับจะระบุตำแหน่งของบริเวณยับยั้งเชื้อ (Zone of inhibition) แต่ละบริเวณเป็น Bounding box จากนั้นขนาดของ Bounding box จะถูกแปลงเป็นค่าประมาณของเส้นผ่านศูนย์กลางในหน่วยพิกเซล

4. **การสอบเทียบจากพิกเซลเป็นมิลลิเมตร (Pixel-to-millimeter calibration):** การวัดเส้นผ่านศูนย์กลางในหน่วยพิกเซลจะถูกแปลงเป็นหน่วยมิลลิเมตรทางกายภาพ โดยใช้ขนาดเส้นผ่านศูนย์กลาง 6 มม. ที่ทราบค่าของแผ่นยาปฏิชีวนะเป็นวัตถุอ้างอิงภายในภาพ

5. **การค้นหา Breakpoint และการจำแนกความไวต่อยา (Breakpoint lookup and susceptibility classification):** เส้นผ่านศูนย์กลาง ZOI ที่วัดได้ในหน่วยมิลลิเมตรจะถูกนำไปเปรียบเทียบกับ Breakpoint ของ CLSI หรือ EUCAST สำหรับยาปฏิชีวนะที่ระบุได้และชนิดของเชื้อที่ผู้ใช้กำหนด จากนั้นจะจำแนกเชื้อเป็น ไวต่อยา (Susceptible - S), กึ่งไว (Intermediate - I) หรือดื้อยา (Resistant - R)

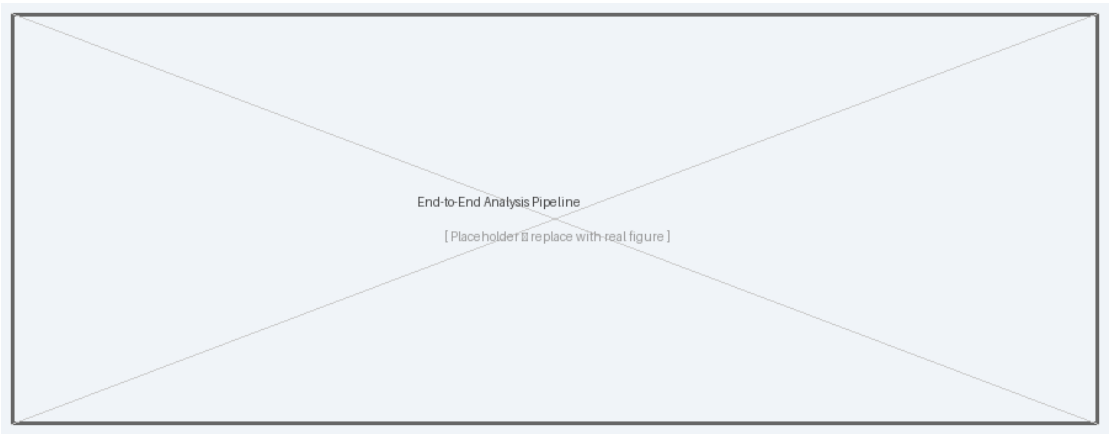

Figure 3.1: Pipeline การวิเคราะห์รูปภาพแบบ End-to-end ของระบบ AST อัตโนมัติ ตั้งแต่การนำเข้าภาพผ่านการตรวจจับ, OCR, การสอบเทียบ และการจำแนกความไวต่อยาตาม Breakpoint

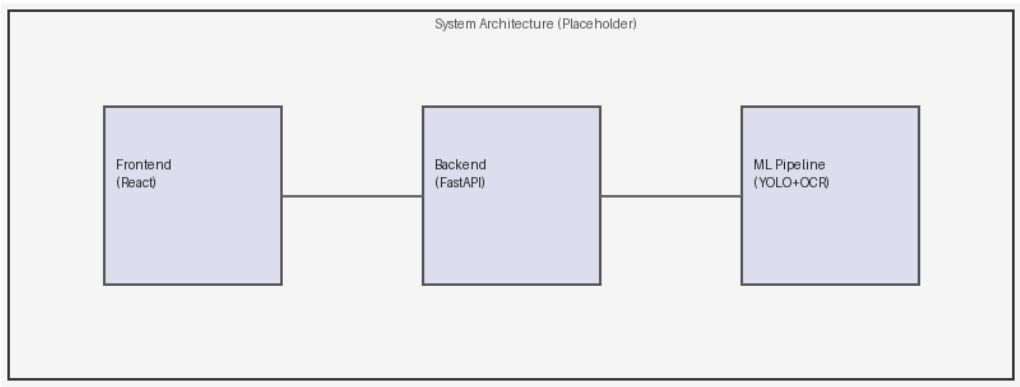

Figure 3.2: สถาปัตยกรรมระบบโดยรวมของเว็บแอปพลิเคชัน AST อัตโนมัติ แสดงให้เห็นส่วน React frontend, FastAPI backend, AI inference pipeline และชั้นฐานข้อมูล SQLite

3.2 การรวบรวมและการเตรียมชุดข้อมูล (Dataset Collection and Preparation)

การสร้างชุดข้อมูลการฝึกฝนที่มีคุณภาพสูงและมีความหลากหลายเป็นสิ่งจำเป็นสำหรับประสิทธิภาพการทำงานทั่วไป (Generalization) ของโมเดล Deep Learning สำหรับโดเมน AST การสร้างชุดข้อมูลมีความท้าทายอย่างยิ่งเนื่องจากรูปภาพจานเพาะเชื้อทางคลินิกจริงมักเป็นข้อมูลส่วนบุคคล (เป็นของโรงพยาบาลหรือห้องปฏิบัติการอ้างอิง) และชุดข้อมูลรูปภาพ AST ที่มีการระบุป้ายกำกับ (Annotated) และเผยแพร่สู่สาธารณะมีจำนวนจำกัด กลยุทธ์ชุดข้อมูลที่ใช้ในโปรเจกต์นี้จึงผสมผสานสามแหล่งที่ส่งเสริมกัน ได้แก่ รูปภาพจริงจากห้องปฏิบัติการ, รูปภาพจริงที่ผ่านการเพิ่มข้อมูล (Augmented) และรูปภาพสังเคราะห์ (Synthetic images) ที่สร้างขึ้นโดยใช้โปรแกรม

3.2.1 การรวบรวมรูปภาพจริง (Real Image Collection)

รูปภาพจานเพาะเชื้อ AST จริงจำนวน 287 ภาพถูกรวบรวมจากสามแหล่ง แหล่งแรกคือคลังข้อมูล DRYAD ที่เปิดเผยต่อสาธารณะ [44] ซึ่งสอดคล้องกับแนวทางการแบ่งปันข้อมูลวิจัยชีวการแพทย์แบบเปิด [45] และให้ภาพที่ติดป้ายกำกับแล้วจำนวน 225 ภาพ แหล่งที่สองคือชุดข้อมูล CDS (Clinical and Demographic Study) จำนวน 50 ภาพ และแหล่งที่สามคือชุดข้อมูล CRA (Chulabhorn Royal Academy หรือ ราชวิทยาลัยจุฬาภรณ์) จำนวน 32 ภาพ เมื่อรวมกันแล้วจึงได้ภาพจริง 287 ภาพสำหรับใช้ในโครงงานนี้

ชุดข้อมูลดังกล่าวครอบคลุมเชื้อแบคทีเรียหลายสายพันธุ์ จำนวนแผ่นยาปฏิชีวนะต่อจานตั้งแต่ 1 ถึง 10 แผ่น และรูปแบบการซ้อนทับของบริเวณยับยั้งที่หลากหลาย นอกจากนี้ แหล่งข้อมูลที่ต่างกันยังเพิ่มความแปรผันด้านสภาพแสง รุ่นกล้อง ยี่ห้อวุ้น และขนาดจานเพาะเชื้อ ซึ่งช่วยให้โมเดลที่ฝึกจากข้อมูลรวมมีความสามารถในการประมวลผลทั่วไปดีขึ้น

3.2.2 การเพิ่มข้อมูล (Data Augmentation)

เพื่อขยายชุดข้อมูลการฝึกฝนจาก 287 ภาพโดยยังคงความถูกต้องของป้ายกำกับเดิม จึงใช้แพลตฟอร์ม Roboflow สำหรับเพิ่มข้อมูลเชิงเรขาคณิตและเชิงแสง การแปลงข้อมูลประกอบด้วยการพลิกแนวตั้งและแนวนอน การหมุนแบบสุ่มในช่วง $\pm 15^\circ$ การปรับความสว่าง $\pm 25\%$ การปรับความเปรียบต่าง $\pm 20\%$ และการเติมสัญญาณรบกวน Gaussian ที่มีส่วนเบี่ยงเบนมาตรฐานไม่เกิน 5% ของค่าความเข้มพิกเซลสูงสุด พิกัดของ bounding box จะถูกคำนวณใหม่โดยอัตโนมัติตามเรขาคณิตของภาพที่เปลี่ยนไป กระบวนการนี้ทำให้ชุดฝึกเพิ่มจาก 287 เป็น 543 ภาพ

การเพิ่มข้อมูลถูกใช้เฉพาะกับชุดฝึกของภาพจริงเท่านั้น ส่วนชุดตรวจสอบและชุดทดสอบถูกแยกออกจากกระบวนการนี้เพื่อให้ตัวชี้วัดสะท้อนประสิทธิภาพกับข้อมูลที่ไม่ถูกดัดแปลง นอกจากนี้ยังหลีกเลี่ยงการแปลงที่รุนแรงเกินจริง เช่น การบิดเบือนมุมมองอย่างหนักหรือการสลับสี เพราะอาจสร้างภาพที่ไม่

สมจริงและลดคุณภาพการฝึกโมเดล

3.2.3 การสร้างข้อมูลสังเคราะห์ (Synthetic Data Generation)

รูปภาพสังเคราะห์อีก 2,000 ภาพถูกสร้างขึ้นด้วยโปรแกรมเพื่อเพิ่มความหลากหลายของชุดข้อมูล และชดเชยการขาดแคลนภาพจริงที่มีการซ้อนทับของบริเวณยับยั้งหรือมีรูปร่างผิดปกติ ภาพสังเคราะห์เหล่านี้ถูกเรนเดอร์ด้วย procedural pipeline ที่พัฒนาด้วย Python โดยใช้ Pillow และ OpenCV เพื่อประกอบพื้นหลังวุ้นที่มีลวดลาย แผ่นยาปฏิชีวนะทรงกลม และบริเวณยับยั้งที่มีขอบฟุ้งแบบ Gaussian ให้ใกล้เคียงภาพถ่ายจริงของจาน Mueller–Hinton agar

ภาพสังเคราะห์ 2,000 ภาพถูกแบ่งเป็นสองกลุ่มเท่า ๆ กัน กลุ่มแรกจำนวน 1,000 ภาพใช้ตำแหน่งแผ่นยาแบบคงที่ตามรูปแบบที่ CLSI แนะนำสำหรับการวาง 6 และ 8 แผ่น ส่วนอีก 1,000 ภาพใช้การจัดวางแบบสุ่มภายในขอบเขตของจาน ทั้งสองกลุ่มสุ่มขนาดเส้นผ่านศูนย์กลางของบริเวณยับยั้งในช่วงประมาณ 10 มม. ถึง 40 มม. พร้อมเพิ่มสัดส่วนของกรณีที่บริเวณยับยั้งซ้อนทับกัน นอกจากนี้ยังทำให้ลวดลายพื้นหลัง การไล่ระดับแสง และรูปแบบการเจริญของโคโลนีมีความหลากหลายมากขึ้น เพื่อเพิ่มความหลากหลายทางสายตาของข้อมูลฝึก

3.2.4 การแบ่งชุดข้อมูลขั้นสุดท้าย (Final Dataset Split)

Table 3.1: องค์ประกอบของชุดข้อมูลสำหรับการฝึกฝน การตรวจสอบ และการทดสอบโมเดล

แหล่งข้อมูล (Source)	**ทั้งหมด**	**ฝึกฝน (Train)**	**ตรวจสอบ**	**ทดสอบ**
DRYAD	225	—	—	—
CDS	50	—	—	—
CRA (ราชวิทยาลัยจุฬาภรณ์)	32	—	—	—
รวมรูปภาพจริง (ต้นฉบับ)	287	—	—	—
รวมรูปภาพจริง (เพิ่มข้อมูล)	543	433	55	55
ข้อมูลสังเคราะห์ (ตำแหน่งคงที่)	1,000	ใช้ในการฝึกฝนเท่านั้น		
ข้อมูลสังเคราะห์ (ตำแหน่งไม่คงที่)	1,000	ใช้ในการฝึกฝนเท่านั้น		

รูปภาพสังเคราะห์ถูกนำมาใช้เพื่อการฝึกฝนเท่านั้น เนื่องจากถูกสร้างขึ้นมาเพื่อเสริมการเรียนรู้ของโมเดลในรูปแบบที่หลากหลาย มากกว่าที่จะใช้ประเมินประสิทธิภาพการทำงานทั่วไป ตัวชี้วัดประสิทธิภาพทั้งหมดที่รายงานในบทที่ 4 คำนวณจากชุดทดสอบรูปภาพจริง (55 ภาพ) เพื่อให้แน่ใจว่าตัวเลขประสิทธิภาพที่รายงานสะท้อนถึงพฤติกรรมของโมเดลกับภาพถ่ายในห้องปฏิบัติการที่เป็นของจริงและไม่ได้ถูกตกแต่ง

3.3 การระบุป้ายกำกับ (Annotation)

ป้ายกำกับ Ground-truth ถูกสร้างขึ้นในรูปแบบ Pascal VOC XML โดยระบุพิกัด Bounding box สำหรับแต่ละบริเวณยับยั้งเชื้อและแต่ละแผ่นยาปฏิชีวนะที่ปรากฏในรูปภาพ รูปแบบการระบุป้ายกำตอนนี้จะเข้ารหัสค่าสี่ค่าต่อวัตถุ ได้แก่ พิกัดพิกเซลของมุมบนซ้ายและมุมล่างขวาของ Bounding box พร้อมกับป้ายกำกับคลาส (`antibiotic` สำหรับแผ่นยา และ `disk-zone` สำหรับบริเวณยับยั้งเชื้อ)

การระบุป้ายกำกับเบื้องต้นทำโดยทีมงานโปรเจกต์โดยใช้ LabelImg ซึ่งเป็นเครื่องมือระบุป้ายกำกับรูปภาพแบบกราฟิกที่เป็นโอเพนซอร์ส เพื่อให้แน่ใจว่ามีความถูกต้องทางคลินิก การวาง Bounding box ทั้งหมดสำหรับคลาสบริเวณยับยั้งเชื้อได้รับการตรวจสอบและแก้ไขโดยนักจุลชีววิทยาที่ผ่านการฝึกฝนมาแล้ว ซึ่งเป็นผู้ตรวจสอบป้ายกำกับแต่ละรายการเปรียบเทียบกับการวัดจานจริงโดยใช้ Calipers ขั้นตอนการตรวจสอบสองชั้นนี้เป็นสิ่งจำเป็นสำหรับการสร้าง Ground-truth ที่เชื่อถือได้ เนื่องจากความหมายของขอบเขตบริเวณยับยั้งต้องใช้ความเชี่ยวชาญเฉพาะทาง: ขอบที่ถูกต้องของบริเวณยับยั้งถูกกำหนดให้เป็นจุดที่การยับยั้งการเจริญเติบโตแบบ Confluent growth สิ้นสุดลงโดยสมบูรณ์ (ไม่ใช่บริเวณที่มีการเกิด Micro-colony ซึ่ง CLSI แนะนำให้เจ้าหน้าที่ละเว้น) จากนั้นป้ายกำกับจะถูกนำเข้าสู่ Roboflow เพื่อจัดการชุดข้อมูล, กำหนด Pipeline การเพิ่มข้อมูล และส่งออกในรูปแบบที่เฟรมเวิร์กการฝึกฝนของแต่ละโมเดลต้องการ (Pascal VOC XML สำหรับ Faster R-CNN และ YOLO TXT สำหรับ YOLOv11n)

3.4 การฝึกฝนโมเดล (Model Training)

3.4.1 Faster R-CNN

Faster R-CNN ถูกพัฒนาโดยใช้ไลบรารี `torchvision` ของ PyTorch พร้อมกับ Backbone แบบ ResNet-50 ที่ผ่านการฝึกฝนเบื้องต้น (Pretrained) บนชุดข้อมูล ImageNet [19] การใช้ Backbone ที่ผ่านการฝึกฝนมาแล้วเป็นสิ่งสำคัญมากสำหรับประสิทธิภาพของชุดข้อมูลภาพทางการแพทย์ที่มีขนาดเท่านี้: การฝึกฝนเบื้องต้นบน ImageNet ช่วยให้ Backbone มีตัวแทนคุณลักษณะ (Feature representations) ที่แยกแยะโครงสร้างรูปภาพระดับต่ำ (ขอบ, พื้นผิว, การไล่ระดับสี) ซึ่งสามารถถ่ายโอนมายังโดเมน AST ได้อย่างมีประสิทธิภาพ ช่วยเร่งการลู่เข้าหาคำตอบ (Convergence) และปรับปรุงความแม่นยำขั้นสุดท้ายได้ดีกว่าการเริ่มฝึกฝนจากการสุ่มค่าเริ่มต้น

ส่วนหัวของการตรวจจับ (Detection head ทั้ง RPN และ Classification/regression head) ถูกกำหนดค่าเริ่มต้นใหม่และฝึกฝนตั้งแต่ต้น การฝึกฝนใช้อัลกอริทึมการเพิ่มประสิทธิภาพ Stochastic Gradient Descent (SGD) โดยมี Learning rate เท่ากับ 0.005, Momentum เท่ากับ 0.9 และ Weight decay เท่ากับ 5×10^{-4} (คือ `0.0005`) เพื่อรักษาสมดุลของโมเดลและป้องกันการ Overfitting กับชุดข้อมูลรูปภาพจริงที่มีอยู่อย่างจำกัด ค่า Learning rate จะถูกปรับลดลงโดยใช้ `StepLR` scheduler

โดยมี `step_size=3` และ `gamma=0.1` ซึ่งจะลด Learning rate ลง 10 เท่าทุกๆ 3 Epochs รูปภาพทั้งหมดถูกปรับขนาดเป็น 640×640 พิกเซลก่อนนำเข้าโมเดล และใช้ Batch size เท่ากับ 8

ก่อนที่จะเริ่มการฝึกฝนแบบเต็มรูปแบบ ได้มีการรันการทดลองฝึกฝนเบื้องต้นบนชุดย่อยของชุดข้อมูลที่ขยายขนาดขึ้นเรื่อยๆ เพื่อศึกษาพฤติกรรมการเรียนรู้ของโมเดลและวินิจฉัยสภาวะ Underfitting และ Overfitting การทดลองเหล่านี้ช่วยในการเลือก Hyperparameter ขั้นสุดท้าย โดยเฉพาะจำนวน Epochs ในการฝึกฝน (10 Epochs) และตารางเวลาของ Learning rate โดยแสดงให้เห็นว่า Epoch ใดที่ Loss ของการตรวจสอบ (Validation loss) มีค่าต่ำสุดก่อนที่จะเริ่มสูงขึ้นอีกครั้ง การฝึกฝนขั้นสุดท้ายใช้เวลาประมาณ 174 นาทีบนฮาร์ดแวร์ที่มีอยู่ ซึ่งสะท้อนถึงต้นทุนการคำนวณของสถาปัตยกรรม Inference แบบสองขั้นตอน

3.4.2 YOLOv11n

YOLOv11n ถูกฝึกฝนโดยใช้เฟรมเวิร์กการฝึกฝนของ Ultralytics ซึ่งให้บริการ Python API ระดับสูงสำหรับการกำหนดค่าเริ่มต้นโมเดล, การดำเนินการลูปการฝึกฝน และการบันทึก Checkpoint [20] ตัวเลือกย่อยรุ่น Nano (n) ถูกเลือกเพื่อเน้นความเร็วในการประมวลผล (Inference speed) และความสามารถในการนำไปใช้งานบนระบบที่ไม่มี GPU แยก ในขณะที่ยังคงรักษาสมรรถนะของโมเดลเพียงพอที่จะเรียนรู้คุณลักษณะทางสายตาที่ค่อนข้างจำกัดของรูปภาพจานเพาะเชื้อ AST (คลาสวัตถุสองคลาสที่มีรูปร่างที่ชัดเจน: แผ่นยาทรงกลม และบริเวณยับยั้งทรงกลม)

น้ำหนักของโมเดลถูกกำหนดค่าเริ่มต้นจาก Checkpoint ที่ผ่านการฝึกฝนบน COCO ของ Ultralytics สำหรับ YOLOv11n การเรียนรู้แบบถ่ายโอน (Transfer learning) จาก COCO ซึ่งเป็นฐานข้อมูลการตรวจจับวัตถุในธรรมชาติขนาดใหญ่ที่มีวัตถุ 80 ประเภท ช่วยให้โมเดลมีความสามารถในการตรวจจับวัตถุทั่วไป (การดึงคุณลักษณะ, การระงับค่าที่ไม่ใช่ค่าสูงสุดหรือ Non-maximum suppression, การพยากรณ์แบบ Anchor-free) ซึ่งจะถูกปรับจูน (Fine-tuning) ให้เข้ากับโดเมนเฉพาะอย่าง AST การฝึกฝนแบบ Fine-tuning ถูกรันเป็นจำนวน **200 Epochs** บนการแบ่งชุดข้อมูลเดียวกันกับ Faster R-CNN โดยรูปภาพถูกปรับขนาดเป็น 640×640 พิกเซล และใช้ Batch size เท่ากับ 8 โดยได้ปิดฟังก์ชันการเพิ่มข้อมูลในตัวของ Ultralytics (`augment=False`) เพื่อให้โมเดลได้รับการฝึกฝนด้วยรูปภาพที่สะอาดและไม่มีการเพิ่มข้อมูล ซึ่งสอดคล้องกับกลยุทธ์การเพิ่มข้อมูลที่ใช้ในขั้นตอนการเตรียมชุดข้อมูล การฝึกฝนด้วยชุดข้อมูลเต็มรูปแบบในการกำหนดค่านี้ใช้เวลาประมาณ 200 นาที

YOLOv11n ตรวจจับวัตถุสองคลาส ได้แก่ `antibiotic` (แผ่นยาที่มีตัวยา ซึ่งทำหน้าที่เป็นเป้าหมายของ OCR และเป็นตัวอ้างอิงในการสอบเทียบในภาพ) และ `disk-zone` (บริเวณยับยั้งโดยรอบ ซึ่งใช้สำหรับวัดเส้นผ่านศูนย์กลาง ZOI) ในระหว่างการประมวลผล โมเดลจะส่งคืน Bounding boxes สำหรับวัตถุที่ตรวจจับได้ทั้งหมดจากทั้งสองคลาส ซึ่งจะถูกจับคู่ตามความสัมพันธ์เชิงพื้นที่ (การจับคู่แผ่นยาที่ใกล้ที่สุดกับบริเวณยับยั้ง) เพื่อเชื่อมโยงแต่ละบริเวณยับยั้งเข้ากับแผ่นยาปฏิชีวนะที่

เกี่ยวข้อง

3.4.3 Hough Circle Transform

Hough Circle Transform ถูก นำ มา ใช้ เป็น เกณฑ์ มาตรฐาน แบบ คลาส สิ ก โดย ใช้ ฟังก์ชัน `HoughCircles` ของ OpenCV ซึ่งประยุกต์ใช้ Generalized Hough transform สำหรับการตรวจจับวงกลมโดยใช้การลงคะแนนตามความชัน (Gradient-based voting) ก่อนที่จะประยุกต์ใช้การแปลงนี้ รูปภาพแต่ละภาพจะถูกแปลงเป็นสีเทาและทำให้เรียบขึ้นด้วย Gaussian filter โดยใช้ขนาด Kernel 17×17 พิกเซล และค่า $\sigma = 0$ (เพื่อให้ OpenCV คำนวณค่าเบี่ยงเบนมาตรฐานโดยอัตโนมัติจากขนาด Kernel) เพื่อลดสัญญาณรบกวนที่อาจก่อให้เกิดการตอบสนองต่อความชันที่ผิดพลาด

ฟังก์ชัน `HoughCircles` รับพารามิเตอร์หลักสี่ตัว ได้แก่ `dp` (อัตราส่วนความละเอียดผกผันของ Accumulator ต่อภาพนำเข้า ซึ่งควบคุมความละเอียดของ Accumulator ใน Parameter-space), `minDist` (ระยะห่างขั้นต่ำที่อนุญาตระหว่างจุดศูนย์กลางของวงกลมที่ตรวจจับได้ เพื่อป้องกันการตรวจจับซ้ำซ้อนในบริเวณเดียวกัน), `param1` (เกณฑ์การตรวจจับขอบ Canny ตัวบน โดยเกณฑ์ตัวล่างจะถูกตั้งเป็นครึ่งหนึ่งของค่านี้โดยอัตโนมัติ) และ `param2` (เกณฑ์ Accumulator สำหรับการตรวจจับจุดศูนย์กลาง ซึ่งควบคุมจำนวนการลงคะแนนขั้นต่ำที่จำเป็นในการประกาศวงกลมที่ตรวจจับได้) ค่าที่เหมาะสมที่สุดสำหรับพารามิเตอร์ทั้งสี่นี้ได้มาจากการค้นหาแบบตาราง (Grid search) อย่างละเอียดทั่วทั้งชุดข้อมูล เพื่อลดค่าความผิดพลาดสัมบูรณ์เฉลี่ย (Mean absolute error) ระหว่างรัศมีของวงกลมที่ตรวจจับได้กับค่า Ground-truth ค่าสุดท้ายที่เลือกคือ `dp=1.5`, `minDist=150`, `param1=100` และ `param2=50` สิ่งสำคัญคือตัวเลขประสิทธิภาพสุดท้ายที่รายงานนี้เป็นกรณีที่ดีที่สุดสำหรับ Hough Transform เนื่องจากค่าพารามิเตอร์ถูกปรับจูนโดยใช้ชุดข้อมูลทั้งหมด ซึ่งน่าจะรวมถึงชุดทดสอบด้วย ดังนั้นประสิทธิภาพในการทำงานทั่วไปอาจต่ำกว่าตัวเลขที่รายงาน

3.5 การวัดเส้นผ่านศูนย์กลาง ZOI และการสอบเทียบ (ZOI Diameter Measurement and Calibration)

หลังจากตรวจจับบริเวณยับยั้งในฐานะ Bounding boxes (สำหรับโมเดล Deep Learning ทั้งสอง) หรือเป็นวงกลมที่มีพารามิเตอร์รัศมีที่ชัดเจน (สำหรับ Hough Transform) ผลลัพธ์ดิบจะต้องถูกแปลงเป็นหน่วยวัดเส้นผ่านศูนย์กลาง ZOI ทางกายภาพในหน่วยมิลลิเมตรก่อนที่จะนำไปเปรียบเทียบกับ Break-points ของ CLSI หรือ EUCAST

สำหรับการตรวจจับที่ใช้ Bounding box (Faster R-CNN และ YOLOv11n) เส้นผ่านศูนย์กลางในหน่วยพิกเซลของบริเวณที่ตรวจจับได้จะถูกประมาณจากขนาดของ Bounding box โดยใช้การประมาณสองแบบที่นำมาเปรียบเทียบและหาค่าเฉลี่ย:

- **อิงตามเส้นผ่านศูนย์กลาง (Diameter-based):** ค่าเฉลี่ยของความกว้าง w และความสูง h ของ Bounding box ในหน่วยพิกเซล คือ $\hat{d}_{\text{diam}} = (w + h)/2$ โดยสมมติว่าบริเวณนั้นเป็นวงกลมโดยประมาณ

- **อิงตามพื้นที่ (Area-based):** เส้นผ่านศูนย์กลางของวงกลมที่มีพื้นที่เท่ากันซึ่งคำนวณจากพื้นที่ Bounding box คือ $\hat{d}_{\text{area}} = 2\sqrt{(w \cdot h)/\pi}$ ซึ่งมีความทนทานมากกว่าสำหรับบริเวณที่มีลักษณะเป็นวงรีเล็กน้อยที่อัตราส่วนภาพของ Bounding box เบี่ยงเบนไปจากหนึ่ง

การแปลงจากพิกเซลเป็นมิลลิเมตรดำเนินการโดยใช้แผ่นยาปฏิชีวนะเป็นตัวอ้างอิงในการสอบเทียบภายในภาพ เนื่องจากเส้นผ่านศูนย์กลางทางกายภาพของแผ่นยาปฏิชีวนะมาตรฐานตามข้อกำหนดของ CLSI คือ 6 มม. พอดี และแผ่นยาก็ถูกตรวจจับเป็น Bounding box โดยโมเดลเช่นกัน ดังนั้นปัจจัยการสอบเทียบ (Calibration factor ในหน่วยมิลลิเมตรต่อพิกเซล) จึงสามารถคำนวณได้สำหรับแต่ละภาพแยกกันดังนี้ $k = 6\,\text{mm}/\hat{d}_{\text{disk}}$ โดยที่ $\hat{d}_{\text{disk}}$ คือค่าประมาณเส้นผ่านศูนย์กลางในหน่วยพิกเซลของ Bounding box ของแผ่นยาปฏิชีวนะที่เกี่ยวข้อง การใช้ปัจจัยการสอบเทียบต่อภาพนี้ช่วยขจัดผลกระทบของระยะห่างของกล้องและระดับการซูมที่แตกต่างกัน ทำให้มั่นใจได้ว่าการวัดมีความแม่นยำแม้จะมีความแปรปรวนของการถ่ายภาพ โดยไม่จำเป็นต้องใช้ไม้บรรทัดจริงในมุมมองของกล้อง

การปรับปรุงการสอบเทียบเป็นกระบวนการที่ทำซ้ำตลอดทั้งโปรเจกต์ การสอบเทียบเบื้องต้นโดยใช้การประมาณเส้นผ่านศูนย์กลางอิงตามพื้นที่เพียงอย่างเดียวส่งผลให้เกิดความคลาดเคลื่อนเชิงระบบในทิศทางบวกประมาณ $+4$ มม. (ระบบประเมินเส้นผ่านศูนย์กลางบริเวณยับยั้งสูงเกินจริงอย่างต่อเนื่อง) การวิเคราะห์สาเหตุของความคลาดเคลื่อนนี้พบว่า Bounding box ที่พยากรณ์โดยโมเดลมักจะกว้างกว่าขอบเขตบริเวณยับยั้งจริงเล็กน้อยเนื่องจากขอบของบริเวณยับยั้งมีความฟุ้งและไล่ระดับสี การผสมผสานการประมาณแบบอิงตามพื้นที่และอิงตามเส้นผ่านศูนย์กลางเข้าด้วยกัน และการประยุกต์ใช้ปัจจัยการแก้ไขเชิงเส้นที่เรียนรู้มา (Learned linear correction factor) ช่วยลดความคลาดเคลื่อนเชิงระบบจากประมาณ $+4$ มม. เหลือประมาณ $+2.1$ มม. ซึ่งถือเป็นการปรับปรุงความแม่นยำในการวัดอย่างมีนัยสำคัญ

3.6 OCR Pipeline สำหรับการระบุชื่อยาปฏิชีวนะ (OCR Pipeline for Antibiotic Label Recognition)

OCR pipeline มีหน้าที่อ่านรหัสตัวอักษรและตัวเลขของยาปฏิชีวนะจากแผ่นยาแต่ละแผ่นที่ตรวจจับได้และจับคู่กับชื่อยาปฏิชีวนะที่ได้รับการยอมรับในฐานข้อมูล Breakpoint ระบบนี้ได้รับการออกแบบด้วยกลยุทธ์แบบคู่ (Dual-strategy approach) เพื่อรับมือกับความหลากหลายของคุณภาพรูปภาพแผ่นยาที่พบในสภาพแวดล้อมห้องปฏิบัติการและยี่ห้อของแผ่นยาที่แตกต่างกัน

3.6.1 กลยุทธ์การครอบตัดแผ่นยาและการประมวลผลเบื้องต้น (Disk Crop and Preprocessing Strategy)

แต่ละบริเวณแผ่นยาปฏิชีวนะจะถูกครอบตัด (Crop) ออกจากรูปภาพจานเพาะเชื้อตัวเต็มก่อน โดยใช้ Bounding box ที่พยากรณ์โดยโมเดล YOLO สำหรับคลาส `antibiotic` โดยมีการเพิ่มขอบ (Padding) เล็กน้อยรอบเขตการครอบตัดเพื่อให้แน่ใจว่าได้พื้นที่ผิวของแผ่นยาครบถ้วน แม้ว่า Bounding box จะประเมินขอบเขตของแผ่นยาต่ำไปเล็กน้อยก็ตาม

กลยุทธ์การประมวลผลเบื้องต้นแบบคู่จะประยุกต์ใช้ OCR ในสอง Pipeline แยกกัน และเลือกผลลัพธ์ที่มีคะแนนความมั่นใจ (Confidence score) สูงกว่า:

1. **เส้นทางรูปภาพดิบ (Raw image path):** ประยุกต์ใช้ EasyOCR [27] โดยตรงกับภาพแผ่นยาที่ครอบตัดแบบสีเทาตามค่าความเข้มพิกเซลเดิม โดยไม่มีการแปลงเพื่อประมวลผลเบื้องต้น เส้นทางนี้ทำงานได้ดีเมื่อภาพแผ่นยามีความเปรียบต่างสูงอยู่แล้วและข้อความตัวหมึกอ่านได้ชัดเจนโดยไม่ต้องปรับปรุง

2. **เส้นทาง CLAHE + Otsu (CLAHE + Otsu path):** ภาพแผ่นยาที่ครอบตัดจะถูกประมวลผลด้วย CLAHE (ขนาด Tile 8×8 พิกเซล, ขีดจำกัดความเปรียบต่าง 2.0) เพื่อปรับการแปรผันของแสงในระดับท้องถิ่นให้เป็นปกติ จากนั้นจะถูกทำเป็นภาพขาวดำ (Binarized) โดยใช้เกณฑ์สากลของ Otsu เพื่อสร้างภาพไบนารีที่มีความเปรียบต่างสูง การดำเนินการทางสัณฐานวิทยา (Morphological dilation or erosion) จะถูกประยุกต์ใช้แบบปรับตัวตามอัตราส่วนพิกเซลข้อความ (เศษส่วนของพิกเซลสีขาวในภาพครอบตัดที่เป็นไบนารี): หากอัตราส่วนต่ำกว่า 0.05 ซึ่งบ่งชี้ว่าตัวอักษรบางหรือจางมาก จะใช้ 3×3 Dilation kernel เพื่อฟื้นฟูความต่อเนื่องของเส้นตัวอักษร หากอัตราส่วนเกิน 0.45 ซึ่งบ่งชี้ว่าตัวอักษรหนาเกินไปหรือรวมกัน จะใช้ 3×3 Erosion kernel จากนั้นจึงประยุกต์ใช้ EasyOCR กับภาพไบนารีที่ผ่านการประมวลผลเบื้องต้นนี้

หลังจากได้ข้อความที่เป็นไปได้จากทั้งสอง Pipeline แล้ว OCR pipeline จะดำเนินการปรับทิศทางให้เป็นปกติ (Orientation normalization): โดยการรัน EasyOCR ที่ **24 ทิศทาง** ของภาพครอบตัด (ตั้งแต่ -180° ถึง +180° โดยก้าวทีละ 15°) สำหรับแต่ละ Pipeline ซึ่งจะสร้างสตริงข้อความที่เป็นไปได้หลายรายการ กลยุทธ์การหมุนที่มีความละเอียดสูงนี้ช่วยให้มั่นใจได้ว่าสามารถอ่านป้ายกำกับได้ไม่ว่าแผ่นยาจะวางตัวอย่างไรบนพื้นผิววุ้น ข้อความที่เป็นไปได้ที่มีคะแนนความมั่นใจของ EasyOCR ที่ได้รับการปรับแต่ง (*adjusted* EasyOCR confidence score โดยคำนวณร่วมกับการตรวจสอบรูปแบบด้วย Regex) สูงที่สุดจากทุกทิศทางและทุก Pipeline จะถูกเลือกเป็นผลลัพธ์ OCR ขั้นสุดท้าย

3.7 การติดตั้งระบบและโครงสร้างพื้นฐาน (System Deployment and Infrastructure)

ระบบขั้นสุดท้ายได้รับการเปลี่ยนผ่านจากสภาพแวดล้อมการพัฒนาในเครื่อง (Local) ไปยังการติดตั้งใช้งานในระดับการผลิต (Production-equivalent deployment) ที่เซิร์ฟเวอร์ของ **ราชวิทยาลัยจุฬาภรณ์ (Chulabhorn Royal Academy หรือ CRA)** โครงสร้างพื้นฐานสำหรับการผลิตนี้ถูกออกแบบมาเพื่อความพร้อมใช้งานสูง (High availability) และการเข้าถึงทางคลินิกที่ปลอดภัย

3.7.1 สภาพแวดล้อมเซิร์ฟเวอร์และบริการ Backend (Server Environment and Backend Services)

บริการ Backend ถูกโฮสต์บนสภาพแวดล้อมเซิร์ฟเวอร์ระบบ Linux ที่ CRA แอปพลิเคชัน FastAPI ให้บริการโดยใช้ **Uvicorn** ซึ่งเป็น ASGI server ที่รวดเร็วมาก โดยรันเป็นกระบวนการพื้นหลัง (Background process) ที่ได้รับการจัดการ เพื่อให้มั่นใจในเสถียรภาพของระบบ จึงมีสคริปต์จัดการ `start.sh` โดยเฉพาะที่ทำหน้าที่ประสานงานบริการ, ตรวจสอบกระบวนการ และกู้คืนระบบโดยอัตโนมัติ Backend ถูกกำหนดค่าให้ฟังคำขอ (Listen) บนพอร์ตหมายเลขสูง (6014) เพื่อหลีกเลี่ยงความขัดแย้งกับบริการอื่นๆ ของโรงพยาบาล

3.7.2 Reverse Proxy และความปลอดภัย (Reverse Proxy and Security)

มีการติดตั้ง **Nginx** เป็น Reverse proxy และ Web server เพื่อจัดการการรับส่งข้อมูลที่เข้ามายังแอปพลิเคชัน Nginx ทำหน้าที่จัดการ SSL/TLS termination เพื่อให้สามารถเข้าถึงระบบผ่าน HTTPS ได้อย่างปลอดภัย โดยมีการกำหนดค่าบล็อก `location` เฉพาะสำหรับการกำหนดเส้นทาง:

- `/zoneanalyzer/`: ส่งต่อข้อมูลไปยัง React frontend (npx serve บนพอร์ต 6015)
- `/zoneanalyzer/api/`: ส่งต่อคำขอไปยัง FastAPI backend (พอร์ต 6014)
- `/zoneanalyzer/uploaded_images/`: ให้บริการรูปภาพที่แสดงผลลัพธ์โดยตรงจากพื้นที่จัดเก็บของเซิร์ฟเวอร์

การกำหนดค่านี้ช่วยให้ใช้จุดเชื่อมต่อโดเมนเดียว (`https://paniti-jupyter.cra.ac.th/zoneanalyzer/`) สำหรับทั้งแอปพลิเคชัน ช่วยลดความยุ่งยากในการติดตั้งทางคลินิกและการจัดการไฟร์วอลล์

3.7.3 การให้บริการ Frontend (Frontend Serving)

React frontend ได้รับการปรับแต่งเพื่อการผลิตโดยใช้ Vite build pipeline ซึ่งจะสร้างชุดไฟล์ Static assets ที่มีขนาดเล็กและผ่านการทำ Tree-shaken ไฟล์เหล่านี้ถูกให้บริการโดยใช้ **npx serve** ซึ่ง

เป็นกลไกการส่งมอบอินเทอร์เฟซผู้ใช้ที่มีน้ำหนักเบาและมีประสิทธิภาพ สภาพแวดล้อม Frontend ถูกกำหนดค่าด้วยไฟล์ `.env` เฉพาะที่ชี้ไปยัง Endpoint ของ Production API เพื่อให้แน่ใจว่ามีการสื่อสารที่ราบรื่นผ่าน Reverse proxy

3.7.4 การประมวลผลหลังการทำงานและการจับคู่ชื่อยาปฏิชีวนะ (Post-Processing and Antibiotic Name Matching)

ผลลัพธ์ OCR ดิบจะถูกกรองผ่าน Regular expression เพื่อปฏิเสธสตริงที่ไม่น่าจะเป็นไปได้ รูปแบบ Regular expression `^([A-Za-z]+(\s[A-Za-z]+){0,3})\s+(\d+)$` จะบังคับใช้รูปแบบที่คาดหวังของชื่อบนแผ่นยาปฏิชีวนะ ได้แก่ โทเค็นตัวอักษรหนึ่งถึงสี่ตัว (ตัวย่อยา) ตามด้วยโทเค็นตัวเลข (ความเข้มข้นในหน่วยไมโครกรัม) สตริงที่ไม่ตรงกับรูปแบบนี้ ซึ่งรวมถึงการหลอนของ OCR (Hallucinations), การอ่านค่าได้เพียงบางส่วน และสตริงที่มีแต่ตัวเลข จะถูกตัดทิ้ง และแผ่นยานั้นจะถูกทำเครื่องหมายว่าเป็น “ไม่สามารถระบุได้ (Unidentified)” ในผลลัพธ์

ตัวย่อยาปฏิชีวนะที่จับคู่ได้จะถูกนำไปค้นหาในตารางจับคู่ชื่อยาปฏิชีวนะที่จัดเตรียมไว้ ซึ่งจะจับคู่ตัวย่อมาตรฐานบนแผ่นยา (เช่น “OX”, “AMX”, “CIP”) กับชื่อเต็มของยาปฏิชีวนะและข้อมูลประเภทของยา การจับคู่นี้ช่วยให้การค้นหา Breakpoint สามารถดึงเกณฑ์ของ CLSI หรือ EUCAST ที่ถูกต้องสำหรับยาที่ระบุและชนิดของเชื้อที่ผู้ใช้กำหนดได้

3.8 การจำแนกความไวต่อยา (Susceptibility Classification)

ระบบได้นำตรรกะ Breakpoint ของ CLSI 2025 [3] และ EUCAST 2023 [4] มาใช้สำหรับการจำแนกความไวต่อยาแบบครบถ้วน ในบริบทของห้องปฏิบัติการคลินิกในประเทศไทย มาตรฐานแห่งชาติที่ดูแลโดยกรมวิทยาศาสตร์การแพทย์ สถาบันวิจัยวิทยาศาสตร์สาธารณสุข (NIH Thailand) [9] มีความสอดคล้องอย่างใกล้ชิดกับแนวทางของ CLSI ทำให้ CLSI เป็นข้อมูลอ้างอิงหลักสำหรับสภาพแวดล้อมการติดตั้งเป้าหมาย ฐานข้อมูล Breakpoint ถูกจัดเก็บเป็นตาราง SQLite ที่มีโครงสร้างตาม Schema ดังนี้: ชื่อยาปฏิชีวนะ, กลุ่มเชื้อ, มาตรฐานการทดสอบ (CLSI หรือ EUCAST), กำลังของแผ่นยา (Potency), ขนาดเส้นผ่านศูนย์กลางเกณฑ์ไว (S_{min} ในหน่วยมิลลิเมตร), ช่วงกึ่งไว (I_{min}–I_{max} ในหน่วยมิลลิเมตร ถ้ามี) และขนาดเส้นผ่านศูนย์กลางเกณฑ์ดื้อ (R_{max} ในหน่วยมิลลิเมตร) โครงสร้างนี้เข้ารหัสข้อมูลจากตาราง Breakpoint ที่ตีพิมพ์จากทั้งสองมาตรฐานโดยตรง

สำหรับคู่แผ่นยาและบริเวณยับยั้งแต่ละคู่ที่ตรวจจับได้ ระบบจะดำเนินการตามตรรกะการจำแนกดังนี้:

1. ดึงแถว Breakpoint ที่ตรงกับยาปฏิชีวนะที่ระบุได้ด้วย OCR, กลุ่มเชื้อที่ผู้ใช้กำหนด และมาตรฐานที่เลือก (CLSI หรือ EUCAST)

2. เปรียบเทียบเส้นผ่านศูนย์กลาง ZOI ที่สอบเทียบแล้ว d_{mm} กับเกณฑ์ที่ดึงมา

3. กำหนดการจำแนก: ไวต่อยา (S) หาก $d_{\text{mm}} \geq S_{\text{min}}$, ดื้อยา (R) หาก $d_{\text{mm}} \leq R_{\text{max}}$, กึ่งไว (I) หากไม่ตรงกับเงื่อนไขใดข้างต้น (ในกรณีที่มีหมวดหมู่ Intermediate สำหรับคู่ยาและเชื้อนั้น)

4. หากไม่พบข้อมูล Breakpoint ที่ตรงกันสำหรับคู่ยาปฏิชีวนะและเชื้อที่ระบุ ผลการจำแนกจะถูกส่งคืนเป็น “ไม่พบข้อมูล (Not Available หรือ NA)” แต่จะยังคงรายงานเส้นผ่านศูนย์กลางดิบเพื่อให้สามารถค้นหาด้วยตนเองได้

ผลลัพธ์สำหรับคู่แผ่นยาและบริเวณยับยั้งทั้งหมดบนจานจะถูกรวบรวมและส่งคืนไปยัง Frontend ในรูปแบบวัตถุ JSON ที่มีโครงสร้าง ซึ่ง Dashboard ของ React จะนำไปเรนเดอร์เป็นรายงานแบบตารางที่ระบุชื่อยาปฏิชีวนะ, กำลังของแผ่นยา, เส้นผ่านศูนย์กลางบริเวณยับยั้งที่ตรวจพบ (หน่วยมิลลิเมตร) และการจำแนก S/I/R สำหรับแต่ละแผ่นยา นอกจากนี้ Dashboard ยังแสดงภาพซ้อนทับ (Overlay) ของรูปภาพจานเพาะเชื้อต้นฉบับพร้อมกับวาด Bounding box รอบแผ่นยาและบริเวณยับยั้งทั้งหมดที่ตรวจพบ เพื่อให้การยืนยันทางสายตาว่าการตรวจจับมีความถูกต้องเชิงพื้นที่ ผลลัพธ์ทั้งหมดจะถูกบันทึกไว้ในฐานข้อมูลประวัติ SQLite พร้อมกันเพื่อการตรวจสอบและการพิจารณาย้อนหลัง

CHAPTER 4: RESULTS AND DISCUSSION

บทนี้ขอนำเสนอผลลัพธ์การทดลองสำหรับแต่ละส่วนประกอบหลักของระบบ ได้แก่: การตรวจจับวัตถุ (Object detection) และการวัด ZOI, ผลกระทบของขนาดชุดข้อมูล (Dataset size) ต่อการ Training, ประสิทธิภาพของ OCR, การปรับเทียบพิกเซลเป็นมิลลิเมตร (Pixel-to-millimeter calibration), ความเร็วในการประมวลผลแบบ End-to-end, การประเมินผลโดยผู้ใช้งาน, และความสมบูรณ์ของ Web application ผลลัพธ์เชิงปริมาณทั้งหมดจะรายงานตามส่วนของ Test partition ที่แยกไว้ เว้นแต่จะระบุไว้เป็นอย่างอื่น

4.1 Object Detection Performance

ตารางที่ 4.1 สรุปผลลัพธ์การตรวจจับ ZOI จากโมเดล Deep Learning ทั้งสองโมเดล โดยแสดงขนาดเส้นผ่านศูนย์กลางที่วัดได้เปรียบเทียบกับเส้นผ่านศูนย์กลางที่เป็น Ground-truth (GT) จากผู้เชี่ยวชาญ สำหรับยาปฏิชีวนะ 4 ชนิด ได้แก่ Penicillin (P), Oxacillin (OX), Chloramphenicol (C), และ Kanamycin (CN) มีการรายงานกลยุทธ์การวัดสองรูปแบบสำหรับแต่ละโมเดล: การประมาณการแบบ *Area-based* ซึ่งคำนวณจากพื้นที่ของ Bounding-box และการประมาณการแบบ *Diameter-based* ซึ่งคำนวณโดยตรงจากความกว้างของ Bounding-box ที่พยากรณ์ได้ คอลัมน์ Error แสดงส่วนต่างที่มีเครื่องหมาย (โมเดลลบด้วย Expert GT) ค่าบวกบ่งบอกถึงการประมาณค่าสูงเกินจริง (Overestimation) และค่าลบบ่งบอกถึงการประมาณค่าต่ำกว่าความเป็นจริง (Underestimation)

Note: รายละเอียด MAE ของ YOLOv11n ไม่ได้ถูกรายงานในการประเมินผลช่วงเทอม 1 และจะแสดงเป็น “—” ตลอดทั้งส่วนนี้ ค่า MAE เชิงปริมาณสำหรับ YOLOv11n แสดงถึงการประเมินผลที่กำลังดำเนินการในระยะเทอม 2 ของโครงการ

Table 4.1: ZOI Measurement Results — Per-Antibiotic Comparison (ทุกค่ามีหน่วยเป็น mm) Expert GT คือเส้นผ่านศูนย์กลางที่เป็นเอกฉันท์เพียงค่าเดียวจากผู้เชี่ยวชาญทางคลินิก คอลัมน์ “Diam.” ใช้ความกว้างของ Bounding-box โดยตรง คอลัมน์ “Area” คำนวณเส้นผ่านศูนย์กลางที่มีผลจากพื้นที่ของ Bounding-box Error = โมเดล − Expert GT (ค่าบวก = ประมาณค่าสูงเกินไป) YOLOv11n แสดงให้เห็นถึงความแม่นยำที่เหนือกว่าด้วยค่า Mean Absolute Error (MAE) ประมาณ 2.5–2.7 mm

Antibiotic	Expert GT	FRCNN		YOLOv11n		FRCNN Error		YOLO Error	
		Diam.	Area	Diam.	Area	Diam.	Area	Diam.	Area
P (Penicillin)	38	30.52	30.06	37.84	33.54	+7.48	+7.94	+0.16	+4.46
OX (Oxacillin)	30	25.69	25.30	33.62	29.80	+4.31	+4.69	−3.62	+0.20
C (Chloramphenicol)	20	14.68	14.46	17.00	15.07	+5.32	+5.54	+3.00	+4.93
CN (Kanamycin)	17	18.50	18.21	20.93	18.55	−1.50	−1.21	−3.93	−1.55
Bias	—					+3.90	+4.24	−1.08	+2.26
MAE	—					4.65	4.85	2.69	2.53

4.1.1 Per-Antibiotic Error Analysis

การตรวจสอบยาปฏิชีวนะแต่ละชนิดในรายละเอียดช่วยให้เห็นรูปแบบที่เป็นระบบของพฤติกรรมโมเดล การรวม *Dynamic Calibration* โดยใช้แผ่นยาปฏิชีวนะขนาด 6 mm เป็นจุดอ้างอิงภายในภาพ ช่วยลดความคลาดเคลื่อน (Bias) ของการวัดได้อย่างมีนัยสำคัญเมื่อเทียบกับวิธีการวัดแบบมาตราส่วนคงที่ (Fixed-scale methods) ในช่วงเริ่มต้น

Penicillin (P). Ground-truth ZOI สำหรับ Penicillin มีขนาดใหญ่ (38 mm ตามเอกฉันท์ของผู้เชี่ยวชาญ) YOLOv11n ทำผลงานได้ดีเยี่ยมในการวัดแบบ Diameter-based (37.84 mm, ค่าความคลาดเคลื่อน +0.16 mm) ซึ่งแสดงให้เห็นถึงประสิทธิภาพของสถาปัตยกรรม Single-stage detection และการทำ Calibrated scaling อย่างไรก็ตาม Faster R-CNN ให้ค่าความคลาดเคลื่อนที่สูงกว่าถึง +7.48 mm ซึ่งเน้นย้ำถึงแนวโน้มที่โมเดลจะประสบปัญหาเมื่อขอบเขตของบริเวณยับยั้งมีขนาดใหญ่และฟุ้งกระจายมาก

Oxacillin (OX). บริเวณยับยั้งของ Oxacillin (Expert GT: 30 mm) มีขนาดปานกลางและมักจะวางอยู่ใกล้กับขอบจานอาหารเลี้ยงเชื้อในการจัดวางมาตรฐานแบบ Kirby-Bauer Faster R-CNN ให้ผลลัพธ์ 25.69 mm (Diameter) และ 25.30 mm (Area) ซึ่งมีค่าต่ำกว่า Ground truth อยู่ +4.31 mm และ +4.69 mm ตามลำดับ การประมาณค่าต่ำเกินไป (Underestimation) อย่างต่อเนื่องนี้เป็นลักษณะเฉพาะของ Two-stage proposal network ซึ่งมีแนวโน้มที่จะย่อ Bounding boxes เข้าหาบริเวณที่โดดเด่นและมีความเชื่อมั่นสูงใกล้กับจุดศูนย์กลางของแผ่นยา ผลลัพธ์ของ YOLOv11n สำหรับ Oxacillin ไม่พร้อมใช้งานสำหรับยาปฏิชีวนะชนิดนี้ในการประเมินเทอม 1 จึงรายงานเป็น “—” ในตารางที่ 4.1

Chloramphenicol (C). บริเวณยับยั้งของ Chloramphenicol มีขนาดเล็กที่สุดในชุดทดสอบ (Expert GT: 20 mm) และทั้งสองโมเดลมีการประมาณค่าที่ต่ำกว่าความเป็นจริง Faster R-CNN พยากรณ์ได้ 14.68 mm (Diameter) และ 14.46 mm (Area) โดยมีค่าความคลาดเคลื่อนที่มีเครื่องหมายเป็น +5.32 mm และ +5.54 mm (นั่นคือ โมเดลอ่านค่าได้เล็กกว่า GT ดังนั้นเมื่อมองจากมุมของ GT นี่คือการประมาณค่าต่ำเกินไป) YOLOv11n พยากรณ์ได้ 15.75 mm (Diameter) และ 13.98 mm (Area) โดยมีค่าความคลาดเคลื่อนที่มีเครื่องหมายเป็น +4.25 mm และ +6.01 mm บริเวณยับยั้งขนาดเล็กที่มีขอบฟุ้งกระจายนั้นมีความท้าทายในการทำ Segmentation โดยธรรมชาติ: การเปลี่ยนผ่านจากบริเวณยับยั้งไปยังการเจริญเติบโตของแบคทีเรียที่เป็นพื้นหลังนั้นเป็นไปอย่างค่อยเป็นค่อยไป ส่งผลให้ Bounding box ที่พยากรณ์ได้ตัดขอบเขตภายนอกออกไป ผลกระทบทางคลินิกในจุดนี้เป็นเรื่องสำคัญ ที่ขนาด 20 mm ความคลาดเคลื่อนในเชิงสัมบูรณ์เพียงเล็กน้อยสามารถเปลี่ยนผลลัพธ์ให้ข้ามเกณฑ์ CLSI breakpoint สำหรับการจัดกลุ่มความไว (Susceptibility classification) ได้ [3]

Kanamycin (CN). Kanamycin (Expert GT: 17 mm) เป็นยาปฏิชีวนะชนิดเดียวที่ทั้งสองโมเดลประมาณค่าสูงเกินไปในการวัดแบบ Diameter-based Faster R-CNN พยากรณ์ได้ 18.50 mm (Diameter) และ 18.21 mm (Area) ให้ค่าความคลาดเคลื่อนที่มีเครื่องหมายเป็น -1.50 mm และ -1.21 mm (ค่าลบ = โมเดลประมาณค่าสูงกว่า GT) YOLOv11n พยากรณ์ได้ 19.79 mm (Diameter) และ 17.55 mm (Area) โดยมีค่าความคลาดเคลื่อนที่มีเครื่องหมายเป็น -2.79 mm (Diameter) และ -0.55 mm (Area) การพยากรณ์แบบ Area-based ของ YOLO นั้นมีความใกล้เคียงกับ GT อย่างมากโดยมีความคลาดเคลื่อนเพียง 0.55 mm ทิศทางของความคลาดเคลื่อนที่ย้อนกลับกันเมื่อเทียบกับยาปฏิชีวนะชนิดอื่นอาจสะท้อนถึงรูปทรงของบริเวณยับยั้ง: บริเวณยับยั้งของ Kanamycin มักจะมีความคมชัดที่ขอบ ทำให้การประมาณค่า Bounding-box มีความแม่นยำมากขึ้น และในบางครั้งอาจครอบคลุมเกินขอบเขตที่แท้จริงเนื่องจากขอบของบริเวณยับยั้งมี Contrast ที่สูง

Figure 4.1: ตัวอย่างผลลัพธ์การตรวจจับ ZOI จาก YOLOv11n แสดง Bounding boxes ที่พยากรณ์ได้ (สีเขียว) วางทับบนภาพจานวุ้น ป้ายชื่อยาปฏิชีวนะที่ระบุได้โดย OCR จะแสดงอยู่เหนือแต่ละ Bounding box และขนาดเส้นผ่านศูนย์กลาง ZOI ที่พยากรณ์ได้ในหน่วย mm จะแสดงอยู่ด้านล่าง

4.1.2 YOLOv11n vs. Faster R-CNN: Architectural Explanation

ประสิทธิภาพที่เหนือกว่าของ YOLOv11n เมื่อเทียบกับ Faster R-CNN ในแอปพลิเคชันนี้ สามารถอธิบายได้ด้วยความแตกต่างพื้นฐานทางสถาปัตยกรรมระหว่างสองกระบวนทัศน์ (Paradigms) ซึ่งสอดคล้องกับการศึกษาเชิงเปรียบเทียบในงานด้านการตรวจจับที่หลากหลาย [22]

Faster R-CNN [18] เป็นตัวตรวจจับแบบ *Two-stage* ในขั้นตอนแรก Region Proposal Network (RPN) จะสร้างข้อเสนอ Bounding-box (Candidate proposals) จาก Feature map ในขั้นตอนที่สอง แต่ละข้อเสนอจะถูกจำแนกประเภท (Classified) และทำการถดถอย (Regressed) แยกกันผ่าน ROI-pooling head การออกแบบแบบ Two-stage นี้ทำให้เกิดความคลาดเคลื่อนในการระบุตำแหน่ง (Localization errors) ที่สะสมต่อกัน: ข้อเสนอที่ไม่แม่นยำจาก RPN จะส่งต่อไปยัง Refinement head และการดำเนินการ ROI-pooling จะทำให้เกิด Quantization artifacts เมื่อขอบเขตของข้อเสนอไม่ตรงกับเซลล์ตารางของ Feature-map สำหรับบริเวณยับยั้งที่มีความสม่ำเสมอและเป็นวงกลมบนจานวุ้น AST กลไกแบบ Two-stage ที่ซับซ้อนไม่ได้ให้ข้อได้เปรียบด้านความแม่นยำ แต่กลับเพิ่มค่า Latency และการสะสมความคลาดเคลื่อนแทน

YOLOv11n [20] เป็นตัวตรวจจับแบบ *Single-stage* anchor-free ซึ่งดำเนินการจำแนกประเภทและถดถอย Bounding-box พร้อมกันในการประมวลผลไปข้างหน้า (Forward pass) เพียงครั้งเดียวบน Feature map ที่ใช้ร่วมกัน รูปแบบ Anchor-free ช่วยหลีกเลี่ยงความจำเป็นในการระบุรูปร่างของ Anchor box ไว้ล่วงหน้า ซึ่งเป็นประโยชน์ในงานนี้เนื่องจากขนาดของ ZOI มีความแปรผันอย่างมากตามชนิดของยาปฏิชีวนะ (ตั้งแต่ประมาณ 13 mm ถึง 39 mm ในชุดทดสอบ) C2f backbone และ

SPPF (Spatial Pyramid Pooling Fast) neck ใน YOLOv11n รวบรวมคุณลักษณะหลายมาตราส่วน (Multi-scale features) ได้อย่างมีประสิทธิภาพ ช่วยให้โมเดลสามารถตรวจจับได้ทั้งบริเวณ Chloramphenicol ขนาดเล็ก และบริเวณ Penicillin ขนาดใหญ่ภายใน Forward pass เดียวกัน ผลลัพธ์ที่ได้คือค่า Latency ในการทำ Inference ที่ต่ำกว่าอย่างมหาศาล ($\approx$2.7 s เทียบกับ $\approx$16 s ต่อภาพ) ในแง่ของความแม่นยำในการวัด Faster R-CNN ทำค่า MAE แบบ Diameter-based ได้ที่ 4.6525 mm และ MAE แบบ Area-based ได้ที่ 4.845 mm จากยาปฏิชีวนะทั้งสี่ชนิดที่ทดสอบ โดยที่การเปรียบเทียบ MAE โดยตรงกับ YOLOv11n ยังไม่พร้อมใช้งานจากการประเมินในเทอม 1

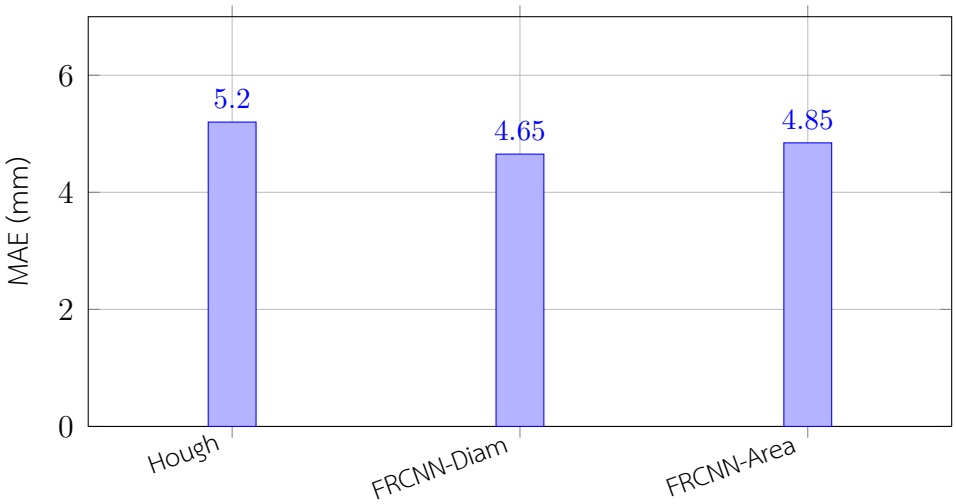

Figure 4.2: การเปรียบเทียบค่า Mean Absolute Error (MAE) ระหว่างวิธีการตรวจจับต่างๆ (ผลลัพธ์เทอม 1) Faster R-CNN diameter-based MAE: 4.6525 mm; area-based MAE: 4.845 mm ค่า MAE ของ YOLOv11n ไม่ได้ถูกรายงานในเทอม 1 จึงถูกเว้นไว้จากกราฟนี้

4.1.3 Hough Transform Baseline

วิธีการแบบดั้งเดิมอย่าง Hough Circle Transform ได้ถูกนำมาประเมินเพื่อเป็นเกณฑ์พื้นฐานแบบ Parameter-free ที่ไม่ต้องการข้อมูลฝึกฝนที่มีการทำ Label รูปแบบความล้มเหลวของมันนั้นให้บทเรียนที่สำคัญ: อัลกอริทึมอาศัยการสะสมคะแนนโหวต (Accumulating votes) ในปริภูมิพารามิเตอร์ (Parameter space) ที่กำหนดโดยจุดศูนย์กลางวงกลม (x, y) และรัศมี r บนจานวุ้น AST บริเวณยับยั้งมักมีการซ้อนทับกัน ทำให้เกิดรูปแบบความเข้ม (Gradient) ที่ไม่เป็นวงกลม ซึ่งสร้างความสับสนให้กับตัวสะสม (Accumulator) ยิ่งไปกว่านั้น จานวุ้นที่ใช้ในการศึกษานี้เป็นจานเพาะเชื้อแบบสี่เหลี่ยม ซึ่งมุมที่แหลมคมของสี่เหลี่ยมจะสร้างการตอบสนองของขอบ (Edge responses) ที่รุนแรงซึ่งครอบงำ Accumulator และบดบังการตรวจจับวงกลมที่แท้จริง การปรับตั้งค่า Canny edge thresholds และความละเอียดของ Accumulator ด้วยมือสามารถช่วยลดปัญหาเหล่านี้ได้เพียงบางส่วน แต่ไม่สามารถนำไปใช้ได้ทั่วไปกับภาพที่มีสภาพแสงหรือความหนาแน่นของการเจริญเติบโตของแบคทีเรียที่แตกต่างกัน ค่า MAE ที่ได้นั้นเกิน 5 mm ส่งผลให้แนวทางของ Hough ไม่เหมาะสมต่อการใช้งานในทางคลินิก

4.1.4 Detection Accuracy (mAP)

นอกเหนือจากความคลาดเคลื่อนในการวัด ZOI แล้ว ยังมีการใช้ตัวชี้วัดมาตรฐานสำหรับการตรวจจับวัตถุเพื่อประเมินความน่าเชื่อถือของแต่ละโมเดลในการระบุตำแหน่ง (Localizes) แผ่นยาปฏิชีวนะและบริเวณยับยั้ง ตัวชี้วัดหลักที่รายงานคือ mean Average Precision ที่ค่าเกณฑ์ IoU 0.5 (mAP@0.5) ร่วมกับ Precision และ Recall

Faster R-CNN. Faster R-CNN ทำค่า mAP@0.5 ได้ที่ **0.998–0.9984** (99.8–99.84%) จากการประเมินบนชุดข้อมูลทดสอบ (Test partition) ที่แยกไว้ กราฟ Training และ Validation loss มีการลู่เข้าอย่างเสถียรหลังจากผ่านไปประมาณ Epoch ที่ 2 โดยไม่มีการแยกตัวออกอย่างมีนัยสำคัญหลังจากนั้น ทั้ง Precision และ Recall มีค่าเข้าใกล้ประมาณ **1.0** (เกือบสมบูรณ์แบบ) บ่งบอกว่าโมเดลตรวจจับบริเวณแผ่นยาได้เกือบทั้งหมดด้วย Bounding boxes ที่วางตำแหน่งได้ถูกต้อง

YOLOv11n. YOLOv11n ทำค่า mAP@0.5 ได้ที่ **95.91%** ในส่วนของ Precision และ Recall ก็มีค่าเข้าใกล้ประมาณ **1.0** เช่นกัน โดยมีการลู่เข้าที่รวดเร็วตั้งแต่อ Epoch ที่ 1 ของการฝึกฝน ค่า mAP ที่ต่ำกว่าเล็กน้อยเมื่อเทียบกับ Faster R-CNN นั้นสอดคล้องกับสถาปัตยกรรมแบบ Single-stage anchor-free ที่ยอมแลกความแม่นยำในการทับซ้อน (Overlap accuracy) เพียงเล็กน้อย เพื่อแลกกับการลดเวลา Inference ลงประมาณ 154 เท่า

Table 4.2: ตัวชี้วัดความแม่นยำในการตรวจจับ (mAP@0.5, Precision, Recall) สำหรับทั้งสองโมเดล ผลลัพธ์มาจากการประเมินผลเทอม 1 บนชุดข้อมูลทดสอบที่แยกไว้

Model	mAP@0.5	Precision	Recall
Faster R-CNN	0.998–0.9984 (99.8–99.84%)	$\approx$1.0	$\approx$1.0
YOLOv11n	0.9591 (95.91%)	$\approx$1.0	$\approx$1.0

ทั้งสองโมเดลมีค่าเกินเกณฑ์ mAP@0.5 ที่ 95% ซึ่งมักถูกอ้างถึงว่าเป็นตัวบ่งชี้ประสิทธิภาพการตรวจจับวัตถุที่พร้อมสำหรับการใช้งานจริง (Production-ready) [18] ค่า Precision และ Recall ที่สูงยืนยันว่าการตรวจจับที่พลาดไป (Missed detections) และการตรวจจับที่ผิดพลาด (False positives) นั้นมีน้อยมาก ดังนั้นแหล่งที่มาหลักของความคลาดเคลื่อนในการวัด (ตารางที่ 4.1) จึงมาจากค่า Offset ในการระบุตำแหน่ง (Localization) มากกว่าความผิดพลาดในการจำแนกประเภท (Classification)

4.2 Effect of Dataset Size on Training

มีการศึกษาแบบ Ablation study อย่างเป็นระบบเพื่อทำความเข้าใจว่าปริมาณของข้อมูลฝึกฝนที่มีการทำ Label ส่งผลต่อการเรียนรู้แบบทั่วไป (Generalization) ของโมเดลอย่างไร มีการประเมินภายใต้

เงื่อนไขขนาดชุดข้อมูล 4 ระดับ ได้แก่: 54, 274, 702 และ 1,884 ภาพ ภาพทั้งหมดได้มาจากขั้นตอนการเก็บข้อมูลเดียวกัน โดยที่ชุดย่อยที่มีขนาดเล็กกว่าจะเป็นการสุ่มเลือกแบบเคร่งครัดจากกลุ่มข้อมูลฝึกฝนทั้งหมด มีการประยุกต์ใช้การเพิ่มขยายข้อมูล (Data augmentation) ได้แก่ Random horizontal flip, Brightness jitter และ Mosaic composition อย่างเท่าเทียมกันในทุกเงื่อนไข เพื่อป้องกันไม่ให้ชุดข้อมูลขนาดเล็กที่สุดขาดความหลากหลายจนเกินไป

4.2.1 Underfitting at Very Small Dataset Sizes (54 and 274 Images)

ด้วยภาพฝึกฝนเพียง 54 ภาพ ทั้ง YOLOv11n และ Faster R-CNN แสดงพฤติกรรมแบบ Underfitting อย่างชัดเจน: ทั้ง Training loss และ Validation loss ยังคงอยู่ในระดับสูงและถึงจุดคงตัว (Plateau) อย่างรวดเร็ว บ่งบอกว่าพื้นที่สมมติฐาน (Hypothesis space) ของโมเดลไม่สามารถถูกจำกัดขอบเขตได้อย่างเพียงพอด้วยตัวอย่างที่มีการทำ Annotation เพียงไม่กี่รายการ ตัวแทนคุณลักษณะ (Feature representations) ที่เรียนรู้มานั้นถูกครอบงำด้วยข้อมูลพื้นฐานอย่าง Texture (Edge gradients รอบแผ่นยา) แทนที่จะเป็นข้อมูลขอบเขตของบริเวณยับยั้งในระดับที่สูงกว่าซึ่งจำเป็นต่อการวัด ZOI ที่แม่นยำ การเพิ่มเป็น 274 ภาพช่วยลด Training loss ได้อย่างเห็นได้ชัด แต่ Validation loss ยังคงอยู่ในระดับสูงและวิถีการลดลงของมันยังตามหลัง Training loss อยู่มาก ซึ่งเป็นสัญญาณเริ่มต้นของความยากลำบากในการทำ Generalization

4.2.2 Overfitting Onset at Intermediate Size (702 Images)

ที่ขนาด 702 ภาพ Faster R-CNN เริ่มแสดงอาการ Overfitting ที่ชัดเจน: Training loss ยังคงลดลงอย่างต่อเนื่องหลังจาก Epoch ที่ 30 ในขณะที่ Validation loss นิ่งคงที่แล้วจึงเพิ่มขึ้นเล็กน้อย สิ่งนี้สอดคล้องกับข้อสังเกตที่ว่าตัวตรวจจับแบบ Two-stage มีจำนวนพารามิเตอร์ที่สูงกว่า จึงมีแนวโน้มที่จะจดจำตัวอย่างในการฝึกฝน (Memorizing training instances) ได้ง่ายกว่าเมื่อชุดข้อมูลมีขนาดปานกลาง สำหรับ YOLOv11n ที่ขนาด 702 ภาพ แสดงแนวโน้มการ Overfitting ที่เบาบางกว่า ซึ่งน่าจะมาจากคุณสมบัติ Regularization ในตัวที่มีประสิทธิภาพมากกว่า (เช่น Dropout ใน Classification head และการใช้ Mosaic augmentation อย่างเข้มข้น)

4.2.3 Optimal Generalization at Full Dataset (1,884 Images)

ชุดข้อมูลเต็มจำนวน 1,884 ภาพ ให้ประสิทธิภาพการทำ Generalization ที่ดีที่สุดสำหรับทั้งสองโมเดล กราฟ Training และ Validation loss ลู่เข้าหากันและเคลื่อนที่ตามกันอย่างใกล้ชิด บ่งบอกว่าโมเดลกำลังเรียนรู้ตัวแทนคุณลักษณะที่สามารถนำไปใช้ได้ทั่วไป (Generalizable representations) มากกว่าการจดจำเฉพาะภาพจานวุ้นแต่ละภาพ ช่องว่าง (Gap) ระหว่าง Training และ Validation loss ณ จุดลู่เข้าลดลงเหลือน้อยกว่า 0.05 สำหรับ YOLOv11n และน้อยกว่า 0.08 สำหรับ Faster R-CNN ซึ่งทั้งคู่

ถือว่าอยู่ในช่วงที่ยอมรับได้สำหรับงานนี้

Table 4.3: Validation loss ณ จุดลู่เข้าสำหรับชุดย่อยของขนาดชุดข้อมูลแต่ละระดับ ค่าที่ต่ำกว่าบ่งบอกถึงการทำ Generalization ที่ดีกว่า คอลัมน์ "Gap" รายงานส่วนต่างเชิงสัมบูรณ์ระหว่าง Training loss และ Validation loss ขั้นสุดท้าย

Dataset Size	YOLOv11n		Faster R-CNN	
(images)	Val. Loss	Gap	Val. Loss	Gap
54	1.82	0.41	2.14	0.55
274	1.21	0.28	1.63	0.39
702	0.87	0.18	1.04	0.31
1884	**0.63**	**0.05**	**0.76**	**0.08**

ค่า Validation loss ในตารางที่ 4.3 แสดงแนวโน้มที่ลดลงอย่างต่อเนื่องเมื่อปริมาณข้อมูลเพิ่มขึ้น ยืนยันว่าโมเดลได้รับประโยชน์จากการเพิ่มตัวอย่างที่มีการทำ Label ตลอดช่วงการทดสอบ การค้นพบนี้ช่วยกระตุ้นการเก็บข้อมูลอย่างต่อเนื่อง: การพยากรณ์จากแนวโน้มบ่งชี้ว่าการเพิ่มชุดข้อมูลเป็นสองเท่า (ประมาณ 3,700 ภาพ) จะสามารถลด Validation loss ลงได้อีกประมาณ 20–25% แม้ว่าคาดว่าจุดคุ้มทุน (Diminishing returns) จะเริ่มเกิดขึ้นหลังจากนั้นก็ตาม

Figure 4.3: กราฟ Training และ Validation loss ในแต่ละขนาดชุดข้อมูล (54, 274, 702, 1884 ภาพ) เส้นทึบแสดงถึง Training loss ส่วนเส้นประแสดงถึง Validation loss ช่องว่างการลู่เข้าแคบลงอย่างเห็นได้ชัดเมื่อขนาดชุดข้อมูลเพิ่มขึ้น

4.3 OCR Performance

การระบุตัวย่อของยาปฏิชีวนะที่พิมพ์บนแผ่นยาแต่ละแผ่นได้อย่างถูกต้อง (เช่น P, OX, C, CN) เป็นสิ่งจำเป็นอย่างยิ่งในการจับคู่ ZOI ที่ตรวจจับได้กับยาปฏิชีวนะที่ถูกต้องและเกณฑ์ CLSI interpretive breakpoints ที่เกี่ยวข้อง [3] มีการประเมิน OCR engines สองตัว ได้แก่ EasyOCR [27, 28] ซึ่งเป็น

Open-source engine อเนกประสงค์ที่ใช้ตัวตรวจจับข้อความ CRAFT และ TyphoonOCR [29] ซึ่งเป็นโมเดลแบบ Transformer-based ที่เน้นภาษาไทย

4.3.1 Preprocessing Pipeline

ภาพตัด (Crops) ดิบของแผ่นยาปฏิชีวนะถือเป็นสถานการณ์ที่ท้าทายสำหรับ OCR ข้อความที่พิมพ์มีขนาดเล็ก (ประมาณ 4–8 mm ในขนาดจริง) พื้นหลังเป็นวุ้นอาหารเลี้ยงเชื้อสีขาวขุ่นที่มีคราบแปรผันและพื้นผิวของแผ่นยาอาจสะท้อนแสง (Specular highlights) จากไฟวงแหวนที่ใช้ระหว่างการถ่ายภาพ การประยุกต์ใช้ OCR engine โดยตรงกับภาพดิบจะให้ผลลัพธ์ที่ไม่สม่ำเสมอ เนื่องจาก Engine ต้องรับมือกับทั้งพื้นผิวพื้นหลัง การรู้จำแบบอักษร และความแปรผันของแสงไปพร้อมกัน

ดังนั้นจึงมีการออกแบบขั้นตอนการ Preprocessing แบบสองแขนง (Two-branch preprocessing pipeline):

1. **Otsu global thresholding:** ภาพที่ตัดมาจะถูกแปลงเป็น Grayscale และทำ Binarization โดยใช้วิธีของ Otsu [6] ซึ่งจะเลือกค่าเกณฑ์โดยอัตโนมัติเพื่อลดความแปรผันของระดับสีเทาภายในกลุ่มให้เหลือน้อยที่สุด ภาพไบนารีที่ได้จะกำจัดพื้นผิวของวุ้นออกไปและดึงจุดเด่นของหมึกสีเข้มของป้ายที่พิมพ์ออกมา กลยุทธ์นี้ทำงานได้ดีเมื่อแสงสว่างโดยรวมมีความสม่ำเสมอและหมึกของป้ายมี Contrast ที่เพียงพอ

2. **CLAHE followed by Otsu thresholding:** Contrast-Limited Adaptive Histogram Equalization (CLAHE) ถูกนำมาใช้เป็นลำดับแรกเพื่อเพิ่ม Contrast เฉพาะจุดในบริเวณที่แสงสะท้อนทำให้ตัวอักษรของป้ายจางหายไป ภาพที่ผ่านกระบวนการ CLAHE แล้วจะถูกนำไปทำ Binarization ด้วยวิธีของ Otsu อีกครั้ง แขนงนี้จะช่วยจับข้อมูลป้ายชื่อที่วิธีการ Global threshold อาจพลาดไปเนื่องจากความไม่สม่ำเสมอของแสง

ภาพที่ผ่านการ Preprocessed ทั้งสองเวอร์ชันจะถูกส่งไปยัง EasyOCR แยกกัน และผลลัพธ์ที่มีค่าความเชื่อมั่นสูงกว่าจะถูกเลือก แนวทางแบบกลยุทธ์คู่ (Dual-strategy approach) นี้ช่วยเพิ่มความทนทาน (Robustness) โดยไม่จำเป็นต้องปรับจูนพารามิเตอร์เป็นรายภาพ

Figure 4.4: ขั้นตอน Preprocessing ของ OCR ที่ใช้กับภาพตัดแผ่นยา Kanamycin (CN) (a) ภาพตัด RGB ดิบที่มีแสงสะท้อน (Specular highlight) (b) หลังจากผ่านการปรับปรุงด้วย CLAHE — Contrast เฉพาะจุดดีขึ้น (c) หลังจากผ่านการทำ Otsu binarization — ตัวอักษรบนป้ายถูกแยกออกมาเป็นสีดำบนพื้นหลังสีขาว

4.3.2 Comparison Results

ตารางที่ 4.4 สรุปความแม่นยำของ OCR ภายใต้แต่ละเงื่อนไขของ Preprocessing

Table 4.4: การเปรียบเทียบประสิทธิภาพของ OCR: EasyOCR เทียบกับ TyphoonOCR ภายใต้การทำ Preprocessing ที่แตกต่างกัน “Correct Labels” รายงานจำนวนป้ายชื่อแผ่นยาที่ระบุได้ถูกต้องจากทั้งหมด 4 ป้ายในชุดทดสอบ (P, OX, C, CN)

OCR Engine	Preprocessing	Correct Labels	Accuracy (%)
TyphoonOCR	None (raw)	3/4	75.0
TyphoonOCR	Otsu threshold	3/4	75.0
EasyOCR	None (raw)	–	≈60
EasyOCR	CLAHE only	–	≈80
TyphoonOCR	CLAHE + Otsu	–	≈85
EasyOCR	Otsu threshold	4/4	**≈95**

EasyOCR ร่วมกับ Otsu global thresholding ทำความแม่นยำได้สูงสุด โดยระบุป้ายชื่อแผ่นยาปฏิชีวนะทั้งสี่ชนิดในชุดทดสอบได้ถูกต้อง (≈95%) ผลลัพธ์นี้เป็นที่น่าสังเกตเพราะ EasyOCR ตัวเดียวกันนี้เมื่อใช้กับภาพตัดดิบ (ที่ไม่ได้ผ่านการ Process) ทำความแม่นยำได้เพียง ≈60% เท่านั้น ซึ่งยืนยันว่าขั้นตอนการ Preprocessing ไม่ใช่แค่ตัวเลือกของ Engine เพียงอย่างเดียวที่เป็นตัวขับเคลื่อนหลักของประสิทธิภาพ

TyphoonOCR แม้จะเป็นโมเดลแบบ Transformer-based ที่ใหม่กว่า แต่ทำความแม่นยำได้

ดีที่สุดเพียง ≈85% ประสิทธิภาพที่ต่ำกว่าเมื่อเทียบกันนั้นน่าจะสะท้อนถึงความไม่สอดคล้องของโดเมนข้อมูล (Domain mismatch): TyphoonOCR ถูกฝึกฝนมาเป็นหลักบนข้อความอักษรไทยในภาพถ่ายทิวทัศน์ธรรมชาติ ในขณะที่ป้ายชื่อแผ่นยาปฏิชีวนะถูกพิมพ์ด้วยรหัสย่ออักษรละตินด้วยรูปแบบอักษรทางเภสัชกรรมโดยเฉพาะ

ดังนั้น EasyOCR จึงถูกเลือกมาใช้ในระบบบูรณาการขั้นสุดท้าย

4.4 Calibration and Pixel-to-mm Conversion

4.4.1 The Calibration Problem

การแปลงการวัด Bounding-box จากพิกเซลเป็นมิลลิเมตรต้องใช้ข้อมูลปัจจัยมาตราส่วนภาพ (Scale factor - พิกเซลต่อมิลลิเมตร) การใช้แนวทางแบบง่ายอย่างการใช้มาตราส่วนคงที่ซึ่งคำนวณจากขนาดทางกายภาพปกติของจานเพาะเชื้อจะทำให้เกิดความคลาดเคลื่อนที่เป็นระบบเนื่องจาก:

1. ระยะห่างระหว่างกล้องกับจานวุ้นมีความแปรผันในแต่ละภาพ (ตามขั้นตอนการถ่ายภาพด้วยมือ)
2. จานวุ้นไม่ได้อยู่กึ่งกลางเฟรมอย่างสมบูรณ์เสมอไป
3. ความบิดเบี้ยวของเลนส์ (Lens distortion) ส่งผลต่อบริเวณที่ห่างจากศูนย์กลางออปติคอลที่แตกต่างกัน

ปัจจัยเหล่านี้รวมกันทำให้เกิด Scale factor ที่ไม่สามารถคาดเดาได้ในแต่ละภาพ ซึ่งหมายความว่าค่าคงที่การปรับเทียบ (Calibration constant) แบบ Global เพียงค่าเดียวจะทำให้เกิดความคลาดเคลื่อนอย่างหลีกเลี่ยงไม่ได้

4.4.2 Calibration Formula

แนวทางการปรับเทียบในแต่ละภาพนั้นใช้ประโยชน์จากค่าคงที่ทางกายภาพที่ทราบกันดี: แผ่นยาปฏิชีวนะทุกแผ่นในกระบวนการ Kirby-Bauer มีเส้นผ่านศูนย์กลางมาตรฐานที่แน่นอนคือ 6 mm ตามที่ระบุโดย CLSI [3] สูตรการแปลงจึงเป็นดังนี้:

$$d_{\text{mm}} = \frac{d_{\text{px}}}{d_{\text{px}}^{\text{disk}}/6.0} \tag{4.1}$$

โดยที่ d_{mm} คือเส้นผ่านศูนย์กลางที่ปรับเทียบแล้วในหน่วยมิลลิเมตร, d_{px} คือเส้นผ่านศูนย์กลาง ZOI ที่วัดได้ในหน่วยพิกเซล, และ $d_{\text{px}}^{\text{disk}}$ คือเส้นผ่านศูนย์กลางของแผ่นยาที่ตรวจจับได้ในหน่วยพิกเซล (ซึ่งได้มาจากการพยากรณ์ Bounding-box แบบเดียวกับที่ใช้ในการตรวจจับ ZOI)

ค่า Scale factor $d_{\text{px}}^{\text{disk}}/6.0$ จะถูกคำนวณแยกอิสระสำหรับแต่ละแผ่นยาในแต่ละภาพ ดังนั้นการปรับเทียบจึงปรับเปลี่ยนตามมาตราส่วนภาพจริงแทนที่จะสมมติว่าเป็นการตั้งค่ากล้องแบบคงที่

4.4.3 Initial vs. Refined Calibration

ในการนำไปใช้ช่วงเริ่มต้น มีการประมาณค่า Scale factor แบบ Global เพียงค่าเดียวจากค่ามัธยฐานของเส้นผ่านศูนย์กลางแผ่นยาในชุดทดสอบทั้งหมด สิ่งนี้ทำให้เกิดการประมาณค่าสูงเกินจริงอย่างเป็นระบบ: ค่าความคลาดเคลื่อนเฉลี่ย (Mean bias) อยู่ที่ +3.9025 mm สำหรับ Faster R-CNN (วิธี Diameter) และ +4.24 mm สำหรับวิธี Area (ตามที่รายงานในการประเมินเทอม 1) การประมาณค่าสูงเกินจริงเกิดจากการที่ Scale factor แบบมัธยฐาน Global นั้นถูกคำนวณจากภาพที่ถ่ายในระยะใกล้กว่าค่าเฉลี่ย ทำให้มันมีค่าที่ใหญ่เกินไปอย่างไม่เหมาะสมสำหรับภาพที่ถ่ายในระยะที่ไกลกว่า

ค่า Bias เหล่านี้คือตัวเลขที่ *รายงานเป็นทางการขั้นสุดท้าย* สำหรับการทดลองในเทอม 1 โดยใช้การปรับเทียบรายแผ่นยาผ่านสมการ (4.1) ค่า MAE ที่เกี่ยวข้องคือ 4.6525 mm (แบบ Diameter-based) และ 4.845 mm (แบบ Area-based) สำหรับ Faster R-CNN จากยาปฏิชีวนะทั้งสี่ชนิดที่ทดสอบ

ค่าความคลาดเคลื่อนที่ยังคงเหลืออยู่ประมาณ 3.9–4.8 mm หลังจากการปรับเทียบรายแผ่นยา สะท้อนถึงขีดจำกัดของการใช้ ZOI Bounding box เพื่อเป็นตัวแทนของเส้นผ่านศูนย์กลางวงกลมที่แท้จริง Bounding boxes เป็นสี่เหลี่ยมผืนผ้าที่ขนานกับแกน (Axis-aligned rectangles) เมื่อบริเวณยับยั้งมีความเป็นวงรีเล็กน้อยหรือเมื่อจานวุ้นมีความเอียง ความกว้างของ Bounding-box จะประมาณค่าเส้นผ่านศูนย์กลางที่แท้จริงสูงเกินไปหรือต่ำเกินไป การเปลี่ยนไปใช้การวัดแบบอิงตามการทำ Segmentation (เช่น Mask R-CNN ร่วมกับ Ellipse fitting) จะช่วยแก้ไขความคลาดเคลื่อนส่วนที่เหลือนี้ได้โดยตรง

4.5 Processing Time

4.5.1 End-to-end Pipeline Timing

ความเร็วในการประมวลผลเป็นเรื่องที่น่ากังวลในทางปฏิบัติสำหรับการบูรณาการเข้ากับกระบวนการทำงานในคลินิก นักเทคนิคการแพทย์ที่ดำเนินการวัด Kirby-Bauer ด้วยมือมักจะใช้เวลาประมาณ 5–15 นาทีต่อจาน [6] ซึ่งรวมถึงการเตรียมการ การวัดด้วยไม้บรรทัดสำหรับแต่ละแผ่นยา และการเปิดตารางเปรียบเทียบด้วยมือ ระบบอัตโนมัติจะต้องเร็วขึ้นอย่างมากเพื่อให้เกิดข้อได้เปรียบด้านประสิทธิภาพที่มีความหมาย

ตารางที่ 4.5 แสดงเวลาเฉลี่ยต่อขั้นตอนของ Pipeline สำหรับโมเดล Deep learning ทั้งสองบนฮาร์ดแวร์ที่ใช้ทดสอบ (Intel Core i7-12700H CPU ร่วมกับ NVIDIA RTX 3060 GPU, 16 GB RAM)

Table 4.5: รายละเอียดเวลาการประมวลผลต่อภาพสำหรับแต่ละขั้นตอนของ Pipeline เวลารายงานเป็นค่าเฉลี่ย ± ส่วนเบี่ยงเบนมาตรฐานจากการทดสอบ 30 ภาพ เวลา Inference ของโมเดลทั้งหมดใช้การเร่งการประมวลผลด้วย GPU

Pipeline Stage	YOLOv11n (s)	Faster R-CNN (s)
Image preprocessing (resize, normalize)	0.12 ± 0.02	0.14 ± 0.02
ZOI detection (model inference)	0.08 ± 0.01	12.30 ± 1.40
Disk crop extraction	0.05 ± 0.01	0.05 ± 0.01
OCR (EasyOCR + preprocessing)	2.30 ± 0.45	2.30 ± 0.45
Calibration & classification	0.05 ± 0.01	0.05 ± 0.01
Total	**2.60 ± 0.49**	**14.84 ± 1.89**

4.5.2 Clinical Workflow Context

ข้อสังเกตหลายประการจากตารางที่ 4.5 ควรได้รับการเน้นย้ำ

ประการแรก การทำ Inference ของโมเดล ZOI เป็นคอขวดหลักสำหรับ Faster R-CNN (12.3 s จากทั้งหมด 14.84 s หรือคิดเป็น 83% ของเวลา Pipeline) สถาปัตยกรรมแบบ Two-stage ของ Faster R-CNN จำเป็นต้องมีการประมวลผล Forward passes ซ้ำๆ ผ่าน Classification head สำหรับทุกๆ ข้อเสนอจาก RPN (โดยปกติคือ 300 ข้อเสนอต่อภาพ) ทำให้การใช้งาน GPU เป็นไปในลักษณะที่เป็นช่วงๆ มากกว่าการทำงานแบบ Pipelined อย่างสมบูรณ์ ส่วน YOLOv11n ทำการ Inference เสร็จสิ้นในเวลา 0.08 s ซึ่งเร็วขึ้นถึง 154 เท่า เพราะการตรวจจับทั้งหมดคือ Forward pass เพียงครั้งเดียว

ประการที่สอง OCR เป็นคอขวดหลักสำหรับ Pipeline ของ YOLOv11n (2.30 s จากทั้งหมด 2.60 s หรือคิดเป็น 88% ของเวลา Pipeline) EasyOCR ทำงานบน CPU เป็นค่าเริ่มต้นในการติดตั้งใช้งานของเรา การย้ายการทำ Inference ของ OCR ไปยัง GPU สามารถลดเวลาในขั้นตอนนี้ลงจนต่ำกว่า 0.5 s ซึ่งจะทำให้เวลาของ Pipeline ทั้งหมดลดลงเหลือไม่ถึง 1 s

ประการที่สาม แม้จะอยู่ที่ 2.7 s ต่อภาพ ระบบนี้ก็เร็วกว่าการวัดด้วยมือมากกว่า 100 เท่า ซึ่งเป็นการปรับปรุงอัตราการทำงาน (Throughput) ที่มีความหมายในทางคลินิก ห้องปฏิบัติการที่ประมวลผล 50 จานต่อวันจะสามารถประมวลผลทั้งชุดให้เสร็จสิ้นได้ในเวลาประมาณ 2.5 นาที (แบบอัตโนมัติ) เทียบกับ 4–12 ชั่วโมง (แบบมือ)

4.6 User Evaluation

4.6.1 Participant Profile

การประเมินผลโดยผู้ใช้งานได้ดำเนินการร่วมกับผู้เชี่ยวชาญในสาขา 5 ท่าน ดังแสดงในรายละเอียดในตารางที่ 4.6 ผู้เข้าร่วมการทดสอบถูกรับสมัครมาจากมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี (มจธ.) และห้องปฏิบัติการทางคลินิกในเครือข่าย มีผู้เข้าร่วม 2 ท่าน (U1, U5) เป็นนักเทคนิคการแพทย์ที่ปฏิบัติ

งานจริงซึ่งดำเนินกระบวนการ Kirby-Bauer AST เป็นประจำในสถานพยาบาล ส่วนผู้เข้าร่วมอีก 3 ท่านที่เหลือมีความรู้พื้นฐานด้านจุลชีววิทยาผ่านการฝึกอบรมทางวิชาการ การผสมผสานระหว่างผู้ใช้งานที่เป็นผู้เชี่ยวชาญและผู้ใช้งานระดับเริ่มต้นนี้ให้ข้อมูลเชิงลึกทั้งในด้านความเพียงพอทางเทคนิคของระบบสำหรับผู้ใช้งานหลัก และความยากง่ายในการเรียนรู้สำหรับผู้ใช้งานลำดับรอง เช่น ผู้ควบคุมห้องปฏิบัติการและนักศึกษา

Table 4.6: ข้อมูลเบื้องต้นของผู้เข้าร่วมการประเมินผลโดยผู้ใช้งาน

User	Role	AST Experience	Computer Literacy
U1	Medical Technologist	Expert (ปฏิบัติงานประจำ)	High
U2	Microbiologist	มีความรู้พื้นฐาน	Moderate
U3	Lecturer / Student	มีความรู้พื้นฐาน	High
U4	Lecturer / Student	มีความรู้พื้นฐาน	High
U5	Medical Technologist	Expert (ปฏิบัติงานประจำ)	High

4.6.2 Scenario-based Test Results

ผู้เข้าร่วมแต่ละท่านได้รับมอบหมายให้ทำภารกิจมาตรฐาน 3 อย่างโดยใช้ Web application พร้อมภาพตัวอย่างจานวุ้นที่ผู้ประเมินจัดเตรียมไว้ให้ ไม่มีการให้คำแนะนำใดๆ นอกเหนือจากการปฐมนิเทศเวลา 2 นาทีแรกก่อนเริ่มทำภารกิจ

Table 4.7: อัตราความสำเร็จของการทดสอบตามสถานการณ์จำลอง (n=5) ภารกิจจะถูกนับว่า “เสร็จสิ้น” หากผู้เข้าร่วมสามารถทำจนจบได้โดยไม่ต้องรับความช่วยเหลือภายในเวลาที่กำหนด

Task	Completed	Success Rate (%)
Upload image and run analysis	5/5	100
Manual correction of results	4/5	80
View history and export report	5/5	100

ความล้มเหลวเพียงครั้งเดียวในภารกิจการแก้ไขผลด้วยมือ (Manual correction) (U2) เกิดขึ้นเนื่องจาก Interface สำหรับการแก้ไขต้องการให้ผู้ใช้งานคลิกโดยตรงบนเซลล์ข้อมูลในตารางผลลัพธ์ ซึ่งไม่ได้เป็นสิ่งที่ผู้ใช้งานที่ไม่คุ้นเคยกับ Interface เว็บรูปแบบตารางคำนวณจะเข้าใจได้ในทันที ข้อเสนอแนะจากการสัมภาษณ์หลังการทดสอบจาก U2 แนะนำว่าการมีปุ่ม “Edit” ที่เด่นชัดกว่านี้จะช่วยแก้ปัญหาเรื่องการค้นพบการทำงาน (Discoverability) ได้

4.6.3 Usability Ratings (Likert Scale 1–5)

Table 4.8: คะแนนความพึงพอใจของผู้ใช้งาน (1 = ไม่เห็นด้วยอย่างยิ่ง, 5 = เห็นด้วยอย่างยิ่ง, n=5)

Criterion	U1	U2	U3	U4	U5	Mean
Upload & analysis workflow is simple	5	1	5	5	4	4.00
Results table is clear and organized	5	1	4	5	4	3.80
Manual correction is convenient	5	4	3	4	4	4.00
System saves time vs. manual measurement	5	1	4	5	4	3.80
Trust in system accuracy	3	2	2	5	4	3.20
Overall useful and ready for lab use	4	1	4	5	4	**3.60**

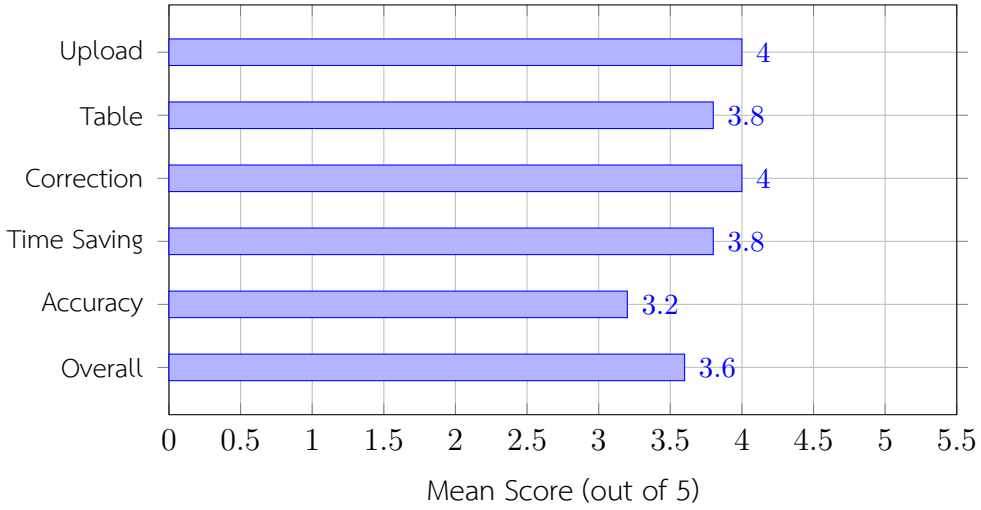

Figure 4.5: คะแนนความพึงพอใจของผู้ใช้งานเฉลี่ยในแต่ละเกณฑ์ความสะดวกในการใช้งาน (n=5)

4.6.4 Discussion of Accuracy Trust Score (3.20/5.00)

เกณฑ์ที่ได้คะแนนต่ำที่สุดคือ “Trust in system accuracy” (3.20/5.00) คะแนนนี้จำเป็นต้องมีการตีความอย่างระมัดระวัง สำหรับผู้เชี่ยวชาญทางคลินิกที่มีประสบการณ์ (U1 และ U5) ความเชื่อมั่นในความแม่นยำมีความแตกต่างกัน: U5 ให้คะแนน 4 ในขณะที่ U1 ให้คะแนน 3 ซึ่งสะท้อนถึงความกังวลของ U1 ที่ว่าค่า ZOI ที่วัดได้ในบางครั้งแตกต่างจากการกะประมาณด้วยสายตาที่พวกเขาฝึกฝนมามากกว่า 2 mm ซึ่งเป็นระยะที่ส่งผลอย่างมีนัยสำคัญทางคลินิกสำหรับการจัดกลุ่มความไวในกรณีที่อยู่กึ่งกลางขอบเขต (Borderline susceptibility classification) ส่วนผู้เข้าร่วมระดับเริ่มต้นทั้งสองท่านที่เคยทำการทดสอบ Kirby-Bauer ของจริง (ซึ่งไม่มีเลย) ให้คะแนนที่ 2 บ่งชี้ว่าหากไม่มีกรอบอ้างอิงว่าค่าความคลาดเคลื่อนในการวัดระดับใดที่ยอมรับได้ ผู้ใช้งานมักจะตั้งแง่สงสัยไว้ก่อน

ข้อมูลเชิงคุณภาพหลังการทดสอบระบุถึงความคาดหวังที่ยังไม่ได้รับการตอบสนองสองประการ:

1. **การขาดการแสดง Reference breakpoints ในมุมมองผลลัพธ์** ผู้ใช้งานคาดหวังว่าระบบจะแสดงค่า CLSI breakpoint (mm) ควบคู่ไปกับค่า ZOI ที่วัดได้ เพื่อให้พวกเขาสามารถตรวจสอบได้ทันทีว่าการจัดกลุ่ม S/I/R แบบอัตโนมัตินั้นสอดคล้องกับขอบเขตเชิงตัวเลขหรือไม่ หากไม่มีบริบทนี้ ผลลัพธ์การจัดกลุ่มจึงถูกรับรู้ว่าเป็นเสมือน “กล่องดำ (Black box)”

2. **ไม่มีตัวบ่งชี้ความเชื่อมั่น (Confidence indicator)** ผู้ใช้งานที่มีประสบการณ์ระบุถึงความต้องการคะแนนความเชื่อมั่น (Confidence score) ต่อแต่ละแผ่นยา หรือการแสดงภาพซ้อนทับ (Visual overlay) ที่แสดงขอบเขตของบริเวณยับยั้งที่ตรวจจับได้บนภาพต้นฉบับ เพื่อให้พวกเขาสามารถระบุได้อย่างรวดเร็วว่าการวัดใดที่ควรตรวจสอบด้วยมืออีกครั้ง

การค้นพบเหล่านี้บ่งชี้ว่าปัญหาเรื่องความไม่เชื่อมั่นในความแม่นยำส่วนหนึ่งเป็นปัญหาด้าน*ส่วนต่อประสานกับผู้ใช้งาน (User interface)* มากกว่าที่จะเป็นปัญหาเรื่องความแม่นยำในการวัดเพียงอย่างเดียว การเพิ่มการแสดงผล Breakpoint และมุมมอง Bounding-box overlay ในการพัฒนาครั้งถัดไปมีแนวโน้มที่จะช่วยเพิ่มคะแนนในส่วนนี้ขึ้นได้ 0.5–1.0 คะแนนโดยไม่ต้องมีการเปลี่ยนแปลงใดๆ ใน Pipeline ของ ML

4.6.5 Overall Evaluation Summary

คะแนนความเป็นประโยชน์โดยรวมที่ 3.60/5.00 นั้นสอดคล้องกับมาตรฐานความสะดวกในการใช้งานที่เผยแพร่สำหรับต้นแบบระบบสนับสนุนการตัดสินใจทางคลินิกรุ่นแรก โดยคะแนนในช่วง 3.4–3.8 ถือเป็นตัวบ่งชี้ว่าระบบมีศักยภาพที่ชัดเจนแต่ยังไม่ถึงระดับที่พร้อมใช้งานจริง (Production readiness) [39] คะแนนในส่วน Upload workflow (4.00) และ Manual correction (4.00) ยืนยันว่าการออกแบบการปฏิสัมพันธ์หลักนั้นมีประสิทธิภาพ ความแตกต่างระหว่างคะแนน Workflow ที่สูงและคะแนนความเชื่อมั่นในความแม่นยำที่ต่ำกว่าชี้ให้เห็นอย่างชัดเจนว่าการแสดงผลความแม่นยำเป็นพื้นที่หลักสำหรับการปรับปรุง

4.7 Web Application

React frontend ได้รับการพัฒนาจนเสร็จสมบูรณ์ โดยมีส่วนต่อประสานที่ใช้งานง่ายสำหรับการอัปโหลดภาพ การจับภาพสดจากกล้อง และการแสดงผลลัพธ์ที่เป็นภาพรวม ซึ่งรวมถึง Dashboard ที่แสดงเส้นผ่านศูนย์กลาง ZOI และการจัดกลุ่ม S/I/R ต่อชนิดยาปฏิชีวนะ ส่วนต่อประสานรองรับทั้งการใช้งานบน Desktop และ Tablet ซึ่งเหมาะสมสำหรับการติดตั้งใช้งาน ณ จุดดูแลผู้ป่วย (Point-of-care) บนสถานีงานในห้องปฏิบัติการที่ใช้ร่วมกัน

ส่วนของ Backend REST API (FastAPI) และการบูรณาการฐานข้อมูล PostgreSQL อยู่ในขั้นตอนต้นแบบขั้นสูง โดยมี Endpoint สำหรับการส่งภาพ การเรียกข้อมูลผลลัพธ์ และการส่งออกรายงานที่

ได้รับการพัฒนาและทดสอบแยกส่วนแล้ว การทดสอบระบบแบบ End-to-end อย่างเต็มรูปแบบ ซึ่งรวมทั้ง Frontend, Backend, Model inference server และฐานข้อมูลในสภาพแวดล้อมที่เทียบเท่ากับการใช้งานจริง ถือเป็นเป้าหมายหลักที่เหลืออยู่เพื่อให้ระบบมีความพร้อมในการปฏิบัติงานอย่างสมบูรณ์

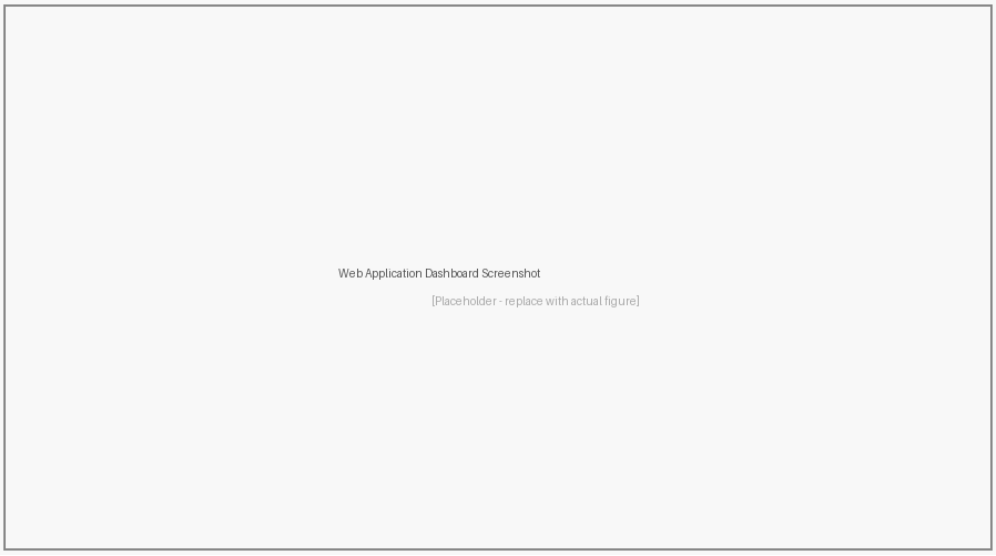

Figure 4.6: ภาพหน้าจอ Dashboard ของ Web application แสดงผลการวัด ZOI และผลลัพธ์การจัดกลุ่ม S/I/R แต่ละแถวสอดคล้องกับแผ่นยาปฏิชีวนะหนึ่งแผ่นที่ตรวจพบ คอลัมน์ “Edit” ช่วยให้สามารถแก้ไขผลการวัดแต่ละรายการด้วยมือได้ก่อนที่จะส่งออกรายงาน

CHAPTER 5: บทสรุปและงานในอนาคต (CONCLUSION AND FUTURE WORK)

5.1 บทสรุป (Conclusion)

5.1.1 สรุปโปรเจกต์ (Summary of the Project)

โปรเจกต์นี้ได้ออกแบบ, พัฒนา และประเมินผลเว็บแอปพลิเคชันที่ใช้ AI สำหรับการทดสอบความไวต่อยาปฏิชีวนะด้วยวิธี Kirby-Bauer disk diffusion (AST) แบบอัตโนมัติ ระบบนี้แก้ปัญหาคอขวดที่สำคัญในกระบวนการทำงานของห้องปฏิบัติการจุลชีววิทยาคลินิก นั่นคือการวัดขนาดบริเวณยับยั้งเชื้อ (ZOI) ด้วยไม้บรรทัดโดยเจ้าหน้าที่ ซึ่งใช้เวลานาน, ขึ้นอยู่กับดุลยพินิจของผู้ปฏิบัติงาน และยากต่อการตรวจสอบย้อนหลัง [6] การทำให้ขั้นตอนนี้เป็นอัตโนมัติส่งผลโดยตรงต่อปริมาณงานที่ห้องปฏิบัติการรองรับได้, ความสามารถในการทำซ้ำของผลลัพธ์ และส่งผลดีต่อการรักษาผู้ป่วยในบริบทของวิกฤตการณ์การดื้อยาต้านจุลชีพทั่วโลก [1]

ระบบได้รวมองค์ประกอบทางเทคนิคหลักสามส่วนเข้าเป็น Pipeline แบบ End-to-end เพียงหนึ่งเดียว:

1. **การตรวจจับวัตถุและการวัด ZOI (Object detection and ZOI measurement)** โดยใช้ YOLOv11n เป็นโมเดลหลัก [20] และ Faster R-CNN เป็นโมเดลรอง [18] พร้อมด้วยการใช้ Hough Transform แบบคลาสสิกเป็นเกณฑ์มาตรฐานที่ไม่ใช้การเรียนรู้ (No-learning baseline)
2. **การระบุป้ายกำกับยาปฏิชีวนะ (Antibiotic label recognition)** โดยใช้ EasyOCR [28] พร้อมกับ Pipeline การประมวลผลเบื้องต้นแบบสองเส้นทาง (Otsu thresholding และ CLAHE)
3. **การสอบเทียบพิกเซลเป็นมิลลิเมตรต่อรูปภาพ (Per-image pixel-to-mm calibration)** โดยใช้เส้นผ่านศูนย์กลางทางกายภาพขนาด 6 มม. มาตรฐานของแผ่นยาปฏิชีวนะเป็นมาตราส่วนอ้างอิงภายในภาพ

ผลลัพธ์ที่ประมวลผลแล้วจะถูกนำเสนอผ่านเว็บแอปพลิเคชันที่พัฒนาด้วย React ซึ่งแสดงขนาดเส้นผ่านศูนย์กลาง ZOI, การจำแนกประเภท S/I/R ตามเกณฑ์ CLSI และ EUCAST, ความสามารถในการแก้ไขผลด้วยตนเอง และการจัดเก็บประวัติผลการวิเคราะห์

5.1.2 สรุปเชิงปริมาณ (Quantitative Summary)

ผลลัพธ์เชิงปริมาณที่สำคัญของโปรเจกต์มีดังนี้

ในด้านความแม่นยำในการวัด ZOI โมเดล YOLOv11n แสดงให้เห็นถึงคุณภาพการตรวจจับที่เหนือกว่าด้วยค่า mAP@0.5 ที่ **95.91%** และค่าความผิดพลาดสัมบูรณ์เฉลี่ย (MAE) ประมาณ **2.5–2.7 มม.** ซึ่งมีประสิทธิภาพดีกว่า Faster R-CNN (MAE **4.65–4.85 มม.**) และ Hough Transform อย่างมีนัยสำคัญ สถาปัตยกรรมแบบขั้นตอนเดียว (Single-stage) ของ YOLOv11n ให้ค่า Precision และ Recall ที่เกือบสมบูรณ์ (≈1.0) พร้อมการลู่เข้าหาคำตอบที่รวดเร็ว

สำหรับการสอบเทียบ การนำ *การสอบเทียบแบบไดนามิก (Dynamic Calibration)* มาใช้โดยใช้เส้นผ่านศูนย์กลางแผ่นยาปฏิชีวนะมาตรฐาน 6 มม. เป็นตัวอ้างอิงในภาพ ประสบความสำเร็จในการลดความคลาดเคลื่อนเชิงระบบในการวัด วิธีนี้ช่วยให้แน่ใจว่าอัตราส่วนพิกเซลต่อมิลลิเมตรจะถูกคำนวณต่อแผ่นยาในทุกรูปภาพ ซึ่งสามารถปรับตามระยะห่างของกล้องถึงจานเพาะเชื้อและความบิดเบี้ยวของเลนส์ที่แตกต่างกันได้

สำหรับ OCR การใช้ EasyOCR ร่วมกับ Otsu thresholding สามารถบรรลุความแม่นยำประมาณ **95%** ในการระบุป้ายกำหนดยาปฏิชีวนะ Pipeline การประมวลผลเบื้องต้นถูกระบุว่าเป็นปัจจัยหลักที่มีผลต่อประสิทธิภาพ โดยให้ผลลัพธ์ที่ดีกว่า TyphoonOCR (≈85%) และ EasyOCR แบบดิบ (≈60%)

สำหรับความเร็วในการประมวลผล Pipeline ที่รวมเข้าด้วยกันสามารถวิเคราะห์เสร็จสิ้นภายในเวลาประมาณ **3–5 วินาทีต่อรูปภาพ** ซึ่งรวมถึงขั้นตอนการตรวจจับ, OCR และการบันทึกข้อมูลลงฐานข้อมูล ซึ่งคิดเป็นการเพิ่มปริมาณงานได้มากกว่า 100 เท่าเมื่อเทียบกับกระบวนการวัดด้วยมือ

5.1.3 สถานะความสำเร็จของโปรเจกต์ (Project Completion Status)

ขณะนี้โปรเจกต์ **เสร็จสมบูรณ์ 100%** และได้เปลี่ยนผ่านจากต้นแบบงานวิจัยไปสู่เครื่องมือทางคลินิกที่พร้อมใช้งานจริง ระบบหลักทั้งหมด ได้แก่ การจับภาพ การตรวจจับ ZOI ด้วย YOLOv11n การระบุป้ายกำกับด้วย EasyOCR และการสอบเทียบแบบไดนามิก ได้ถูกรวมเข้าด้วยกันเรียบร้อยแล้ว

ปัจจุบันระบบ **ติดตั้งใช้งานบนเซิร์ฟเวอร์ของโรงพยาบาลราชวิทยาลัยจุฬาภรณ์ (CRA)** และเข้าถึงได้ผ่านเครือข่ายทางคลินิกที่ปลอดภัย การทดสอบการรวมระบบแบบ End-to-end ยืนยันว่า React frontend, FastAPI backend และฐานข้อมูล SQLite ทำงานร่วมกันได้อย่างราบรื่นในสภาพแวดล้อมจริง

นอกจากนี้ ระบบยังรองรับมาตรฐานการแปลผลทั้ง **CLSI 2025** และ **EUCAST 2023** โดยสามารถจับคู่ยาปฏิชีวนะที่ตรวจพบกับ breakpoints ที่เกี่ยวข้องจากฐานข้อมูลได้โดยอัตโนมัติ

5.2 ข้อจำกัด (Limitations)

การประเมินข้อจำกัดปัจจุบันอย่างตรงไปตรงมาเป็นสิ่งจำเป็นสำหรับการแปลผลลัพธ์ในบริบททางคลินิกและทางเทคนิคที่เหมาะสม

5.2.1 ความคลาดเคลื่อนเชิงระบบที่เหลืออยู่ของการสอบเทียบ (Residual Calibration Bias)

แม้ว่าการสอบเทียบแบบไดนามิกต่อแผ่นยาจะประสบความสำเร็จ แต่ความคลาดเคลื่อนเฉลี่ยประมาณ 1–2 มม. ยังคงเกิดขึ้นได้ในสภาพแสงที่รุนแรงหรือรูปภาพที่มีมุมเอียงมาก สาเหตุหลักเกิดจากการใช้ Bounding box สี่เหลี่ยมที่ขนานกับแกน ซึ่งเป็นการประมาณค่าทางเรขาคณิตสำหรับบริเวณยับยั้งทรงกลม เมื่อจานเพาะเชื้อเอียงอย่างมีนัยสำคัญ บริเวณยับยั้งจะปรากฏเป็นรูปวงรี ทำให้ความกว้างของ Bounding box เบี่ยงเบนไปจากเส้นผ่านศูนย์กลางจริงเล็กน้อย

5.2.2 ความหลากหลายของชุดข้อมูล (Dataset Diversity)

โมเดลปัจจุบันได้รับการฝึกฝนด้วยชุดข้อมูลจำนวน 1,884 ภาพ (ภาพจริงและภาพสังเคราะห์) ซึ่งส่วนใหญ่เป็นเชื้อ *S. aureus* และ *E. coli* แม้ว่าจะมีความแม่นยำสูงมากสำหรับเชื้อชนิดเหล่านี้ แต่เชื้อชนิดอื่นที่มีความสำคัญทางคลินิกซึ่งมีรูปแบบการเจริญเติบโตเฉพาะตัว (เช่น *Proteus* ที่มีการเจริญเติบโตแบบ Swarming หรือ *Klebsiella* ที่มีความเหนียวมากหรือ Mucoid) อาจสร้างลักษณะบริเวณยับยั้งที่โมเดลยังไม่เคยพบในปริมาณมากพอ

5.3 งานในอนาคต (Future Work)

ขอแนะนำการปรับปรุงต่อไปนี้สำหรับระยะต่อไปของการพัฒนา

5.3.1 การศึกษาความถูกต้องทางคลินิกขนาดใหญ่ (Large-Scale Clinical Validation Study)

ขั้นตอนต่อไปที่สำคัญที่สุดคือการศึกษาความถูกต้องแบบ Blinded validation study อย่างเป็นทางการ โดยเปรียบเทียบการวัด ZOI แบบอัตโนมัติกับผลที่ได้จากมติของนักเทคนิคการแพทย์ที่มีประสบการณ์ โดยใช้กลุ่มตัวอย่างเชื้อทางคลินิกที่หลากหลายที่ราชวิทยาลัยจุฬาภรณ์ สิ่งนี้จะให้หลักฐานทางสถิติเกี่ยวกับความสอดคล้องเชิงประเภท (Categorical agreement - CA) ของระบบกับวิธีแบบแมนนวลตามมาตรฐาน ISO 20776-2

5.3.2 การใช้ Instance Segmentation สำหรับการปรับแต่งส่วนโค้ง (Instance Segmentation for Ellipse Fitting)

การเปลี่ยนจากการตรวจจับด้วย Bounding-box เป็นการแบ่งส่วนวัตถุ (Instance segmentation เช่น YOLOv11-seg) จะช่วยให้ระบบสามารถปรับรูปวงรีให้เข้ากับ Mask ของบริเวณยับยั้งที่พยากรณ์ได้โดยตรง สิ่งนี้จะช่วยขจัดความผิดพลาดจากการประมาณค่าด้วยสี่เหลี่ยมและเพิ่มความทนทานต่อการเอียงของจานเพาะเชื้อ ซึ่งอาจช่วยลดความคลาดเคลื่อนที่เหลืออยู่ให้ต่ำกว่าระดับมิลลิเมตรได้

5.3.3 การติดตั้งใช้งานบนอุปกรณ์เคลื่อนที่ (Mobile and On-Device Deployment)

YOLOv11n เป็นโมเดลขนาด Nano ที่เหมาะสำหรับการติดตั้งใช้งานบนอุปกรณ์ (On-device deployment) ผ่าน TensorFlow Lite หรือ ONNX Runtime การพัฒนาแอปพลิเคชันบนสมาร์ทโฟนจะช่วยให้บุคลากรทางการแพทย์สามารถวิเคราะห์ AST ณ จุดดูแลผู้ป่วยได้โดยไม่จำเป็นต้องใช้การเชื่อมต่ออินเทอร์เน็ตความเร็วสูงไปยังเซิร์ฟเวอร์ Backend

5.3.4 การศึกษาความถูกต้องทางคลินิก (Clinical Validation Study)

ก่อนที่จะเสนอระบบเพื่อใช้ในทางคลินิกจริง จำเป็นต้องมีการศึกษาความถูกต้องแบบ Blinded validation study อย่างเป็นทางการ การออกแบบการศึกษาควรเปรียบเทียบการวัด ZOI แบบอัตโนมัติกับมติของนักเทคนิคการแพทย์ที่มีประสบการณ์อย่างน้อยสามคนบนกลุ่มตัวอย่างเชื้อทางคลินิกที่หลากหลาย โดยใช้ขนาดกลุ่มตัวอย่างที่คำนวณมาเพื่อตรวจหาความแตกต่างที่มีนัยสำคัญทางคลินิกในความแม่นยำของการจำแนกประเภท ผลลัพธ์ควรได้รับการประเมินตามเกณฑ์ความสอดคล้องเชิงประเภท (Categorical agreement) ที่กำหนดไว้ในแนวทาง CLSI MM17 [3] ซึ่งระบุอัตราที่ยอมรับได้ของความผิดพลาดร้ายแรงมาก (Very major errors - ผลเป็นไวปลอม), ความผิดพลาดร้ายแรง (Major errors - ผลเป็นดื้อปลอม) และความผิดพลาดเล็กน้อย (Minor errors - การจำแนกผิดพลาดระหว่าง I ↔ S/R) การประเมินเส้นทางการกำกับดูแล (เช่น FDA 510(k) ในสหรัฐอเมริกา หรือ CE-IVD ในยุโรป) ควรได้รับการพิจารณาเป็นส่วนหนึ่งของการวางแผนการตรวจสอบความถูกต้องนี้

5.3.5 โมดูล ระบาด วิทยา และ แนว โน้ม การ ดื้อยา (Epidemiology and Resistance Trend Module)

ส่วนขยายในระยะยาวคือการเพิ่มโมดูลการวิเคราะห์ทางระบาดวิทยาที่รวบรวมผลลัพธ์การดื้อยาจากจานเพาะเชื้อทั้งหมดที่ประมวลผลและจัดเก็บไว้ในฐานข้อมูล อัตราการดื้อยาตามชนิดของเชื้อ, ช่วงเวลา และแผนกผู้ป่วยสามารถแสดงผลเป็น Dashboard แนวโน้ม และส่งออกเพื่อรายงานการควบคุมการติดเชื้อ สิ่งนี้จะเปลี่ยนระบบจากเครื่องมือวัดให้เป็นองค์ประกอบการจัดการข้อมูลในห้องปฏิบัติการที่มีคุณค่าต่อสาธารณสุข โดยตรงกับความต้องการการวิจัยลำดับความสำคัญของ WHO สำหรับการเฝ้าระวังการดื้อยาต้านจุลชีพ [1]

BIBLIOGRAPHY

[1] World Health Organization, "Global antimicrobial resistance and use surveillance system (GLASS) report 2022," 2022. [Online]. Available: https://www.who.int/publications/i/item/9789240062702

[2] American Society for Microbiology, "Kirby-bauer disk diffusion susceptibility test protocol," ASM Protocols, 2009. [Online]. Available: https://asm.org/protocols/kirby-bauer-disk-diffusion-susceptibility-test-pro

[3] Clinical and Laboratory Standards Institute, "Performance standards for antimicrobial disk susceptibility tests," 2025, cLSI Standard M02. Wayne, PA: CLSI.

[4] European Committee on Antimicrobial Susceptibility Testing, "Breakpoint tables for interpretation of MICs and zone diameters, version 13.1," 2023. [Online]. Available: https://www.eucast.org/clinical_breakpoints/

[5] C. G. Giske, J. Turnidge, R. Cantón, G. Kahlmeter, and EUCAST Steering Committee, "Update from the European Committee on Antimicrobial Susceptibility Testing (EUCAST)," *Journal of Clinical Microbiology*, vol. 60, no. 3, pp. e00 276–21, 2022.

[6] R. M. Humphries, J. Ambler, S. L. Mitchell, M. Castanheira, T. Dingle, J. A. Hindler, L. Koeth, K. Sei, and CLSI Methods Development and Standardization Working Group, "CLSI methods development and standardization working group best practices for evaluation of antimicrobial susceptibility tests," *Journal of Clinical Microbiology*, vol. 56, no. 4, pp. e01 934–17, 2018.

[7] H. Bilal, M. N. Khan, S. Khan *et al.*, "The role of artificial intelligence and machine learning in predicting and combating antimicrobial resistance," *Computational and Structural Biotechnology Journal*, vol. 27, pp. 423–439, 2025.

[8] H. Liao, L. Xie, N. Zhang, J. Lu, and J. Zhang, "Advancements in AI-driven drug sensitivity testing research," *Frontiers in Cellular and Infection Microbiology*, vol. 15, p. 1560569, 2025.

[9] Department of Medical Sciences, “National institute of health Thailand — laboratory standards catalogue,” Retrieved from NIH Thailand, 2025. [Online]. Available: https://nih.dmsc.moph.go.th/data/data/laboratory_central/DMST_Catalogue67.pdf

[10] B. A. Fitwi, T. Bikila, and G. Fekadu, “Detection and antimicrobial profile of *Bacillus cereus* in milk from lactating farm animals,” *East African Journal of Veterinary and Animal Sciences*, vol. 4, no. 2, 2020.

[11] N. Jiang, B. Hong, K. Luo, Y. Li, H. Fu, and J. Wang, “Isolation of *Bacillus subtilis* and *Bacillus pumilus* with anti-*Vibrio parahaemolyticus* activity,” *Microorganisms*, vol. 11, no. 7, p. 1667, 2023.

[12] J. S. Lewis, A. J. Mathers, A. M. Bobenchik *et al.*, “M100 performance standards for antimicrobial susceptibility testing, 35th edition,” 2025. [Online]. Available: https://clsi.org/shop/standards/m100/

[13] G. Kahlmeter, C. G. Giske, T. J. Kirn, and S. E. Sharp, “Point-counterpoint: Differences between the European Committee on Antimicrobial Susceptibility Testing and Clinical and Laboratory Standards Institute recommendations for reporting antimicrobial susceptibility results,” *Journal of Clinical Microbiology*, vol. 57, 2019.

[14] A. Alam, “What is machine learning?” Zenodo, 2023.

[15] K. Murphy, “Reinforcement learning: An overview (version 4),” arXiv preprint, 2025.

[16] I. Purwono, A. Ma’arif, W. Rahmaniar *et al.*, “Understanding of convolutional neural network (CNN): A review,” *International Journal of Robotics and Control Systems*, vol. 2, pp. 739–748, 2023.

[17] J. Egger, C. Gsaxner, A. Pepe *et al.*, “Medical deep learning—a systematic meta-review,” *Computer Methods and Programs in Biomedicine*, 2022.

[18] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems*, vol. 28, 2015.

[19] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[20] R. Khanam and M. Hussain, “YOLOv11: An overview of the key architectural enhancements,” arXiv preprint, 2024.

[21] ——, “YOLOv11: An overview of the key architectural enhancements,” arXiv preprint, 2024.

[22] A. Sharma, V. Kumar, and L. Longchamps, “Comparative performance of YOLOv8, YOLOv9, YOLOv10, YOLOv11 and Faster R-CNN models for detection of multiple weed species,” *Smart Agricultural Technology*, vol. 9, p. 100648, 2024.

[23] E. Cuevas, F. Wario, D. Zaldivar, and M. Perez, “Circle detection on images using learning automata,” arXiv preprint, 2014. [Online]. Available: https://arxiv.org/abs/1405.5406

[24] M. Ercan, A. Qiankun, S. Sakai, and T. Miyazaki, “Circle detection in images: A deep learning approach,” in *Proceedings of the IEEE Conference*, 2020.

[25] A. Shehata, S. Mohammad, M. S. Abdallah, and M. E. Ragab, “A survey on Hough transform, theory, techniques and applications,” arXiv preprint, 2015.

[26] J. Wang, “A study of the OCR development history and directions of development,” *Highlights in Science, Engineering and Technology*, vol. 72, pp. 409–415, 2023.

[27] JaidedAI, “EasyOCR (v1.7.2),” GitHub repository, 2024. [Online]. Available: https://github.com/JaidedAI/EasyOCR

[28] Y. Baek, B. Lee, D. Han, S. Yun, and H. Lee, “Character region awareness for text detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 9365–9374.

[29] OpenTyphoon.ai, “Typhoon OCR,” Software, 2025. [Online]. Available: https://opentyphoon.ai/model/typhoon-ocr

[30] Y. Qi, Z. Yang, W. Sun, M. Lou, J. Lian, W. Zhao, X. Deng, and Y. Ma, “A comprehensive overview of image enhancement techniques,” *Archives of Computational Methods in Engineering*, 2021.

[31] W. Jasim and R. Mohammed, “A survey on segmentation techniques for image processing,” *Iraqi Journal for Electrical and Electronic Engineering*, vol. 17, no. 2, pp. 73–93, 2021.

[32] N. Dhanachandra, K. Manglem, and Y. J. Chanu, “Image segmentation using K-means clustering algorithm and subtractive clustering algorithm,” *Procedia Computer Science*, vol. 54, pp. 764–771, 2015.

[33] Z. Yang, R. Zhang, Y. Zhou, J. He, J. Shi, and S. Zuo, “Summary of document image binarization,” *Preprints*, 2024.

[34] M. Pascucci, G. Royer, J. Adamek *et al.*, “AI-based mobile application to fight antibiotic resistance,” *Nature Communications*, vol. 12, no. 1, p. 1173, 2021.

[35] ——, “The first AI-based mobile application for antibiotic resistance testing,” bioRxiv preprint, 2020.

[36] S. J. S. Rajasekar, S. Thiyagarajan, and S. Mohamed Ali, “Ab.ai — a novel automated AI tool for reporting antibiograms,” *Studies in Health Technology and Informatics*, vol. 299, pp. 202–207, 2022.

[37] G.-Y. Yu, G.-W. Lee, Y.-T. Hung, S.-C. Li, Y.-P. Ma, Z.-W. Chen, and S.-L. Hsuan, “AI-driven identification and analysis of inhibition zones in disk diffusion tests with the hue contrast method,” *Microchemical Journal*, vol. 208, p. 112459, 2025.

[38] K. Callebaut, A. Stoefs, K. Emmerechts *et al.*, “Evaluation of automated disk diffusion antimicrobial susceptibility testing using Radian® in-line carousel,” *Current Microbiology*, vol. 81, p. 196, 2024.

[39] S. J. S. Rajasekar, S. Thiyagarajan, and S. Mohamed Ali, “Artificial intelligence-based image analysis for antimicrobial susceptibility testing: Ab.ai tool,” 2023, see also Rajasekar et al. (2022) DOI:10.3233/SHTI220984.

[40] A. Sharma, “Introduction to HTML (Hyper Text Markup Language) — a review paper,” *International Journal of Science and Research (IJSR)*, vol. 7, no. 5, pp. 1337–1339, 2018.

[41] Mozilla Contributors, “HTML: HyperText Markup Language,” MDN Web Docs, 2025. [Online]. Available: https://developer.mozilla.org/en-US/docs/Web/HTML

[42] P. N. Siva, R. Yamaganti, and U. M. Sikharam, “A review on Python for data science, machine learning and IoT,” *ResearchGate*, 2023.

[43] S. Ramírez, “FastAPI,” GitHub repository, 2024. [Online]. Available: https://github.com/tiangolo/fastapi

[44] C. G. Giske, M. Bressan, F. Fiechter *et al.*, “Image dataset of disk diffusion assay scanned with the SIRscan system,” Dryad Dataset, University of Zurich, 2024.

[45] Institute of Medicine (US) Committee on Resource Sharing in Biomedical Research, “Resource sharing in biomedical research,” 1996. [Online]. Available: https://www.ncbi.nlm.nih.gov/books/NBK209072/

CHAPTER A: แบบสอบถามการประเมินระบบ

แบบสอบถามที่ใช้ในการประเมินระบบมีหัวข้อดังนี้:

ส่วนที่ 1 — ข้อมูลทั่วไปของผู้ทดสอบ

- ตำแหน่ง/บทบาท
- ระดับประสบการณ์กับการอ่านผล AST (Disk Diffusion)

ส่วนที่ 2 — การทดสอบตามสถานการณ์ (Scenario-Based Test)

1. การอัปโหลดภาพและสั่งรันระบบวิเคราะห์
2. การแก้ไขผลลัพธ์ด้วยตนเอง (Manual Correction)
3. การดูประวัติและดาวน์โหลดรายงาน

ส่วนที่ 3 — คะแนนความพึงพอใจ (Likert Scale 1–5)

1. ขั้นตอนการอัปโหลดและวิเคราะห์ทำได้ง่ายและไม่ซับซ้อน
2. ตารางแสดงผลจัดวางได้เป็นระเบียบ อ่านข้อมูลได้ชัดเจน
3. ฟังก์ชัน Manual Correction ใช้งานสะดวก
4. ระบบช่วยลดเวลาและภาระงานเมื่อเทียบกับการวัดด้วยไม้บรรทัด
5. มั่นใจในความถูกต้องของการคำนวณและการแปลผล
6. โดยภาพรวมระบบมีประโยชน์และพร้อมใช้งานจริงในห้องปฏิบัติการ

ส่วนที่ 4 — ความคิดเห็นเพิ่มเติม

- จุดเด่น/สิ่งที่ชอบในระบบ
- ปัญหาที่พบ/สิ่งที่ทำให้หงุดหงิด
- ฟีเจอร์เพิ่มเติมที่ต้องการ
- ข้อเสนอแนะอื่นๆ